

복합 프롬프트를 활용한 거대 언어 모델 기반 로그 이상 탐지 (Hybrid Prompting for LLM-based Log Anomaly Detection)

박 주 봉 [†] 최 은 성 ^{**} 이 종 욱 ^{***}
(Jubong Park) (Eunseong Choi) (Jongwook Lee)

요 약 로그 이상 탐지는 비정상 패턴을 식별하여 시스템의 안정적인 운영을 보장하는 핵심 기술이다. 하지만 최근 거대 언어 모델(LLM)을 활용한 프롬프트 기반 접근은 제한된 예시와 국소 맥락에 의존해 전체 로그 분포나 도메인 맥락을 충분히 반영하지 못하는 한계가 있다. 이에 본 연구에서는 LLM의 언어 능력과 전체 데이터셋 기반 정량 신호를 결합할 수 있는 하이브리드 프롬프트 기법을 제안한다. 구체적으로, 학습 데이터에 존재하지 않는 로그를 명시하는 entry 기반의 분석, 정상 및 테스트 시퀀스 간 유사도 분석을 통한 분포 비교가 가능한 sequence 기반 분석, 유사한 정상 시퀀스 예시 제공을 통한 직관적 판단 보조의 세 가지 보완 신호를 프롬프트에 포함한다. 이를 통해 LLM이 단순한 예시 매칭을 넘어 다양한 통계·맥락 정보를 근거로 종합적 추론을 수행한다. 실험 결과, 3개의 데이터셋에서 높은 탐지 성능을 보였으며, F1-score를 평균 9.93%p 개선하였다.

키워드: 로그 이상 탐지, 거대 언어 모델, 복합 프롬프트, 피처 엔지니어링

Abstract Log anomaly detection is crucial for maintaining stable operations in large-scale IT systems by identifying abnormal patterns. Recently, prompt-based approaches utilizing large language models (LLMs) have gained attention. However, these methods often depend on limited examples and local contexts, which prevents them from fully capturing the overall log distribution and domain context. To overcome this limitation, we propose a hybrid prompt method that integrates the language understanding capabilities of LLMs with quantitative signals from feature engineering. Our approach incorporates three complementary signals into the prompt: entry-based analysis for identifying syntactic anomalies, context comparison through similarity computation between normal and test sequences, and intuitive decision support by presenting the most similar normal sequence. This allows the LLM to engage in comprehensive reasoning based on diverse statistical and contextual information, rather than relying solely on example matching. Experimental results demonstrate that our method achieves high detection performance across three datasets, improving the average F1-score by 9.93%p.

Keywords: log anomaly detection, large language models, hybrid prompt, feature engineering

· 이 논문은 정부(과학기술정보통신부)의 재원으로 정보통신기획평가원의 지원
(RS-2019-II190421, RS-2021-II212068)을 받아 수행된 연구임

[†] 학생회원 : 성균관대학교 인공지능학과 학생
bong6642@g.skku.edu

^{**} 비 회 원 : 성균관대학교 인공지능학과 학생
eunseong@g.skku.edu

^{***} 종신회원 : 성균관대학교 소프트웨어학과 교수(Sungkyunkwan Univ.)
jongwooklee@g.skku.edu
(Corresponding author)

논문접수 : 2025년 8월 20일

(Received 20 August 2025)

논문수정 : 2025년 9월 24일

(Revised 24 September 2025)

심사완료 : 2025년 10월 2일

(Accepted 2 October 2025)

Copyright©2025 한국정보과학회 : 개인 목적이나 교육 목적의 경우, 이 저작물의 전체 또는 일부에 대한 복사본 혹은 디지털 사본의 제작을 허가합니다. 이 때, 사본은 상업적 수단으로 사용할 수 없으며 첫 페이지에 본 문구와 출처를 반드시 명시해야 합니다. 이 외의 목적으로 복제, 배포, 출판, 전송 등 모든 유형의 사용행위를 하는 경우에 대하여는 사전에 허가를 얻고 비용을 지불해야 합니다.
정보과학회논문지 제52권 제12호(2025. 12)

1. 서론

대규모 IT 시스템에서 생성되는 로그는 실행 중인 애플리케이션이나 소프트웨어의 상태를 구조화된 텍스트 형태로 기록한다. 이는 운영 모니터링과 장애 진단 등 다양한 목적의 핵심 관측 수단이며, 로그 시퀀스에서 비정상 패턴을 식별하는 것을 목표로 하는 로그 이상 탐지는 안정적인 시스템 운영을 위한 필수 기술이다.

이를 위해, 전통적인 로그 이상 탐지 방법론들은 Principal Component Analysis[1], Isolation forest[2], One-class Support Vector Machines[3] 등의 Feature Engineering 기반 방법을 활용하여 비정상적인 패턴을 탐지하였다. 이러한 방식은 특징 추출과 규칙 설계를 통해 빠르고 효율적으로 이상을 탐지할 수 있지만, 복잡 패턴이나 예외 상황에는 취약하며 수치 정보만으로는 의미적 해석이 어렵다는 한계가 있다.

한편, 최근에는 거대 언어 모델(LLM)에 로그 시퀀스와 소수의 예시(Few-shot)를 함께 제공하여 이상 여부를 판단하는 프롬프트 기반 접근 방법이 제안되었다[4,5]. LLM은 고도의 언어 이해와 단계적 추론 능력을 바탕으로 로그 메시지에 담긴 텍스트 의미를 정밀하게 파악하며, 별도의 추가 학습 없이도 범용적인 이상 탐지를 수행할 수 있다는 장점이 있다. 그러나 제한된 예시와 국소 맥락에 의존하기 때문에 전체 로그 분포나 시스템 상태를 충분히 반영하기 어렵고, 특히 새로운 패턴이나 경계 사례에서는 정상·비정상 구분에 필요한 도메인 맥락이 결여되는 한계가 있다. 즉, Feature Engineering과 LLM을 단독으로 활용하는 기존의 로그 이상 탐지 방법론은 복잡하고 다양한 로그 이상 탐지 요구를 충족하기 어렵다.

이러한 배경에서 본 연구는 Feature Engineering을 통한 정량 분석 신호와 LLM의 언어 이해 능력을 결합하는 하이브리드 프롬프트 설계를 제안한다. 제안 방법은 단순한 예시 제시를 넘어, LLM의 추론에 직접 기여할 수 있는 통계 수치 정보를 프롬프트에 포함함으로써 성능과 안정성을 동시에 확보한다. 정보 검색 분야에서 BM25 점수와 같은 관련성 수치를 LLM 프롬프트에 포함시켜 성능을 향상시키는 연구[6]는 수치 신호와 LLM 추론의 상호 보완 가능성을 보여준다.

구체적으로, 제안 방법은 LLM의 입력 프롬프트에 세 가지 Feature 정보를 포함한다. (1) Entry-based Analysis: 정상 시퀀스에 한번도 등장하지 않은 로그(Unseen 로그)를 명시적으로 제시하여 점 이상(Point Anomaly, 단일 로그 항목이 정상 패턴에서 벗어난 경우) 탐지를 지원한다. 이는 LLM이 언어적 이해에 앞서, 출현 여부에 기반한 명시적 이상 신호를 포착할 수 있도록 함으




그림 1 프롬프트 기반 모델과 Feature 정보를 주입한 제안 방법의 차이 비교

Fig. 1 Comparison of the Differences Between a Prompt-based Model and a Proposal Method that Injects Feature Information

로써 초기 판단에 도움을 준다. (2) Sequence-based Analysis: 정상과 테스트 시퀀스 임베딩 간 유사도 통계 정보를 제공하여 전반적인 문맥 비교를 통한 문맥적 이상(Contextual Anomaly, 개별 로그는 정상이나 시퀀스 맥락으로는 비정상) 탐지를 지원한다. 특히, 군집화 기반의 통계 정보를 제공함으로써 테스트 시퀀스가 정상 시퀀스 분포 내에서 어느 정도 이탈했는지를 세밀하게 판단할 수 있도록 한다. (3) 유사한 정상 시퀀스 제공: 테스트 로그와 가장 유사한 정상 로그 시퀀스를 함께 제공하여, 정량 정보로는 포착하기 어려운 미묘한 차이를 직관적으로 비교할 수 있도록 한다.

이러한 정보를 하나의 프롬프트에 통합하여 제공함으로써 LLM은 각각의 단서를 개별적으로 해석하는 것이 아니라, 다양한 이상 신호를 종합적으로 고려하는 복합적 추론 구조를 형성할 수 있다. 즉, 점 이상 가능성은 빠르게 포착되고 문맥적 이상은 통계 정보로 보완되며, 정량 정보만으로는 판단이 애매한 경우에도 유사 사례 비교를 통해 신뢰도 높은 결정을 내릴 수 있다.

실험 결과, 본 연구에서 제안하는 복합 프롬프트 구조는 기존 프롬프팅 기반 이상 탐지 성능을 평균 9.93%p 개선하였으며 학습 없이도 다양한 이상 유형에 효과적으로 대응할 수 있음을 확인하였다. 또한, 구체적인 근거 정보를 포함함으로써 거짓 양성을 크게 줄이고 최대 18.45%p 높은 정밀도를 기록하였다. 아울러 근거 정보를 명시적으로 포함함으로써 모델의 판단 과정에 대한 설명 가능성도 확보할 수 있었다. 이러한 성과는 LLM의 추론 능력과 Feature Engineering 기반 정량 신호의 유기적 결합에서 기인하며 로그 이상 탐지에서 정밀도




그림 2 제안 방법 전체 파이프라인

Fig. 2 Entire Pipeline of the Proposed Method

와 재현율을 동시에 향상시키고 안정적인 시스템 운영을 지원한다.

2. 관련 연구

2.1 프롬프트 기반 로그 이상 탐지

전통적인 딥러닝 기반 방법은 각 log entry를 원자 식별자(identifier) 임베딩으로 표현하거나[7] 사전학습 언어 모델로 메시지를 임베딩하여[8] 시계열 모델을 학습한다. 그러나 이러한 학습 기반 방법은 미관측(out-of-distribution) 패턴에 취약하고 로그 텍스트의 풍부한 정보를 알지 못하는 한계가 있다. 이에 반해, 최근에는 프롬프팅만으로 주어진 로그 시퀀스의 이상을 탐지하는 LLM 기반 접근이 제안되었다[4,5]. 프롬프트 기반 기법은 LLM의 깊은 언어 이해를 활용해 일반화된 탐지를 수행하고 이상 징후의 근거와 대응 조치를 자연어로 제시해 설명 가능성을 높일 수 있다는 장점을 가진다. LogGPT[4]는 지도문(instruction)과 예시를 조합한 프롬프트로 학습 없이도 기존 딥러닝과 경쟁적인 성능을 보고하였다. RAGLog[5]는 검색 증강 생성(RAG)[9]을 통해 정상 로그 시퀀스 임베딩을 벡터 데이터베이스에 저장하고, 유사한 정상 시퀀스를 검색해 few-shot 예시로 제공하여 무작위 예시 대비 성능 향상을 보였다. 다만 이러한 프롬프트 기반 방법들은 도메인 지식과 예시 선택 품질에 크게 의존하며 프롬프트가 제한된 예시와 국소 맥락에 한정되어 전체 로그 분포를 충분히 반영하지 못한다는 한계가 남아 있다.

2.2 언어 모델을 위한 Feature Engineering

언어 모델의 성능 향상을 위해 수치 정보를 명시적 특성으로 주입하려는 시도가 꾸준히 이루어졌다. 초기 연구로, BM25Cat[10]은 BERT 기반 재순위화 모델 입

력에 BM25 점수를 텍스트로 삽입하여 단순 이상률보다 큰 개선을 보였고 언어 모델이 수치 신호를 포착·활용할 수 있음을 입증하였다. 한편, 추가 학습 없이도 프롬프트에 포함된 수치 정보가 효과적으로 작동함이 보고되었다. 최근 InsertRank[6]는 list-wise 재순위화 프롬프트에 BM25 점수와 같은 어휘 신호를 주입하여 다양한 LLM에서 일관된 성능 향상을 검증하였다. 아울러 LLM의 수학·산술 추론 능력도 폭넓게 관찰되었다[11,12]. 이러한 결과는 텍스트화된 수치 정보가 LLM의 추론에 실질적으로 기여함을 시사한다.

본 연구는 이러한 흐름을 로그 이상 탐지로 확장한다. 로그 도메인에 특화된 feature engineering 신호를 프롬프트에 체계적으로 주입하여 LLM의 언어 이해를 보완하고, 학습 없이도 프롬프트 기반 이상 탐지의 정밀도와 안정성을 향상시키는 방향을 제안한다.

3. 제안 방법

본 연구는 전통적인 Feature Engineering과 LLM의 고급 추론 능력을 결합한 하이브리드 접근 방식을 제안한다. 선행 연구[13]에 따르면 로그 데이터의 이상은 크게 점 이상(Point Anomaly)과 맥락 이상(Contextual Anomaly)의 두 유형으로 구분된다. 점 이상은 정상 로그와 형태나 내용이 뚜렷하게 다른 로그가 나타나는 경우로, 개별 로그 엔트리만으로도 판별이 가능하다. 반면, 맥락 이상은 개별 로그만 보면 정상으로 보이지만 특정 문맥 속에서만 이상으로 판단되는 경우를 의미한다.

이러한 이상 유형에 대응하기 위해, 본 연구에서는 Unseen 로그 정보를 주입하는 Entry-based Analysis(3.1절)와 로그 시퀀스 단위의 유사도 통계를 제공하는 Sequence-based Analysis(3.2절)를 제안하며, 이를

표 1 프롬프트 구성 요소 예시
Table 1 Prompt Component Example

Entry-based Analysis Prompt
Entry-based Analysis Normal Log Entry refers to the log templates that appear in the Normal Train Log Sequence. If a log that is not in the normal log entry appears in the provided Log sequence, it provides what the log is. # Comparison Results - Unseen log from provided log sequence: {UNSEEN_LOGS}
Sequence-based Analysis Prompt
Sequence-based Analysis We have a Train set consisting of 4,855 normal log sequences. First, as an example, we provide the results of comparing the Similarity between one normal data and the log sequences of the train set. Then, we provide the results of comparing the Similarity between the provided test data and the log sequences of the train set. Depending on whether the test data is normal or abnormal, the results of comparing the Similarity may differ, so refer to the results of the two comparisons. # Example (Normal Log Sequence) - The average similarity between the example normal log sequence and the Train set : {EX_SIM_MEAN} - The standard deviation of similarity between the example normal log sequence and the Train set : {EX_SIM_STD} # Comparison Result for the provided log sequence - The average similarity between the provided log sequence and the Train set : {TEST_SIM_MEAN} - The standard deviation of similarity between the provided log sequence and the Train set : {TEST_SIM_STD}
Few-shot Examples Prompt
Few-shot Example Refer to the following example of a normal log sequence # Examples : {EX_LOG}

few-shot 예시(3.3절)와 함께 활용하여 이상 탐지의 정확도를 향상시킨다. 표 1은 프롬프트 구성 예시, 그림 2는 제안 방법의 전체 파이프라인을 각각 나타낸다.




그림 3 Thunderbird 데이터셋 KMeans Clustering 수행 결과 예시

Fig. 3 Example of KMeans Clustering Results on the Thunderbird Dataset

3.1 Entry-based Analysis

정상 로그에 포함되지 않은 새로운 로그는 잠재적 점 이상을 나타내는 강력한 지표이며, 전통적인 로그 분석에서도 구조적 불규칙성을 식별하는 핵심 근거로 활용되어 왔다. 특히, 일부 데이터셋[14]에서는 이상 로그 시퀀스의 약 절반이 정상 로그 시퀀스에 등장하지 않은 Unseen 로그를 포함하는 것으로 확인되었다. 이를 위해, 제안 방법은 테스트 데이터에서 정상 로그 시퀀스에 존재하지 않았던 새로운 로그(Unseen 로그)를 식별하는 Entry-based Analysis를 프롬프트에 포함한다. 제안 방법은 Unseen 로그에 기반하여 점 이상에 대해서 LLM이 오류 패턴을 보다 민감하게 포착하도록 한다.

3.2 Sequence-based Analysis

다음으로는 로그 시퀀스 간의 임베딩 유사도 통계 정보를 프롬프트에 주입하는 Sequence-based Analysis를 소개한다. 동일한 로그로 구성되어 있다고 하더라도 이벤트 순서의 변화에 따라 의미가 달라질 수 있다. 특히 오류 메시지를 포함하지 않는 로그로 구성되어 있는 시퀀스는 개별 로그 만으로는 이상을 식별하기 어렵기 때문에 문맥적 이상을 판단하기 위한 추가적인 근거를 필요로 한다.

시퀀스 기반의 분석은 학습 데이터셋에 포함된 정상 시퀀스와 테스트 시퀀스의 임베딩을 활용한 유사도를 통해 수행된다. 먼저, 정상 로그 시퀀스 집합을 $\{x_1, x_2, \dots, x_N\}$ 라 하고, 테스트 시퀀스를 t 라 할 때, 각각을 임베딩 모델 $f_{emb}(\cdot)$ 에 입력해 인코딩을 수행한다:

$$E_{normal} = \{e_1, e_2, \dots, e_N\}, \quad e_i = f_{emb}(x_i) \quad (1)$$

$$z = f_{emb}(t)$$




그림 4 거대 언어 모델의 수치 정보 인식 및 추론 능력 관련 예시

Fig. 4 Example of the Numerical Information Recognition and Inference Capabilities of Large Language Models

이 때, x_i 는 i 번째 정상 시퀀스를 나타낸다. 이후, E_{normal} 에 대해 KMeans 군집화를 적용하여 유사한 정상 로그 시퀀스끼리 그룹화를 수행한다.

$$KMeans(E_{normal}) = \{C_1, C_2, \dots, C_K\} \quad (2)$$

클러스터 단위로 통계 기준을 설정함으로써, 다양한 로그 패턴을 효과적으로 구분하고 테스트 시퀀스를 정밀하게 분석할 수 있다. 클러스터링을 활용을 통한 성능 개선은 실험 결과의 '4.2.3 기준 선정 방식 실험'에서 확인할 수 있으며 그림 3은 정상 로그 시퀀스들에 대한 KMeans Clustering 수행 결과 예시를 보여준다. 유사도 분석을 위한 각 클러스터의 Centroid는 다음과 같이 클러스터 내 임베딩의 평균으로 정의된다:

$$c_k = \frac{1}{|C_k|} \sum_{e_i \in C_k} e_i \quad (3)$$

이때, c_k 는 k 번째 클러스터의 centroid를 의미한다.

테스트 시퀀스 임베딩 z 가 포함되는 클러스터를 C_p 라고 할 때, 해당 클러스터에 포함되는 모든 로그 시퀀스 임베딩에 대해 코사인 유사도를 계산하여 테스트 데이터의 유사도 벡터 v_{test} 를 도출한다:

$$v_{test} = [\cos(z, e_1^p), \dots, \cos(z, e_n^p)] \quad (4)$$

여기서 $e_i^p \in C_p$, $n = |C_p|$ 이다. 또한, 클러스터 Centroid c_p 와 클러스터 내 임베딩 간의 유사도 벡터 v_{cent} 를 다음과 같이 정의한다:

$$v_{cent} = [\cos(c_p, e_1^p), \dots, \cos(c_p, e_n^p)] \quad (5)$$

v_{test} 는 테스트 데이터가 해당 정상 클러스터와 얼마나 가까운지를 정량적으로 나타내고 v_{cent} 는 군집 응집도를 나타내며 v_{test} 를 평가하기 위한 기준 정보로 활용된다. 마지막으로, 각 유사도 벡터에 대해 평균과 표준편차를 산출하고, 이를 프롬프트 입력으로 활용한다.

$$Prompt(\mu(v_{test}), \sigma(v_{test}), \mu(v_{cent}), \sigma(v_{cent})) \quad (6)$$

여기서 $\cos(a, b)$ 는 코사인 유사도 측정 함수, $\mu(\cdot)$ 는 평균, $\sigma(\cdot)$ 는 표준 편차를 의미한다. 이러한 통계값은 표 1의 Sequence based Analysis 프롬프트에 활용되어 LLM이 문맥적 이상 여부를 판단하는 근거로 사용되며, 정상 패턴의 다양성과 비균질성을 반영한 기준 설정을 가능하게 한다.

그림 4는 두 분포의 평균 및 표준편차를 제공할 때, LLM이 이를 활용하여 분포 간의 정량적 차이를 인지하고 있음을 보여준다. 이는 LLM이 통계 정보를 직접 참조하여 논리적 추론을 수행할 수 있다는 점에서, 프롬프트 내 통계값의 활용 가능성을 뒷받침한다.

3.3 Few-shot Example

마지막으로, LLM이 테스트 데이터를 정상 로그와 직관적으로 비교할 수 있도록 테스트 데이터와 가장 유사한 정상 로그 시퀀스를 선별해 few-shot 예시로 제공한다. 이러한 예시 제공 전략은 기존 프롬프트 기반 로그 이상 탐지 연구들에서도 효과가 입증된 바 있으며[1, 2] 본 연구에서는 이를 Entry 및 Sequence 기반 분석 정보와 결합해 활용한다. 구체적으로, 테스트 데이터의 임베딩과 정상 로그 데이터 전체의 임베딩 간 코사인 유사도를 계산한 뒤, 유사도가 가장 높은 하나의 정상 로그를 선택해 표 1의 Few-shot Examples 프롬프트 형식에 맞춰 삽입한다. 이를 통해 LLM은 단순한 수치 정보에 의존하지 않고 의미적 단서를 확보하여, 잠재적 이상 여부를 보다 정밀하게 판별한다.

표 2 원본 데이터셋 통계
Table 2 Original Dataset Statistics

Dataset	Avg. Seq. Len.	Train	Test (Normal)	Test (Abnormal)
HDFS	19	4,855	553,368	16,838
BGL	564	13,718	50,579	3,018
TBird	104	6,000	71,155	45,385

4. 실험 및 평가

4.1 실험 환경

본 연구에서는 제안 방법의 성능을 검증하기 위해 로그 이상 탐지 과업에서 널리 채택되는 세 가지 공개 로그 데이터셋(HDFS, BGL, Thunderbird)을 사용하였다.

- Hadoop Distributed File System (HDFS)[14]: Hadoop 기반 작업에서 수집된 데이터셋으로, 이상 여부는 정의된 규칙에 따라 수동으로 라벨링된다. 각 로그 메시지에 포함된 세션 ID를 기준으로 로그 시퀀스를 구성한다.
- BlueGene/L (BGL)[16]: BlueGene/L 슈퍼컴퓨터 시스템에서 수집된 로그 데이터셋으로, 경고 메시지를 이상으로 간주한다. 1분 단위 슬라이딩 윈도우를 적용하여 로그 시퀀스를 생성한다.
- Thunderbird (TBird)[16]: Sandia National Laboratories의 슈퍼컴퓨터 시스템에서 수집된 데이터셋으로, 1분 단위 슬라이딩 윈도우를 통해 로그 시퀀스를 구성한다.

기존 연구 설정을 따라, 테스트 데이터에서 정상 시퀀스와 이상 시퀀스를 각각 1,000개씩 무작위 샘플링하여 실험을 수행하였다. 표 2는 각 데이터셋의 원본 통계 정보를 제시한다.

비교 대상으로는 프롬프트 기반 로그 이상 탐지 모델인 LogGPT[4]와 RAGLog[5]를 채택하였다. LogGPT는 논문에서 제시한 기본 프롬프트에 무작위로 선정한 예시를 1개 포함하였으며 RAGLog는 논문에 기재된 구현 세부사항에 따라 클러스터링을 수행한 뒤, 테스트 시퀀스가 속한 클러스터에서 무작위 예시 1개를 선택하여 포함하는 방식으로 재현하였다.

제안 방법과 비교 모델 모두 LLM은 OpenAI의 GPT-4o-mini[17]를 사용했으며 임베딩 모델로는 Qwen3-Embedding-8B[18]를 채택하였다. KMeans 클러스터링의 클러스터 수 K는 Elbow Point[15] 기법으로 선정하였다. 그 결과 HDFS, BGL, TBird의 K값은 각각 3, 5, 6이었다. 성능지표는 정밀도(Precision), 재현율(Recall), 그리고 이들의 조화평균인 F1-score로 채택하였다.

표 3 로그 이상 탐지 성능 비교 결과표

Table 3 Log Anomaly Detection Performance Comparison Results

Dataset	Metric	LogGPT	RAGLog	Ours
HDFS	Precision	66.44	89.69	81.80
	Recall	87.90	70.50	96.60
	F1	75.68	78.95	88.58
BGL	Precision	51.47	58.74	63.65
	Recall	99.80	99.10	99.60
	F1	67.91	73.76	77.81
TBird	Precision	50.23	57.41	68.68
	Recall	100.0	99.90	100.0
	F1	66.87	72.92	81.43

표 4 규칙 기반 앙상블 결과와의 비교 결과

Table 4 Comparison Results with Rule-based Ensemble

Dataset	Ensemble	P	R	F1
HDFS	Rule-based	100.0	51.0	67.55
	LLM-based (Ours)	75.68	78.95	88.58
BGL	Rule-based	98.51	59.60	74.27
	LLM-based (Ours)	63.65	99.60	77.81
TBird	Rule-based	100.0	35.20	52.07
	LLM-based (Ours)	68.68	100.0	81.43

4.2 실험 결과

4.2.1 이상 탐지 성능 비교

표 3은 세 데이터셋에서 제안 방법과 비교 모델들의 이상 탐지 효과성을 보여준다. 모든 데이터셋에서 제안 방법은 정밀도와 재현율 모두에서 균형 잡힌 성능을 보였으며, F1-score 기준 Baseline 대비 평균 9.93%p 이상의 향상을 달성하였다. 특히, HDFS의 경우 RAGLog[2] 대비 낮은 정밀도를 보였으나 대부분의 이상을 탐지하여 높은 F1-score를 달성하였다. LogGPT[4]은 세 데이터셋 전반에서 높은 재현율을 기록했으나 정상 로그 시퀀스를 비정상적으로 잘못 분류하는 경향이 커 정밀도가 크게 저하되었다. 반면 RAGLog[5]는 비교적 낮은 재현율을 보이는데 이는 클러스터 기반으로 테스트 시퀀스와 유사도가 높은 예시를 제공하여 불필요한 오탐은 줄였지만 다양한 이상 패턴을 포착하는 데 한계가 있었기 때문으로 분석된다. 제안 방법은 Entry-based, Sequence-based, Few-shot 정보를 모두 결합하여 두 모델의 단점을 보완하고, 높은 재현율을 유지하면서도 정밀도를 유의미하게 향상시켰다.

4.2.2 규칙 기반 분류와의 비교

표 4는 HDFS[14] 데이터셋에서 본 연구가 제안한 두 가지 feature를 단독으로 활용한 규칙 기반 이상 탐지 결과를 종합하여 평가한 결과를 보여준다. Entry-based 방식은 정상 로그 시퀀스들에 포함되지 않은 Unseen

표 5 유사도 통계 기준에 따른 성능 비교

Table 5 Performance Comparison Based on Similarity Statistics Criteria

Dataset	Centroid Selection	P	R	F1
HDFS	Train Data	70.46	94.70	80.80
	Cluster (Ours)	81.80	96.60	88.58
BGL	Train Data	50.87	99.90	67.41
	Cluster (Ours)	63.65	99.60	77.81
TBird	Train Data	62.31	100.0	76.78
	Cluster (Ours)	68.68	100.0	81.43

Log가 등장하는 경우를 이상으로 판정하였다. 또한, Sequence-based 방식은 수식 (4), (5)에서 도출되는 분포 v_{cent} , v_{test} 와의 차이를 Cohen's d[19]로 측정하고 권고 기준인 0.8을 초과하는 경우 해당 테스트 시퀀스를 이상으로 판정하였다. 규칙 기반 이상탐지의 경우 두 방법 중 하나라도 이상인 경우에 대해 최종적으로 이상으로 판정하였다. 실험 결과, 규칙 기반 이상탐지를 수행했을 때에는 대부분의 이상을 검출해 높은 재현율을 기록했으나 정상 시퀀스 중 일부를 과도하게 이상으로 분류해 낮은 정밀도를 보였다. 이는 정상 패턴의 세부 변화를 단순 규칙만으로 구분하기 어렵다는 점을 시사하며 이상 신호를 단순히 결합하는 것만으로는 이상 탐지에 한계가 있음을 보여준다. 반면 LLM을 활용해 두 통계 정보를 종합하여 판단하는 경우에는 성능이 향상되는 것을 확인할 수 있다. 동시에 이러한 결과는 LLM이 두 feature를 상호 보완적으로 결합하여 추론함으로써 보다 균형 잡힌 탐지 성능을 달성할 수 있음을 입증한다.

4.2.3 Sequence-based Analysis 기준 선정 방식

표 5는 시퀀스 유사도 기반 통계 정보를 활용하는 과정에서 기준을 설정하는 방식에 따른 성능 차이를 보여준다. 구체적으로, 전체 정상 로그 시퀀스들을 하나의 분포로 보고 평균 유사도를 기준으로 한 Train Data Centroid 방식과 제안하는 클러스터 기반의 유사도 측정 방식을 비교한다. 실험 결과, 모든 데이터셋에서 Train Data Centroid 방식의 정밀도와 재현율이 대부분 하락함을 확인하였다. 이는 제안하는 Cluster Centroid 방식이 KMeans로 정상 로그를 세밀하게 군집화하고 계산하는 각 클러스터별 통계치가 정밀한 이상 탐지에 도움을 줄 수 있음을 보여준다. 즉, 정상 패턴 다양성을 반영한 세밀한 기준 설정이 LLM 추론의 신뢰성을 높임을 확인하였다.

4.2.4 Few-shot Example 개수에 따른 성능 비교

그림 5는 Entry-based Analysis와 Sequence-based Analysis를 사용하지 않고 Few-shot Example만 활용하는 프롬프트와 제안 방법에서 예시 개수에 따른 성능 비교 결과를 그래프로 나타낸 것이다. Few-shot Prompt




그림 5 Few-shot 예시 개수에 따른 성능 비교

Fig. 5 Performance Comparison Based on Number of Few-shot Examples

표 6 프롬프트 구성 요소에 따른 실험 결과

Table 6 Ablation Study by Prompt Component

Ablation Study	P	R	F1
Only Instruction	53.47	77.00	63.11
Entry-based Prompt	97.72	55.60	70.87
Sequence-based Prompt	76.60	99.50	86.56
Few-shot Prompt	72.86	79.20	75.90
Ours (LLM-based Ensemble)	81.80	96.60	88.58
Majority Voting	77.92	79.40	78.65

의 경우, 제안 방법과 비교하여 낮은 성능을 보였으나 예시의 수가 늘어남에 따라 성능이 향상되는 것을 관측할 수 있었다. 특히, 예시로 정상 시퀀스를 제공하고 있기 때문에 Recall 성능이 높게 나타났으며 F1-score의 경우에도 미비하게나마 향상되는 것을 확인할 수 있었다. 제안 방법의 경우 Entry-based Analysis, Sequence-based Analysis를 통해 충분한 정보를 제공하고 있기 때문에 많은 수의 예시를 제공하는 것이 성능 향상에 많은 영향을 끼치지 않음을 확인하였다.

4.3 절제 연구 (Ablation Study)

표 6에서는 본 연구에서 제안하는 프롬프트의 구성 요소 각각의 기여도를 평가한다. 구체적으로, 제안 방법의 프롬프트는 크게 Entry-based Prompt, Sequence-based Prompt, Few-shot Prompt 세 가지 핵심 요소로 구성된다. 이때 기본적인 Instruction과 테스트 데이터는 모든 설정에서 동일하게 제공하고 나머지 세 요소를 각각 단독으로 적용하여 HDFS[14] 데이터셋 위에서 성능 변화를 비교하였다. 핵심 분석은 다음과 같다:

1) Entry-based Prompt는 정상 로그 시퀀스에서 한 번도 등장하지 않은 로그 항목이라는 강력한 이상 신호를 명시적으로 제공하는 방식으로, 정상 시퀀스를 비정상적으로 잘못 분류하는 False Positive를 줄이는 데 효과적이다. 실험 결과에서도 높은 Precision을 기록했으나 문맥적 이상을 탐지하는 능력이 부족하여 Recall은 상대적으로 낮았다.

2) Sequence-based Prompt는 정상 패턴과의 유사도

Effect of "Entry-based Analysis"	
BLOCK* NameSystem.allocateBlock: <*> blk_<*>, Receiving block blk_<*> src: <*> dest: /<*>:50010, Receiving block blk_<*> src: <*> dest: /<*>:50010, Receiving block blk_<*> src: <*> dest: /<*>:50010, Receiving empty packet for block blk_<*>, Receiving empty packet for block blk_<*>, Receiving empty packet for block blk_<*>, ... Verification succeeded for blk_<*>, BLOCK* NameSystem.delete: blk_<*> is added to invalidSet of <*>:50010, BLOCK* NameSystem.delete: blk_<*> is added to invalidSet of <*>:50010, BLOCK* NameSystem.delete: blk_<*> is added to invalidSet of <*>:50010, Deleting block blk_<*> file <*><*>, Deleting block blk_<*> file <*><*>, Deleting block blk_<*> file <*><*>	
Only Instruction	classification: normal ❌ brief_explanation: The log sequence indicates a typical process of allocating, receiving, storing, verifying, and deleting blocks. The repetitive nature of receiving empty packets and the subsequent updates to the block map and invalid set suggest normal operational behavior within the system.
Ours	classification: abnormal ✅ brief_explanation: The log sequence contains the entry "Receiving empty packet for block blk_<*>" which is not found in normal log entries. This indicates an unusual event where empty packets are being received, which could suggest a communication issue, data loss, or other underlying problems, making the sequence abnormal despite other normal-like entries.

그림 6 Entry-based Analysis를 통한 성능 개선 예시
Fig. 6 Example of Performance Improvement Using Entry-Based Analysis

Effect of "Sequence-based Analysis"	
BLOCK* NameSystem.allocateBlock: <*> blk_<*>, Receiving block blk_<*> src: <*> dest: /<*>:50010, Receiving block blk_<*> src: <*> dest: /<*>:50010, Receiving block blk_<*> src: <*> dest: /<*>:50010, BLOCK* ask <*>:50010 to replicate blk_<*> to datanode(s) <*>:50010, BLOCK* NameSystem.addStoredBlock: blockMap updated: <*>:50010 is added to blk_<*> size <*>, ... BLOCK* NameSystem.delete: blk_<*> is added to invalidSet of <*>:50010, BLOCK* NameSystem.delete: blk_<*> is added to invalidSet of <*>:50010, Deleting block blk_<*> file <*><*>, Deleting block blk_<*> file <*><*>, Deleting block blk_<*> file <*><*>	
Only Instruction	classification: normal ❌ brief_explanation: The log sequence indicates typical operations of a block storage system, including block allocation, replication requests, updates to the block map, successful block transfers, and deletions. All operations appear consistent with expected behavior in a block management system, without any error messages or anomalies.
Ours	classification: abnormal ✅ brief_explanation: The provided log sequence has a significantly lower average similarity score (0.93123) compared to the normal log sequences (average similarity is above 0.99656). While there are no unseen logs, the low similarity indicates deviations from typical patterns, suggesting potential anomalies in block allocation or deletion processes.

그림 7 Sequence-based Analysis를 통한 성능 개선 예시
Fig. 7 Example of Performance Improvement Through Sequence-based Analysis

차이를 정량적으로 판단할 수 있어 Recall을 크게 향상시키는 효과가 나타났다. 그러나 정상 시퀀스 중 일부가 과도하게 이상으로 판정되어 Precision이 하락함을 보인다.

3) Few-shot Prompt는 테스트 데이터와 가장 유사한 정상 로그 시퀀스를 예시로 제공하여 정상 패턴을 직관적으로 비교하도록 한다. 이 방식은 Precision과 Recall 모두 중간 수준을 보이며 안정적이고 균형 잡힌 성능을 제공한다.

4) 세 요소를 모두 포함한 Ours (LLM-based Ensemble)

는 단독 사용 대비 F1-score가 최대 17.71%p 향상되었으며 단순히 각 결과를 결합하는 Majority Voting보다도 성능이 우수했다. 이는 LLM이 Feature 정보를 단순 병합하는 수준을 넘어 세 가지 근거를 상호 보완적으로 통합하는 능력을 갖추고 있음을 시사한다.

4.4 정성평가

그림 6과 7은 제안 방법이 실제 환경에서 이상을 효과적으로 탐지하는 사례를 보여준다. 정성평가 결과, 제안 방법은 Feature 정보를 단순 참고가 아닌 명확한 판정 근거로 활용함을 확인하였다. 그림 6은 정상 로그 시퀀스와 유사한 패턴을 포함하지만 "Receiving empty packet for block blk_*" 항목이 존재하는 경우로, 기존 방법은 이를 정상으로 분류한 반면, 제안 방법은 정상 로그에 존재하지 않는 신규 로그를 탐지하고 잠재적 통신 오류 가능성을 분석하여 비정상적으로 판단하였다. 그림 7은 모든 로그 항목이 정상 패턴과 유사한 예시이며 제안 방법은 평균 유사도(0.9312)가 정상 시퀀스 평균(0.9956)보다 현저히 낮다는 통계적 차이를 근거로 이상으로 식별하였다. 이는 명시적 오류가 없더라도 로그 간 관계 패턴의 미세한 변화를 포착할 수 있음을 보여준다.

5. 결론

본 연구에서는 Feature Engineering과 LLM의 고급 추론 능력을 결합한 하이브리드 로그 이상 탐지 방법을 제안한다. 제안된 방법은 점 이상(Point Anomaly)과 문맥 이상(Contextual Anomaly)에 대응하는 특징 정보를 프롬프트에 주입함으로써 LLM이 더 정확하게 이상을 탐지할 수 있도록 설계되었다. 구체적으로, 제안 방법은 정상 로그 시퀀스들에 등장하지 않은 Unseen 로그를 활용한 Entry-based Analysis, 군집화 기반 통계 정보를 활용한 Sequence-based Analysis, 테스트 데이터와 가장 유사한 정상 로그 시퀀스를 제공하는 Few-shot prompt로 구성된다. 세 가지 데이터셋에서의 실험을 통해 제안 방법이 기존 프롬프트 기반 방법 대비 모든 데이터셋에서 더 높은 F1-score를 달성함을 확인하였다. 특히, 높은 재현율 성능을 유지하면서 정밀도를 크게 개선했다. 향후 연구에서는 제안된 방법을 다양한 로그 도메인과 이상 유형에 적용해 일반화를 검증하고 데이터 규모와 복잡성이 증가하는 상황에서도 안정적인 성능을 유지할 수 있도록 기법을 개선할 예정이다.

References

- [1] W. Xu, L. Huang, A. Fox, D. Patterson, and M. I. Jordan, "Detecting large-scale system problems by mining console logs," *Proc. of the ACM SIGOPS 22nd symposium on Operating systems principles*,

- pp. 117–132. 2009.
- [2] F. T. Liu, K. M. Ting, and Z.-H. Zhou, "Isolation forest," *2008 eighth IEEE international conference on data mining. IEEE*, pp. 413–422. 2008.
 - [3] Y. Wang, J. Wong, and A. Miner, "Anomaly intrusion detection using one class svm," *Proc. from the Fifth Annual IEEE SMC Information Assurance Workshop, 2004. IEEE*, pp. 358–364. 2004.
 - [4] J. Qi, S. Huang, Z. Luan, S. Yang, C. J. Fung, H. Yang, D. Qian, J. Shang, Z. Xiao, and Z. Wu, "LogGPT: Exploring ChatGPT for Log-Based Anomaly Detection," *Proc. of the IEEE International Conference on High Performance Computing & Communications, Data Science & Systems, Smart City & Dependability in Sensor, Cloud & Big Data Systems & Application (HPCC/DSS/SmartCity/DependSys 2023)*, Melbourne, Australia, pp. 273–280, Dec. 2023.
 - [5] J. Pan, S. L. Wong, and Y. Yuan, "RAGLog: Log Anomaly Detection using Retrieval Augmented Generation," *CoRR*, Vol. abs/2311.05261, 2023.
 - [6] R. Seetharaman, K. D. Dhole, and A. Bansal, "InsertRank: LLMs can reason over BM25 scores to Improve Listwise Reranking," *CoRR*, Vol. abs/2506.14086, 2025.
 - [7] M. Du, F. Li, G. Zheng, and V. Srikumar, "DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning," *Proc. of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS 2017)*, Dallas, TX, USA, pp. 1285–1298, Oct.–Nov. 2017.
 - [8] H. Guo, S. Yuan, and X. Wu, "LogBERT: Log Anomaly Detection via BERT," *Proc. of the International Joint Conference on Neural Networks (IJCNN 2021)*, Shenzhen, China, pp. 1–8, Jul. 2021.
 - [9] P. Lewis, E. Perez, A. Piktus, F. Petroni, V. Karpukhin, N. Goyal, H. Küttler, M. Lewis, W. Yih, T. Rocktäschel, S. Riedel, and D. Kiela, "Retrieval-Augmented Generation for Knowledge-Intensive NLP Tasks," *Proc. of the 33rd Annual Conference on Neural Information Processing Systems (NeurIPS 2020)*, virtual, Dec. 2020.
 - [10] A. Askari, A. Abolghasemi, G. Pasi, W. Kraaij, and S. Verberne, "Injecting the BM25 Score as Text Improves BERT-Based Re-rankers," *Proc. of the 45th European Conference on Information Retrieval (ECIR 2023)*, Dublin, Ireland, Lecture Notes in Computer Science, Vol. 13980, pp. 66–83, Apr. 2023.
 - [11] W. Liu, H. Hu, J. Zhou, Y. Ding, J. Li, J. Zeng, M. He, Q. Chen, B. Jiang, A. Zhou, and L. He, "Mathematical Language Models: A Survey," *CoRR*, Vol. abs/2312.07622, 2023.
 - [12] J. Ahn, R. Verma, R. Lou, D. Liu, R. Zhang, and W. Yin, "Large Language Models for Mathematical Reasoning: Progresses and Challenges," *Proc. of the 18th Conference of the European Chapter of the Association for Computational Linguistics (EACL 2024): Student Research Workshop*, St. Julian's, Malta, pp. 225–237, Mar. 2024.
 - [13] T. Wittkopp, P. Wiesner, D. Scheinert, and O. Kao, "A Taxonomy of Anomalies in Log Data," *Proc. of the ICSOC 2021 Workshops - AIOps, STRAPS, AI-PA and Satellite Events*, Dubai, United Arab Emirates, Lecture Notes in Computer Science, Vol. 13236, pp. 153–164, Nov. 2021.
 - [14] W. Xu, L. Huang, A. Fox, D. A. Patterson, and M. I. Jordan, "Detecting Large-Scale System Problems by Mining Console Logs," *Proc. of the 27th International Conference on Machine Learning (ICML 2010)*, Haifa, Israel, pp. 37–46, Jun. 2010.
 - [15] Knead Documentation. [Online]. Available: <https://knead.readthedocs.io/en/stable/>
 - [16] A. J. Oliner and J. Stearley, "What Supercomputers Say: A Study of Five System Logs," *Proc. of the 37th Annual IEEE/IFIP International Conference on Dependable Systems and Networks (DSN 2007)*, Edinburgh, UK, pp. 575–584, Jun. 2007.
 - [17] GPT-4o mini Model Documentation. [Online]. Available: <https://platform.openai.com/docs/models/gpt-4o-mini>
 - [18] Y. Zhang, M. Li, D. Long, X. Zhang, H. Lin, B. Yang, P. Xie, A. Yang, D. Liu, J. Lin, F. Huang, and J. Zhou, "Qwen3 Embedding: Advancing Text Embedding and Reranking Through Foundation Models," *CoRR*, Vol. abs/2506.05176, 2025.
 - [19] J. Cohen, *Statistical Power Analysis for the Behavioral Sciences*, 2nd Ed., Lawrence Erlbaum Associates, Hillsdale, NJ, 1988.



박 주 봉

2024 성균관대학교 소프트웨어학과 졸업(학사). 2024~현재 성균관대학교 인공지능학과 석사 과정. 관심분야는 자연어처리, 거대 언어 모델



최 은 성

2020년 성균관대학교 건축학과 졸업(학사) 2020년~현재 성균관대학교 인공지능학과 석박통합. 관심분야는 검색증강생성

이 중 욱

정보과학회논문지
제 52 권 제 5 호 참조