

فهرست جدول ها

جدول ۱-۲: مشخصات و مقایسه تمام ۲۷ مقاله موجود در پوشه پژوهش	۲۵
جدول ۲-۲: جمع‌بندی دسته‌های مطالعات و ارتباط آن‌ها با طراحی پژوهش	۲۹

فهرست نمودار ها

فهرست شکل ها

شکل ۱-۲: ارتباط ۲۷ مقاله بررسی شده و جایگاه پژوهش حاضر	۲۴
--	----

چکیده

رشد سامانه‌های توزیع شده موجب تولید حجم عظیمی از لاگ‌های ناهمگون شده است و تشخیص سریع ناهنجاری در آن‌ها برای افزایش پایداری و امنیت سامانه‌ها اهمیت دارد. روش‌های سنتی معمولاً به قواعد دست‌نویس، الگوهای ثابت یا داده‌های برچسب‌خورده وابسته‌اند و در مواجهه با تغییر ساختار لاگ‌ها و حجم بالای داده محدودیت دارند. هدف این پژوهش، ارائه چارچوبی مبتنی بر مدل زبانی بزرگ و مهندسی پرامپت برای طبقه‌بندی دودویی رویدادهای مجموعه داده Blue Gene/L، بدون ریزتنظیم مدل است. در روش پیشنهادی، برچسب واقعی از ورودی مدل حذف شده و مقادیر پویایی مانند شناسه‌ها، مسیرها، نشانی‌های شبکه، مقادیر هگزادسیمال و اعداد به قالب‌های قابل‌بازاستفاده تبدیل می‌شوند؛ درعین حال، تفاوت‌های معنایی مهم مانند مقادیر صفر و غیرصفر حفظ می‌گردد. سپس مدل محلی Qwen2.5:7B-Instruct از طریق Ollama و با خروجی ساخت‌یافته، هر لاگ را عادی یا ناهنجار طبقه‌بندی می‌کند. برای کاهش هزینه استنتاج، نتایج معتبر در سطح قالب ذخیره شده و پیش از ورود به حافظه نهان اعتبارسنجی می‌شوند. سامانه در دو حالت ترکیبی قواعد قطعی و مدل زبانی، و حالت صرفاً مبتنی بر پرامپت پیاده‌سازی شده و نتایج خطبه‌خط در MongoDB ذخیره می‌شوند. ارزیابی با معیارهای صحت، دقت، بازخوانی، امتیاز F1، نرخ خروجی نامعتبر، زمان پاسخ و آمار حافظه نهان انجام شد. نتایج نشان داد نرمال‌سازی قالب‌ها و استفاده از حافظه نهان، فراخوانی‌های تکراری مدل و زمان پردازش را کاهش می‌دهد، درحالی‌که ثبت خطبه‌خط، قابلیت ارزیابی و ممیزی را حفظ می‌کند. چارچوب پیشنهادی راهکاری سبک و قابل‌استقرار برای تحلیل لاگ‌های سیستمی بدون آموزش مجدد مدل فراهم می‌سازد.

کلمات کلیدی(فارسی)

تشخیص ناهنجاری، لاگ‌های سیستمی، مهندسی پرامپت، مدل‌های زبانی بزرگ

کلمات کلیدی(انگلیسی)

Anomaly Detection, System Logs, Prompt Engineering, Large Language Models (LLMs)

فصل اول: کلیات تحقیق

مقدمه ۱-۱

گسترش سامانه‌های نرم‌افزاری و معماری‌های توزیع‌شده، موجب تولید پیوسته حجم زیادی از لاگ‌های سیستمی شده است. این لاگ‌ها اطلاعات ارزشمندی درباره وضعیت عملکرد، خطاها و رخدادهای امنیتی سامانه‌ها در اختیار قرار می‌دهند. از این رو، تشخیص سریع و دقیق ناهنجاری‌ها در آن‌ها نقش مهمی در افزایش پایداری و قابلیت اطمینان سیستم‌ها دارد. با این حال، حجم بالا، ساختار نامنظم و تغییرپذیری الگوهای لاگ، کارایی روش‌های سنتی را محدود می‌سازد. مدل‌های زبانی بزرگ، به دلیل توانایی درک متون غیرساختاریافته و روابط معنایی، ظرفیت مناسبی برای تحلیل این داده‌ها دارند. در این پژوهش، از مهندسی پرامپت برای بهره‌گیری از توانایی مدل‌های زبانی، بدون نیاز به آموزش مجدد و داده‌های برچسب‌خورده گسترده استفاده می‌شود. در ادامه این فصل، بیان مسأله، اهمیت و ضرورت، اهداف، پرسش‌ها و فرضیه‌های تحقیق تشریح می‌شوند.

بیان مسئله ۱-۲

در سامانه‌های مدرن با معماری توزیع‌شده، حجم عظیمی از لاگ‌های سیستمی به صورت پیوسته تولید می‌شود که حاوی اطلاعات مهمی برای عیب‌یابی، پایش سلامت و بررسی حوادث امنیتی هستند. کشف ناهنجاری‌ها در این لاگ‌ها نقش کلیدی در افزایش پایداری و قابلیت اطمینان سیستم دارد. با این حال، چند ویژگی مشکل‌ساز وجود دارد: ساختار نامنظم لاگ‌ها (متن آزاد همراه با پارامترها و شناسه‌ها)، حجم بسیار بالا و پویایی سریع الگوهای آن‌ها و تعداد کم رخدادهای ناهنجار نسبت به رویدادهای عادی. روش‌های سنتی مبتنی بر قوانین دست‌نویس یا الگوریتم‌های آماری، که اغلب به الگوهای ثابت یا داده‌های پارس شده نیاز دارند، در مواجهه با این چالش‌ها کارآمدی خود را از دست می‌دهند. برای مثال، LogLLM نشان می‌دهد که روش‌های معمول نیاز به استخراج الگو دستی دارند اما مدل‌های زبانی بزرگ می‌توانند با پیش‌پردازش ساده مانند عبارات با قاعده، فرایند را ساده کنند و به دقت بالا در تشخیص ناهنجاری برسند [۱].

مدل‌های زبانی بزرگ (مانند GPT، BERT، LLaMa و...) توانایی قوی در پردازش متون غیرساختاریافته و یادگیری روابط معنایی دارند. این مدل‌ها می‌توانند پیام‌های لاگ را مانند جمله‌های طبیعی در نظر گرفته و معنا و زمینه آن‌ها را استخراج کنند [۱].

همچنین استفاده از LLM‌ها فراتر از خود تشخیص ناهنجاری رفته و در فرایندهای پیشین مانند تجزیه لاگ نیز تأثیرگذار بوده است. به عنوان نمونه، LogParser-LLM نشان می‌دهد که با ادغام دانش معنایی مدل‌های زبانی در فرایند پارس لاگ، می‌توان بدون نیاز به داده‌های برچسب‌دار یا تنظیمات دقیق، ساختار لاگ را استخراج کرد [۲].

این کار با بهره‌گیری هم‌زمان از اطلاعات معنایی و ویژگی‌های آماری، دقت بالایی در تشخیص الگوها ایجاد می‌کند. در کل، این مطالعات همگی حکایت از این دارند که مدل‌های زبانی بزرگ می‌توانند محدودیت روش‌های سنتی را با درک عمیق‌تر متن لاگ و تشخیص ناهنجاری حتی در شرایط تغییر الگو برطرف سازند [۳].

با وجود موفقیت اولیه، چندین چالش و سؤال پژوهشی باقی مانده است که باید بررسی شوند:

یکی از موانع اصلی در بکارگیری مدل‌های زبانی بزرگ، پارامترهای فراوان و محاسبات سنگینی است که منجر به افزایش تأخیر اجرا و هزینه‌های عملیاتی می‌شود. اکثر رویکردهای فعلی مانند LogLLM [۱] یا روش‌های مبتنی بر تنظیم دقیق^۱ مانند LogBERT [۴]، نیازمند زیرساخت‌های پردازشی قدرتمند (GPU) و زمان آموزش طولانی هستند. از سوی دیگر، در محیط‌های صنعتی، سرعت تشخیص ناهنجاری حیاتی است.

برای مقابله با این چالش، پژوهش‌هایی مانند AdaptiveLog [۵] استراتژی همکاری میان مدل‌های کوچک و بزرگ (SLM/LLM) را پیشنهاد داده‌اند تا تنها در موارد پیچیده از توان محاسباتی مدل بزرگ استفاده شود. با این حال، حتی در این مدل‌ها نیز نیاز به داده‌های برچسب‌دار و فرآیند آموزش همچنان پابرجاست.

علاوه بر چالش‌های محاسباتی و داده‌ای، یکی از موانع جدی در به‌کارگیری مدل‌های زبانی بزرگ در محیط‌های عملیاتی حساس، مسئله «توهم»^۲ و «شکاف دانش دامنه»^۳ است. مدل‌های زبانی عمومی اغلب بر روی داده‌های عمومی اینترنت آموزش دیده‌اند و ممکن است فاقد دانش تخصصی عمیق در مورد معماری‌های خاص سازمانی، کدهای خطای اختصاصی و وابستگی‌های پیچیده میان میکروسرویس‌ها باشند. این محدودیت می‌تواند منجر به تولید توضیحات نادرست اما با ظاهر موجه شود که در فرآیند عیب‌یابی سیستم‌های حیاتی، ریسک عملیاتی را افزایش می‌دهد. پژوهش‌های اخیر نشان می‌دهند که صرفاً تکیه بر دانش درونی مدل برای تشخیص ریشه خطا کافی نیست و مدل‌ها در مواجهه با لاگ‌های ناشناخته، ممکن است روابط علی و معلولی را به اشتباه استنتاج کنند [۶]. از این رو، مبحث تلفیق مدل‌های زبانی با پایگاه‌های دانش خارجی از طریق تکنیک‌هایی مانند «تولید افزوده به بازایی»^۴ (RAG) مطرح شده است. سوال اساسی اینجاست که چگونه می‌توان مستندات فنی، سوابق تیکت‌های گذشته و گراف دانش سیستم را به صورت پویا در اختیار مدل قرار داد تا خروجی آن واقعیت‌محور باقی بماند. مطالعاتی نظیر OpsEval نشان داده‌اند که مدل‌های فعلی بدون دسترسی به دانش زمینه، در وظایف استدلال منطقی پیچیده دچار افت عملکرد می‌شوند [۷]. بنابراین، بررسی راهکارهایی که بتوانند دانش زمینه را بدون نیاز به بازآموزی سنگین به مدل تزریق کنند و نرخ توهم را در تشخیص ناهنجاری به حداقل برسانند، یک خلأ پژوهشی آشکار است که نیازمند تحقیقات متمرکز می‌باشد.

در این پژوهش، شکاف موجود با استفاده از «مهندسی پرامپت هوشمند»^۵ و تکنیک‌های یادگیری با مثال‌های محدود^۶ پر می‌شود. این رویکرد به جای بازآموزی مدل یا استفاده از معماری‌های دوگانه پیچیده، بر استفاده بهینه از توانایی‌های ذاتی مدل‌های پیش‌آموزش‌دیده تمرکز دارد. هدف این است که با طراحی استراتژی‌های پرامپت‌دهی کارآمد [۸]،

^۱ Fine-tuning

^۲ Hallucination

^۳ Domain Knowledge Gap

^۴ Retrieval-Augmented Generation

^۵ Prompt Engineering

^۶ Few-shot

دقت تشخیص در سطح مدل‌های ریزتنظیم‌شده حفظ شود، در حالی که هزینه محاسباتی و نیاز به داده‌های آموزشی برچسب‌دار به حداقل برسد.

هدف اصلی، دستیابی به سیستمی است که بتواند به‌صورت مؤثر ناهنجاری‌های معنایی و ترتیبی را در لاگ‌های سیستمی تشخیص دهد، به‌گونه‌ای که دقت تشخیص در سطح مدل‌های پیچیده حفظ شده، اما نیاز به داده‌های برچسب‌دار و هزینه‌های محاسباتی به حداقل برسد. این سیستم با استفاده از استراتژی‌های پرامپت‌دهی کارآمد (مانند زنجیره افکار [۱۰])، اختلالات واقعی را از هشدارهای کاذب تفکیک کرده و برخلاف روش‌های سنتی، در مواجهه با تغییرات ناگهانی در الگوهای لاگ، پویایی و تعمیم‌پذیری بالایی از خود نشان می‌دهد.

نتایج مورد انتظار این تحقیق شامل ارائه راهکاری سبک و قابل پیاده‌سازی در محیط‌های واقعی است که علاوه بر بهبود پایداری و امنیت سامانه‌ها، زمان و هزینه‌های اشکال‌یابی را از طریق ارائه توضیحات قابل فهم برای ناهنجاری‌ها کاهش دهد.

در نهایت، این تحقیق می‌تواند به توسعه سامانه‌های مانیتورینگ خودکار و پایدار در مقیاس بزرگ کمک کند، طوری که پایداری و امنیت سامانه‌ها بهبود یابد و زمان و هزینه‌های اشکال‌یابی کاهش پیدا کند.

اهمیت و ضرورت انجام پژوهش ۱-۳

در دنیای امروز، سیستم‌های نرم‌افزاری و زیرساخت‌های توزیع‌شده به ستون فقرات صنایع گوناگون از جمله مالی، سلامت، مخابرات و سرویس‌های ابری تبدیل شده‌اند. پایداری و امنیت این سیستم‌ها وابستگی مستقیم به توانایی تشخیص سریع و دقیق ناهنجاری‌ها در لاگ‌های سیستمی دارد. با توجه به اینکه حجم و تنوع لاگ‌ها به‌طور مداوم در حال افزایش است، استفاده از روش‌های سنتی نظیر قواعد دست‌نویس یا الگوریتم‌های آماری دیگر پاسخگوی نیازهای فعلی نیست.

از نظر علمی، خلأهای تحقیقاتی قابل‌توجهی در این حوزه وجود دارد. نخست، بیشتر پژوهش‌های گذشته یا بر جنبه‌های آماری و ساختاری لاگ‌ها تمرکز داشته‌اند یا تنها به مدل‌سازی مبتنی بر توالی رویدادها پرداخته‌اند و کمتر به ترکیب ابعاد معنایی و زمانی توجه شده است. دوم، اگرچه مطالعات اخیر استفاده از مدل‌های زبانی بزرگ (LLMs) را پیشنهاد کرده‌اند، اما همچنان پرسش‌های مهمی درباره میزان کارایی، هزینه محاسباتی و قابلیت تعمیم‌پذیری LLM‌ها در محیط‌های عملیاتی بدون پاسخ مانده است. اختلاف‌نظرهایی نیز درباره روش بهینه تنظیم این مدل‌ها (تنظیم پرامپت در مقابل فاین‌تیونینگ) و نیاز به داده‌های برچسب‌دار وجود دارد.

از جنبه کاربردی، اهمیت این تحقیق در افزایش پایداری و امنیت سیستم‌ها آشکار است. یک چارچوب هوشمند می‌تواند:

- زمان تشخیص و رفع خطا را به شکل چشمگیری کاهش دهد،
- هزینه‌های ناشی از توقف سیستم یا حملات سایبری را کم کند،
- و ابزار قدرتمندی برای تیم‌های عملیات و نگهداری فراهم آورد.

علاوه بر این، نتایج تحقیق می‌تواند به توسعه روش‌هایی منجر شود که حتی در محیط‌هایی با منابع محاسباتی محدود یا داده‌های برچسب‌دار اندک، عملکرد مؤثر و مقیاس‌پذیر داشته باشند. این موضوع به‌ویژه برای سازمان‌هایی که امکان استفاده از منابع ابری گسترده ندارند، اهمیت حیاتی خواهد داشت. بنابراین، ضرورت این پژوهش هم در پاسخ به نیازهای عملی صنعت و هم در پر کردن شکاف‌های نظری موجود در ادبیات علمی نهفته است.

اهداف مشخص پژوهش ۴-۱

الف) هدف اصلی:

طراحی و ارائه یک چارچوب تشخیص ناهنجاری در لاگ‌های سیستمی مبتنی بر مهندسی پرامپت بهینه و مدل‌های زبانی بزرگ، با هدف دستیابی هم‌زمان به دقت و سرعت بالا و حذف نیاز به فرآیند پرهزینه تنظیم دقیق و داده‌های برچسب‌گذاری شده.

ب) اهداف فرعی:

۱. طراحی استراتژی‌های پرامپت‌دهی ساختاریافته برای استخراج هم‌زمان ویژگی‌های معنایی و ترتیبی از لاگ‌های سیستمی.
۲. ارزیابی و سنجش میزان افزایش سرعت پردازش و تشخیص خطا در روش پیشنهادی نسبت به روش‌های مبتنی بر تنظیم دقیق.
۳. تحلیل و ارزیابی دقت تشخیص ناهنجاری‌های پیچیده و شرطی در روش پیشنهادی در مقایسه با روش‌های سنتی و آماری.
۴. کاهش وابستگی به داده‌های آموزشی برچسب‌دار و بررسی کارایی مدل در شرایط محدودیت داده.
۵. کاهش نیاز به مداخله انسانی و دانش خبره در فرآیند تحلیل و تفسیر لاگ‌ها.

سؤال‌ها و فرضیه‌های پژوهش ۵-۱

سؤال‌های پژوهش

۱. آیا استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش‌آموزش‌دیده مانند Qwen2.5:7B-Instruct می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد؟
۲. آیا ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش‌آموزش‌دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود؟
۳. آیا استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد؟

۴. آیا استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود یابد؟

فرضیه‌های پژوهش

۱. استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش‌آموزش‌دیده مانند Qwen2.5:7B-Instruct می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد.
۲. ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش‌آموزش‌دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود.
۳. استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد.
۴. استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود می‌یابد.