

را روی ReFT و LoRA عملکرد Pang و Lim، Zhu مقاله ۹ - تنظیم پارامترکارای مدل‌های زبانی برای تشخیص ناهنجاری لاگ بررسی کردند. پژوهش فقط یک مدل Llama-۳ و GPT-۲، RoBERTa پیشنهادی ارائه نمی‌کند، بلکه پایداری اجرا، کارایی نمونه، مقاومت در برابر لاگ ناپایدار و تعمیم میان مقایسه می‌کند. [۹] Thunderbird و Spirit، BGL، HDFS مجموعه‌ها را در چهار مجموعه

بر پایداری و انتقال اثر دارد [۹]. این مطالعه معیار PEFT نتایج مقاله نشان می‌دهد نوع مدل پایه و روش در پژوهش حاضر Qwen و «استفاده بدون تنظیم» فراهم می‌کند «LLM مناسبی برای تفکیک» استفاده از fine-tuned detection، نه prompt-only inference سازگار نمی‌شود و بنابراین نتیجه آن باید در طبقه PEFT با tuned detection.

و همکاران Hadadi **Anomaly Detection on Unstable Logs with GPT Models:** مقاله ۱۱ - روی لاگ مقصد تنظیم و GPT-۳. بررسی کردند GPT مسئله تغییر قالب‌ها میان نسخه‌های نرم‌افزار را با تشکیل می‌شود تا LOGEVOL-Hadoop با مهندسی پرامپت استفاده شد. داده آزمایش از دو نسخه GPT-۴ اثر ناپایداری و انتقال میان نسخه‌ها سنجیده شود. [۱۱]

نتیجه بهتری گزارش کرده است [۱۱] prompt engineering نسبت به fine-tuning، در پروتکل مقاله این یافته محدود به مدل‌ها و داده همان مطالعه است، اما نشان می‌دهد نبود تنظیم می‌تواند در تغییر توزیع هزینه عملکرد داشته باشد. پژوهش حاضر مسئله انتقال نسخه‌ای را آزمایش نمی‌کند و تمرکز آن بر دو محل اعمال ثابت است BGL قاعده در

و همکاران برای انتقال آشکارساز به سامانه نرم‌افزاری جدید، تفسیر رخداد LogSynergy: Sui مقاله ۱۵ - تفاوت‌های نحوی رخدادها را LLM و استخراج ویژگی یکپارچه میان سامانه‌ها را ترکیب کردند LLM با به توصیف‌های هم‌معنا نزدیک می‌کند و سپس ویژگی‌های استاندارد شده به طبقه‌بند انتقالی داده می‌شوند. [۱۵] بیش از ۸۹ درصد روی داده واقعی و بیش از ۸۳ درصد F۱ با پنج هزار توالی برچسب‌خورده LogSynergy روی داده‌های عمومی گزارش می‌کند [۱۵]. مسئله اصلی آن انتقال بین سامانه‌هاست، نه تصمیم بدون آموزش برای کاهش LLM در یک مجموعه. ارتباط آن با پژوهش حاضر به نقش نرمال‌سازی معنایی و استفاده از ناهمگونی ورودی مربوط می‌شود

را ارائه کردند SemiRALD و همکاران چارچوب نیمه‌نظارتی SemiRALD: Sun مقاله ۱۶ - همراه با RoBERTa و یادگیری درون‌متنی برای تجزیه لاگ استفاده می‌شود و سپس بازنمایی ChatGPT توجه‌محور، الگوی توالی را برای طبقه‌بندی می‌آموزد. طراحی روش، مرحله تجزیه معنایی و BiLSTM طبقه‌بند آموزش‌پذیر را از یکدیگر جدا می‌کند. [۱۶]

برابر ۷،۳ و ۸،۲ درصد را در مقایسه با F۱ بررسی شده و مقاله میانگین بهبود BGL و HDFS روش روی دو گروه خط پایه گزارش می‌کند؛ بهبود در نسبت ۰،۱ درصد داده برچسب‌خورده برجسته‌تر است [۱۶] پژوهش حاضر guard+LLM در نام این مقاله به ترکیب مدل زبانی و مدل ترتیبی اشاره دارد و با Hybrid متفاوت است

را برای تجزیه، تشخیص LogLAA و همکاران چارچوب یکپارچه و تطبیقی LogLAA: Gao مقاله ۱۷ - از طول، فراوانی کلمات، جایگزینی متغیر و درخت پیشوند استفاده می‌کند؛ parser و توضیح طراحی کردند توضیح نتیجه LLM دوتوجهی داده می‌شوند؛ و CNN-LSTM بازنمایی‌های شمارشی، ترتیبی و معنایی به را تولید می‌کند. [۱۷]

تشخیص نسبت به میانگین Precision مقاله افزایش ۰,۸ درصدی کیفیت تجزیه، بهبود حدود ۶ درصدی سامانه‌ای چندمرحله‌ای و LogLAA. روش‌های مقایسه و امتیاز ۰,۷ برای توضیح را گزارش می‌کند [۱۷] آموزش‌پذیر است؛ پژوهش حاضر بخش توضیح و مدل ترتیبی را حذف و بر کنترل تصمیم، کش و استنتاج ثابت تمرکز می‌کند LLM محلی یک

مطالعات مبتنی بر پرامپت ۲-۳-۴

LogPrompt: Liu و همکاران در مقاله **Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies**، استفاده از LLM برای تجزیه و تشخیص آنلاین لاگ بدون آموزش درون‌دامنه بررسی کردند. هسته روش، ارائه دستور مرحله‌بندی‌شده، دانش وظیفه و درخواست توجیه تصمیم است تا مدل از معنا و زمینه رخداد استفاده کند. [۱] را معرفی و چند وظیفه تحلیل لاگ را در یک چارچوب LogPrompt نسخه سال ۲۰۲۳ پایه خط پژوهشی پرامپتی جمع می‌کند [۱]. مقاله [۶] نسخه توسعه‌یافته همین کار است؛ بنابراین نتایج آن‌ها مستقل از یکدیگر جمع نمی‌شوند. حضور جداگانه هر دو در پیشینه برای نشان‌دادن تحول نسخه و پوشش کامل فایل‌های موجود است.

و همکاران **Exploring ChatGPT for Log-Based Anomaly Detection: Qi** مقاله ۲ - بررسی کردند. پژوهش پنج محور را مطالعه Spirit و BGL را برای تشخیص ناهنجاری روی ChatGPT می‌کند: تغییر پرامپت، اندازه پنجره، تزیق دانش انسانی، مقایسه با مدل‌های عمیق و تبیین‌پذیری. برای اطلاعات اصلی شامل ۴,۷۴۷,۹۶۳ پیام و ۳۴۸,۴۶۰ ناهنجاری گزارش شده است. [۲] مقاله دو هزار پیام متوالی از بخش آزمون را انتخاب و نسبت وجود ناهنجاری، API به دلیل محدودیت نرخ BGL را به‌صورت دستی کنترل کرده است [۲]. این محدودیت برای تفسیر نتیجه مهم است، زیرا آزمایش کل نرخ، F۱ نیست. پژوهش حاضر با مدل محلی و کش قالب برای اجرای گسترده‌تر طراحی می‌شود و علاوه بر و زمان را ثبت می‌کند INVALID

Prompt Engineering Towards Zero-Shot and Interpretable Log Analysis مقاله **LogPrompt: نسخه توسعه‌یافته** است و راهبردهای پرامپت را روی ۹ مجموعه LogPrompt نسخه کامل‌تر Interpretable Log Analysis داده و چند وظیفه تجزیه و تشخیص ارزیابی می‌کند. اجزای پرامپت شامل تعریف وظیفه، دانش ضمنی یا صریح و زنجیره استدلال برای هدایت مدل به تصمیم و توضیح است. [۶]

مقاله بهبود تا ۵۵,۹ درصد نسبت به روش‌های آموزش‌دیده در برخی تنظیم‌ها و امتیاز ۴,۴۲ از ۵ برای نشان می‌دهد افزودن BGL تفسیرپذیری در ارزیابی متخصصان را گزارش می‌کند [۶]. تحلیل حذف مؤلفه در سطح نشست و قالب را تغییر دهد. پژوهش حاضر برای کاهش F۱ استدلال یا درخواست توجیه می‌تواند دودویی محدود می‌کند JSON خروجی آزاد، استدلال را به

سه نوع شواهد را در یک پرامپت ترکیب کردند Lee و Choi و **Hybrid Prompting: Park** مقاله ۳ - Qwen۳- وجود رخداد دیده‌نشده، آمار و شباهت توالی و نزدیک‌ترین نمونه عادی. برای تعبیه از Embedding-۸B و BGL، HDFS، استفاده شده است GPT-۴o-mini و برای طبقه‌بندی از Thunderbird [۳] پروتکل‌های توالی ارزیابی می‌شوند.

F1 برابر ۹۹٫۶۰ و Recall برابر ۶۳٫۶۵، با پنجره یک‌دقیقه‌ای و نمونه متوازن BGL روش در روی سه مجموعه ۹٫۹۳ واحد درصد است [۳] F1 برابر ۷۷٫۸۱ درصد گزارش می‌کند و میانگین بهبود است LLM و guard پایان‌نامه یک آبشار Hybrid ترکیب اطلاعات در متن است؛ Hybrid Prompting و سطح تصمیم آن خط است.

۲-۳-۵ بازیابی، همکاری مدل‌ها و کنترل هزینه

پایگاه برداری را از نمونه‌های عادی تشکیل دادند و برای Yuan و RAGLog: Pan، Wong مقاله ۱۲ - K-ارائه کردند. نمونه‌های پایگاه با خوشه‌بندی LLM هر ورودی، نمونه مرتبط را بازیابی و همراه پیام به انتخاب می‌شوند و مدل بدون دریافت نمونه ناهنجار، براساس شباهت و Thunderbird و BGL از means تحلیل معنایی تصمیم می‌گیرد. [۱۲]

برابر ۰٫۸۹ را در F1 برابر ۰٫۸۸ و Recall برابر ۰٫۹۱ Precision در تنظیم گزارش‌شده RAGLog ارائه می‌کند [۱۲]. مقاله مصرف منابع و تأخیر تحلیل خطبه‌خط را محدودیت می‌داند LogPrompt مقایسه با نمونه را برای زمینه انتخاب می‌کند، درحالی‌که کش پایان‌نامه تصمیم معتبر قالب RAGLog پایگاه برداری را بازاستفاده می‌کند.

و همکاران همکاری مدل زبانی کوچک و بزرگ را برای چند وظیفه AdaptiveLog: Ma مقاله ۱۳ - تحلیل لاگ پیشنهاد کردند. مدل کوچک ابتدا نمونه را پردازش می‌کند؛ معیار عدم‌قطعیت تعیین می‌کند کدام ارجاع شود؛ و موارد دشوار مشابه از مخزن خطا بازیابی و در پرامپت قرار می‌گیرند LLM نمونه به نیز برای بهبود تدریجی مدل کوچک استفاده می‌شود. [۱۳] LLM بازخورد

تا ۷۳ درصد را گزارش می‌کند [۱۳]. این روش برای کنترل LLM کاهش هزینه فراخوانی AdaptiveLog پایان‌نامه به‌جای مدل Hybrid. هزینه به یک مدل کوچک آموزش‌پذیر و معیار عدم‌قطعیت وابسته است همان دروازه را حذف می‌کند؛ در Prompt-only کوچک، قواعد قطعی محدود را دروازه قرار می‌دهد و نتیجه مقایسه بدون آموزش مدل جانبی انجام می‌شود.

را برای تشخیص داده‌کارآمد روی لاگ‌های ناپایدار FlexLog و همکاران FlexLog: Hadadi مقاله ۱۰ - بازیابی نمونه و کش ترکیب Mistral و شبکه پیش‌خور با KNN، طراحی کردند. خروجی درخت تصمیم برای نمونه‌های دشوار یا نیازمند معنا به‌کار LLM می‌شود. مدل‌های کلاسیک موارد آشنا را پوشش می‌دهند و می‌رود. [۱۰]

انجام شده است. مقاله SYNEVOL-U و SynHDFS-U، LOGEVOL-U، ADFA-U آزمایش روی با ۶۲٫۸۷ واحد درصد داده برچسب‌خورده کمتر، در برخی تنظیم‌ها تا ۱۳ F1 حداقل ۱٫۲ واحد درصد بهبود از نظر FlexLog. واحد درصد بهبود و زمان استنتاج کمتر از یک ثانیه برای هر توالی گزارش می‌کند [۱۰]. کش و آبشار تصمیم نزدیک است، اما داده، واحد تحلیل و ترکیب چند طبقه‌بند آن با پایان‌نامه تفاوت دارد.

۲-۳-۶ مطالعات تجزیه و تولید قالب لاگ

RoBERTa را روی few-shot برای تجزیه لاگ، پرامپت‌تیونینگ Zhang و Le LogPPT: مقاله ۲۴ - به‌کار گرفتند. الگوریتم نمونه‌گیری تصادفی تطبیقی مجموعه‌ای کوچک و متنوع از پیام‌ها را انتخاب می‌کند و مدل یاد می‌گیرد توکن‌های پارامتر را با یک برچسب مجازی تشخیص دهد. روش به عبارت منظم دستی وابسته نیست و تنظیمات یکسان را در دامنه‌های مختلف حفظ می‌کند. [۲۴]

Group روی ۱۶ مجموعه عمومی و با ۳۲ نمونه برجسب‌خورده ارزیابی شده و میانگین LogPPT، بیش از ۰٫۹ گزارش می‌کند [۲۴]. هدف آن تشخیص ناهنجاری نیست Parsing Accuracy و Accuracy ولی تعریف قالب و پارامتر مبنای نرمال‌سازی و کش قالب در پژوهش حاضر است. را با یک درخت پیشنهاد برای LLM و همکاران معناشناسی LogParser-LLM: Zhong مقاله ۲۳ - تجزیه برخط ترکیب کردند. پیام‌ها ابتدا با ساختار موجود تطبیق داده می‌شوند و فقط الگوهای جدید یا مبهم به یک معیار و امکان بازخورد انسانی نیز پیشنهاد می‌کند parser می‌روند. مقاله برای کنترل دانه‌بندی LLM [۲۳]

به‌طور متوسط ۲۷۲٫۵ LogParser-LLM، با میانگین ۳٫۶ میلیون لاگ در ۱۴ مجموعه LogPub در برابر ۸۱٫۱ درصد گزارش می‌کند Parsing Accuracy گروه‌بندی ۹۰٫۶ درصد و F1، LLM، فراخوانی این روش نشان می‌دهد تجمیع سطح قالب می‌تواند تعداد فراخوانی را کاهش دهد، اما خروجی آن قالب [۲۳] است و برجسب ناهنجاری تولید نمی‌کند.

مرورها، معیار ارزیابی، مدل پایه و استقرار واقعی ۲-۳-۷

LLM: De la Cruz Cabello، Prince Sales مقاله ۱۴ - مرور نظام‌مند تشخیص ناهنجاری لاگ در عصر و تشخیص ناهنجاری لاگ را تحلیل کردند AIOps با روش مرور نظام‌مند، ۳۳ مقاله حوزه Machado و مطالعه مراحل آماده‌سازی داده، تجزیه، استخراج ویژگی، مدل تشخیص، مجموعه‌های معیار و شیوه ارزیابی را جمع‌بندی می‌کند. [۱۴] LLM را طبقه‌بندی و روند حرکت از مدل‌های عمیق به ارائه نمی‌کند و نقش آن ایجاد چارچوب دسته‌بندی و استخراج BGL این مقاله یک روش آزمایشی جدید روی مسائل باز مانند هزینه، تفسیرپذیری، تعمیم و محرمانگی است [۱۴]. ساختار دسته‌بندی فصل حاضر از محورهای این مرور استفاده می‌کند، اما جدول ۲-۱ به مجموعه ۲۷ فایل محلی محدود است.

و همکاران چارچوب خودنظارتی مبتنی بر AIOps: De la Cruz Cabello مقاله ۲۰ - پیاده‌سازی واقعی عادی آموزش و در محیط دارای محدودیت محرمانگی به‌صورت Linux syslog را روی LogBERT محلی مستقر کردند. اثر حداقل تعداد توکن، اندازه و همپوشانی پنجره و نرخ ماسک بر تشخیص و تأخیر بررسی شده است. [۲۰]

پنجره ۱۵ ثانیه‌ای با همپوشانی ۱۰ ثانیه بهترین موازنه گزارش‌شده میان اثربخشی و تأخیر را ایجاد کرد و ارزیابی متخصصان کاربرد عملی روش را تأیید نمود [۲۰]. مقاله اهمیت استقرار محلی و اندازه‌گیری تأخیر بدون Qwen واقعی است، نه syslog آموزش‌دیده و داده آن LogBERT را پشتیبانی می‌کند، اما مدل آن BGL تنظیم روی

در عملیات فناوری LLM و همکاران یک مجموعه معیار برای ارزیابی توان OpsEval: Liu مقاله ۲۵ - شامل ۷،۳۳۴ سؤال چندگزینه‌ای و ۱،۷۳۶ سؤال پاسخ‌آزاد در چند زیرحوزه OpsEval. اطلاعات ارائه کردند مقایسه می‌کند in-context learning و chain-of-thought، self-consistency است و ۲۴ مدل را تحت [۲۵]

پاسخ را از نظر روانی، صحت و شواهد می‌سنجد و همبستگی حدود ۰٫۹۱۸۵ با ارزیابی FAE-Score معیار آشکارساز لاگ نیست، اما حساسیت مدل‌های عملیات به OpsEval. متخصصان گزارش شده است [۲۵] پرامپت و ضرورت تعریف معیار متناسب با خروجی را نشان می‌دهد. در پایان‌نامه، چون خروجی دودویی جای معیار متنی را می‌گیرند INVALID است، معیارهای ماتریس اغتشاش و یک مدل متن‌باز ۱۲ میلیارد پارامتری YuLan و همکاران گزارش فنی توسعه **YuLan: Zhu مقاله ۲۶** - را ارائه کردند. مدل با حدود ۱٫۷ تریلیون توکن چندزبانه پیش‌آموزی شده و پس از آن تنظیم دستوری و داده tokenizer، هم‌ترازی انسانی انجام گرفته است. مقاله برنامه‌ریزی آسان‌به‌دشوار و جزئیات معماری را تشریح می‌کند. [۲۶]

روی ۲۲ معیار عمومی ارزیابی شده و مقاله‌ای درباره تشخیص ناهنجاری لاگ نیست [۲۶]. حضور YuLan آن در فصل دوم برای تعریف مدل متن‌باز، مراحل پیش‌آموزی تا دستورپذیری و تفاوت مدل پایه با مدل در آزمایش مقایسه‌ای YuLan است و Qwen_{۲,۵:۷B-Instruct} است. انتخاب عملی پایان‌نامه Instruct استفاده نمی‌شود.

آثار تشخیص ناهنجاری و داده خارج از Ding و Xu و **OOD: Xu و Ding مقاله ۲۷** - مرور LLM برای تشخیص و LLM را در حوزه‌های مختلف مرور و براساس نقش مدل به دو گروه LLM توزیع با برای تولید تقسیم کردند. مطالعه تفاوت تغییر هم‌توزیعی و تغییر معنایی، مجموعه‌های داده و مسیرهای آینده را توضیح می‌دهد. [۲۷]

دامنه مقاله فراتر از لاگ و شامل متن، سری زمانی و سایر انواع داده است [۲۷]. در این فصل از آن برای تعریف نقش مدل، تفکیک تشخیص از تولید و قرار دادن مطالعات تبیین یا افزایش داده در طبقه مناسب استفاده در آن وجود ندارد BGL یا Qwen می‌شود؛ ارزیابی مستقیمی از

جمع‌بندی تحلیلی مسیر پژوهش‌ها ۸-۳-۲

رخداد بعدی را پیش‌بینی می‌کند DeepLog. مرحله نخست تحول ادبیات با مدل‌سازی توالی شکل گرفته است مسیر BERT-Log. زمینه دوطرفه و وظیفه خودنظارتی را به توالی می‌افزاید [۲۱، ۱۹] LogBERT و را با طبقه‌بند نظارت‌شده ترکیب می‌نماید [۱۸]. این سه مطالعه BERT دیگری را دنبال می‌کند و بازنمایی مبنای تفاوت میان یادگیری الگوی عادی و طبقه‌بندی برچسب‌محور را مشخص می‌کنند.

MLM از وظیفه ADALog و LogFiT. مرحله دوم بر کاهش وابستگی به برچسب ناهنجار تمرکز دارد الگوی توکن LogFiT: است parser روی داده عادی استفاده می‌کنند [۲۲، ۸]. تفاوت آن‌ها در واحد تحلیل و پیام خام و مستقل را با آستانه تطبیقی ارزیابی می‌کند. این تفاوت ADALog در توالی را می‌سنجد، درحالی‌که نشان می‌دهد حذف برچسب به‌تنهایی واحد تصمیم را تعیین نمی‌کند.

LLM-LogLLM، GPT مبتنی بر LogGPT. به‌عنوان مدل آموزش‌پذیر است LLM مرحله سوم ورود از پیش‌آموزی عمومی آغاز می‌کنند، اما برای دامنه لاگ وزن‌ها یا نگاشت‌های PEFT و روش‌های LLADE تفاوت بنیادی دارد، زیرا هزینه prompt-only مدل را تغییر می‌دهند [۴، ۵، ۷، ۹]. این خانواده با روش‌های آموزش و داده انطباق بخشی از روش است.

و مطالعه LogPrompt مرحله چهارم استفاده از توان دستورپذیری بدون تغییر وزن است. دو نسخه Hybrid. اثر دستور، دانش دامنه و استدلال را بررسی می‌کنند [۱، ۲، ۶] ChatGPT-LogGPT، همین مسیر را با شواهد سطح توالی و نمونه بازیابی‌شده توسعه می‌دهد [۳]. در این خانواده Prompting متن پرامپت و روش انتخاب زمینه بخشی از مدل عملیاتی محسوب می‌شود.

AdaptiveLog، از بازیابی نمونه عادی RAGLog. مرحله پنجم به کنترل هزینه و مقیاس اختصاص دارد، و کش استفاده می‌کند [۱۰ RAG، از ترکیب مدل‌های کلاسیک FlexLog از واگذاری مبتنی بر عدم قطعیت و نیز در وظیفه تجزیه نشان می‌دهد ساختار پیشوند می‌تواند فراخوانی را در [۱۳، ۱۲]. مقیاس میلیون‌ها پیام محدود کند [۲۳]

توضیح را در پاسخ مستقیم مدل قرار LogPrompt. مسیر دیگری از ادبیات بر تفسیرپذیری متمرکز است آشکارساز LogLAA توضیح را همراه تشخیص آموزش می‌دهد [۷]؛ و LLM-LADE می‌دهد [۱، ۶]؛ عمیق و تولید توضیح را در دو جزء جدا ترکیب می‌کند [۱۷]. این سه الگو نشان می‌دهند تفسیرپذیری می‌تواند خروجی زبانی، هدف آموزشی یا جزء پس‌پردازش باشد.

روی GPT مطالعات انتقال و ناپایداری، محدودیت ارزیابی روی یک توزیع ثابت را مطرح می‌کنند. پژوهش بازنمایی یکپارچه میان سامانه‌ها LogSynergy تغییر نسخه را مستقیماً آزمایش می‌کند [۱۱]؛ LOGEVOL مجموعه‌های ناپایدار واقعی و مصنوعی را بررسی می‌کند [۱۰]. پایان‌نامه حاضر FlexLog می‌سازد [۱۵]؛ و ثابت است BGL این مسئله را به‌صورت تجربی پوشش نمی‌دهد و دامنه آن

و few-shot با LogPPT. پژوهش‌های تجزیه نشان می‌دهند آماده‌سازی ورودی یک مسئله مستقل است. و درخت پیشوند، کیفیت قالب را به‌عنوان خروجی اصلی می‌سنجند [۲۳، ۲۴] LLM با LogParser-LLM تفکیک شود. پایان‌نامه parser رخ دهد باید از اثر خود parser بنابرین هر بهبود آشکارساز که پس از تغییر نرمال‌سازی را در هر دو روش ثابت نگه می‌دارد

فاصله میان معیار عمومی و استقرار را نشان می‌دهد؛ پارامتر پنجره و تأخیر AIops مطالعه کاربرد واقعی در عملیات به LLM نیز نشان می‌دهد ارزیابی OpsEval. به اندازه دقت برای کار عملی اهمیت دارند [۲۰] معیار و پرامپت تخصصی نیاز دارد [۲۵]. این دو منبع مبنای گزارش زمان، نسخه مدل و قرارداد خروجی هستند F۱ در کنار

را AIops دو مقاله مروری نقش کنترل دامنه را دارند. مرور نظام‌مند لاگ، مراحل خط لوله و شکاف‌های را به تشخیص و تولید تقسیم می‌نماید [۲۷] LLM نقش Anomaly/OOD استخراج می‌کند [۱۴] و مرور جدول فصل از اولی برای محورهای لاگ و از دومی برای نقش مدل استفاده می‌کند؛ هیچ‌یک به‌عنوان نتیجه شمرده نمی‌شود BGL آزمایش

نیز در گروه نتیجه تشخیص قرار نمی‌گیرد، اما مراحل ساخت مدل پایه، تنظیم دستوری و هم‌ترازی YuLan محصول چنین Qwen۲,۵:۷B-Instruct را مستند می‌کند [۲۶]. این تفکیک برای پایان‌نامه لازم است، زیرا مراحل عمومی است، ولی وزن آن در پروژه تغییر نمی‌کند و فقط در زمان استنتاج به‌کار می‌رود [۲۸]

برآیند ۲۷ مقاله نشان می‌دهد پنج تصمیم طراحی باید صریح باشند: واحد تحلیل، نوع انطباق مدل، روش در پایان‌نامه فقط Prompt-only و Hybrid آماده‌سازی، سازوکار کنترل هزینه و محل استقرار. دو روش یکی از این تصمیم‌ها—محل اعمال دانش قاعده—را تغییر می‌دهند و سایر عوامل برای مقایسه ثابت می‌مانند

دسته‌بندی و تحلیل مقایسه‌ای ۲-۴

شکل ۲-۱ تمام ۲۷ مقاله را در شش مسیر روش‌شناختی قرار می‌دهد و سپس نشان می‌دهد کدام مؤلفه‌ها در طراحی پژوهش حاضر به هم می‌رسند. شماره‌های شکل با شماره فایل‌های پوشه و ارجاع‌های فصل یکسان‌اند هم مدل FlexLog قرارگرفتن یک مقاله در یک دسته به معنای نبود مؤلفه‌های دسته دیگر نیست؛ برای نمونه و کش دارد [۱۰] RAG، LLM، کلاسیک

نقشه مطالعات بررسی‌شده در فصل دوم (۲۷ مقاله)			
ترتیبی و پیش‌آموزش‌دیده		LLM آموزش، تنظیم و انتقال	
LogPrompt [۱، ۶]؛ ChatGPT-LogGPT [۲]؛ Hybrid Prompting [۳]		LogGPT [۵]؛ LogLLM [۴]؛ LLM-LADE [۷]؛ PEFT [۹]؛ GPT [۱۱]؛ ناپایدار [۱۱]؛ LogSynergy [۱۵]؛ SemiRALD [۱۶]؛ LogLAA [۱۷]	
DeepLog [۲۱]؛ LogBERT [۱۹]؛ BERT-Log [۱۸]؛ LogFiT [۸]؛ ADALog [۲۲]		بازیابی، همکاری و کنترل هزینه	
مرور، معیار و استقرار		تجزیه و ساخت قالب	
SLR [۱۴]؛ AIops [۲۰]؛ واقعی OpsEval [۲۵]؛ YuLan [۲۶]؛ Anomaly/OOD [۲۷]		LogPPT [۲۴]؛ LogParser-LLM [۲۳]	
RAGLog [۱۲]؛ AdaptiveLog [۱۳]؛ FlexLog [۱۰]		ترکیب شواهد ادبیات برای طراحی پژوهش حاضر: معناشناسی مدل زبانی + قالب پایدار + کنترل تصمیم + استنتاج محلی	
دامنه و واحد تحلیل		متغیر مستقل مقایسه	
استقرار و سنجش		کارایی	
Qwen۲،۵:۷B-Instruct روی Ollama؛ کیفیت؛ زمان و منبع تصمیم		نرمال‌سازی و کش سطح قالب؛ رد INVALID	
؛ طبقه‌بندی خطبه‌خط؛ حذف برجسب BGL فقط از ورودی		Hybrid: guard قطعی پیش از LLM انتقال دانش قاعده به پرامپت: Prompt-only	

شکل ۲-۱: ارتباط ۲۷ مقاله بررسی‌شده و جایگاه پژوهش حاضر

پرامپت، بازیابی و استقرار، LLM تا BERT در بخش بالایی شکل، مسیر تاریخی و فنی از مدل‌های ترتیبی و واقعی دیده می‌شود. بخش پایینی نوآوری عملیاتی مورد سنجش را نشان می‌دهد: ثابت نگه‌داشتن مدل و بیرونی و پرامپت. این شکل ادعای برتری هیچ guard پیش‌پردازش و تغییر محل اعمال دانش قاعده میان مسیر را بیان نمی‌کند و فقط رابطه اجزای برگرفته از منابع را نمایش می‌دهد.

جدول ۱-۲: مشخصات و مقایسه تمام ۲۷ مقاله موجود در پوشه پژوهش

شماره و مطالعه	سال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش شده
اولیه LogPrompt [۱]	۲۰۲۳	پرامپت	راهبرد دستور و تبیین + LLM	چند مجموعه لاگ	قالب/توالی	نسخه اولیه تحلیل بدون آموزش درون دامنه
ChatGPT-LogGPT [۲]	۲۰۲۳	پرامپت	و دانش دامنه ChatGPT	BGL، Spirit	خط/پنجره	بررسی پرامپت، پنجره و تبیین روی نمونه تالی ۲۰۰۰
Hybrid Prompting [۳]	۲۰۲۵	پرامپت ترکیبی	رخداد + توالی + بازیابی	HDFS، BGL، Thunderbird	توالی یکدقیقه‌ای	BGL: P=۶۳،۶۵، R=۹۹،۶۰، F۱=۷۷،۸۱
LogLLM [۴]	۲۰۲۴	LLM آموزش	BERT + projector + LLaMA	HDFS، BGL، Liberty، Thunderbird	توالی	LLM و طبقه‌بند encoder ترکیب بازنمایی
LogGPT via GPT [۵]	۲۰۲۳	آموزش/RL	RL + پیش‌بینی رخداد GPT	HDFS، BGL، Thunderbird	توالی	هم‌استاسازی پیش‌بینی رخداد با هدف تشخیص
LogPrompt توسعه‌یافته [۶]	۲۰۲۴	پرامپت	و تبیین CoT، zero-shot	مجموعه ۹	قالب/توالی	تا ۵۵،۹٪ بهبود؛ تفسیرپذیری ۴،۴۲/۵
LLM-LADE [۷]	۲۰۲۵	تبیین/PEFT	LoRA + افزایش داده + بهینه‌سازی برخط	مجموعه‌های عمومی	پیام/توالی	تشخیص و توضیح هم‌زمان با پایگاه دانش
LogFiT [۸]	۲۰۲۵	خودنظارتی	top-k مدل زبانی ماسک‌شده و	HDFS، BGL، Thunderbird	توالی	آموزش فقط روی لاگ عادی
PEFT-LAD [۹]	۲۰۲۵	PEFT	روی LoRA/ReFT، RoBERTa، GPT-۲، Llama-۳	HDFS، BGL، Spirit، Thunderbird	توالی	تحلیل پایداری، کارایی نمونه و انتقال
FlexLog [۱۰]	۲۰۲۴/۲۵	ترکیبی	ML ensemble + Mistral + RAG + cache	چهار مجموعه ناپایدار	توالی	داده کمتر؛ تا ۱۳ واحد درصد بهبود؛ کمتر از ۱ ثانیه
Unstable Logs GPT [۱۱]	۲۰۲۴	تنظیم/پرامپت	GPT-۴ تنظیم‌شده و GPT-۳ پرامپت	LOGEVOL-Hadoop	توالی	در پروتکل مطالعه fine-tuning برتری
RAGLog [۱۲]	۲۰۲۳/۲۴	بازیابی	LLM + پایگاه برداری عادی	BGL، Thunderbird	خط/توالی	Precision=۰،۹۱، Recall=۰،۸۸، F۱=۰،۸۹
AdaptiveLog [۱۳]	۲۰۲۵	همکاری مدل	بازیابی + LLM + مدل کوچک	چند وظیفه لاگ	وابسته به وظیفه	LLM تا ۷۳٪ کاهش هزینه فراخوانی
مرور نظام‌مند AIOps [۱۴]	۲۰۲۵	مرور	و طبقه‌بندی ۳۳ مقاله SLR	ادبیات حوزه	مطالعه	چارچوب مراحل، داده‌ها، مدل‌ها و شکاف‌ها
LogSynergy [۱۵]	۲۰۲۵	انتقال	ویژگی یکپارچه + LLM تفسیر	عمومی و واقعی	توالی	بیش از ۸۳٪ عمومی و ۸۹٪ واقعی F۱
SemiRALD [۱۶]	۲۰۲۵	نیمه‌نظارتی	ChatGPT parsing + RoBERTa + BiLSTM	HDFS، BGL	توالی	٪ برابر ۷،۳ و ۸،۲ F۱ بهبود متوسط
LogLAA [۱۷]	۲۰۲۶	یکپارچه	parser + CNN-LSTM + LLM explanation	چند مجموعه	توالی	و تولید توضیح Precision، parser بهبود
BERT-Log [۱۸]	۲۰۲۲	نظارت‌شده	BERT + طبقه‌بند	HDFS، BGL	پنجره/توالی	BGL گزارش‌شده ۹۹،۴٪ روی F۱
LogBERT [۱۹]	۲۰۲۱	خودنظارتی	و ابرکره MLM با BERT	HDFS، BGL، Thunderbird	توالی	یادگیری الگوی عادی با دو هدف خودنظارتی
AIOps واقعی [۲۰]	۲۰۲۶	استقرار	محلی LogBERT	واقعی Linux syslog	پنجره زمانی	پنجره ۱۵ ثانیه با همپوشانی ۱۰ ثانیه
DeepLog [۲۱]	۲۰۱۷	ترتیبی	و پیش‌بینی رخداد بعدی LSTM	HDFS، OpenStack	توالی	تشخیص برخط، به‌روزرسانی و جریان عیب‌یابی
ADALog [۲۲]	۲۰۲۵	بدون نظارت	آستانه + DistilBERT MLM تطبیقی	BGL، Thunderbird، Spirit	خط	و مستقل از توالی parser بدون
LogParser-LLM [۲۳]	۲۰۲۴	تجزیه	درخت پیشوند + LLM	Loghub-۲k، LogPub	خط/قالب	٪ گروه‌بندی ۹۰،۶ F۱ فراخوانی؛ ۲۷۲،۵
LogPPT [۲۴]	۲۰۲۳	تجزیه	few-shot prompt tuning روی RoBERTa	مجموعه ۱۶	خط/قالب	بیش از ۰،۹ با ۳۲ نمونه برجسته‌شده
OpsEval [۲۵]	۲۰۲۵	معیار	MCQ/QA + CoT/ICL + FAE-Score	Ops پرسش ۹۰۷۰	پرسش	حدود ۰،۹۱۸۵ FAE؛ همبستگی LLM ۲۴

شماره و مطالعه	سال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش شده
[۲۶] YuLan	۲۰۲۴	مدل پایه	و سه B متن‌باز ۱۲ LLM مرحله آموزش	توکن؛ ۲۲ معیار ۱۰۷۲	متن	مرجع ساخت مدل دستورمحور؛ نه آشکارساز لاگ
مرور [۲۷] Anomaly/OOD	۲۰۲۵	مرور	برای LLM ردیابی تشخیص/تولید	چند حوزه داده	مطالعه	LLM و نقش‌های OOD و anomaly تفکیک

جدول ۱-۲ حضور هر ۲۷ فایل را قابل ردیابی می‌کند. سطرهای [۱۴]، [۲۵]، [۲۶] و [۲۷] نتیجه تشخیص ندارند، زیرا به ترتیب مرور نظام‌مند، معیار عملیات، گزارش مدل پایه و مرور عمومی‌اند. درج آن‌ها BGL در جدول برای تفکیک نقش منبع نظری از مطالعه آزمایشی انجام شده است.

۲-۴-۱ BGL مقایسه براساس واحد تحلیل و پروتکل

نزدیک‌ترین ADALog واحد تحلیل از خط تا توالی و پنجره تغییر می‌کند، BGL در میان مطالعات دارای پنجره یا توالی Hybrid Prompting و LogBERT، BERT-Log مطالعه به تصمیم خط‌محور است [۲۲]؛ بخشی نمونه‌گیری شده از آزمون را بررسی می‌کند ChatGPT مبتنی بر LogGPT می‌سازند [۳، ۱۸، ۱۹]؛ و بنابراین مقایسه عددی فقط زمانی معتبر است که واحد و نمونه یکسان باشد. [۲]

Hybrid اصلی حدود ۷،۳۴ درصد پیام ناهنجار دارد [۲، ۱۹]، اما BGL نسبت کلاس‌ها نیز متفاوت است در داده متوازن و نامتوازن رفتار Accuracy. هزار توالی از هر کلاس انتخاب می‌کند [۳] Prompting و ماتریس اغتشاش در سطح خط برای F1 و Precision، Recall یکسانی ندارد؛ به همین دلیل گزارش پایان‌نامه ضروری است.

۲-۴-۲ مقایسه براساس نیاز به آموزش

روی داده مقصد آموزش یا تنظیم می‌شوند ADALog، LogFiT، LogBERT، BERT-Log، DeepLog آموزش چندمرحله‌ای یا یادگیری تقویتی GPT مبتنی بر LogGPT و LogLLM [۲۲، ۲۱، ۱۹، ۱۸، ۸]. LoRA، ReFT، SemiRALD و LogSynergy، PEFT-LAD، LLM-LADE دارند [۴، ۵] انتقال یا آموزش نیمه‌نظارتی بهره می‌گیرند [۷، ۹، ۱۵، ۱۶]

تغییر وزن طبقه‌بند RAGLog و Hybrid Prompting، ChatGPT-LogGPT، LogPrompt، در مقابل را شرط اصلی قرار نمی‌دهند و تصمیم را از پرامپت و زمینه می‌گیرند [۱-۳، ۶، ۱۲]. پژوهش حاضر در بیرونی با دانش درون پرامپت را به پروتکل اضافه guard این گروه قرار دارد، اما کش سطح قالب و مقایسه می‌کند.

۲-۴-۳ مقایسه کنترل هزینه و استقرار

با بازیابی، زمینه مرتبط را انتخاب می‌کند [۱۲] RAGLog. سه الگوی کنترل هزینه در منابع دیده می‌شود و FlexLog. واگذار می‌کند [۱۳] LLM با عدم قطعیت مدل کوچک، نمونه را به AdaptiveLog، از کش یا ساختار تجمیعی برای جلوگیری از پردازش تکراری استفاده می‌کنند [۱۰] LogParser-LLM. این سازوکارها از نظر هدف مشترک اما از نظر داده ذخیره‌شده و منطق تصمیم متفاوت‌اند. [۲۳]

مطرح شده است [۲۰]. بیشتر مطالعات پرامپتی AIOps استقرار محلی به صورت صریح در مطالعه واقعی Mistral یا LLaMA استفاده می‌کنند [۲، ۳، ۱۱] و برخی از GPT-۴o-mini یا GPT-۴، ChatGPT از fine-tuning بدون Ollama، روی Qwen۲،۵:۷B-Instruct تنظیم شده بهره می‌گیرند [۴، ۷، ۱۰]. استفاده از ترکیب عملیاتی مورد سنجش پایان نامه است [۲۸، ۲۹]، INVALID و با ثبت زمان و tuning

مقایسه بازنمایی ورودی و آماده سازی ۲-۴-۴

ابتدا پیام را به کلید رخداد تبدیل می‌کند DeepLog. خانواده ترتیبی معمولاً پیام خام را مستقیماً دریافت نمی‌کند با BERT-Log. قرار می‌دهد [۱۹، ۲۱] BERT نیز توالی کلیدهای تجزیه شده را ورودی LogBERT و می‌تواند به مرحله parser و پنجره، پیام‌ها را برای مدل آماده می‌کند [۱۸]. در این روش‌ها خطای parser تشخیص منتقل شود

کلاسیک، پاکسازی یا قواعد منظم را parser برای کاهش وابستگی به LogLLM و ADALog روش‌های مسیر، عدد و نشانی را با جانشین عمومی جایگزین می‌کند و ADALog. روی متن به کار می‌گیرند [۴، ۲۲] به «parser» از متن پردازش شده می‌سازد. بنابراین اصطلاح «بدون BERT بردارهای معنایی LogLLM» معنی نبود پیش پردازش نیست

نمونه عادی RAGLog. در روش‌های پرامپتی، آماده سازی علاوه بر پاکسازی شامل انتخاب زمینه نیز هست ویژگی‌های رخداد و توالی را محاسبه می‌کند [۳] و Hybrid Prompting، بازیابی شده را می‌افزاید [۱۲] LLM دانش وظیفه را در دستور می‌نویسد [۱، ۶]. در نتیجه بخشی از توان روش خارج از خود LogPrompt و در ساخت ورودی قرار دارد

پایان نامه ورودی را به قالب نرمال شده تبدیل می‌کند، اما نمونه بازیابی شده یا توالی زمانی را به پرامپت نمی‌افزاید. ثابت ماندن این بازنمایی در دو روش باعث می‌شود اختلاف نتیجه به تغییر آماده سازی نسبت داده نشود. تعداد قالب‌های یکتا و نرخ برخورد کش نیز اندازه عملی اثر نرمال سازی را نشان می‌دهند

مقایسه سازوکار تصمیم و نوع خروجی ۲-۴-۵

LogFiT رخداد بعدی و DeepLog. سازوکار تصمیم در مدل‌های پیش‌بینی محور، احتمال رخداد یا توکن است top-۱ توکن ماسک شده را پیش‌بینی می‌کنند [۸، ۲۱، ۲۲]. آستانه یا قرار گرفتن رخداد واقعی در ADALog و خروجی پیوسته مدل را به برچسب دودویی تبدیل می‌کند. انتخاب آستانه بخشی از پروتکل این روش‌هاست k BERT-Log. تنظیم شده مستقیماً احتمال کلاس را تولید می‌کند LLM در مدل‌های طبقه بندی شده، یک سر طبقه بندی یا نمونه‌های این گروه‌اند [۴، ۷، ۱۶، ۱۸]. کیفیت خروجی SemiRALD و LogLLM، Log، LogLLM به داده آموزش، تابع زیان و روش تنظیم وابسته است

می‌توانند ChatGPT-Log و LogPrompt. در روش پرامپتی، پاسخ متنی باید به برچسب تبدیل شود برای پاسخ آزاد معیار جداگانه می‌سازد [۲۵]. در OpsEval توضیح همراه برچسب تولید کنند [۱، ۲، ۶] و یک سامانه خودکار، متن اضافی یا برچسب مبهم می‌تواند پردازش پایین دستی را مختل کند؛ به همین دلیل دودویی محدود می‌کند JSON پایان نامه خروجی را به

پاسخ مدل را از خطای طبقه بندی جدا می‌کند. اگر پاسخ نامعتبر به صورت عادی یا ناهنجار INVALID ثبت رفتار مدل را به درستی نشان نمی‌دهند. همچنین ذخیره نکردن F1 و Accuracy، پیش فرض گذاری شود در کش مانع تکثیر یک خطای قالب در خطوط تکراری می‌شود INVALID