

مقایسه تبیین‌پذیری و بازتولیدپذیری ۶-۴-۲

برای کاربر انسانی قابل خواندن است، اما ارزیابی آن به معیار یا قضاوت متخصص نیاز LLM تبیین آزاد از طراحی هم‌زمان تشخیص و توضیح و LLM-LADE، از امتیاز متخصصان LogPrompt. دارد. طبقه‌بندی نیازمند F1 از امتیاز کیفیت توضیح استفاده می‌کند [۱، ۶، ۷، ۱۷]. مقایسه این امتیازها با LogLAA تفکیک دو هدف است.

تبیین ساختاری به‌جای متن آزاد می‌تواند شامل شناسه قالب، منبع تصمیم، قاعده فعال و زمان باشد. این اطلاعات برای ممیزی خطبه‌خط قابل ذخیره و مقایسه‌اند. طراحی پایان‌نامه این نوع تبیین را انتخاب می‌کند تا خروجی دو روش یکسان بماند و تفاوت طول پاسخ، زمان را مخدوش نکند. ChatGPT-DS شوارتر است؛ مطالعه API بازتولیدپذیری مدل‌های تجاری با تغییر نسخه خدمت و محدودیت نیز به مدل تجاری مشخص وابسته است. Hybrid Prompting ناچار به نمونه‌گیری محدود شده و LogGPT را فراهم می‌کند runtime استقرار محلی مدل باز امکان ثبت فایل مدل، کوانتیزه‌سازی و نسخه [۳، ۲] هرچند سخت‌افزار و تنظیمات تولید همچنان باید گزارش شوند [۲۰، ۲۸، ۲۹].

تعداد تلاش، timeout، بذریه یا ترتیب داده، دما، مدل، نسخه پرامپت، Prompt-only و Hybrid برای مقایسه و خروجی خطبه‌خط امکان run identifier مجدد و سیاست کش باید ثابت باشند. ثبت این متغیرها همراه بازسازی آزمایش و تحلیل منشأ اختلاف را فراهم می‌کند. این الزامات از شکاف بازتولید و ارزیابی عملی پشتیبانی می‌شوند [۱۴، ۲۵] OpsEval مطرح‌شده در مرور نظام‌مند و

جدول ۲-۲: جمع‌بندی دسته‌های مطالعات و ارتباط آن‌ها با طراحی پژوهش

دسته	مقالات	نقش مدل زبانی	نیاز غالب به آموزش	ارتباط با پژوهش حاضر
ترتیبی/پیش‌آموزش‌دی ده	[۸، ۱۸، ۱۹، ۲۱، ۲۲]	یا مدل توالی encoder	بله؛ عادی یا برجسب‌خورده	واحد تحلیل و خط پایه BGL، تعریف زبانی
آموزش/تنظیم/انتقال LLM	[۴، ۵، ۷، ۹، ۱۱، ۱۵، ۱۶، ۱۷]	طبقه‌بند، مولد داده یا تبیین	یا انتقال PEFT، آموزش	بدون تنظیم Qwen مرز تمایز با
پرامپت	[۱، ۲، ۳، ۶]	تصمیم‌گیر مستقیم	بدون تغییر وزن	Prompt-only نزدیکترین خانواده به
بازیابی/همکاری/هز پنه	[۱۰، ۱۲، ۱۳]	RAG جزء آیشار یا	متغیر	مبنای مقایسه کش، دروازه و فراخوانی
تجزیه	[۲۳، ۲۴]	استخراج قالب	بدون آموزش گسترده یا few-shot	مبنای نرمال‌سازی و کش قالب
مرور/معیار/مدل/است قرار	[۱۴، ۲۰، ۲۵، ۲۶، ۲۷]	چارچوب نظری یا زیرساخت	وابسته به منبع	ردمبندی، محرمانگی، ارزیابی و مدل دستورمحور

۲-۵ شکاف تحقیقاتی و جایگاه پژوهش حاضر ۲-۵

۲-۵-۱ BGL ناهمگونی پروتکل‌های ۲-۵-۱

از پیام، توالی، پنجره گره، پنجره زمانی و نمونه متوازن استفاده کرده‌اند [۲-۵، ۸، ۹، ۱۲ BGL مطالعات در نتیجه، یک نتیجه عددی بدون مشخصات نمونه و واحد تصمیم قابل انتقال مستقیم نیست. [۱۶، ۱۸، ۱۹، ۲۲]. پژوهش حاضر تصمیم را خطبه‌خط تعریف، برجسب را از ورودی حذف و ماتریس اغتشاش را در همان سطح محاسبه می‌کند.

۲-۵-۲ جدانشدن کیفیت تصمیم از هزینه استنتاج ۲-۵-۲

هزینه را با کش، واگذاری یا تجمیع کاهش می‌دهند [۱۰ LogParser-LLM و AdaptiveLog، FlexLog بازیابی را وارد زمینه می‌کند [۱۲]. با این حال، همه مطالعات نرخ برخورد کش، منبع RAGLog و [۲۳، ۱۳] و زمان انتهابه‌انتها را همراه معیارهای کیفیت گزارش نمی‌کنند. پایان‌نامه این INVALID، تکتک تصمیم‌ها شاخص‌ها را همزمان ثبت می‌کند.

۲-۵-۳ محل اعمال دانش دامنه ۲-۵-۳

شواهد Hybrid Prompting دانش در پرامپت است [۶، ۲، ۱۱]؛ ChatGPT-LogGPT و LogPrompt در یک جزء بیرونی را FlexLog و AdaptiveLog رخداد، توالی و نمونه را در پرامپت ترکیب می‌کند [۳]؛ قطعی guard به‌کار می‌گیرند [۱۰، ۱۳]. در مجموعه بررسی‌شده، مقایسه کنترل‌شده LLM برای واگذاری به بیرون مدل با انتقال همان دانش به پرامپت، تحت مدل، داده، نرمال‌سازی و کش یکسان، گزارش نشده است.

۲-۵-۴ کش تصمیم سطح قالب ۲-۵-۴

ساختار قالب را برای کاهش فراخوانی استفاده LogParser-LLM پایگاه نمونه می‌سازد [۱۲] و RAGLog نیز کش را در سامانه‌ای چندمدلی به‌کار می‌گیرد [۱۰]. کش نسخه‌بندی‌شده تصمیم FlexLog می‌کند [۲۳]؛ BGL دودویی در سطح قالب نرمال‌شده، همراه با رد پاسخ نامعتبر و مقایسه دو مسیر تصمیم، در مطالعات مرور شده محور آزمایش مستقل نبوده است.

متن‌باز متوسط LLM استنتاج محلی یک ۲-۵-۵

یا LLaMA استفاده کرده‌اند [۲، ۳، ۱۱، ۱۲] و روش‌های مبتنی بر GPT مطالعات پرامپتی عمدتاً از خدمات LogBERT از AIOps معمولاً آموزش یا ترکیب چندمدلی دارند [۴، ۷، ۱۰]. مطالعه محلی Mistral و در Ollama با وزن ثابت روی Qwen۲،۵:۷B-Instruct آموزش‌دیده بهره می‌گیرد [۲۰]. ارزیابی شکاف استقرار موردنظر این پژوهش است [۲۸، ۲۹] BGL طبقه‌بندی خطبه‌خط

صورت‌بندی جایگاه پژوهش ۲-۵-۶

و تصمیم خط‌محور؛ نرمال‌سازی حساس به معنا؛ BGL: جایگاه پژوهش از ترکیب پنج جزء تشکیل می‌شود و Prompt-only با Hybrid اعتبارسنجی‌شده؛ و مقایسه JSON کش نسخه‌بندی‌شده در سطح قالب؛ خروجی در شرایط ثابت. این صورت‌بندی ادعای پیشینی درباره برتری روش‌ها ندارد و نتیجه باید از اجرای کامل هر دو روش روی پروتکل یکسان حاصل شود.

جمع‌بندی ۲-۶

تجزیه و نرمال‌سازی، پارادایم‌های یادگیری، BGL، در این فصل مفاهیم ساختار لاگ، سطوح ناهنجاری و معیارهای Ollama، پرامپت، بازیابی، کش Qwen۲،۵، LLM نقش Transformer مدل‌های ترتیبی و ارزیابی تعریف شد. سپس هر ۲۷ مقاله موجود در پوشه پژوهش به‌صورت مستقل مرور و در جدول مقایسه درج گردید.

پرامپت، LLM مرور مطالعات نشان داد ادبیات از مدل‌سازی توالی به مدل‌های زبانی پیش‌آموزش‌دیده، تنظیم و چارچوب‌های چندمدلی گسترش یافته است. در عین حال، تفاوت واحد تحلیل، آموزش، نمونه‌گیری RAG محل استقرار و کنترل هزینه سبب می‌شود نتایج عددی تنها در پروتکل‌های همسان مقایسه شوند. با دانش قاعده درون پرامپت LLM قطعی خارج از guard شکاف استخراج‌شده، مقایسه مستقیم و کنترل‌شده خط‌محور است. فصل بعد باید BGL محلی، کش سطح قالب و خروجی اعتبارسنجی‌شده در Qwen همراه با اجرای دو روش و Ollama معماری نرم‌افزار، قواعد نرمال‌سازی، متن پرامپت‌ها، کلید کش، تنظیمات محاسبه معیارها را به‌صورت عملیاتی تشریح کند.

منابع فصل دوم ۲-۷

- [۱] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies. ۲۰۲۳.
- [۲] Qi, J.; Huang, S.; Luan, Z.; Fung, C.; Yang, H.; Qian, D. LogGPT: Exploring ChatGPT for Log-Based Anomaly Detection. ۲۰۲۳.
- [۳] Park, J.; Choi, E.; Lee, J. Hybrid Prompting for LLM-based Log Anomaly Detection. Journal of KIISE, ۵۲(۱۲), ۲۰۲۵. DOI: ۱۰.۵۶۲۶/JOK.۲۰۲۵.۵۲.۱۲.۱۰۶۷.
- [۴] Guan, W.; Cao, J.; Qian, S.; Gao, J.; Ouyang, C. LogLLM: Log-based Anomaly Detection Using Large Language Models. ۲۰۲۴.
- [۵] Han, X.; Yuan, S.; Trabelsi, M. LogGPT: Log Anomaly Detection via GPT. ۲۰۲۳.
- [۶] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Prompt Engineering Towards Zero-Shot and Interpretable Log Analysis. ۲۰۲۴.
- [۷] Zhang, Z.; Li, S.; Zhang, L.; Ye, J.; Hu, C.; Yan, L. LLM-LADE: Large language model-based log anomaly detection with explanation. Knowledge-Based Systems, ۳۲۶, Article ۱۱۴۰۶۴, ۲۰۲۵.
- [۸] Almodovar, C.; Sabrina, F.; Karimi, S.; Azad, S. LogFiT: Log Anomaly Detection using Fine-Tuned Language Models. ۲۰۲۵.

- [⁹] Lim, Y. F.; Zhu, J.; Pang, G. Adapting Large Language Models for Parameter-Efficient Log Anomaly Detection. 2020.
- [¹⁰] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. LLM meets ML: Data-efficient Anomaly Detection on Unstable Logs. 2024–2020.
- [¹¹] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. Anomaly Detection on Unstable Logs with GPT Models. 2024.
- [¹²] Pan, J.; Wong, S. L.; Yuan, Y. RAGLog: Log Anomaly Detection using Retrieval Augmented Generation. 2023–2024.
- [¹³] Ma, L.; Yang, W.; Li, Y.; Fei, B.; Zhou, M.; Li, S.; Jiang, S.; Xu, B.; Xiao, Y. AdaptiveLog: An Adaptive Log Analysis Framework with the Collaboration of Large and Small Language Model. arXiv:2001.11031, 2020.
- [¹⁴] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. AIOps for log anomaly detection in the era of LLMs: A systematic literature review. Intelligent Systems with Applications, 28, Article 200608, 2020.
- [¹⁵] Sui, Y.; Wang, X.; Cui, T.; Xiao, T.; He, C.; Zhang, S.; Zhang, Y.; Yang, X.; Sun, Y.; Pei, D. Bridging the Gap: LLM-Powered Transfer Learning for Log Anomaly Detection in New Software Systems. 2020.
- [¹⁶] Sun, Y.; Keung, J. W.; Yang, Z.; Liu, S.; Yu, H. K. SemiRALD: A semi-supervised hybrid language model for robust Anomalous Log Detection. Information and Software Technology, 183, 107743, 2020. DOI: 10.1016/j.infsof.2020.107743.
- [¹⁷] Gao, Y.; Luo, T.; Huang, K.; Tang, J.; Li, X. LogLAA: an adaptive integrated log anomaly analysis framework. Cybersecurity, 9:141, 2026. DOI: 10.1186/s42400-026-00573-8.
- [¹⁸] Chen, S.; Liao, H. BERT-Log: Anomaly Detection for System Logs Based on Pre-trained Language Model. Applied Artificial Intelligence, 36(1), 2022. DOI: 10.1080/08839014.2022.2140642.
- [¹⁹] Guo, H.; Yuan, S.; Wu, X. LogBERT: Log Anomaly Detection via BERT. arXiv:2103.04470, 2021.
- [²⁰] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. Log anomaly detection in AIOps: A real-world implementation using Large Language Models. Systems and Soft Computing, 8, Article 200470, 2026.
- [²¹] Du, M.; Li, F.; Zheng, G.; Srikumar, V. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. ACM CCS, 2017. DOI: 10.1145/3133906.3134010.
- [²²] Pospieszny, P.; Mormul, W.; Szyndler, K.; Kumar, S. ADALog: Adaptive Unsupervised Anomaly Detection in Logs with Self-attention Masked Language Model. arXiv:2005.13496, 2020.
- [²³] Zhong, A.; Mo, D.; Liu, G.; Liu, J.; Lu, Q.; Zhou, Q.; Wu, J.; Li, Q.; Wen, Q. LogParser-LLM: Advancing Efficient Log Parsing with Large Language Models. arXiv:2408.13727, 2024.
- [²⁴] Le, V.-H.; Zhang, H. Log Parsing with Prompt-based Few-shot Learning. arXiv:2302.07430, 2023.
- [²⁵] Liu, Y.; Pei, C.; Xu, L.; et al. OpsEval: A Comprehensive Benchmark Suite for Evaluating Large Language Models' Capability in IT Operations Domain. FSE Companion, 2020. DOI: 10.1145/3696630.3728872.
- [²⁶] Zhu, Y.; Zhou, K.; Mao, K.; et al. YuLan: An Open-source Large Language Model. arXiv:2406.19803, 2024.
- [²⁷] Xu, R.; Ding, K. Large Language Models for Anomaly and Out-of-Distribution Detection: A Survey. arXiv:2409.01980, 2020.
- [²⁸] Qwen Team. Qwen2.0 Technical Report. arXiv:2412.15110, 2024.
- [²⁹] Ollama. API Introduction; Structured Outputs; Usage Metrics. Official documentation. Accessed 14 August 2026.