

سید علی



بایاری از خداوند بجان و اعتقاد به این که عالم محضر خداست و بهاره ناظر بر اعمال انسان و به منظور پاس داشت مقام بلند دانش و پژوهش و نظریه ایست جایگاه دانشگاه در اعتلای فرهنگ و تمدن بشری، مادران و دانشمندان و

اعضای هیأت علمی و اعضای دانشگاه آزاد اسلامی متعهد می گردیم اصول زیر را در انجام فعالیت های پژوهشی مد نظر قرار داده و از آن تخطی نکنیم:

۱- اصل حقیقت جویی: تلاش در راستای پی جویی حقیقت و وفاداری به آن و دوری از هرگونه پنهان سازی حقیقت.

۲- اصل رعایت حقوق: التزام به رعایت کامل حقوق پژوهشگران و پژوهیدگان (انسان، حیوان و نبات) و سایر صاحبان حق.

۳- اصل مالکیت مادی و معنوی: تعهد به رعایت کامل حقوق مادی و معنوی دانشگاه و کلیه بهکاران پژوهش.

۴- اصل منافع ملی: تعهد به رعایت مصالح ملی و در نظر داشتن پیشبرد و توسعه کشور در کلیه مراحل پژوهش.

۵- اصل رعایت انصاف و امانت: تعهد به اجتناب از هرگونه جانب داری غیر علمی و حفاظت از اموال، تجهیزات و منابع در اختیار.

۶- اصل رازداری: تعهد به صیانت از اسرار و اطلاعات محرمانه افراد، سازمان ها و کشور و کلیه افراد و نهادهای مرتبط با تحقیق.

۷- اصل احترام: تعهد به رعایت حریم ها و حرمت ها در انجام تحقیقات و رعایت جانب تقد و خودداری از هرگونه حرمت شکنی.

۸- اصل ترویج: تعهد به رواج دانش و اشاعه نتایج تحقیقات و انتقال آن به بهکاران علمی و دانشمندان به غیر از مواردی که منع قانونی دارد.

۹- اصل برانست: التزام به برانست جویی از هرگونه رفتار غیر حرفه ای و اعلام موضع نسبت به کسانی که حوزه علم و پژوهش را به شبهه های غیر علمی می آلائند.



دانشگاه آزاد اسلامی

واحد علوم و تحقیقات (تهران)

تعهذنامه اصالت رساله یا پایان‌نامه تحصیلی

اینجانب مسعود دباغی دانش‌آموخته مقطع کارشناسی ارشد در رشته مهندسی کامپیوتر گرایش نرم افزار که در تاریخ ۱۴۰۵/۰۱/۰۱ از پایان‌نامه/رساله خود تحت عنوان بهبود تشخیص ناهنجاری‌ها در لاگ‌های سیستمی مبتنی بر مدل‌های زبانی بزرگ با بهره‌گیری از مهندسی پرامپت با کسب نمره ۰۰ و درجه ۰۰ دفاع نموده‌ام بدینوسیله متعهد می‌شوم:

- (۱) این پایان‌نامه / رساله حاصل تحقیق و پژوهش انجام شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران (اعم از پایان‌نامه، کتاب، مقاله و ...) استفاده نموده‌ام، مطابق ضوابط و رویه موجود، نام منبع مورد استفاده و سایر مشخصات آنرا در فهرست مربوطه ذکر و درج کرده‌ام.
- (۲) این پایان‌نامه / رساله قبلاً برای دریافت هیچ مدرک تحصیلی (هم‌سطح، پایین‌تر یا بالاتر) در سایر دانشگاهها و مؤسسات آموزش عالی ارائه نشده است.
- (۳) چنانچه بعد از فراغت از تحصیل، قصد استفاده و هر گونه بهره‌برداری اعم از چاپ کتاب، ثبت اختراع و ... از این پایان‌نامه یا رساله داشته باشم، از حوزه معاونت پژوهشی واحد مجوزهای مربوطه را اخذ نمایم.
- (۴) چنانچه در هر مقطع زمانی خلاف موارد فوق ثابت شود، عواقب ناشی از آن را می‌پذیرم و دانشگاه آزاد اسلامی واحد علوم و تحقیقات مجاز است با اینجانب مطابق ضوابط و مقررات رفتار نموده و در صورت ابطال مدرک تحصیلی‌ام هیچگونه ادعایی نخواهم داشت.

نام و نام خانوادگی: مسعود دباغی

تاریخ و امضاء



دانشگاه آزاد اسلامی
واحد علوم و تحقیقات (تهران)
دانشکده برق و کامپیوتر، گروه نرم افزار

پایان نامه برای دریافت درجه ی کارشناسی ارشد در رشته کامپیوتر (M.Sc)
گرایش نرم افزار

عنوان:

بهبود تشخیص ناهنجاری ها در لاگ های سیستمی مبتنی بر مدل های زبانی بزرگ با بهره گیری از مهندسی پرآمپت

استاد راهنما:

دکتر محمدرضا علی زاده

نگارش :

مسعود دباغی

تابستان ۱۴۰۵

بر خود لازم می‌دانم مراتب سپاس و قدردانی صمیمانه خود را از استاد ارجمند، جناب آقای دکتر محمدرضا علی‌زاده، استاد راهنمای محترم، ابراز نمایم.

راهنمایی‌های علمی و ارزشمند، دقت نظر، صبوری و حمایت‌های دلسوزانه ایشان در تمامی مراحل انجام این پژوهش، نقشی اساسی در شکل‌گیری و به سرانجام رسیدن این پایان‌نامه داشته است.

بی‌تردید، بهره‌مندی از دانش و تجربیات گران‌قدر ایشان، از ارزشمندترین بخش‌های این مسیر علمی برای من بوده است. بدین‌وسیله از تمامی زحمات، همراهی‌ها و راهنمایی‌های ایشان صمیمانه سپاسگزاری می‌نمایم.

تقدیم به

پدر و مادر عزیزم؛

آنان که با مهر بی پایان، صبوری و فداکاری‌های بی دریغشان، همواره استوارترین تکیه‌گاه و روشن‌ترین چراغ مسیر زندگی من بوده‌اند.

این پایان‌نامه را به پاس تمام محبت‌ها، رنج‌ها و حمایت‌های همیشگی‌شان، با نهایت عشق، احترام و قدردانی تقدیم می‌کنم.

فهرست مطالب

مقدمه ۲-۱.....	۹
مبانی نظری و مفاهیم موردنیاز ۲-۲.....	۱۰
لاگ سیستمی و تشخیص ناهنجاری ۲-۲-۱.....	۱۰
انواع ناهنجاری و واحد تحلیل ۲-۲-۲.....	۱۰
BGL مجموعه داده ۲-۲-۳.....	۱۰
تجزیه، نرمال سازی و قالب لاگ ۲-۲-۴.....	۱۱
روش های قاعده محور، یادگیری ماشین و مدل های ترتیبی ۲-۲-۵.....	۱۱
مدل های زبانی پیش آموزش دیده و مدل های زبانی بزرگ ۲-۲-۶.....	۱۱
مدل Qwen۲,۵:۷B-Instruct ۲-۲-۷.....	۱۲
مهندسی پرامپت و خروجی ساخت یافته ۲-۲-۸.....	۱۲
Ollama استنتاج محلی با ۲-۲-۹.....	۱۲
کش سطح قالب و اعتبارسنجی تصمیم ۲-۲-۱۰.....	۱۳
Hybrid و Prompt-only دو معماری ۲-۲-۱۱.....	۱۳
معیارهای ارزیابی ۲-۲-۱۲.....	۱۳
پیشینه تحقیق ۲-۳.....	۱۴
روش های ترتیبی و پیش آموزش دیده ۲-۳-۱.....	۱۴
LLM روش های مبتنی بر آموزش یا تنظیم ۲-۳-۲.....	۱۴
روش های مبتنی بر پرامپت ۲-۳-۳.....	۱۵
بازیابی، روش های ترکیبی و کاهش هزینه ۲-۳-۴.....	۱۵
تجزیه، انتقال، تبیین و کاربرد عملی ۲-۳-۵.....	۱۶
دسته بندی، جدول مقایسه و تحلیل ۲-۴.....	۱۶
شکاف تحقیقاتی و جایگاه پژوهش حاضر ۲-۵.....	۱۹
جمع بندی ۲-۶.....	۱۹
منابع فصل دوم ۲-۷.....	۲۰

.....مقدمه ۱-۱	Error! Bookmark not defined.
.....بیان مسئله ۱-۲	Error! Bookmark not defined.
.....اهمیت و ضرورت انجام پژوهش ۱-۳	Error! Bookmark not defined.
.....اهداف مشخص پژوهش ۱-۴	Error! Bookmark not defined.
.....سؤال‌ها و فرضیه‌های پژوهش ۱-۵	Error! Bookmark not defined.
.....سؤال‌های پژوهش	Error! Bookmark not defined.
.....فرضیه‌های پژوهش	Error! Bookmark not defined.
.....فصل دوم: مروری بر ادبیات و پیشینه تحقیق	Error! Bookmark not defined.

مقدمه ۲-۱

لاگ‌های سیستمی ردپای رخدادهای زمان اجرا، وضعیت اجزا و پیام‌های خطا را ثبت می‌کنند و از این‌رو یکی از ورودی‌های اصلی پایش، عیب‌یابی و تشخیص ناهنجاری در سامانه‌های نرم‌افزاری به‌شمار می‌روند. افزایش حجم و تنوع لاگ‌ها، بررسی دستی را دشوار کرده و پژوهش‌ها را از قواعد و شمارش رخدادها به‌سوی مدل‌های ترتیبی، مدل‌های زبانی پیش‌آموزش‌دیده و در سال‌های اخیر مدل‌های زبانی بزرگ سوق داده است [۱، ۲، ۲۲].

در روش‌های مبتنی بر یادگیری عمیق، توالی قالب‌های لاگ یا بازنمایی متنی پیام‌ها برای یادگیری الگوی با دو وظیفه خودنظارتی و LogBERT، با پیش‌بینی رخداد بعدی DeepLog. رفتار عادی استفاده می‌شود — برای طبقه‌بندی، سه مسیر شاخص این تحول را نشان می‌دهند [۱] BERT با تنظیم یک مدل BERT-Log، این روش‌ها توانایی مدل‌سازی الگو را افزایش داده‌اند، اما معمولاً به آموزش اختصاصی، ساخت توالی [۳]. تجزیه لاگ یا داده برچسب‌خورده وابسته‌اند [۲، ۳، ۲۲]

مدل‌های زبانی بزرگ مسیر دیگری را فراهم کرده‌اند: انجام تشخیص از طریق دستور متنی، نمونه‌های LogPrompt، LogGPT، درون‌متنی، بازیابی شواهد، تنظیم کامل یا تنظیم پارامترکارا. مطالعات نشان می‌دهند که نقش مدل زبانی FlexLog و AdaptiveLog، LLM-LADE، LogLLM، RAGLog، می‌تواند از طبقه‌بند مستقیم تا مفسر، تولیدکننده داده، جزء کمکی یا تصمیم‌گیر پشتیبان تغییر کند [۴-۸، ۱۰]. بنابراین مقایسه پژوهش‌ها تنها با نام مدل کافی نیست و باید نوع آموزش، واحد تحلیل، شیوه [۱۵، ۱۲]. آماده‌سازی ورودی، محل استقرار و سازوکار کنترل هزینه نیز در نظر گرفته شود [۲۲، ۲۴]

Qwen۲,۵:۷B- با BGL فصل حاضر مبانی موردنیاز برای پژوهش تشخیص ناهنجاری در لاگ‌های را ارائه می‌کند. سپس پیشینه در پنج دسته مرور و با جدول و شکل مقایسه می‌شود. در Ollama و Instruct و Hybrid پایان، شکاف تحقیقاتی با اتکا به مجموعه منابع بررسی‌شده و جایگاه دو روش مورد مطالعه، یعنی در موارد LLM در این پژوهش به «قاعده قطعی با فراخوانی Hybrid تبیین می‌شود. واژه Prompt-only در مطالعه پارک و همکاران، که ترکیبی از شواهد Hybrid Prompting باقیمانده» اشاره دارد و با اصطلاح سطح رخداد و توالی را در پرامپت قرار می‌دهد، یکسان نیست [۹]

مبانی نظری و مفاهیم موردنیاز ۲-۲

لاگ سیستمی و تشخیص ناهنجاری ۲-۲-۱

هر پیام لاگ معمولاً از سرآیندی مانند زمان، سطح شدت و مؤلفه تولیدکننده و یک بدنه متنی تشکیل می‌شود. در بدنه، بخش‌های ثابت بیانگر رخداد برنامه و بخش‌های متغیر شامل شناسه‌ها، نشانی‌ها، مسیرها، مقادیر فرایند تبدیل پیام LogParser-LLM و LogPPT عددی و سایر پارامترهای زمان اجرا هستند. پژوهش‌های خام به قالب ثابت و پارامترهای متغیر را «تجزیه لاگ» تعریف می‌کنند و نشان می‌دهند که کیفیت این مرحله بر تحلیل‌های پایین‌دستی، از جمله تشخیص ناهنجاری، اثر می‌گذارد [۱۹، ۱۸].

در ادبیات، ناهنجاری به انحراف مشاهده از الگوی عادی آموخته‌شده یا تعریف‌شده اطلاق می‌شود. این انحراف و DeepLog می‌تواند در یک پیام منفرد، فراوانی رخدادها، ترتیب قالب‌ها یا معنای یک توالی ظاهر شود. هر پیام ساخت‌نیافته را ADALog بر انحراف توالی از رفتار عادی تمرکز دارند؛ در مقابل LogBERT مستقل تحلیل و احتمال بازسازی توکن‌ها را به امتیاز سطح پیام تبدیل می‌کند [۱۷، ۲، ۱]. این تفاوت، واحد تحلیل و در نتیجه نحوه ساخت نمونه آزمایشی را تعیین می‌کند.

انواع ناهنجاری و واحد تحلیل ۲-۲-۲

سه سطح رایج در پژوهش‌های لاگ قابل تفکیک است: ناهنجاری رخداد یا خط، ناهنجاری توالی و ناهنجاری کمی. در سطح خط، هر پیام یک نمونه تصمیم است و برچسب به همان پیام تعلق دارد. در سطح توالی، پیام‌ها بر اساس شناسه نشست، گره یا پنجره زمانی گروه‌بندی می‌شوند و وجود یک رخداد غیر عادی می‌تواند برچسب کل توالی را تعیین کند. در ناهنجاری کمی، تغییر غیر عادی فراوانی قالب‌ها در پنجره موردنظر بررسی می‌شود [۱-۳، ۲۲].

از پنجره لغزان BGL در BERT-Log، واحد تحلیل بر قابلیت مقایسه نتایج اثر مستقیم دارد. برای نمونه توالی‌های یک‌دقیقه‌ای Hybrid Prompting مبتنی بر شناسه گره، اندازه پنجره و گام استفاده کرده است؛ تصمیم را برای یک پیام مستقل گزارش می‌کند [۱۷، ۹، ۳]. از این‌رو اعداد دقت یا ADALog می‌سازد؛ اما مطالعاتی که خط، نشست یا پنجره زمانی را نمونه می‌گیرند بدون همسان‌سازی پروتکل ارزیابی قابل F1 مقایسه مستقیم نیستند.

BGL مجموعه داده ۲-۲-۳

در آزمایشگاه ملی لارنس Blue Gene/L از لاگ‌های ابررایانه BGL یا Blue Gene/L مجموعه داده لیورمور تهیه شده است. در این مجموعه ۴,۷۴۷,۹۶۳ پیام لاگ وجود دارد که ۳۴۸,۴۶۰ پیام، معادل حدود درصد، با برچسب هشدار به‌عنوان ناهنجار مشخص شده‌اند [۶، ۲]. وجود برچسب در ابتدای هر خط ۷,۳۴ امکان ارزیابی نظارت‌شده را فراهم می‌کند، اما آن برچسب باید پیش از ارسال متن به مدل حذف شود تا نشست پاسخ به ورودی رخ ندهد.

پنجره زمانی پنج‌دقیقه‌ای با LogBERT را با پروتکل‌های متفاوت به‌کار گرفته‌اند BGL مطالعات مختلف Hybrid از پنجره مبتنی بر گره استفاده کرده و BERT-Log میانگین طول ۵۶۲ رخداد ساخته است؛ پنجره یک‌دقیقه‌ای و نمونه متوازن از هزار توالی عادی و هزار توالی ناهنجار را ارزیابی کرده Prompting است [۹، ۳، ۲]. در پژوهش حاضر، مسئله در سطح خط تعریف می‌شود؛ بنابراین برچسب مرجع هر خط فقط حذف می‌شود Qwen برای ارزیابی نگهداری و از ورودی

۲-۲-۴ تجزیه، نرمال‌سازی و قالب لاگ

هدف تجزیه لاگ جداکردن کلمات ثابت قالب از پارامترهای متغیر است. روش‌های سنتی از فراوانی، شباهت با پرامپت‌تیونینگ و تعداد کمی نمونه برجسب‌خورده، و LogPPT یا قواعد نحوی استفاده می‌کنند؛ معنا را نیز وارد فرایند استخراج، LLM با ترکیب درخت پیشوند و فراخوانی محدود LogParser-LLM با میانگین ۳،۶ میلیون لاگ در هر LogPub در ارزیابی LogParser-LLM. قالب کرده‌اند [۱۸، ۱۹] گروه‌بندی ۹۰،۶ درصد و دقت تجزیه ۸۱،۱ درصد F1، LLM مجموعه، به‌طور متوسط با ۲۷۲،۵ فراخوانی گزارش کرده است [۱۸]

نرمال‌سازی در این پژوهش یک تجزیه کامل مبتنی بر خوشه‌بندی نیست؛ بلکه تبدیل قطعی مقادیر پویا به مقادیر هگزادسیمال، IP، جانشین‌های پایدار برای ساخت قالب نرمال‌شده است. شناسه گره، واحدها، نشانی تاریخ و زمان، مسیرها و اعداد پویا ماسک می‌شوند. با این حال صفر و غیرصفر با دو جانشین متمایز نگه داشته می‌شوند، زیرا برخی پیام‌های عملیاتی تفاوت معنایی خود را از <NON_ZERO> و <ZERO> همین وضعیت عددی می‌گیرند. این طراحی با اصل جداسازی قالب و پارامتر در مطالعات تجزیه لاگ سازگار است، اما قاعده جانشینی آن به‌طور مشخص برای خط‌لوله این پژوهش تعریف شده است [۱۸، ۱۹]

یک نتیجه عملی نرمال‌سازی، کاهش تنوع ظاهری پیام‌هایی است که یک رخداد واحد را با شناسه یا عدد متفاوت بیان می‌کنند. در نتیجه، تصمیم سطح قالب می‌تواند میان خطوط هم‌معنا بازاستفاده شود. در این حالت دقت نرمال‌سازی اهمیت دارد: ماسک بیش‌ازحد ممکن است نشانه معنایی را حذف کند و ماسک کم نیز تعداد نیز LogLAA و LogParser-LLM، LogPPT قالب‌ها و فراخوانی مدل را افزایش می‌دهد. مطالعات حساسیت تحلیل پایین‌دستی به کیفیت آماده‌سازی و تجزیه را گزارش کرده‌اند [۱۸، ۱۹، ۲۱]

۲-۲-۵ روش‌های قاعده‌محور، یادگیری ماشین و مدل‌های ترتیبی

روش‌های قاعده‌محور الگوهای از پیش تعریف‌شده را با واژه کلیدی یا عبارت منظم تطبیق می‌دهند. مزیت آن‌ها تصمیم سریع و قابل ردیابی برای الگوهای شناخته‌شده است، ولی دامنه کشف به قواعد نوشته‌شده محدود می‌شود و نگهداری قواعد در برابر تغییر قالب‌ها هزینه‌بر است [۲۲، ۲۳]. روش‌های کلاسیک یادگیری ماشین ماشین بردار پشتیبان، PCA پس از استخراج بردار فراوانی یا ویژگی‌های آماری، از الگوریتم‌هایی مانند تک‌کلاسه یا درخت تصمیم برای تشخیص انحراف استفاده می‌کنند [۱۰، ۱۱]

رخداد بعدی را از رخدادهای قبلی پیش‌بینی LSTM لاگ را همانند توالی زبان مدل‌سازی و با DeepLog می‌کند؛ رخدادی که در مجموعه پیش‌بینی‌های محتمل قرار نگیرد ناهنجار تلقی می‌شود. این روش آموزش LogBERT، افزایشی و یک جریان تشخیص و عیب‌یابی را نیز ارائه می‌کند [۱]. روش‌های بعدی مانند وابستگی دوطرفه و وظایف خودنظارتی را جایگزین اتکای صرف به پیش‌بینی رخداد بعدی کرده‌اند [۲]. این خانواده برای ناهنجاری‌های ترتیبی مناسب است، اما به تعریف توالی و آموزش روی داده سامانه وابستگی دارد.

۲-۲-۶ مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ

بازنمایی زمینه‌مند واژه‌ها را از متن فرا می‌گیرند و سپس برای وظیفه BERT مدل‌های پیش‌آموزش‌دیده مانند دو وظیفه «پیش‌بینی کلید ماسک‌شده» و «کمینه‌سازی حجم ابرکره» را بر LogBERT. خاص تنظیم می‌شوند و یک لایه تمام‌متصل را برای طبقه‌بندی BERT مدل BERT-Log. توالی‌های عادی به‌کار می‌گیرد [۲] نیز LogFiT. گزارش کرده است [۳] BGL برابر ۹۹،۴ درصد را برای F1 تنظیم کرده و در پروتکل خود با مدل‌سازی توکن ماسک‌شده، فقط از لاگ‌های عادی برای یادگیری استفاده می‌کند [۱۳]

با ظرفیت زیاد و پیش‌آموزی گسترده است که می‌تواند Transformer مدل زبانی بزرگ معمولاً یک مدل دستور متنی را دنبال و خروجی تولید کند. در حوزه تشخیص ناهنجاری، این مدل ممکن است مستقیماً نقش آشکارساز داشته باشد یا برای تولید داده، تبیین و پشتیبانی از مدل کوچک‌تر استفاده شود؛ این دو نقش در «برای تولید» نامگذاری شده‌اند [۲۴] LLM «برای تشخیص» و LLM «به‌ترتیب Ding و Xu رده‌بندی مرور و همکاران نیز روش‌های لاگ را براساس آماده‌سازی، بازنمایی، مدل De la Cruz Cabello مرور نظام‌مند و شیوه ارزیابی دسته‌بندی می‌کند [۲۲]

۲-۲-۷ مدل Qwen۲,۵:B-Instruct

خانواده‌ای از مدل‌های متن‌باز با نسخه‌های پایه و دستورمحور در اندازه‌های ۰٫۵ تا ۷۲ میلیارد Qwen۲,۵ پارامتر است. گزارش فنی این خانواده، پیش‌آموزی بر ۱۸ تریلیون توکن و پس‌آموزی با بیش از یک میلیون در این گزارش حدود ۶٫۵ میلیارد نمونه تنظیم دستوری و مراحل تقویت یادگیری را شرح می‌دهد. نسخه ۷ برای پیروی از دستور و تولید پاسخ ساخت‌یافته بهینه شده است Instruct پارامتر غیرتعبيه‌ای دارد و نسخه [۲۵].

به‌صورت محلی و بدون تنظیم دقیق برای طبقه‌بندی دودویی هر Qwen۲,۵:B-Instruct در این پژوهش قالب نرمال‌شده استفاده می‌شود. نبود تنظیم اختصاصی باعث می‌شود تفاوت دو روش آزمایش‌شده به معماری تصمیم و متن پرامپت مربوط باشد، نه تغییر وزن‌های مدل. انتخاب یک مدل و یک نسخه پرامپت ثابت برای است Prompt-only یا Hybrid هر دو روش، شرط لازم برای نسبت‌دادن اختلاف نتایج به سازوکار

۲-۲-۸ مهندسی پرامپت و خروجی ساخت‌یافته

پرامپت مجموعه دستورها، زمینه دامنه، تعریف برجسب‌ها و قالب خروجی است که رفتار مدل را در زمان اثر نوع پرامپت، اندازه پنجره و تزریق دانش انسانی ChatGPT مبتنی بر LogGPT. استنتاج هدایت می‌کند از راهبردهای چندمرحله‌ای و درخواست LogPrompt. بررسی کرده است [۶] Spirit و BGL را روی تبیین برای تجزیه و تشخیص ناهنجاری استفاده می‌کند و بدون آموزش درون‌دامنه روی چند مجموعه لاگ نیز حساسیت وظایف عملیات فناوری اطلاعات به پرامپت، زنجیره فکر و OpsEval. ارزیابی شده است [۷] یادگیری درون‌متنی را در سطح معیار ارزیابی بررسی می‌کند [۲۳]

برای طبقه‌بندی خودکار، خروجی باید از متن آزاد به قرارداد ماشین‌خوان تبدیل شود. قرارداد این پژوهش فقط برای ناهنجار را می‌پذیرد {"label": "۱"} برای عادی و {"label": "۰"} یعنی JSON یکی از دو شیء ثبت می‌شود و وارد کش INVALID ناقص با وضعیت JSON پاسخ دارای متن اضافی، برجسب نامعتبر یا و کاهش JSON امکان درخواست خروجی ساخت‌یافته با قالب یا طرح Ollama نمی‌گردد. مستندات رسمی تصادفی‌بودن با دمای صفر را بیان می‌کند [۲۶]. اعتبارسنجی مستقل پاسخ همچنان لازم است، زیرا قرارداد خروجی بخشی از پروتکل آزمایش و محاسبه نرخ پاسخ نامعتبر است

۲-۲-۹ Ollama استنتاج محلی با

پیش‌فرض API فراهم می‌کند API یک واسط محلی برای اجرای مدل و فراخوانی آن از طریق Ollama در دسترس است و پاسخ‌های آن علاوه بر محتوای مدل، شاخص‌های زمان localhost:۱۱۴۳۴/api در نشانی اجرا و شمار توکن را نیز گزارش می‌کنند [۲۶]. استنتاج محلی مانع ارسال لاگ به خدمت خارجی می‌شود و و De la Cruz Cabello کنترل نسخه مدل و پارامترهای اجرا را ممکن می‌سازد؛ مطالعه کاربرد واقعی را برای محیط دارای محدودیت محرمانگی به‌کار گرفته است LogBERT همکاران نیز استقرار محلی مدل [۲۷].

استنتاج محلی به معنی نبود هزینه محاسباتی نیست. زمان بارگذاری مدل، زمان ارزیابی پرامپت و زمان تولید فیلدهای Ollama پاسخ باید ثبت شوند و فراخوانی تکراری برای پیام‌های هم‌قالب کاهش یابد. مستندات total_duration، load_duration، prompt_eval_count، prompt_eval_duration، eval_count را برای اندازه‌گیری این اجزا معرفی می‌کند [۲۶]. این داده‌ها در کنار زمان انتهایی‌های eval_duration و برنامه، مبنای تحلیل کارایی قرار می‌گیرند.

۲-۲-۱۰ کش سطح قالب و اعتبارسنجی تصمیم

از کش و LLM برای کاهش فراخوانی FlexLog. کش نگاشت یک کلید پایدار به تصمیم معتبر قبلی است با واگذاری نمونه‌های مطمئن به مدل کوچک‌تر، تعداد فراخوانی AdaptiveLog بازیابی استفاده می‌کند و نیز با تجمع الگوها در درخت LogParser-LLM. مدل بزرگ را تا ۷۳ درصد کاهش داده است [۱۰، ۱۲] برای پیام‌های مشابه جلوگیری می‌کند [۱۸]. این مطالعات نشان می‌دهند LLM پیشوند از تکرار فراخوانی کنترل هزینه استنتاج بخشی مستقل از کیفیت طبقه‌بندی است.

در پژوهش حاضر کلید کش از نسخه پرامپت، نام و نسخه مدل، قالب نرمال‌شده و در صورت فعال بودن مؤلفه، سطح شدت و دسته پیام ساخته می‌شود. بنابراین با تغییر پرامپت یا مدل، تصمیم قبلی به اشتباه باز استفاده خطای ارتباط یا پاسخ ناقص در کش قرار INVALID نمی‌شود. فقط پاسخ معتبر ۰ یا ۱ ذخیره می‌شود؛ نمی‌گیرد. نرخ برخورد کش، نرخ عدم برخورد و تعداد کلیدهای یکتا همراه با منبع تصمیم ثبت می‌شود تا اثر کش از اثر مدل و قواعد جدا شود.

۲-۲-۱۱ Prompt-only و Hybrid دو معماری

این پژوهش، خط پس از استخراج فیلدها و نرمال‌سازی ابتدا در کش جست‌وجو می‌شود Hybrid در معماری در نبود تصمیم کش‌شده، مجموعه‌ای محدود از قواعد قطعی و با اطمینان بالا بررسی می‌گردد. اگر هیچ ارسال و پاسخ پس از اعتبارسنجی ذخیره می‌شود. منبع هر تصمیم Qwen قاعده‌ای تصمیم ندهد، قالب به یک آبشار تصمیم است و هدف آن سنجش Hybrid ثبت می‌شود. در نتیجه llm یا cache، guard به صورت است LLM اثر قاعده قطعی پیش از

guard همان نرمال‌سازی، کلید کش، مدل و قرارداد خروجی حفظ می‌شود، اما Prompt-only در معماری برای هر قالب فاقد Qwen قطعی غیرفعال است. دانش دامنه و قواعد تشخیص در متن پرامپت بیان می‌شوند و کش تصمیم می‌گیرد. مقایسه منصفانه مستلزم ثابت ماندن مجموعه داده، ترتیب ورودی، نسخه مدل، گزینه‌های آن است که Hybrid Prompting نرمال‌سازی و سیاست اعتبارسنجی است. تفاوت این تعریف با Ollama، روش پارک و همکاران شواهد سطح رخداد، شباهت توالی و نمونه عادی مشابه را در یک پرامپت ترکیب می‌کند و طبقه‌بندی آن در سطح توالی است [۹].

۲-۲-۱۲ معیارهای ارزیابی

خطوط FP، تعداد خطوط عادی درست TN، تعداد ناهنجاری‌های درست کشف‌شده TP، برای مسئله دودویی ناهنجاری‌های از دست‌رفته است. دقت کل نسبت همه تصمیم‌های درست به FN عادی با برچسب ناهنجار و سهم Recall تشخیص‌های ناهنجار درست از همه پیش‌بینی‌های ناهنجار؛ Precision کل نمونه‌هاست؛ است Recall و Precision میانگین هارمونیک F۱ ناهنجاری‌های کشف‌شده از همه ناهنجاری‌های واقعی؛ و [۹، ۳].

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP) \quad \text{Recall} = TP / (TP + FN) \quad F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

گزارش شوند. افزون Accuracy باید در کنار Recall، Precision، F1، BGL به دلیل نامتوازن بودن منبع تصمیم و آمار برخورد کش LLM، زمان پاسخ، تعداد فراخوانی، INVALID بر این چهار معیار، نرخ برای مقایسه دو معماری ضروری است. گزارش این شاخص‌ها کمک می‌کند افزایش سرعت ناشی از کش یا با کیفیت طبقه‌بندی اشتباه نشود guard

پیشینه تحقیق ۲-۳

روش‌های ترتیبی و پیش‌آموزش‌دیده ۲-۳-۱

برای یادگیری توالی رخدادهای عادی، تشخیص LSTM را به‌عنوان یک مدل DeepLog و همکاران و دو هدف BERT از LogBERT و همکاران در Guo. انحراف و به‌روزرسانی برخط ارائه کردند [۱] و BGL، HDFS، خودنظارتی برای یادگیری الگوی توالی‌های عادی بهره گرفتند و روش را روی Thunderbird [۲] ارزیابی کردند. Chen و Liao در BERT-Log بازنمایی BERT برای HDFS و BGL ۹۹٫۴ درصد برای HDFS برابر ۹۹٫۳ درصد برای F1 تمام‌متصل ترکیب کردند و در پروتکل خود گزارش دادند [۳]

top-k از تنظیم مدل زبانی پیش‌آموزش‌دیده با وظیفه توکن ماسک‌شده روی لاگ‌های عادی و قاعده LogFiT ADALog آزمایش شده است [۱۳] Thunderbird و BGL، HDFS برای تشخیص استفاده می‌کند و روی لاگ‌های عادی، احتمال بازسازی توکن DistilBERT وابستگی به توالی و تجزیه را حذف و با تنظیم و آستانه صدکی تطبیقی، تصمیم سطح خط تولید می‌کند [۱۷]. این دو مطالعه نشان می‌دهند مدل زبانی پیش‌آموزش‌دیده می‌تواند بدون برچسب ناهنجاری به‌کار رود، اما همچنان به مرحله آموزش یا تنظیم روی داده مقصد نیاز دارد

LLM روش‌های مبتنی بر آموزش یا تنظیم ۲-۳-۲

را برای پیش‌بینی رخداد بعدی آموزش و سپس با یادگیری GPT ابتدا LogGPT در Trabelsi و Han، Yuan انجام Thunderbird و BGL، HDFS تقویتی به هدف تشخیص ناهنجاری هم‌راستا کردند؛ ارزیابی روی برای بردارهای معنایی، یک نگاشت بین بازنمایی‌ها BERT از LogLLM و همکاران در Guan. شد [۴] به‌عنوان طبقه‌بند استفاده کردند و یک فرایند آموزشی چندمرحله‌ای را روی چهار مجموعه LLaMA و گزارش کردند [۵] Thunderbird و Liberty، BGL، HDFS

سه مرحله افزایش داده، تنظیم پارامترکارا و بهینه‌سازی برخط را LLM-LADE و همکاران در Zhang با Llama۳-۸B برای تولید نمونه و GPT-۴ برای تشخیص و تبیین هم‌زمان ترکیب کردند؛ در پیاده‌سازی از RoBERTa، LoRA و ReFT نیز Pang و Zhu، Lim. برای مدل مقصد استفاده شد [۱۵] LoRA از نظر پایداری، کارایی نمونه و تعمیم بین مجموعه‌ها بررسی کردند [۱۴]. این دسته Llama-۳ و GPT-۲ کیفیت مدل را از طریق تغییر پارامترها یا نگاشت بازنمایی افزایش می‌دهد، اما هزینه آموزش و وابستگی به داده تنظیم را وارد فرایند می‌کند

روش‌های مبتنی بر پرامپت ۲-۳-۳

Spirit و BGL برای تشخیص ناهنجاری ChatGPT امکان استفاده از LogGPT و همکاران در مطالعه Qi و Liu را با پرامپت‌های مختلف بررسی کردند و علاوه بر برجسب، تبیین متنی را ارزیابی کردند [۶]. مجموعه‌ای از راهبردهای پرامپت برای تجزیه و تشخیص ارائه و آن را بدون LogPrompt همکاران در آموزش درون‌دامنه روی ۹ مجموعه داده آزمایش کردند؛ نتایج مقاله بهبود تا ۵۵٫۹ درصد نسبت به روش‌های آموزش‌دیده و امتیاز تفسیرپذیری ۴۰٫۴۲ از ۵ در ارزیابی متخصصان را گزارش می‌کند [۷]. فایل سال ۲۰۲۳ موجود در مجموعه منابع، نسخه اولیه همین خط پژوهش است و در جدول به‌عنوان مطالعه مستقل تکرار نشده است.

سه نوع شواهد را در پرامپت ترکیب کردند: مشاهده Hybrid Prompting در Lee و Choi، Park و مدل تعبیه GPT-۴o-mini رخدادهای دیده‌نشده، شباهت یا توزیع توالی و نزدیک‌ترین نمونه عادی. روش با برابر F۱ آزمایش شد و میانگین بهبود Thunderbird و BGL، HDFS روی Qwen۳-Embedding-۸B در پروتکل توالی یک‌دقیقه‌ای ۷۷٫۸۱ BGL روش روی F۱ واحد درصد نسبت به خطاپایه‌ها گزارش شد؛ ۹٫۹۳ درصد بود [۹]. این نتیجه به دلیل سطح توالی و نمونه متوازن با طبقه‌بندی خطبه‌خط این پژوهش قابل مقایسه عددی مستقیم نیست.

بازیابی، روش‌های ترکیبی و کاهش هزینه ۲-۳-۴

را در تشخیص LLM، پایگاه برداری از لاگ‌های عادی می‌سازد و با بازیابی نمونه‌های مرتبط RAGLog انجام شده است [۸]. Thunderbird و BGL بدون آموزش اختصاصی هدایت می‌کند؛ ارزیابی آن روی همکاری مدل کوچک و بزرگ را به‌کار می‌گیرد: عدم‌قطعیت مدل کوچک زمان فراخوانی AdaptiveLog را تعیین می‌کند و نمونه‌های دشوار مشابه به پرامپت افزوده می‌شوند؛ مقاله کاهش هزینه فراخوانی LLM تا ۷۳ درصد را گزارش می‌کند [۱۲].

کش و Mistral، شبکه پیش‌خور را با KNN، خروجی درخت تصمیم FlexLog و همکاران در Hadadi و داده‌های مصنوعی LOGEVOL، ADFA، بازیابی ترکیب کردند و روش را روی مجموعه‌های ناپایدار با ۶۲٫۸۷ واحد درصد داده برجسب‌خورده F۱ ارزیابی کردند. مقاله دست‌کم ۱٫۲ واحد درصد بهبود HDFS کمتر و در برخی تنظیم‌ها تا ۱۳ واحد درصد بهبود را گزارش می‌کند [۱۰]. مطالعه دیگر همین گروه مقایسه انجام داد و برتری تنظیم LOGEVOL را روی نسخه‌های ناپایدار GPT-۴ و مهندسی پرامپت GPT-۳ تنظیم اختصاصی را در پروتکل خود گزارش کرد [۱۱].

BiLSTM و RoBERTa و یادگیری درون‌متنی برای تجزیه، سپس ChatGPT از SemiRALD برابر F۱ ۷٫۳ میانگین بهبود BGL و HDFS توجه‌محور برای تشخیص نیمه‌نظارتی استفاده می‌کند و روی و ۸٫۲ درصد را نسبت به دو گروه خطاپایه گزارش کرده است [۱۶]. بنابراین واژه «ترکیبی» در این گروه یا ترکیب مرحله تجزیه و طبقه‌بندی اشاره کند و باید، LLM می‌تواند به ترکیب چند مدل، ترکیب بازیابی و برای هر مطالعه به‌طور عملیاتی تعریف شود.

تجزیه، انتقال، تبیین و کاربرد عملی ۵-۳-۲

مستقیماً آشکار ساز ناهنجاری نیستند، اما مرحله ورودی تحلیل لاگ را هدف LogPPT و LogParser-LLM با ۳۲ نمونه برچسب خورده روی ۱۶ مجموعه به میانگین بیش از ۰.۹ برای LogPPT می گیرند. LLM با درخت پیشوند، فراخوانی LogParser-LLM رسیده و Parsing Accuracy و Accuracy در مقیاس میلیون ها پیام محدود کرده است [۱۸، ۱۹]. این نتایج برای نرمال سازی و باز استفاده تصمیم سطح قالب اهمیت دارند.

و استخراج ویژگی یکپارچه بین سامانه ها، انتقال آشکار ساز LLM با تفسیر رخداد به وسیله LogSynergy بیش از ۸۹ درصد روی داده واقعی و F۱ به سامانه جدید را بررسی کرده و با ۵۰۰۰ توالی برچسب خورده تجزیه تطبیقی، ویژگی های LogLAA. بیش از ۸۳ درصد روی داده عمومی گزارش کرده است [۲۰] برای تولید توضیح را در یک چارچوب LLM دوتوجهی و CNN-LSTM، شمارشی، ترتیبی و معنایی یکپارچه قرار داده است [۲۱]

را فقط با توالی های LogBERT و همکاران AIops، De la Cruz Cabello در مطالعه کاربرد واقعی آموزش و به صورت محلی مستقر کردند. پنجره ۱۵ ثانیه ای با هم پوشانی ۱۰ ثانیه Linux syslog عادی بهترین موازنه گزارش شده بین اثربخشی و تأخیر بود و ارزیابی کیفی متخصصان کاربرد عملی روش را تأیید آموزش دیده LogBERT کرد [۲۷]. این مطالعه بر محرمانگی و استقرار محلی تأکید دارد، ولی طبقه بند آن دستور محور بدون تنظیم LLM است، نه یک

دسته بندی، جدول مقایسه و تحلیل ۴-۲

در تشخیص ناهنجاری، مطالعات بررسی شده را LLM بر اساس مرور نظام مند حوزه لاگ و رده بندی نقش LLM، می توان در چهار مسیر اصلی قرار داد: مدل سازی توالی، مدل زبانی پیش آموزش دیده با آموزش مقصد مبتنی بر پرامپت، بازیابی یا همکاری مدل ها [۲۲، ۲۴]. شکل ۲-۱ رابطه این LLM با تنظیم یا انتقال، و مسیرها و مؤلفه هایی را که در پژوهش حاضر کنار هم قرار می گیرند نشان می دهد.

ادبیات تشخیص ناهنجاری لاگ			
روش های ترتیبی	مدل های پیش آموزش دیده	با آموزش/تنظیم LLM	پرامپت، بازیابی و ترکیب
مدل سازی توالی DeepLog؛ رخداد	LogBERT، BERT-Log و LogFiT	LogGPT، LogLLM، LLM-LADE و PEFT	LogPrompt، RAGLog، AdaptiveLog و FlexLog
نرمال سازی قالب + کنترل تصمیم + کاهش فراخوانی مدل + LLM همگرایی مؤلفه های مورد نیاز: معناشناسی			
دامنه و ورودی	دو مسیر تصمیم	کارایی و قابلیت باز تولید	استقرار و ارزیابی
تصمیم خطی؛ فقط BGL؛ حذف برچسب از ورودی	قاعده قطعی سپس Hybrid LLM تصمیم صرفاً در: Prompt-only؛ پرامپت	کش سطح قالب نرمال شده؛ نسخه بندی JSON اعتبار سنجی کلید کش	روی Qwen۲، ۵:۷B-Instruct، Ollama، محلی؛ Accuracy، Precision، Recall، F۱، زمان و INVALID

شکل ۲-۱: دسته بندی پژوهش های تشخیص ناهنجاری لاگ و جایگاه پژوهش حاضر

در شکل ۲-۱، مسیر بالایی تحول روش ها را نمایش می دهد و بخش پایینی مشخصات عملیاتی پژوهش حاضر را از ادبیات متمایز می کند. قرار گرفتن یک مطالعه در یک دسته به معنای نبود اجزای دسته دیگر نیست؛ بازیابی و کش را به کار می گیرد [۱۰] و LLM، هم مدل های یادگیری ماشین و هم FlexLog برای نمونه را به مدل ترتیبی پیوند می دهد [۱۶] ChatGPT تجزیه با SemiRALD

جدول ۲-۱: مقایسه مطالعات منتخب در تشخیص ناهنجاری و تحلیل لاگ

مطالعه	سال	روش/مدل	داده‌ها	واحد تحلیل	نوع انطباق	یافته با کارکرد گزارش شده
DeepLog [۱]	۲۰۱۷	LSTM و پیش‌بینی رخداد بعدی	HDFS، OpenStack	توالی	آموزش روی عادی	تشخیص برخط و به‌روزرسانی افزایشی
LogBERT [۲]	۲۰۲۱	با دو هدف BERT خودنظارتی	HDFS، BGL، Thunderbird	توالی	آموزش روی عادی	یادگیری زمینه دوطرفه و الگوی مشترک عادی
BERT-Log [۳]	۲۰۲۲	و طبقه‌بند متصل BERT	HDFS، BGL	توالی/پنجره	تنظیم نظارت‌شده	BGL گزارش شده ۹۹٫۴٪ روی F۱
LogGPT (Han) [۴]	۲۰۲۳	پیش‌بینی رخداد و RL	HDFS، BGL، Thunderbird	توالی	آموزش RL و	هم‌راستاسازی هدف تولید با تشخیص
LogLLM [۵]	۲۰۲۴	نگاشت + BERT + LLaMA	چهار مجموعه شامل BGL	توالی	آموزش چندمرحله‌ای	با طبقه‌بند BERT ترکیب بازنمایی LLaMA
LogGPT (Qi) [۶]	۲۰۲۳	و پرامپت ChatGPT	BGL، Spirit	خط/پنجره	بدون تنظیم	بررسی پرامپت، دانش دامنه و تبیین
LogPrompt [۷]	۲۰۲۴	راهنماهای پرامپت و تبیین	مجموعه لاگ ۹	قالب/توالی	بدون آموزش درون‌دامنه	تا ۵۵٫۹٪ بهبود و امتیاز تبیین ۴۰۴۲/۵
RAGLog [۸]	۲۰۲۳	و پایگاه برداری RAG عادی	BGL، Thunderbird	توالی	بدون تنظیم	بازیابی نمونه عادی برای تصمیم معنایی
Hybrid Prompting [۹]	۲۰۲۵	+ پرامپت رخداد + توالی نمونه	HDFS، BGL، Thunderbird	توالی یک‌دقیقه‌ای	بدون تنظیم طبقه‌بند	F۱ میانگین ۹۰٫۹۳ واحد درصد بهبود
FlexLog [۱۰]	۲۰۲۴/۲۵	ML ensemble + Mistral + RAG + cache	چهار مجموعه ناپایدار	توالی	داده کم/درون‌متنی	کاهش داده برچسب‌خورده و استخراج کمتر از یک ثانیه
Unstable Logs GPT [۱۱]	۲۰۲۴	GPT-۳ تنظیم‌شده و GPT-۴ پرامپت	LOGEVOL-Hadoop	توالی	تنظیم/پرامپت	برتری تنظیم در پروتکل لاگ ناپایدار
AdaptiveLog [۱۲]	۲۰۲۵	+ LLM + مدل کوچک بازیابی	چند وظیفه لاگ	وابسته به وظیفه	همکاری تطبیقی	LLM تا ۷۳٪ کاهش هزینه فراخوانی
LogFiT [۱۳]	۲۰۲۵	top-k مدل ماسک‌شده و	HDFS، BGL، Thunderbird	توالی	تنظیم روی عادی	تشخیص خودنظارتی بدون ناهنجاری برچسب‌خورده
PEFT-LAD [۱۴]	۲۰۲۵	روی چند LoRA/ReFT LM	HDFS، BGL، Spirit، Thunderbird	توالی	تنظیم پارامترکارا	تحلیل پایداری، کارایی نمونه و انتقال
LLM-LADE [۱۵]	۲۰۲۵	+ LoRA + افزایش داده بهینه‌سازی برخط	مجموعه‌های عمومی لاگ	پیام/توالی	PEFT	تشخیص و تبیین همزمان
SemiRALD [۱۶]	۲۰۲۵	ChatGPT parsing + RoBERTa + BiLSTM	HDFS، BGL	توالی	نیم‌نظارتی	به‌ویژه با داده کم F۱ بهبود متوسط
ADALog [۱۷]	۲۰۲۵	و DistilBERT MLM آستانه تطبیقی	BGL، Thunderbird، Spirit	خط	تنظیم روی عادی	و مستقل از توالی parser بدون
LogParser-LLM [۱۸]	۲۰۲۴	درخت پیشوند + LLM	Loghub-۲k، LogPub	خط/قالب	بدون آموزش برچسبی	گروهبندی F۱ کاهش فراخوانی؛ ۹۰٫۶٪
LogPPT [۱۹]	۲۰۲۳	پرامپت‌تئوینگ RoBERTa	مجموعه ۱۶	خط/قالب	؛ Few-shot۳۲ نمونه	بیش از ۰٫۹ میانگین دقت گروه/تجزیه
LogSynergy [۲۰]	۲۰۲۵	و انتقال LLM تفسیر	عمومی و واقعی	توالی	انتقال با ۵۰۰۰ برچسب	بیش از ۸۳٪ عمومی و ۸۹٪ واقعی F۱
LogLAA [۲۱]	۲۰۲۶	parser + CNN-LSTM + LLM explanation	چند مجموعه عمومی	توالی	آموزش چندجزئی	تشخیص یکپارچه و تولید توضیح
واقعی [۲۷] AIOps	۲۰۲۶	محلی LogBERT	Linux syslog واقعی	پنجره زمانی	خودنظارتی	استقرار محلی تحت محدودیت محرمانگی

در بسیاری از مطالعات حضور دارد، اما پروتکل‌های آن یکسان نیستند BGL جدول ۲-۱ نشان می‌دهد که برخی پیام را مستقیماً طبقه‌بندی می‌کنند، برخی پنجره زمانی یا توالی مبتنی بر گره می‌سازند و برخی فقط به‌تنهایی BGL بخشی نمونه‌گیری‌شده را ارزیابی می‌کنند [۲، ۳، ۶، ۹، ۱۷]. بنابراین استفاده مشترک از نام هم‌ارزی آزمایش‌ها را تضمین نمی‌کند.

از نظر انطباق مدل، چهار حالت قابل مشاهده است: آموزش از ابتدا یا روی عادی، تنظیم نظارت‌شده یا پارامترکارا، پرامپت بدون تغییر وزن و همکاری چند مدل. پژوهش حاضر در حالت پرامپت بدون تغییر وزن قرار می‌گیرد، ولی با نرمال‌سازی و کَش قطعی در سطح قالب و دو مسیر تصمیم کنترل‌شده تکمیل می‌شود. این ترکیب در جدول ۲-۲ با نزدیک‌ترین مطالعات مقایسه شده است.

جدول ۲-۲: مقایسه سازوکار مطالعات نزدیک با مؤلفه‌های پژوهش حاضر

مطالعه	سازوکار اصلی	سطح تصمیم	کنترل هزینه	نوع استقرار	تفاوت با پژوهش حاضر
LogGPT (Qi) [۶]	ChatGPT پرامپت	خط/پنجره	نمونه‌گیری به علت محدودیت API	خدمت تجاری	محلی، کَش قالب و Qwen فاقد guard مقایسه
LogPrompt [۷]	راهبرد پرامپت و تبیین	قالب/توالی	بدون کَش عملیاتی محور مقایسه	های مختلف LLM	تمرکز بر راهبرد پرامپت، نه cache و guard آبشار
RAGLog [۸]	بازیابی لاگ عادی	توالی	retrieval کاهش زمینه با	بیرونی LLM	پایگاه برداری نمونه است، نه کَش تصمیم قالب
Hybrid Prompting [۹]	ترکیب شواهد در پرامپت	توالی	بازیابی نزدیک‌ترین نمونه	GPT-4o-mini	به معنای ترکیب Hybrid پرامپت و در سطح توالی است
FlexLog [۱۰]	ensemble + LLM + RAG + cache	توالی	ML کَش و واگذاری به	Mistral	داده‌های ناپایدار و ترکیب چند خط‌محور BGL طبقه‌بند؛ نه
AdaptiveLog [۱۲]	LLM + مدل کوچک	چند وظیفه	فراخوانی براساس عدم قطعیت	همکاری دو مدل	به مدل کوچک آموزش‌دیده نیاز دارد
ADALog [۱۷]	و آستانه تطبیقی MLM	خط	مولد فراخوانی LLM نمی‌شود	مدل محلی	fine-tuning نیازمند ؛ فاقد پرامپت DistilBERT دودویی
LogParser-LLM [۱۸]	LLM + درخت پیشوند	قالب	تجمع در درخت و فراخوانی محدود	قابل انتخاب LLM	هدف تجزیه است؛ تصمیم ناهنجاری تولید نمی‌کند
واقعی [۲۷] AIOps	محلی LogBERT	پنجره	تنظیم پنجره و مدل خودنظارتی	کاملاً محلی	syslog، مدل آموزش‌دیده روی دستور‌محور Qwen نه
پژوهش حاضر	Hybrid دو روش و Prompt-only	خط BGL	نرمال‌سازی + کَش تصمیم قالب	روی Qwen ۲.۵:۷B Ollama	guard مقایسه کنترل‌شده بیرونی با قاعده درون پرامپت

بر رفتار پرامپت LogGPT و LogPrompt: مطالعات نزدیک هرکدام بخشی از مسئله را پوشش داده‌اند، بر واگذاری تطبیقی AdaptiveLog، بر ترکیب کَش و مدل‌های کلاسیک FlexLog، بر بازیابی RAGLog، بر کاهش فراخوانی در سطح قالب تمرکز دارند [۶-۱۰، ۱۲، ۱۸]. در مجموعه منابع LogParser-LLM و قطعی بیرون guard بررسی‌شده، مقایسه کنترل‌شده دو مسیر با مدل، داده، نرمال‌سازی و کَش یکسان—یکی با مدل و دیگری با انتقال همان دانش به پرامپت—به‌صورت مستقیم گزارش نشده است.

شکاف تحقیقاتی و جایگاه پژوهش حاضر ۲-۵

مربوط است. نتایج خطمحر، پنجره مبتنی بر گره BGL نخستین شکاف به ناهمگونی واحد تحلیل و پروتکل پنجره یکدقیقه‌ای و توالی پنج‌دقیقه‌ای در ادبیات با یک نام مجموعه داده گزارش شده‌اند [۲، ۳، ۹، ۱۷]. این به ورودی و گزارش ماتریس BGL وضعیت نیازمند تعریف صریح واحد تصمیم، جلوگیری از ورود برچسب اغتشاش در سطح همان واحد است. پژوهش حاضر واحد تصمیم را خط تعیین می‌کند و برچسب را فقط برای ارزیابی نگه می‌دارد.

دومین شکاف، تفکیک اثر کیفیت تشخیص از هزینه استنتاج است. برخی مطالعات کش، بازیابی یا مدل کوچک به‌کار برده‌اند [۱۰، ۱۲، ۱۸]، اما نرخ برخورد کش، منبع هر تصمیم، زمان LLM را برای کاهش تماس با گزارش نمی‌شود. در F1 و Accuracy، Precision، Recall همیشه در کنار INVALID پاسخ و نرخ یا بازاستفاده guard، پژوهش حاضر این متغیرها بخشی از خروجی آزمایش‌اند تا معلوم شود هر بهبود از مدل تصمیم ناشی شده است.

سومین شکاف به جایگاه قواعد دامنه مربوط است. در پژوهش‌های پرامپتی، دانش در متن دستور یا نمونه‌ها قرار می‌گیرد [۶، ۷، ۹]؛ در روش‌های قاعده‌محور تصمیم خارج مدل است؛ و در سامانه‌های ترکیبی، مدل با همان منطق LLM کلاسیک یا بازیابی نقش دروازه را دارد [۱۰، ۱۲]. مقایسه مستقیم قاعده قطعی خارج از به‌صورت دستور درون پرامپت، تحت شرایط ثابت، در مجموعه مطالعات مرور شده مشاهده نشد. دو روش برای سنجش همین تمایز تعریف شده‌اند Prompt-only و Hybrid.

متن‌باز متوسط در استقرار کاملاً محلی و بدون تنظیم LLM چهارمین شکاف، محدود بودن شواهد درباره یک GPT یا ChatGPT است. بخشی از مطالعات از خدمات تجاری مانند BGL دقیق برای طبقه‌بندی خطبه‌خط را آموزش یا تنظیم کرده‌اند [۵، ۱۰، ۱۵] و Mistral یا LLaMA استفاده کرده‌اند [۶، ۹]، بخشی ۴۰-mini خودنظارتی بهره گرفته است [۲۷]. پژوهش حاضر LogBERT مطالعه محلی سال ۲۰۲۶ از محلی و وزن‌های ثابت ارزیابی می‌کند [۲۵، ۲۶] Ollama را با Qwen۲,۵B-Instruct

شامل BGL برآیند این شکاف‌ها جایگاه پژوهش را چنین مشخص می‌کند: یک خط لوله بازتولیدپذیر برای JSON استخراج و حذف برچسب، نرمال‌سازی حساس به معنا، کش نسخه‌بندی‌شده در سطح قالب، خروجی اعتبارسنجی‌شده و ثبت منبع تصمیم؛ سپس مقایسه دو معماری که فقط در محل اعمال دانش قطعی تفاوت دارند این صورت‌بندی ادعای برتری پیشینی هیچ مسیر را مطرح نمی‌کند و نتیجه باید از آزمایش کامل و یکسان دو روش به‌دست آید.

جمع‌بندی ۲-۶

تجزیه و نرمال‌سازی، مدل‌های ترتیبی، مدل‌های BGL، در این فصل مفاهیم لاگ، ناهنجاری، واحد تحلیل مهندسی پرامپت، استنتاج محلی، کش و معیارهای ارزیابی Qwen۲,۵، LLM، زبانی پیش‌آموزش‌دیده LLM، به تنظیم BERT تعریف شد. مرور پیشینه نشان داد مسیر پژوهش از پیش‌بینی توالی و مدل‌های پرامپت، بازیابی و سامانه‌های چندجزئی گسترش یافته است [۱-۲۴]

مقایسه مطالعات نشان داد که نوع واحد تحلیل، نیاز یا عدم نیاز به آموزش، سازوکار کنترل هزینه و محل استقرار برای تفسیر نتایج ضروری‌اند. شکاف استخراج‌شده از منابع، نبود مقایسه مستقیم و کنترل‌شده بین محلی در طبقه‌بندی Qwen و انتقال دانش آن به پرامپت، همراه با کش قالب و LLM قطعی بیرون guard است. فصل بعد باید معماری نرم‌افزار، قواعد نرمال‌سازی، ساختار پرامپت‌ها، کلید کش BGL خطبه‌خط پروتکل اجرای دو روش و شیوه محاسبه معیارها را به‌صورت عملیاتی تشریح کند Ollama تنظیمات

منابع فصل دوم ۲-۷

- [۱] Du, M.; Li, F.; Zheng, G.; Srikumar, V. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. ACM CCS, ۲۰۱۷. DOI: ۱۰.۱۱۴۵/۳۱۳۳۹۵۶.۳۱۳۴۰۱۵.
- [۲] Guo, H.; Yuan, S.; Wu, X. LogBERT: Log Anomaly Detection via BERT. arXiv:۲۱۰۳.۰۴۴۷۵, ۲۰۲۱.
- [۳] Chen, S.; Liao, H. BERT-Log: Anomaly Detection for System Logs Based on Pre-trained Language Model. Applied Artificial Intelligence, ۳۶(۱), ۲۰۲۲. DOI: ۱۰.۱۰۸۰/۰۸۸۳۹۵۱۴.۲۰۲۲.۲۱۴۵۶۴۲.
- [۴] Han, X.; Yuan, S.; Trabelsi, M. LogGPT: Log Anomaly Detection via GPT. ۲۰۲۳.
- [۵] Guan, W.; Cao, J.; Qian, S.; Gao, J.; Ouyang, C. LogLLM: Log-based Anomaly Detection Using Large Language Models. ۲۰۲۴.
- [۶] Qi, J.; Huang, S.; Luan, Z.; Fung, C.; Yang, H.; Qian, D. LogGPT: Exploring ChatGPT for Log-Based Anomaly Detection. ۲۰۲۳.
- [۷] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Prompt Engineering Towards Zero-Shot and Interpretable Log Analysis. ۲۰۲۴. (نسخه اولیه: Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies, ۲۰۲۳).
- [۸] Pan, J.; Wong, S. L.; Yuan, Y. RAGLog: Log Anomaly Detection using Retrieval Augmented Generation. ۲۰۲۳.
- [۹] Park, J.; Choi, E.; Lee, J. Hybrid Prompting for LLM-based Log Anomaly Detection. Journal of KIISE, ۵۲(۱۲), ۲۰۲۵. DOI: ۱۰.۵۶۲۶/JOK.۲۰۲۵.۵۲.۱۲.۱۰۶۷.
- [۱۰] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. LLM meets ML: Data-efficient Anomaly Detection on Unstable Logs. ۲۰۲۴–۲۰۲۵.
- [۱۱] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. Anomaly Detection on Unstable Logs with GPT Models. ۲۰۲۴.
- [۱۲] Ma, L.; Yang, W.; Li, Y.; Fei, B.; Zhou, M.; Li, S.; Jiang, S.; Xu, B.; Xiao, Y. AdaptiveLog: An Adaptive Log Analysis Framework with the Collaboration of Large and Small Language Model. arXiv:۲۰۰۱.۱۱۰۳۱, ۲۰۲۵.
- [۱۳] Almodovar, C.; Sabrina, F.; Karimi, S.; Azad, S. LogFiT: Log Anomaly Detection using Fine-Tuned Language Models. ۲۰۲۵.
- [۱۴] Lim, Y. F.; Zhu, J.; Pang, G. Adapting Large Language Models for Parameter-Efficient Log Anomaly Detection. ۲۰۲۵.
- [۱۵] Zhang, Z.; Li, S.; Zhang, L.; Ye, J.; Hu, C.; Yan, L. LLM-LADE: Large language model-based log anomaly detection with explanation. Knowledge-Based Systems, ۳۲۶, ۱۱۴۰۶۴, ۲۰۲۵. DOI: ۱۰.۱۰۱۶/j.ksys.۲۰۲۵.۱۱۴۰۶۴.
- [۱۶] Sun, Y.; Keung, J. W.; Yang, Z.; Liu, S.; Yu, H. K. SemiRALD: A semi-supervised hybrid language model for robust Anomalous Log Detection. Information and Software Technology, ۱۸۳, ۱۰۷۷۴۳, ۲۰۲۵. DOI: ۱۰.۱۰۱۶/j.infsof.۲۰۲۵.۱۰۷۷۴۳.
- [۱۷] Pospieszny, P.; Mormul, W.; Szyndler, K.; Kumar, S. ADALog: Adaptive Unsupervised Anomaly Detection in Logs with Self-attention Masked Language Model. arXiv:۲۰۰۵.۱۳۴۹۶, ۲۰۲۵.
- [۱۸] Zhong, A.; Mo, D.; Liu, G.; Liu, J.; Lu, Q.; Zhou, Q.; Wu, J.; Li, Q.; Wen, Q. LogParser-LLM: Advancing Efficient Log Parsing with Large Language Models. arXiv:۲۴۰۸.۱۳۷۲۷, ۲۰۲۴.
- [۱۹] Le, V.-H.; Zhang, H. Log Parsing with Prompt-based Few-shot Learning. arXiv:۲۳۰۲.۰۷۴۳۵, ۲۰۲۳.
- [۲۰] Sui, Y.; Wang, X.; Cui, T.; Xiao, T.; He, C.; Zhang, S.; Zhang, Y.; Yang, X.; Sun, Y.; Pei, D. Bridging the Gap: LLM-Powered Transfer Learning for Log Anomaly Detection in New Software Systems. ۲۰۲۵.
- [۲۱] Gao, Y.; Luo, T.; Huang, K.; Tang, J.; Li, X. LogLAA: an adaptive integrated log anomaly analysis framework. Cybersecurity, ۹:۱۴۱, ۲۰۲۶. DOI: ۱۰.۱۱۸۶/s۴۲۴۰۰۰۰۲۶۰۰۰۵۷۳-۸.

- [۲۲] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. AIOps for log anomaly detection in the era of LLMs: A systematic literature review. *Intelligent Systems with Applications*, ۲۸, ۲۰۰۶۰۸, ۲۰۲۵. DOI: ۱۰.۱۰۱۶/۰.۰۰۰۰.۲۰۲۵.۲۰۰۶۰۸.
- [۲۳] Liu, Y.; Pei, C.; Xu, L.; et al. OpsEval: A Comprehensive Benchmark Suite for Evaluating Large Language Models' Capability in IT Operations Domain. *FSE Companion*, ۲۰۲۵. DOI: ۱۰.۱۱۴۵/۳۶۹۶۶۳۰.۳۷۲۸۵۷۲.
- [۲۴] Xu, R.; Ding, K. Large Language Models for Anomaly and Out-of-Distribution Detection: A Survey. *arXiv:۲۴۰۹.۰۱۹۸۰*, ۲۰۲۵.
- [۲۵] Qwen Team. Qwen۲,۵ Technical Report. *arXiv:۲۴۱۲.۱۵۱۱۵*, ۲۰۲۴.
- [۲۶] Ollama. API Introduction; Structured Outputs; Usage Metrics. مشاهده‌شده در ۱۴ اوت، مستندات رسمی Ollama، ۲۰۲۶.
- [۲۷] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. Log anomaly detection in AIOps: A real-world implementation using Large Language Models. *Systems and Soft Computing*, ۸, ۲۰۰۴۷۵, ۲۰۲۶. DOI: ۱۰.۱۰۱۶/۰.۰۰۰۰.۲۰۲۶.۲۰۰۴۷۵.