

مقدمه ۲-۱

لاگ‌های سیستمی ردپای رخدادهای زمان اجرا، وضعیت اجزا و پیام‌های خطا را ثبت می‌کنند و از این‌رو یکی از ورودی‌های اصلی پایش، عیب‌یابی و تشخیص ناهنجاری در سامانه‌های نرم‌افزاری به‌شمار می‌روند. افزایش حجم و تنوع لاگ‌ها، بررسی دستی را دشوار کرده و پژوهش‌ها را از قواعد و شمارش رخدادها به‌سوی مدل‌های ترتیبی، مدل‌های زبانی پیش‌آموزش‌دیده و در سال‌های اخیر مدل‌های زبانی بزرگ سوق داده است [۱، ۲، ۲۲].

در روش‌های مبتنی بر یادگیری عمیق، توالی قالب‌های لاگ یا بازنمایی متنی پیام‌ها برای یادگیری الگوی با دو وظیفه خودنظارتی و LogBERT، با پیش‌بینی رخداد بعدی DeepLog. رفتار عادی استفاده می‌شود – برای طبقه‌بندی، سه مسیر شاخص این تحول را نشان می‌دهند [۱] BERT با تنظیم یک مدل BERT-Log، این روش‌ها توانایی مدل‌سازی الگو را افزایش داده‌اند، اما معمولاً به آموزش اختصاصی، ساخت توالی [۳]. تجزیه لاگ یا داده برچسب‌خورده وابسته‌اند [۲، ۳، ۲۲]

مدل‌های زبانی بزرگ مسیر دیگری را فراهم کرده‌اند: انجام تشخیص از طریق دستور متنی، نمونه‌های LogGPT، LogPrompt، درون‌متنی، بازیابی شواهد، تنظیم کامل یا تنظیم پارامترکارا. مطالعات نشان می‌دهند که نقش مدل زبانی FlexLog و AdaptiveLog، LLM-LADE، RAGLog، LogLLM، می‌تواند از طبقه‌بند مستقیم تا مفسر، تولیدکننده داده، جزء کمکی یا تصمیم‌گیر پشتیبان تغییر کند [۴-۸، ۱۰]. بنابراین مقایسه پژوهش‌ها تنها با نام مدل کافی نیست و باید نوع آموزش، واحد تحلیل، شیوه [۱۵، ۱۲]. آماده‌سازی ورودی، محل استقرار و سازوکار کنترل هزینه نیز در نظر گرفته شود [۲۲، ۲۴]

Qwen۲,۵:۷B- با فصل حاضر مبانی موردنیاز برای پژوهش تشخیص ناهنجاری در لاگ‌های را ارائه می‌کند. سپس پیشینه در پنج دسته مرور و با جدول و شکل مقایسه می‌شود. در Ollama و Instruct و Hybrid پایان، شکاف تحقیقاتی با اتکا به مجموعه منابع بررسی‌شده و جایگاه دو روش مورد مطالعه، یعنی در موارد LLM در این پژوهش به «قاعده قطعی با فراخوانی Hybrid تبیین می‌شود. واژه، Prompt-only در مطالعه پارک و همکاران، که ترکیبی از شواهد Hybrid Prompting باقیمانده» اشاره دارد و با اصطلاح سطح رخداد و توالی را در پرامپت قرار می‌دهد، یکسان نیست [۹]

مبانی نظری و مفاهیم موردنیاز ۲-۲

لاگ سیستمی و تشخیص ناهنجاری ۲-۲-۱

هر پیام لاگ معمولاً از سرآیندی مانند زمان، سطح شدت و مؤلفه تولیدکننده و یک بدنه متنی تشکیل می‌شود. در بدنه، بخش‌های ثابت بیانگر رخداد برنامه و بخش‌های متغیر شامل شناسه‌ها، نشانی‌ها، مسیرها، مقادیر فرایند تبدیل پیام LogParser-LLM و LogPPT عددی و سایر پارامترهای زمان اجرا هستند. پژوهش‌های خام به قالب ثابت و پارامترهای متغیر را «تجزیه لاگ» تعریف می‌کنند و نشان می‌دهند که کیفیت این مرحله بر تحلیل‌های پایین‌دستی، از جمله تشخیص ناهنجاری، اثر می‌گذارد [۱۸، ۱۹]

در ادبیات، ناهنجاری به انحراف مشاهده از الگوی عادی آموخته‌شده یا تعریف‌شده اطلاق می‌شود. این انحراف و DeepLog. می‌تواند در یک پیام منفرد، فراوانی رخدادها، ترتیب قالب‌ها یا معنای یک توالی ظاهر شود. هر پیام ساختنیافته را ADALog بر انحراف توالی از رفتار عادی تمرکز دارند؛ در مقابل LogBERT مستقل تحلیل و احتمال بازسازی توکن‌ها را به امتیاز سطح پیام تبدیل می‌کند [۱، ۲، ۱۷]. این تفاوت، واحد تحلیل و در نتیجه نحوه ساخت نمونه آزمایشی را تعیین می‌کند.

انواع ناهنجاری و واحد تحلیل ۲-۲-۲

سه سطح رایج در پژوهش‌های لاگ قابل تفکیک است: ناهنجاری رخداد یا خط، ناهنجاری توالی و ناهنجاری کمی. در سطح خط، هر پیام یک نمونه تصمیم است و برچسب به همان پیام تعلق دارد. در سطح توالی، پیام‌ها بر اساس شناسه نشست، گره یا پنجره زمانی گروه‌بندی می‌شوند و وجود یک رخداد غیر عادی می‌تواند برچسب کل توالی را تعیین کند. در ناهنجاری کمی، تغییر غیر عادی فراوانی قالب‌ها در پنجره موردنظر بررسی می‌شود [۲۲، ۳-۱].

از پنجره لغزان BGL در BERT-Log، واحد تحلیل بر قابلیت مقایسه نتایج اثر مستقیم دارد. برای نمونه توالی‌های یک‌دقیقه‌ای Hybrid Prompting مبتنی بر شناسه گره، اندازه پنجره و گام استفاده کرده است؛ تصمیم را برای یک پیام مستقل گزارش می‌کند [۳، ۹، ۱۷]. از این‌رو اعداد دقت یا ADALog می‌سازد؛ اما مطالعاتی که خط، نشست یا پنجره زمانی را نمونه می‌گیرند بدون همسان‌سازی پروتکل ارزیابی قابل F1 مقایسه مستقیم نیستند.

BGL مجموعه داده ۲-۲-۳

در آزمایشگاه ملی لارنس Blue Gene/L از لاگ‌های ابررایانه BGL یا Blue Gene/L مجموعه داده لیورمور تهیه شده است. در این مجموعه ۴,۷۴۷,۹۶۳ پیام لاگ وجود دارد که ۳۴۸,۴۶۰ پیام، معادل حدود درصد، با برچسب هشدار به عنوان ناهنجار مشخص شده‌اند [۲، ۶]. وجود برچسب در ابتدای هر خط ۷,۳۴ امکان ارزیابی نظارت‌شده را فراهم می‌کند، اما آن برچسب باید پیش از ارسال متن به مدل حذف شود تا نشست پاسخ به ورودی رخ ندهد.

پنجره زمانی پنج‌دقیقه‌ای با LogBERT را با پروتکل‌های متفاوت به‌کار گرفته‌اند BGL مطالعات مختلف Hybrid از پنجره مبتنی بر گره استفاده کرده و BERT-Log میانگین طول ۵۶۲ رخداد ساخته است؛ پنجره یک‌دقیقه‌ای و نمونه متوازن از هزار توالی عادی و هزار توالی ناهنجار را ارزیابی کرده Prompting است [۲، ۳، ۹]. در پژوهش حاضر، مسئله در سطح خط تعریف می‌شود؛ بنابراین برچسب مرجع هر خط فقط حذف می‌شود Qwen برای ارزیابی نگهداری و از ورودی.

تجزیه، نرمال‌سازی و قالب لاگ ۲-۲-۴

هدف تجزیه لاگ جداکردن کلمات ثابت قالب از پارامترهای متغیر است. روش‌های سنتی از فراوانی، شباهت با پرامپت‌تیونینگ و تعداد کمی نمونه برچسب‌خورده، و LogPPT یا قواعد نحوی استفاده می‌کنند؛ معنا را نیز وارد فرایند استخراج LLM با ترکیب درخت پیشوند و فراخوانی محدود LogParser-LLM با میانگین ۳,۶ میلیون لاگ در هر LogPub در ارزیابی LogParser-LLM قالب کرده‌اند [۱۸، ۱۹] گروه‌بندی ۹۰,۶ درصد و دقت تجزیه ۸۱,۱ درصد F1، LLM مجموعه، به‌طور متوسط با ۲۷۲,۵ فراخوانی گزارش کرده است [۱۸].

نرمال‌سازی در این پژوهش یک تجزیه کامل مبتنی بر خوشه‌بندی نیست؛ بلکه تبدیل قطعی مقادیر پویا به مقادیر هگزادسیمال IP، جانشین‌های پایدار برای ساخت قالب نرمال‌شده است. شناسه گره، واحدها، نشانی تاریخ و زمان، مسیرها و اعداد پویا ماسک می‌شوند. با این‌حال صفر و غیرصفر با دو جانشین متمایز نگه داشته می‌شوند، زیرا برخی پیام‌های عملیاتی تفاوت معنایی خود را از <NON_ZERO> و <ZERO> همین وضعیت عددی می‌گیرند. این طراحی با اصل جداسازی قالب و پارامتر در مطالعات تجزیه لاگ سازگار است، اما قاعده جانشینی آن به‌طور مشخص برای خط لوله این پژوهش تعریف شده است [۱۸، ۱۹].

یک نتیجه عملی نرمال‌سازی، کاهش تنوع ظاهری پیام‌هایی است که یک رخداد واحد را با شناسه یا عدد متفاوت بیان می‌کنند. در نتیجه، تصمیم سطح قالب می‌تواند میان خطوط هم‌معنا بازاستفاده شود. در این حالت دقت نرمال‌سازی اهمیت دارد: ماسک بیش‌ازحد ممکن است نشانه معنایی را حذف کند و ماسک کم نیز تعداد نیز LogLAA و LogParser-LLM و LogPPT قالب‌ها و فراخوانی مدل را افزایش می‌دهد. مطالعات حساسیت تحلیل پایین‌دستی به کیفیت آماده‌سازی و تجزیه را گزارش کرده‌اند [۲۱، ۱۹، ۲۱]

۲-۲-۵ روش‌های قاعده‌محور، یادگیری ماشین و مدل‌های ترتیبی

روش‌های قاعده‌محور الگوهای از پیش تعریف‌شده را با واژه کلیدی یا عبارت منظم تطبیق می‌دهند. مزیت آن‌ها تصمیم سریع و قابل ردیابی برای الگوهای شناخته‌شده است، ولی دامنه کشف به قواعد نوشته‌شده محدود می‌شود و نگهداری قواعد در برابر تغییر قالب‌ها هزینه‌بر است [۲۲، ۲]. روش‌های کلاسیک یادگیری ماشین ماشین بردار پشتیبان، PCA پس از استخراج بردار فراوانی یا ویژگی‌های آماری، از الگوریتم‌هایی مانند تک‌کلاسه یا درخت تصمیم برای تشخیص انحراف استفاده می‌کنند [۱۰، ۱].

رخداد بعدی را از رخدادهای قبلی پیش‌بینی LSTM لاگ را همانند توالی زبان مدل‌سازی و با DeepLog می‌کند؛ رخدادی که در مجموعه پیش‌بینی‌های محتمل قرار نگیرد ناهنجار تلقی می‌شود. این روش آموزش LogBERT، افزایشی و یک جریان تشخیص و عیب‌یابی را نیز ارائه می‌کند [۱]. روش‌های بعدی مانند وابستگی دوطرفه و وظایف خودنظارتی را جایگزین اتکای صرف به پیش‌بینی رخداد بعدی کرده‌اند [۲]. این خانواده برای ناهنجاری‌های ترتیبی مناسب است، اما به تعریف توالی و آموزش روی داده سامانه وابستگی دارد.

۲-۲-۶ مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ

بازنمایی زمینه‌مند واژه‌ها را از متن فرا می‌گیرند و سپس برای وظیفه BERT مدل‌های پیش‌آموزش‌دیده مانند دو وظیفه «پیش‌بینی کلید ماسک‌شده» و «کمینه‌سازی حجم ابرکره» را بر LogBERT. خاص تنظیم می‌شوند و یک لایه تمام‌متصل را برای طبقه‌بندی BERT مدل BERT-Log. توالی‌های عادی به‌کار می‌گیرد [۲] نیز LogFiT. گزارش کرده است [۳] BGL برابر ۹۹٫۴ درصد را برای F۱ تنظیم کرده و در پروتکل خود با مدل‌سازی توکن ماسک‌شده، فقط از لاگ‌های عادی برای یادگیری استفاده می‌کند [۱۳]

با ظرفیت زیاد و پیش‌آموزی گسترده است که می‌تواند Transformer مدل زبانی بزرگ معمولاً یک مدل دستور متنی را دنبال و خروجی تولید کند. در حوزه تشخیص ناهنجاری، این مدل ممکن است مستقیماً نقش آشکارساز داشته باشد یا برای تولید داده، تبیین و پشتیبانی از مدل کوچک‌تر استفاده شود؛ این دو نقش در «برای تولید» نام‌گذاری شده‌اند [۲۴] LLM «برای تشخیص» و LLM «به‌ترتیب Ding و Xu رده‌بندی مرور و همکاران نیز روش‌های لاگ را براساس آماده‌سازی، بازنمایی، مدل De la Cruz Cabello مرور نظام‌مند و شیوه ارزیابی دسته‌بندی می‌کند [۲۲]

۲-۲-۷ مدل Qwen۲،۵:۷B-Instruct

خانواده‌ای از مدل‌های متن‌باز با نسخه‌های پایه و دستور‌محور در اندازه‌های ۰٫۵ تا ۷۲ میلیارد Qwen۲،۵ پارامتر است. گزارش فنی این خانواده، پیش‌آموزی بر ۱۸ تریلیون توکن و پس‌آموزی با بیش از یک میلیون در این گزارش حدود ۶٫۵ میلیارد B نمونه تنظیم دستوری و مراحل تقویت یادگیری را شرح می‌دهد. نسخه ۷ برای پیروی از دستور و تولید پاسخ ساخت‌یافته بهینه شده است Instruct پارامتر غیرتعبیه‌ای دارد و نسخه [۲۵].

به صورت محلی و بدون تنظیم دقیق برای طبقه‌بندی دودویی هر Qwen2.5:7B-Instruct در این پژوهش قالب نرمال شده استفاده می‌شود. نبود تنظیم اختصاصی باعث می‌شود تفاوت دو روش آزمایش شده به معماری تصمیم و متن پرامپت مربوط باشد، نه تغییر وزن‌های مدل. انتخاب یک مدل و یک نسخه پرامپت ثابت برای است Prompt-only یا Hybrid هر دو روش، شرط لازم برای نسبت دادن اختلاف نتایج به سازوکار

۲-۲-۸ مهندسی پرامپت و خروجی ساخت‌یافته ۲-۲-۸

پرامپت مجموعه دستورها، زمینه دامنه، تعریف برچسب‌ها و قالب خروجی است که رفتار مدل را در زمان اثر نوع پرامپت، اندازه پنجره و تزریق دانش انسانی ChatGPT مبتنی بر LogGPT. استنتاج هدایت می‌کند از راهبردهای چندمرحله‌ای و درخواست LogPrompt. بررسی کرده است [۶] Spirit و BGL را روی تبیین برای تجزیه و تشخیص ناهنجاری استفاده می‌کند و بدون آموزش درون‌دامنه روی چند مجموعه لاگ نیز حساسیت وظایف عملیات فناوری اطلاعات به پرامپت، زنجیره فکر و OpsEval. ارزیابی شده است [۷] یادگیری درون‌متنی را در سطح معیار ارزیابی بررسی می‌کند [۲۳]

برای طبقه‌بندی خودکار، خروجی باید از متن آزاد به قرارداد ماشین‌خوان تبدیل شود. قرارداد این پژوهش فقط برای ناهنجار را می‌پذیرد {"label": "۱"} برای عادی و {"label": "۰"} یعنی JSON یکی از دو شیء ثبت می‌شود و وارد کش INVALID ناقص با وضعیت JSON پاسخ دارای متن اضافی، برچسب نامعتبر یا و کاهش JSON امکان درخواست خروجی ساخت‌یافته با قالب یا طرح Ollama نمی‌گردد. مستندات رسمی تصادفی بودن با دمای صفر را بیان می‌کند [۲۶]. اعتبارسنجی مستقل پاسخ همچنان لازم است، زیرا قرارداد خروجی بخشی از پروتکل آزمایش و محاسبه نرخ پاسخ نامعتبر است

۲-۲-۹ Ollama استنتاج محلی با ۲-۲-۹

پیش‌فرض API فراهم می‌کند API یک واسط محلی برای اجرای مدل و فراخوانی آن از طریق Ollama در دسترس است و پاسخ‌های آن علاوه بر محتوای مدل، شاخص‌های زمان localhost:۱۱۴۳۴/api در نشانی اجرا و شمار توکن را نیز گزارش می‌کنند [۲۶]. استنتاج محلی مانع ارسال لاگ به خدمت خارجی می‌شود و و De la Cruz Cabello کنترل نسخه مدل و پارامترهای اجرا را ممکن می‌سازد؛ مطالعه کاربرد واقعی را برای محیط دارای محدودیت حرمانگی به کار گرفته است LogBERT همکاران نیز استقرار محلی مدل [۲۷].

استنتاج محلی به معنی نبود هزینه محاسباتی نیست. زمان بارگذاری مدل، زمان ارزیابی پرامپت و زمان تولید فیلدهای Ollama پاسخ باید ثبت شوند و فراخوانی تکراری برای پیام‌های هم‌قالب کاهش یابد. مستندات total_duration، load_duration، prompt_eval_count، prompt_eval_duration، eval_count را برای اندازه‌گیری این اجزا معرفی می‌کند [۲۶]. این داده‌ها در کنار زمان انتهابه‌انتهای eval_duration و برنامه، مبنای تحلیل کارایی قرار می‌گیرند

۲-۲-۱۰ کش سطح قالب و اعتبارسنجی تصمیم ۲-۲-۱۰

از کش و LLM برای کاهش فراخوانی FlexLog. کش نگاشت یک کلید پایدار به تصمیم معتبر قبلی است با واگذاری نمونه‌های مطمئن به مدل کوچک‌تر، تعداد فراخوانی AdaptiveLog ارزیابی استفاده می‌کند و نیز با تجمع الگوها در درخت LogParser-LLM. مدل بزرگ را تا ۷۳ درصد کاهش داده است [۱۰، ۱۲] برای پیام‌های مشابه جلوگیری می‌کند [۱۸]. این مطالعات نشان می‌دهند LLM پیشوند از تکرار فراخوانی کنترل هزینه استنتاج بخشی مستقل از کیفیت طبقه‌بندی است

در پژوهش حاضر کلید کش از نسخه پرامپت، نام و نسخه مدل، قالب نرمال شده و در صورت فعال بودن مؤلفه، سطح شدت و دسته پیام ساخته می شود. بنابراین با تغییر پرامپت یا مدل، تصمیم قبلی به اشتباه باز استفاده خطای ارتباط یا پاسخ ناقص در کش قرار، INVALID نمی شود. فقط پاسخ معتبر ۰ یا ۱ ذخیره می شود؛ نمی گیرد. نرخ برخورد کش، نرخ عدم برخورد و تعداد کلیدهای یکتا همراه با منبع تصمیم ثبت می شود تا اثر کش از اثر مدل و قواعد جدا شود

۲-۲-۱۱ Hybrid و Prompt-only دو معماری

این پژوهش، خط پس از استخراج فیلدها و نرمال سازی ابتدا در کش جست و جو می شود Hybrid در معماری در نبود تصمیم کش شده، مجموعه ای محدود از قواعد قطعی و با اطمینان بالا بررسی می گردد. اگر هیچ ارسال و پاسخ پس از اعتبار سنجی ذخیره می شود. منبع هر تصمیم Qwen قاعده ای تصمیم ندهد، قالب به یک آبخار تصمیم است و هدف آن سنجش Hybrid ثبت می شود. در نتیجه llm یا guard، cache به صورت است LLM اثر قاعده قطعی پیش از

guard همان نرمال سازی، کلید کش، مدل و قرارداد خروجی حفظ می شود، اما Prompt-only در معماری برای هر قالب فاقد Qwen قطعی غیر فعال است. دانش دامنه و قواعد تشخیص در متن پرامپت بیان می شوند و کش تصمیم می گیرد. مقایسه منصفانه مستلزم ثابت ماندن مجموعه داده، ترتیب ورودی، نسخه مدل، گزینه های آن است که Hybrid Prompting نرمال سازی و سیاست اعتبار سنجی است. تفاوت این تعریف با Ollama، روش پارک و همکاران شواهد سطح رخداد، شباهت توالی و نمونه عادی مشابه را در یک پرامپت ترکیب می کند و طبقه بندی آن در سطح توالی است [۹]

۲-۲-۱۲ معیارهای ارزیابی

خطوط FP، تعداد خطوط عادی درست TN، تعداد ناهنجاری های درست کشف شده TP، برای مسئله دودویی ناهنجاری های از دست رفته است. دقت کل نسبت همه تصمیم های درست به FN عادی با برچسب ناهنجار و سهم Recall تشخیص های ناهنجار درست از همه پیش بینی های ناهنجار؛ Precision کل نمونه هاست؛ است Recall و Precision میانگین هارمونیک $F1$ ناهنجاری های کشف شده از همه ناهنجاری های واقعی؛ و [۹، ۳]

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP) \quad \text{Recall} = TP / (TP + FN) \quad F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

گزارش شوند. افزون Accuracy باید در کنار Recall و Precision، $F1$ ، BGL به دلیل نامتوازن بودن منبع تصمیم و آمار برخورد کش LLM، زمان پاسخ، تعداد فراخوانی، INVALID بر این چهار معیار، نرخ برای مقایسه دو معماری ضروری است. گزارش این شاخص ها کمک می کند افزایش سرعت ناشی از کش یا با کیفیت طبقه بندی اشتباه نشود guard

پیشینه تحقیق ۲-۳

روش‌های ترتیبی و پیش‌آموزش‌دیده ۲-۳-۱

برای یادگیری توالی رخدادهای عادی، تشخیص LSTM را به‌عنوان یک مدل DeepLog و همکاران Du و دو هدف BERT از LogBERT و همکاران در Guo. انحراف و به‌روزرسانی برخط ارائه کردند [۱] و HDFS، BGL و خودنظارتی برای یادگیری الگوی توالی‌های عادی بهره گرفتند و روش را روی Thunderbird [۲] BERT بازنمایی BERT-Log در Liao و Chen. ارزیابی کردند [۲] BGL و ۹۹٫۴ درصد برای HDFS برابر ۹۹٫۳ درصد برای F1 تمام‌متصل ترکیب کردند و در پروتکل خود گزارش دادند [۳].

top-k از تنظیم مدل زبانی پیش‌آموزش‌دیده با وظیفه توکن ماسک‌شده روی لاگ‌های عادی و قاعده LogFiT ADALog. آزمایش شده است [۱۳] Thunderbird و BGL و HDFS برای تشخیص استفاده می‌کند و روی لاگ‌های عادی، احتمال بازسازی توکن DistilBERT وابستگی به توالی و تجزیه را حذف و با تنظیم و آستانه صدکی تطبیقی، تصمیم سطح خط تولید می‌کند [۱۷]. این دو مطالعه نشان می‌دهند مدل زبانی پیش‌آموزش‌دیده می‌تواند بدون برچسب ناهنجاری به‌کار رود، اما همچنان به مرحله آموزش یا تنظیم روی داده مقصد نیاز دارد.

LLM روش‌های مبتنی بر آموزش یا تنظیم ۲-۳-۲

را برای پیش‌بینی رخداد بعدی آموزش و سپس با یادگیری GPT ابتدا LogGPT در Trabelsi و Han، Yuan انجام Thunderbird و BGL و HDFS تقویتی به هدف تشخیص ناهنجاری هم‌راستا کردند؛ ارزیابی روی برای بردارهای معنایی، یک نگاشت بین بازنمایی‌ها BERT از LogLLM و همکاران در Guan. شد [۴] به‌عنوان طبقه‌بند استفاده کردند و یک فرایند آموزشی چندمرحله‌ای را روی چهار مجموعه LLaMA و گزارش کردند [۵] Thunderbird و Liberty و BGL و HDFS.

سه مرحله افزایش داده، تنظیم پارامترکارا و بهینه‌سازی برخط را LLM-LADE و همکاران در Zhang با Llama۳-۸B برای تولید نمونه و ۴-GPT برای تشخیص و تبیین هم‌زمان ترکیب کردند؛ در پیاده‌سازی از LoRA و ReFT روی LoRA نیز Pang و Lim، Zhu و LoRA [۱۵] برای مدل مقصد استفاده شد [۱۵] از نظر پایداری، کارایی نمونه و تعمیم بین مجموعه‌ها بررسی کردند [۱۴]. این دسته ۳-Llama و ۲-GPT کیفیت مدل را از طریق تغییر پارامترها یا نگاشت بازنمایی افزایش می‌دهد، اما هزینه آموزش و وابستگی به داده تنظیم را وارد فرایند می‌کند.

روش‌های مبتنی بر پرامپت ۲-۳-۳

Spirit و BGL برای تشخیص ناهنجاری ChatGPT امکان استفاده از LogGPT و همکاران در مطالعه Qi و Liu. را با پرامپت‌های مختلف بررسی کردند و علاوه بر برچسب، تبیین متنی را ارزیابی کردند [۶] مجموعه‌ای از راهبردهای پرامپت برای تجزیه و تشخیص ارائه و آن را بدون LogPrompt همکاران در آموزش درون‌دامنه روی ۹ مجموعه داده آزمایش کردند؛ نتایج مقاله بهبود تا ۵۵٫۹ درصد نسبت به روش‌های آموزش‌دیده و امتیاز تفسیرپذیری ۴۰٫۴۲ از ۵ در ارزیابی متخصصان را گزارش می‌کند [۷]. فایل سال ۲۰۲۳ موجود در مجموعه منابع، نسخه اولیه همین خط پژوهش است و در جدول به‌عنوان مطالعه مستقل تکرار نشده است.

سه نوع شواهد را در پرامپت ترکیب کردند: مشاهده Hybrid Prompting در Lee و Choi، Park و مدل تعبیه GPT-4o-mini رخدادهای دیده نشده، شباهت یا توزیع توالی و نزدیکترین نمونه عادی. روش با برابر F1 آزمایش شد و میانگین بهبود Thunderbird و BGL، HDFS روی Qwen3-Embedding-8B در پروتکل توالی یکدقیقه‌ای 77,81 BGL روش روی F1 واحد درصد نسبت به خطایها گزارش شد؛ 9,93 درصد بود [9]. این نتیجه به دلیل سطح توالی و نمونه متوازن با طبقه‌بندی خطبه‌خط این پژوهش قابل مقایسه عددی مستقیم نیست.

بازیابی، روش‌های ترکیبی و کاهش هزینه ۲-۳-۴

را در تشخیص LLM، پایگاه برداری از لاگ‌های عادی می‌سازد و با بازیابی نمونه‌های مرتبط RAGLog انجام شده است [8] Thunderbird و BGL بدون آموزش اختصاصی هدایت می‌کند؛ ارزیابی آن روی همکاری مدل کوچک و بزرگ را به‌کار می‌گیرد: عدم قطعیت مدل کوچک زمان فراخوانی AdaptiveLog را تعیین می‌کند و نمونه‌های دشوار مشابه به پرامپت افزوده می‌شوند؛ مقاله کاهش هزینه فراخوانی LLM تا 73 درصد را گزارش می‌کند [12] LLM

کش و Mistral، شبکه پیش‌خور را با KNN، خروجی درخت تصمیم FlexLog و همکاران در Hadadi و داده‌های مصنوعی LOGEVOL، ADFA بازیابی ترکیب کردند و روش را روی مجموعه‌های ناپایدار با 62,87 واحد درصد داده برچسب‌خورده F1 ارزیابی کردند. مقاله دست‌کم 1,2 واحد درصد بهبود HDFS کمتر و در برخی تنظیم‌ها تا 13 واحد درصد بهبود را گزارش می‌کند [10]. مطالعه دیگر همین گروه مقایسه انجام داد و برتری تنظیم LOGEVOL را روی نسخه‌های ناپایدار GPT-4 و مهندسی پرامپت GPT-3 تنظیم اختصاصی را در پروتکل خود گزارش کرد [11]

SemiRALD و BiLSTM و RoBERTa و یادگیری درون‌متنی برای تجزیه، سپس ChatGPT از LogParser-LLM برای 7,3 F1 میانگین بهبود BGL و HDFS توجه‌محور برای تشخیص نیمه‌منظارتی استفاده می‌کند و روی و 8,2 درصد را نسبت به دو گروه خطایها گزارش کرده است [16]. بنابراین واژه «ترکیبی» در این گروه یا ترکیب مرحله تجزیه و طبقه‌بندی اشاره کند و باید، LLM می‌تواند به ترکیب چند مدل، ترکیب بازیابی و برای هر مطالعه به‌طور عملیاتی تعریف شود

تجزیه، انتقال، تبیین و کاربرد عملی ۲-۳-۵

مستقیماً آشکارساز ناهنجاری نیستند، اما مرحله ورودی تحلیل لاگ را هدف LogPPT و LogParser-LLM Group با 32 نمونه برچسب‌خورده روی 16 مجموعه به میانگین بیش از 0,9 برای LogPPT می‌گیرند را LLM با درخت پیشوند، فراخوانی LogParser-LLM رسیده و Parsing Accuracy و Accuracy در مقیاس میلیون‌ها پیام محدود کرده است [18، 19]. این نتایج برای نرمال‌سازی و بازاستفاده تصمیم سطح قالب اهمیت دارند

و استخراج ویژگی یکپارچه بین سامانه‌ها، انتقال آشکارساز LLM با تفسیر رخداد به‌وسیله LogSynergy بیش از 89 درصد روی داده واقعی و F1 به سامانه جدید را بررسی کرده و با 5000 توالی برچسب‌خورده تجزیه تطبیقی، ویژگی‌های LogLAA بیش از 83 درصد روی داده عمومی گزارش کرده است [20] برای تولید توضیح را در یک چارچوب LLM دوتوجهی و CNN-LSTM، شمارشی، ترتیبی و معنایی یکپارچه قرار داده است [21]

را فقط با توالی‌های LogBERT و همکاران AIOPS، De la Cruz Cabello در مطالعه کاربرد واقعی آموزش و به‌صورت محلی مستقر کردند. پنجره ۱۵ ثانیه‌ای با همپوشانی ۱۰ ثانیه Linux syslog عادی بهترین موازنه گزارش‌شده بین اثربخشی و تأخیر بود و ارزیابی کیفی متخصصان کاربرد عملی روش را تأیید آموزش‌دیده LogBERT کرد [۲۷]. این مطالعه بر محرمانگی و استقرار محلی تأکید دارد، ولی طبقه‌بند آن دستورمحور بدون تنظیم LLM است، نه یک

دسته‌بندی، جدول مقایسه و تحلیل ۲-۴

در تشخیص ناهنجاری، مطالعات بررسی‌شده را LLM براساس مرور نظام‌مند حوزه لاگ و رده‌بندی نقش LLM، می‌توان در چهار مسیر اصلی قرار داد: مدل‌سازی توالی، مدل زبانی پیش‌آموزش‌دیده با آموزش مقصد مبتنی بر پرامپت، بازیابی یا همکاری مدل‌ها [۲۲، ۲۴]. شکل ۱-۲ رابطه این LLM با تنظیم یا انتقال، و مسیرها و مؤلفه‌هایی را که در پژوهش حاضر کنار هم قرار می‌گیرند نشان می‌دهد.

ادبیات تشخیص ناهنجاری لاگ			
روش‌های ترتیبی	مدل‌های پیش‌آموزش‌دیده	با آموزش/تنظیم LLM	پرامپت، بازیابی و ترکیب
مدل‌سازی توالی DeepLog؛ رخداد	LogBERT، BERT-Log و LogFiT	LogGPT، LogLLM، LLM- LADE و PEFT	LogPrompt، RAGLog، AdaptiveLog و FlexLog
نرمال‌سازی قالب + کنترل تصمیم + کاهش فراخوانی مدل + LLM همگرایی مؤلفه‌های موردنیاز: معنانشناسی			
دامنه و ورودی	دو مسیر تصمیم	کارایی و قابلیت بازتولید	استقرار و ارزیابی
تصمیم خطبه‌خط؛ BGL فقط حذف برجسب از ورودی	قاعده قطعی سپس Hybrid: LLM تصمیم صرفاً در: Prompt-only؛ پرامپت	کش سطح قالب نرمال‌شده؛ نسخه‌بندی JSON اعتبارسنجی کلید کش	روی Qwen۲، ۵:۷B-Instruct Ollama، محلی؛ Accuracy، Precision، Recall، F۱، زمان INVALID و

شکل ۱-۲: دسته‌بندی پژوهش‌های تشخیص ناهنجاری لاگ و جایگاه پژوهش حاضر

در شکل ۱-۲، مسیر بالایی تحول روش‌ها را نمایش می‌دهد و بخش پایینی مشخصات عملیاتی پژوهش حاضر را از ادبیات متمایز می‌کند. قرارگرفتن یک مطالعه در یک دسته به معنای نبود اجزای دسته دیگر نیست؛ بازیابی و کش را به‌کار می‌گیرد [۱۰] و LLM، هم مدل‌های یادگیری ماشین و هم FlexLog برای نمونه را به مدل ترتیبی پیوند می‌دهد [۱۶] ChatGPT تجزیه با SemiRALD

جدول ۱-۲: مقایسه مطالعات منتخب در تشخیص ناهنجاری و تحلیل لاگ

مطالعه	سال	روش/مدل	داده‌ها	واحد تحلیل	نوع انطباق	یافته با کارکرد گزارش‌شده
DeepLog [۱]	۲۰۱۷	پیش‌بینی رخداد LSTM و بعدی	HDFS، OpenStack	توالی	آموزش روی عادی	تشخیص برخط و به‌روزرسانی افز‌ایشی
LogBERT [۲]	۲۰۲۱	با دو هدف BERT خودنظارتی	HDFS، BGL، Thunderbird	توالی	آموزش روی عادی	یادگیری زمینه دوطرفه و الگوی مشترک عادی
BERT-Log [۳]	۲۰۲۲	و طبقه‌بند متصل BERT	HDFS، BGL	توالی/پنجره	تنظیم نظارت‌شده	BGL گزارش‌شده ۹۹،۴٪ روی F۱
LogGPT (Han) [۴]	۲۰۲۳	پیش‌بینی رخداد و RL	HDFS، BGL، Thunderbird	توالی	آموزش و RL	هم‌راستاسازی هدف تولید با تشخیص
LogLLM [۵]	۲۰۲۴	نگاشت + BERT + LLaMA	چهار مجموعه شامل BGL	توالی	آموزش چندمرحله‌ای	با طبقه‌بند BERT ترکیب بازنمایی LLaMA
LogGPT (Qi) [۶]	۲۰۲۳	و پرامپت ChatGPT	BGL، Spirit	خط/پنجره	بدون تنظیم	بررسی پرامپت، دانش دامنه و تبیین
LogPrompt [۷]	۲۰۲۴	راهنمای پرامپت و تبیین	مجموعه لاگ ۹	قالب/توالی	بدون آموزش درون‌دامنه	تا ۵۵،۹٪ بهبود و امتیاز تبیین ۴۰۴۲/۵

مطالعه	سال	روش/مدل	داده‌ها	واحد تحلیل	نوع انطباق	یافته یا کارکرد گزارش شده
RAGLog [۸]	۲۰۲۳	و پایگاه برداری عادی RAG	BGL، Thunderbird	توالی	بدون تنظیم	بازبایی نمونه عادی برای تصمیم معنایی
Hybrid Prompting [۹]	۲۰۲۵	+ پرامپت رخداد + توالی نمونه	HDFS، BGL، Thunderbird	توالی یک‌دقیقه‌ای	بدون تنظیم طبقه‌بند	F۱ میانگین ۹۰٫۹۳ واحد درصد بهبود
FlexLog [۱۰]	۲۰۲۴/۲۵	ML ensemble + Mistral + RAG + cache	چهار مجموعه ناپایدار	توالی	داده کم/درون‌متنی	کاهش داده برجسته‌شده و استنتاج کمتر از یک ثانیه
Unstable Logs GPT [۱۱]	۲۰۲۴	GPT-۳ تنظیم‌شده و GPT-۴ پرامپت	LOGEVOL-Hadoop	توالی	تنظیم/پرامپت	برتری تنظیم در پروتکل لاگ ناپایدار
AdaptiveLog [۱۲]	۲۰۲۵	+ LLM + مدل کوچک بازیابی	چند وظیفه لاگ	وابسته به وظیفه	همکاری تطبیقی	LLM تا ۷۳٪ کاهش هزینه فراخوانی
LogFiT [۱۳]	۲۰۲۵	top-k مدل ماسک‌شده و	HDFS، BGL، Thunderbird	توالی	تنظیم روی عادی	تشخیص خودنظارتی بدون ناهنجاری برجسته‌شده
PEFT-LAD [۱۴]	۲۰۲۵	روی چند LoRA/ReFT LM	HDFS، BGL، Spirit، Thunderbird	توالی	تنظیم پارامترکارا	تحلیل پایداری، کارایی نمونه و انتقال
LLM-LADE [۱۵]	۲۰۲۵	+ LoRA + افزایش داده بهینه‌سازی برخط	مجموعه‌های عمومی لاگ	پیام/توالی	PEFT	تشخیص و تبیین همزمان
SemiRALD [۱۶]	۲۰۲۵	ChatGPT parsing + RoBERTa + BiLSTM	HDFS، BGL	توالی	نیم‌نظارتی	به‌ویژه با داده کم F۱ بهبود متوسط
ADALog [۱۷]	۲۰۲۵	و DistilBERT MLM استاندارد تطبیقی	BGL، Thunderbird، Spirit	خط	تنظیم روی عادی	و مستقل از توالی parser بدون
LogParser-LLM [۱۸]	۲۰۲۴	درخت پیشوند + LLM	Loghub-۲k، LogPub	خط/قالب	بدون آموزش برجسته	گرومبندی F۱ کاهش فراخوانی؛ ۹۰٫۶٪
LogPPT [۱۹]	۲۰۲۳	پرامپت‌تیونینگ RoBERTa	مجموعه ۱۶	خط/قالب	؛ Few-shot۳۲ نمونه	بیش از ۰٫۹ میانگین دقت گروه/تجزیه
LogSynergy [۲۰]	۲۰۲۵	و انتقال LLM تفسیر	عمومی و واقعی	توالی	انتقال با ۵۰۰۰ برجسته	بیش از ۸۳٪ عمومی و ۸۹٪ واقعی F۱
LogLAA [۲۱]	۲۰۲۶	parser + CNN-LSTM + LLM explanation	چند مجموعه عمومی	توالی	آموزش چندجزئی	تشخیص یکپارچه و تولید توضیح
واقعی AIOps [۲۷]	۲۰۲۶	محلی LogBERT	Linux syslog واقعی	پنجره زمانی	خودنظارتی	استقرار محلی تحت محدودیت محرمانگی

در بسیاری از مطالعات حضور دارد، اما پروتکل‌های آن یکسان نیستند BGL جدول ۲-۱ نشان می‌دهد که برخی پیام را مستقیماً طبقه‌بندی می‌کنند، برخی پنجره زمانی یا توالی مبتنی بر گره می‌سازند و برخی فقط به‌تنهایی BGL بخشی نمونه‌گیری‌شده را ارزیابی می‌کنند [۲، ۳، ۶، ۹، ۱۷]. بنابراین استفاده مشترک از نام هم‌ارزی آزمایش‌ها را تضمین نمی‌کند.

از نظر انطباق مدل، چهار حالت قابل مشاهده است: آموزش از ابتدا یا روی عادی، تنظیم نظارت‌شده یا پارامترکارا، پرامپت بدون تغییر وزن و همکاری چند مدل. پژوهش حاضر در حالت پرامپت بدون تغییر وزن قرار می‌گیرد، ولی با نرمال‌سازی و کش قطعی در سطح قالب و دو مسیر تصمیم کنترل‌شده تکمیل می‌شود. این ترکیب در جدول ۲-۲ با نزدیک‌ترین مطالعات مقایسه شده است.

جدول ۲-۲: مقایسه سازوکار مطالعات نزدیک با مؤلفه‌های پژوهش حاضر

مطالعه	سازوکار اصلی	سطح تصمیم	کنترل هزینه	نوع استقرار	تفاوت با پژوهش حاضر
LogGPT (Qi) [۶]	ChatGPT پرامپت	خط/پنجره	نمونه‌گیری به علت محدودیت API	خدمت تجاری	محلی، کش قالب و Qwen فاقد guard مقایسه
LogPrompt [۷]	راهبرد پرامپت و تبیین	قالب/توالی	بدون کش عملیاتی محور مقایسه	های مختلف LLM	تمرکز بر راهبرد پرامپت، نه cache و guard آبشار
RAGLog [۸]	بازیابی لاگ عادی	توالی	retrieval کاهش زمینه با	بیرونی LLM	پایگاه برداری نمونه است، نه کش تصمیم قالب
Hybrid Prompting [۹]	ترکیب شواهد در پرامپت	توالی	بازیابی نزدیک‌ترین نمونه	GPT-4o-mini	به معنای ترکیب Hybrid پرامپت و در سطح توالی است
FlexLog [۱۰]	ensemble + LLM + RAG + cache	توالی	ML کش و واگذاری به	Mistral	داده‌های ناپایدار و ترکیب چند خط‌محور BGL طبقه‌بند؛ نه
AdaptiveLog [۱۲]	LLM + مدل کوچک	چند وظیفه	فراخوانی براساس عدم قطعیت	همکاری دو مدل	به مدل کوچک آموزش‌دیده نیاز دارد
ADALog [۱۷]	و آستانه تطبیقی MLM	خط	مولد فراخوانی LLM نمی‌شود	مدل محلی	fine-tuning نیازمند ؛ فاقد پرامپت DistilBERT دودویی
LogParser-LLM [۱۸]	LLM + درخت پیشوند	قالب	تجمیع در درخت و فراخوانی محدود	قابل انتخاب LLM	هدف تجزیه است؛ تصمیم ناهنجاری تولید نمی‌کند
AIOPS [۲۷] واقعی	محلی LogBERT	پنجره	تنظیم پنجره و مدل خودنظارتی	کاملاً محلی	syslog، مدل آموزش‌دیده روی دستور‌محور Qwen نه
پژوهش حاضر	Hybrid دو روش و Prompt-only	خط BGL	نرمال‌سازی + کش تصمیم قالب	روی Qwen ۲.۵:۷B Ollama	guard مقایسه کنترل‌شده بیرونی با قاعده درون پرامپت

بر رفتار پرامپت LogGPT و LogPrompt: مطالعات نزدیک هرکدام بخشی از مسئله را پوشش داده‌اند، بر واگذاری تطبیقی AdaptiveLog، بر ترکیب کش و مدل‌های کلاسیک FlexLog، بر بازیابی RAGLog، بر کاهش فراخوانی در سطح قالب تمرکز دارند [۶-۱۰، ۱۲، ۱۸]. در مجموعه منابع LogParser-LLM و قطعی بیرون guard بررسی‌شده، مقایسه کنترل‌شده دو مسیر با مدل، داده، نرمال‌سازی و کش یکسان—یکی با مدل و دیگری با انتقال همان دانش به پرامپت—به‌صورت مستقیم گزارش نشده است.

۲-۵ شکاف تحقیقاتی و جایگاه پژوهش حاضر

مربوط است. نتایج خط‌محور، پنجره مبتنی بر گره BGL نخستین شکاف به ناهمگونی واحد تحلیل و پروتکل پنجره یک‌دقیقه‌ای و توالی پنج‌دقیقه‌ای در ادبیات با یک نام مجموعه داده گزارش شده‌اند [۲، ۳، ۹، ۱۷]. این به ورودی و گزارش ماتریس BGL وضعیت نیازمند تعریف صریح واحد تصمیم، جلوگیری از ورود برچسب اغتشاش در سطح همان واحد است. پژوهش حاضر واحد تصمیم را خط تعیین می‌کند و برچسب را فقط برای ارزیابی نگه می‌دارد.

دومین شکاف، تفکیک اثر کیفیت تشخیص از هزینه استنتاج است. برخی مطالعات کش، بازیابی یا مدل کوچک به‌کار برده‌اند [۱۰، ۱۲، ۱۸]، اما نرخ برخورد کش، منبع هر تصمیم، زمان LLM را برای کاهش تماس با گزارش نمی‌شود. در F1 و Accuracy، Precision، Recall همیشه در کنار INVALID پاسخ و نرخ یا بازاستفاده guard، پژوهش حاضر این متغیرها بخشی از خروجی آزمایش‌اند تا معلوم شود هر بهبود از مدل تصمیم ناشی شده است.