

لاگ سیستمی گزارشی متنی یا نیمه‌ساخت‌یافته از رخدادهای زمان اجراست. این گزارش می‌تواند وضعیت یک مؤلفه، پیام هشدار، نتیجه^{۱۵} یک عملیات یا اطلاعات لازم برای عیب‌یابی را ثبت کند. از آنجا که زیرساخت‌های نرم‌افزاری و محاسباتی در هر لحظه شمار زیادی از این پیام‌ها را تولید می‌کنند، لاگ یکی از منابع اصلی پایش سلامت سامانه، تشخیص خطا و یافتن علت ریشه‌ای رخدادهاست. افزایش مقیاس سامانه و تنوع قالب‌ها سبب شده است که تحلیل دستی دیگر پاسخ‌گوی جریان پیوسته^{۱۶} داده نباشد [۱۴، ۲۰، ۲۱].

پژوهش در زمینه^{۱۷} تشخیص ناهنجاری لاگ، از قواعد ثابت و روش‌های آماری آغاز شده و سپس به مدل‌های ترتیبی، مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ رسیده است. دیپ‌لاگ با شبکه^{۱۸} حافظه^{۱۹} کوتاه‌مدت بلند^{۲۰}توالی رخدادها را مدل می‌کند؛ لاگ‌برت و برت‌لاگ از بازنمایی رمزگذار دوسویه^{۲۱} بهره می‌گیرند؛ و روش‌هایی مانند LogPrompt، LogGPT، RAGLog و Hybrid Prompting توانایی پیروی از دستور و برداشت معنایی مدل زبانی بزرگ را به کار می‌برند [۱-۶، ۱۲، ۱۸، ۱۹، ۲۱].

نقش مدل زبانی در این مطالعات یکسان نیست. گاهی مدل مستقیماً برچسب عادی یا ناهنجار را تولید می‌کند؛ گاهی برای پیش‌بینی رخداد بعدی آموزش می‌بیند؛ و در برخی چارچوب‌ها وظیفه^{۲۲} تولید داده، توضیح نتیجه یا رسیدگی به نمونه‌های دشوار را بر عهده دارد. مرور نظام‌مند پژوهش‌های لاگ و مرور عمومی تشخیص ناهنجاری نیز همین گوناگونی نقش را یکی از محورهای اصلی دسته‌بندی می‌دانند [۱۴، ۲۷].

در نتیجه، مقایسه^{۲۳} روش‌ها نباید به نام مدل محدود شود. شکل ورودی، واحد تصمیم، نیاز به آموزش، شیوه^{۲۴} آماده‌سازی داده، محل استقرار و روش مهار هزینه نیز باید مشخص باشد. برای مثال، امتیازافیک حاصل از طبقه‌بندی یک پیام با نتیجه^{۲۵} یک پنجره^{۲۶} یک‌دقیقه‌ای یا یک نشست چندرخدادی هم‌معنا نیست. همچنین بازیابی نمونه، حافظه^{۲۷} نهان و ارجاع نمونه به مدل کوچک، با وجود هدف مشترک کاهش هزینه، سازوکارهای متفاوتی دارند [۳، ۱۰، ۱۲، ۱۳].

پژوهش حاضر فقط مجموعه داده^{۲۸} بی‌جی‌ال و مدل کوئن ۲٫۵ دستورمحور را بررسی می‌کند. مدل با اولاما و به‌صورت محلی اجرا می‌شود و وزن‌های آن تغییر نمی‌کنند. مقایسه میان دو روش انجام می‌شود: در روش ترکیبی، قواعد قطعی پیش از فراخوانی مدل اعمال می‌شوند؛ در روش صرفاً مبتنی بر دستور، همان دانش دامنه در متن دستور قرار می‌گیرد. قواعد نرمال‌سازی، حافظه^{۲۹} نهان سطح قالب و اعتبارسنجی خروجی در هر دو روش ثابت‌اند.

این فصل ابتدا مفاهیم نظری موردنیاز را توضیح می‌دهد و سپس هر ۲۷ مقاله^{۳۰} موجود در پوشه^{۳۱} پژوهش را به‌طور مستقل مرور می‌کند. دو منبع [۱] و [۶] که دو نسخه^{۳۲} هم‌پوشان از مسیر پژوهشی LogPrompt هستند نیز جداگانه معرفی می‌شوند، اما در جمع‌بندی شواهد دو روش مستقل به‌شمار نمی‌آیند. پس از مرور مطالعات، دسته‌بندی، جدول مقایسه، شکل ارتباط پژوهش‌ها و شکاف پژوهشی ارائه می‌شود. همه^{۳۳} تعریف‌ها و گزارش نتایج به منابع ارجاع دارند و نتیجه^{۳۴} آزمایش‌های ناتمام پروژه وارد این فصل نشده است.

^{۱۵} Long Short-Term Memory (LSTM)

^{۱۶} Bidirectional Encoder Representations from Transformers (BERT)

۲-۲ مبانی نظری و مفاهیم موردنیاز

۱-۲-۲ ماهیت و ساختار لاگ سیستمی

هر پیام لاگ معمولاً از سرآیند و بدنه تشکیل می‌شود. سرآیند ممکن است زمان، سطح شدت، نام مؤلفه، شناسه^{۱۷} فرایند یا گره را در بر گیرد و بدنه شرح رخداد و مقادیر زمان اجرا را بیان کند. در مطالعات LogPPT و LogParser-LLM، بدنه به دو بخش تقسیم می‌شود: واژه‌های ثابت که «قالب لاگ» را می‌سازند و مقادیر متغیر که «پارامتر» نامیده می‌شوند. شناسه^{۱۸} بلوک، نشانی شبکه، مسیر فایل و زمان نمونه‌هایی از پارامترهای متغیرند [۲۳، ۲۴]. لاگ خام، به سبب وجود اختصارها، کدهای خطا، مقادیر پویا و قالب‌های گوناگون، یک متن طبیعی کامل نیست؛ بالاین‌حال، واژه‌های ثابت و زمینه^{۱۹} عملیاتی آن اطلاعات معنایی ارزشمندی دارند. مدل‌های زبانی این اطلاعات را از متن یا توالی رخدادها استخراج می‌کنند، درحالی‌که بسیاری از روش‌های آماری ابتدا پیام را به شناسه^{۲۰} قالب یا بردار فراوانی تبدیل می‌کنند [۴، ۱۴، ۱۸، ۱۹].

۲-۲-۲ مفهوم ناهنجاری و سطوح تحلیل

در تشخیص ناهنجاری، مشاهده زمانی ناهنجار تلقی می‌شود که با الگوی رفتار عادی یا قواعد ازپیش‌تعریف‌شده سازگار نباشد. شو و دینگ میان تغییری که درون دامنه^{۲۱} شناخته‌شده رخ می‌دهد و داده‌ای که از توزیع آموزش بیرون است^{۲۲} تمایز می‌گذارند. آنان کاربرد مدل زبانی بزرگ را نیز به دو گروه «مدل برای تشخیص» و «مدل برای تولید» تقسیم می‌کنند [۲۷]. در لاگ، ناهنجاری ممکن است در متن یک پیام، فراوانی قالب‌ها، ترتیب رخدادها یا معنای یک پنجره^{۲۳} زمانی آشکار شود [۱۴].

واحد تحلیل در پژوهش‌های این حوزه می‌تواند یک خط، یک قالب، یک پنجره^{۲۴} زمانی، توالی رخدادها یا یک گره یا یک نشست کامل باشد. ADALog پیام را مستقل بررسی می‌کند؛ DeepLog و LogBERT بر توالی تکیه دارند؛ BERT-Log در بی‌جی‌ال پنجره^{۲۵} لغزان مبتنی بر گره می‌سازد؛ و Hybrid Prompting از پنجره^{۲۶} یک‌دقیقه‌ای استفاده می‌کند [۳، ۱۸، ۱۹، ۲۱، ۲۲]. انتخاب واحد تحلیل، تعریف مؤلفه‌های ماتریس اغتشاش^{۲۷} و امکان مقایسه^{۲۸} نتایج را تعیین می‌کند.

۳-۲-۲ مجموعه داده بی‌جی‌ال

مجموعه داده بی‌جی‌ال از ابررایانه^{۲۹} Blue Gene/L در آزمایشگاه ملی لارنس لیورمور گردآوری شده است. این مجموعه ۴۰۷۴۷۰۹۶۳ پیام دارد که ۳۴۸۰۴۶۰ پیام، یعنی حدود ۷۰۳۴ درصد، با برچسب هشدار به‌عنوان ناهنجار مشخص شده‌اند [۲، ۱۸، ۱۹]. برچسب مرجع در ابتدای هر خط قرار دارد. این برچسب برای ارزیابی لازم است، اما ورود آن به متن مدل پاسخ را آشکار می‌کند؛ ازاین‌رو پیش از ساخت ورودی حذف می‌شود. شیوه^{۳۰} استفاده از بی‌جی‌ال در مقالات یکسان نیست. LogBERT پنجره‌های زمانی پنج‌دقیقه‌ای با میانگین ۵۶۲ رخداد می‌سازد؛ BERT-Log پیام‌ها را با شناسه^{۳۱} گره، اندازه^{۳۲} پنجره و گام سازمان می‌دهد؛ Hybrid Prompting

^{۱۷} Out-of-Distribution (OOD)

^{۱۸} True Positive (TP), True Negative (TN), False Positive (FP), False Negative (FN)

پنجره^۱ یک دقیقه‌ای و نمونه‌ای متوازن شامل هزار توالی عادی و هزار توالی ناهنجار به کار می‌گیرد؛ و ADALog پس از پاک‌سازی، پیام‌های یکتای عادی و ناهنجار را در سطح خط بررسی می‌کند [۳، ۱۸، ۱۹، ۲۲]. در مطالعه^۲ LogGPT مبتنی بر ChatGPT، محدودیت نرخ رابط برنامه‌نویسی کاربردی^۱ باعث شده است فقط دو هزار پیام متوالی از بخش آزمون انتخاب شود [۲]. RAGLog نیز برای تشکیل خوشه‌ها و پایگاه برداری از نمونه‌گیری و الگوریتم میانگین‌های کا-بهره می‌گیرد [۱۲]. بنابراین عبارت «ارزیابی روی بی‌جی‌ال» تنها زمانی معنا دارد که واحد تحلیل، روش نمونه‌گیری، اندازه^۳ پنجره و نسبت کلاس‌ها نیز گزارش شوند.

۲-۲-۴ تجزیه، پاک‌سازی و نرمال‌سازی

تجزیه^۴ لاگ فرایندی است که پیام خام را به یک قالب ثابت و فهرستی از پارامترهای متغیر تبدیل می‌کند. روش‌های سنتی برای این کار از فراوانی واژه، شباهت پیام و قواعد نحوی بهره می‌برند. LogPPT مدل RoBERTa را با تنظیم مبتنی بر دستور و شمار اندکی نمونه برای شناسایی توکن‌های پارامتر سازگار می‌کند. LogParser-LLM نیز توان معنایی مدل زبانی بزرگ را با درخت پیشوند ترکیب می‌کند تا تنها الگوهای تازه یا مبهم به مدل فرستاده شوند [۲۳، ۲۴].

نرمال‌سازی در این پژوهش جایگزین یک تجزیه‌گر خوشه‌بندی شده^۵ کامل^۶ نیست؛ بلکه مجموعه‌ای از قواعد قطعی است که مقادیر پویا را به جانشین‌های ثابت تبدیل می‌کند تا یک قالب پایدار برای حافظه^۷ نهان ساخته شود. شناسه^۸ گره، نشانی شبکه، مقدار شانزده‌شانزده‌ی، تاریخ، زمان، مسیر و اعداد پویا پوشانده می‌شوند. با این حال، صفر و غیرصفر جدا می‌مانند؛ زیرا در برخی رخدادها همین تفاوت عددی حامل معنای عملیاتی است. این تصمیم با اصل جداسازی قالب و پارامتر در مطالعات تجزیه سازگار است [۲۳، ۲۴].

کیفیت نرمال‌سازی بر دو جنبه اثر می‌گذارد: میزان اطلاعاتی که برای تشخیص باقی می‌ماند و تعداد قالب‌های یکتایی که باید به مدل فرستاده شود. پوشاندن بیش‌ازحد ممکن است نشانه‌ای معنادار را حذف کند؛ پوشاندن کمتر از حد نیز پیام‌های هم‌معنا را به کلیدهای جدا تبدیل می‌کند. LogLAA و LogParser-LLM نیز نشان می‌دهند که دانه‌بندی نامناسب قالب می‌تواند کیفیت تحلیل مرحله^۹ بعد را کاهش دهد [۱۷، ۲۳].

۲-۲-۵ پارادایم‌های یادگیری در تشخیص ناهنجاری لاگ

در یادگیری نظارت‌شده، مرز تصمیم با نمونه‌های عادی و ناهنجار برچسب‌خورده آموخته می‌شود؛ BERT-Log نمونه‌ای از این رویکرد است [۱۸]. یادگیری نیمه‌نظارتی مقدار اندکی داده^{۱۰} برچسب‌خورده را با داده^{۱۱} بدون برچسب ترکیب می‌کند و SemiRALD از همین الگو بهره می‌برد [۱۶]. در یادگیری خودنظارتی، مدل با وظیفه‌ای کمکی، مانند پیش‌بینی بخش پوشانده‌شده^{۱۲} پیام، الگوی عادی را فرا می‌گیرد؛ LogFiT، LogBERT و ADALog در این گروه قرار دارند [۸، ۱۹، ۲۲].

^۱Application Programming Interface (API)

^۲K-means

^۳Log Parser

سازگار کردن مدل زبانی با دامنه می‌تواند به سه صورت انجام شود: تنظیم کامل وزن‌ها، تنظیم کارآمد پارامترها^{۳۳} یا یادگیری از نمونه‌ها و دستورهای داخل متن. LogLLM و LogGPT آموزش اختصاصی دارند. LLM-LADE و مطالعه^{۳۴} لیم و همکاران از سازگارسازی کم‌رتبه^{۳۳}، تنظیم بازنمایی^{۳۴} یا روش‌های مشابه استفاده می‌کنند. در مقابل، LogPrompt و LogGPT مبتنی بر ChatGPT بدون تغییر وزن مدل، وظیفه و نمونه‌ها را در متن دستور قرار می‌دهند [۱، ۲، ۴-۷، ۹].

۶-۲-۲ مدل‌های ترتیبی، معماری ترنسفورمر و مدل‌های زبانی

مدل ترتیبی می‌کوشد احتمال رخداد بعدی یا سازگاری کل توالی را برآورد کند. DeepLog با شبکه^{۳۵} حافظه^{۳۶} کوتاه‌مدت بلند رخداد بعدی را از تاریخچه پیش‌بینی می‌کند و انحراف از رخداد‌های محتمل را نشانه^{۳۷} ناهنجاری می‌داند [۲۱]. معماری ترنسفورمر^{۳۸} با سازوکار توجه، استفاده از زمینه^{۳۹} دورتر و پردازش موازی را ممکن می‌سازد. LogBERT با زمینه^{۴۰} دوسویه و دو هدف خودنظارتی، و BERT-Log با بازنمایی زبانی و یک طبقه‌بند، این معماری را برای لاگ به کار گرفته‌اند [۱۸، ۱۹].

مدل‌های زبانی بزرگ دستورمحور معمولاً بر ترنسفورمر خودبازگشتی تکیه دارند و پاسخ را با توجه به دستور متنی تولید می‌کنند. مقاله^{۴۱} YuLan ساخت یک مدل متن‌باز دوازده‌میلیارد پارامتری را در سه مرحله^{۴۲} پیش‌آموزی، تنظیم دستوری و هم‌ترازی انسانی شرح می‌دهد و توانایی یادگیری درون‌متنی را از پیامدهای پس‌آموزی می‌داند [۲۶]. YuLan آشکار ساز لاگ نیست و در این فصل فقط برای توضیح منشأ دستورپذیری مدل‌های زبانی به کار می‌رود.

۷-۲-۲ نقش مدل زبانی بزرگ در فرایند تحلیل لاگ

مدل زبانی بزرگ می‌تواند در زنجیره^{۴۳} تحلیل لاگ نقش تجزیه‌گر، طبقه‌بند، مولد داده، توضیح‌دهنده یا هماهنگ‌کننده را داشته باشد. LogParser-LLM و LogPPT قالب پیام را استخراج می‌کنند [۲۳، ۲۴]. LogGPT، LogPrompt و Hybrid Prompting تصمیم تشخیص را مستقیماً از مدل می‌گیرند [۱-۳، ۶]. LLM-LADE از مدل برای افزایش داده و تولید توضیح استفاده می‌کند و LogLAA پس از تشخیص، شرح رخداد را می‌سازد [۷، ۱۷].

در سامانه‌های چندمدلی، لازم نیست همه^{۴۴} نمونه‌ها به مدل بزرگ فرستاده شوند. AdaptiveLog عدم قطعیت مدل کوچک را ملاک ارجاع قرار می‌دهد [۱۳]. FlexLog خروجی چند مدل یادگیری ماشین را با Mistral، بازیابی و حافظه^{۴۵} نهان ترکیب می‌کند [۱۰]. LogSynergy نیز با تفسیر معنایی رخدادها، بازنمایی ای می‌سازد که میان سامانه‌های گوناگون قابل انتقال باشد [۱۵].

Parameter-Efficient Fine-Tuning (PEFT)^{۳۳}

Low-Rank Adaptation (LoRA)^{۳۴}

Representation Fine-Tuning (ReFT)^{۳۴}

Transformer^{۳۵}

۸-۲-۲ مدل دستورمحور کوئن ۲۰۵ با هفت میلیارد پارامتر

خانواده کوئن ۲۰۵ شامل مدل‌های پایه و دستورمحور با اندازه‌های ۰.۵ تا ۷۲ میلیارد پارامتر است. گزارش فنی این خانواده، پیش‌آموزی بر حدود ۱۸ تریلیون توکن و پس‌آموزی با بیش از یک میلیون نمونه تنظیم دستوری و مراحل تقویت یادگیری را شرح می‌دهد. نسخه هفت میلیارد پارامتری حدود ۶۰۵ میلیارد پارامتر غیرتعبیه‌ای دارد و نسخه دستورمحور برای پیروی از فرمان و تولید پاسخ ساخت‌یافته آماده شده است [۲۸].

در پژوهش حاضر، وزن‌های کوئن ۲۰۵ ثابت می‌مانند و تنظیم دقیق انجام نمی‌شود. نسخه مدل، شیوه کوانتیزه‌سازی^{۲۶}، دما و گزینه‌های تولید نیز در هر دو روش یکسان‌اند؛ زیرا در غیر این صورت نمی‌توان تفاوت خروجی را فقط به محل اعمال قاعده نسبت داد. Hybrid Prompting برای تعبیه از Qwen-Embedding-۸B و برای تصمیم از GPT-۴o-mini استفاده کرده است؛ بنابراین نقش و ترکیب مدل‌های آن با پژوهش حاضر یکسان نیست [۳].

۹-۲-۲ مهندسی دستور، یادگیری درون‌متنی و قرارداد خروجی

دستور متنی باید وظیفه، معنای برچسب‌ها، دانش لازم، نمونه‌های احتمالی و قالب پاسخ را روشن کند. مطالعه LogGPT مبتنی بر ChatGPT اثر نوع دستور، اندازه پنجره، دانش انسانی، مقایسه با روش‌های عمیق و توضیح‌پذیری را بررسی می‌کند [۲]. LogPrompt نیز دستور ساده، دستور غنی‌شده با دانش دامنه و زنجیره استدلال را در وظایف تجزیه و تشخیص با یکدیگر می‌سنجد [۱، ۶].

در یادگیری چندنمونه‌ای^{۲۷}، چند نمونه برچسب‌خورده در خود دستور قرار می‌گیرند و وزن مدل تغییر نمی‌کند. RAGLog نمونه عادی مرتبط را از پایگاه برداری بازیابی می‌کند [۱۲] و Hybrid Prompting نزدیک‌ترین نمونه عادی را همراه شواهد رخداد و توالی در اختیار مدل می‌گذارد [۳]. OpsEval نیز اثر خودسازگاری^{۲۸}، زنجیره استدلال^{۲۹} و یادگیری درون‌متنی^{۳۰} را در وظایف عملیات فناوری اطلاعات به‌طور مستقل بررسی می‌کند [۲۵].

در پژوهش حاضر فقط دو پاسخ ساخت‌یافته، با برچسب صفر یا یک، پذیرفته می‌شود. متن افزوده، ساختار ناقص یا برچسبی غیر از این دو «پاسخ نامعتبر»^{۳۱} به‌شمار می‌رود و در حافظه نهان ذخیره نمی‌شود. مستندات اولاما امکان تعیین ساختار پاسخ و استفاده از دمای صفر برای کاهش نویسن را توضیح می‌دهند [۲۹]. برنامه پاسخ را مستقل از ظاهر آن تجزیه و اعتبارسنجی می‌کند.

^{۲۶}Quantization

^{۲۷}Few-shot Learning

^{۲۸}Self-Consistency

^{۲۹}Chain-of-Thought (CoT)

^{۳۰}In-Context Learning (ICL)

^{۳۱}INVALID

۲-۲-۱۰ بازیابی، کش و کنترل هزینه استنتاج

بازیابی و حافظه^۳ نهان دو کار متفاوت انجام می‌دهند. در تولید تقویت‌شده با بازیابی^۳، نمونه یا دانش مرتبط برای غنی کردن زمینه^۳ دستور انتخاب می‌شود؛ RAGLog و AdaptiveLog از این الگو بهره می‌برند [۱۲، ۱۳]. حافظه^۳ نهان، تصمیم معتبر مربوط به یک ورودی پایدار را نگه می‌دارد تا هنگام تکرار همان ورودی، مدل دوباره فراخوانی نشود. FlexLog هر دو سازوکار را در کنار مدل‌های یادگیری ماشین به کار می‌گیرد [۱۰]. حافظه^۳ نهان این پژوهش در سطح قالب نرمال شده عمل می‌کند. کلید آن نسخه^۳ دستور، نام و نسخه^۳ مدل، متن قالب و در صورت فعال بودن، مؤلفه، شدت و دسته^۳ رخداد را در بر می‌گیرد. به این ترتیب، تصمیم یک مدل یا دستور قدیمی به اجرای تازه راه نمی‌یابد. شمار کلیدهای یکتا، تعداد برخورد و عدم برخورد و منبع هر تصمیم جداگانه ثبت می‌شود.

AdaptiveLog با سپردن نمونه‌های نامطمئن به مدل بزرگ، کاهش هزینه^۳ فراخوانی تا ۷۳ درصد را گزارش کرده است [۱۳]. LogParser-LLM نیز با درخت پیشوند و تجمیع پیام‌های مشابه، برای مجموعه‌های LogPub با میانگین ۳۰۶ میلیون پیام، به‌طور متوسط فقط ۲۷۲٫۵ بار مدل زبانی بزرگ را فراخوانده است [۲۳]. این نتایج نشان می‌دهند که شمار فراخوانی و زمان اجرا باید در کنار معیارهای طبقه‌بندی گزارش شوند.

۲-۲-۱۱ استنتاج محلی با اولاما

اولاما اجرای محلی مدل و دسترسی نرم‌افزار از طریق یک رابط برنامه‌نویسی را فراهم می‌کند. پاسخ این رابط می‌تواند زمان کل، زمان بارگذاری، شمار توکن‌های ورودی و خروجی و مدت ارزیابی را گزارش کند [۲۹]. ثبت این اطلاعات امکان می‌دهد زمان بارگذاری مدل از زمان پردازش دستور و تولید پاسخ جدا شود. استقرار محلی مانع ارسال لاگ به یک خدمت بیرونی می‌شود و کنترل نسخه^۳ مدل را در اختیار پژوهشگر قرار می‌دهد. دلا کروز کابل و همکاران نیز LogBERT را در محیطی با محدودیت محرمانگی به‌صورت درون‌سازمانی مستقر کرده‌اند [۲۰]. تفاوت آن مطالعه با پژوهش حاضر در نوع مدل و شیوه^۳ آموزش است: مدل آنان با لاگ‌های عادی سامانه^۳ واقعی آموزش می‌بیند، اما کوئن در این پژوهش بدون تنظیم اختصاصی اجرا می‌شود.

۲-۲-۱۲ دو معماری ترکیبی و صرفاً مبتنی بر دستور در پژوهش حاضر

در روش ترکیبی، پس از استخراج فیلدها، حذف برچسب و نرمال‌سازی، ابتدا حافظه^۳ نهان بررسی می‌شود. اگر کلید وجود نداشته باشد، مجموعه‌ای محدود از قواعد قطعی و پُر اطمینان اجرا می‌شود. تنها نمونه‌هایی که نگهبان قاعده‌محور درباره^۳ آن‌ها تصمیمی ندارد به کوئن فرستاده می‌شوند. پاسخ معتبر در حافظه^۳ نهان قرار می‌گیرد و منبع تصمیم به‌صورت «حافظه^۳ نهان»، «قاعده» یا «مدل زبانی» ثبت می‌شود.

در روش صرفاً مبتنی بر دستور، نگهبان قاعده‌محور غیرفعال است و دانش دامنه در متن دستور نوشته می‌شود. نرمال‌سازی، حافظه^۳ نهان، نسخه^۳ مدل، قرارداد خروجی و ترتیب داده تغییر نمی‌کنند؛ بنابراین متغیر اصلی، محل

اعمال دانش قاعده است. اصطلاح «ترکیبی» در این پایان نامه با Hybrid Prompting تفاوت دارد؛ مقاله [۳] شواهد رخداد، توالی و نمونه بازیابی شده را در یک دستور ترکیب می کند و تصمیم را در سطح توالی می گیرد.

۲-۲-۱۳ معیارهای ارزیابی

در طبقه بندی دودویی، مثبت واقعی به ناهنجاری درست شناسایی شده، منفی واقعی به پیام عادی درست، مثبت کاذب به پیام عادی با برچسب ناهنجار و منفی کاذب به ناهنجاری از دست رفته گفته می شود. صحت نسبت همه تصمیم های درست است؛ دقت سهم پیش بینی های ناهنجاری درست را نشان می دهد؛ بازخوانی سهم ناهنجاری های کشف شده است؛ و امتیاز افیک میانگین هارمونیک دقت و بازخوانی است [۲، ۳، ۱۸].

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP) \quad \text{Recall} = TP / (TP + FN) \quad F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

به دلیل نامتوازن بودن بی جی ال، گزارش صحت به تنهایی کافی نیست و باید دقت، بازخوانی، امتیاز افیک و ماتریس اغتشاش نیز ارائه شوند. نرخ پاسخ نامعتبر، زمان پاسخ، شمار فراخوانی مدل، منبع تصمیم و نرخ استفاده از حافظه نهان نیز برای این پژوهش ضروری اند؛ و گرنه ممکن است کاهش فراخوانی ناشی از حافظه نهان یا قاعده با بهبود توان طبقه بندی مدل اشتباه گرفته شود.

۲-۲-۱۴ انواع الگوهای ناهنجاری در لاگ

ناهنجاری رخدادی هنگامی دیده می شود که خود یک پیام یا قالب، مستقل از پیام های پیرامون، نشانه وضعیت غیرعادی باشد. عبارت خطا، توقف مؤلفه، خرابی سخت افزار یا کد بازگشتی غیرمنتظره از نمونه های این نوع اند. ADALog احتمال بازسازی توکن های هر پیام را به امتیازی در سطح خط تبدیل می کند [۲۲]. طبقه بندی خط به خط پژوهش حاضر نیز در درجه نخست همین سطح را هدف می گیرد.

در ناهنجاری ترتیبی، هر رخداد ممکن است به تنهایی عادی باشد، اما ترتیب یا فاصله زمانی رخدادها با الگوی عادی سازگار نیست. DeepLog با پیش بینی رخداد بعدی و LogBERT با یادگیری زمینه دوسویه این نوع انحراف را بررسی می کنند [۱۹، ۲۱]. Hybrid Prompting نیز اطلاعات توالی را همراه رخداد های پیش تر دیده نشده در دستور قرار می دهد [۳].

ناهنجاری کمی به افزایش یا کاهش غیرعادی فراوانی یک یا چند قالب در یک بازه مربوط است. روش های مبتنی بر بردار شمارش و برخی مدل های ترکیبی، فراوانی را در کنار ترتیب یا معنا به کار می گیرند. LogLAA بازنمایی های شمارشی، ترتیبی و معنایی را هم زمان وارد آشکارساز می کند [۱۷]. در این پایان نامه شمارش پنجره مستقیماً به کوئن داده نمی شود و این محدودیت باید هنگام تحلیل خطا در نظر گرفته شود.

ناهنجاری معنایی زمانی رخ می دهد که ساختار ظاهری پیام به نمونه های عادی شبیه باشد، اما واژه یا مقدار موجود در آن معنای نامطلوبی داشته باشد. LogPrompt، RAGLog و LogLLM استفاده از بازنمایی زبانی را برای فهم یا بازیابی چنین تفاوت هایی بررسی کرده اند [۱، ۴، ۶، ۱۲]. جدا نگه داشتن صفر از مقدار غیرصفر در نرمال سازی این پایان نامه با هدف حفظ همین نشانه عملیاتی انجام می شود.

ناپایداری لاگ به تغییر قالب، واژگان یا توزیع رخدادها پس از به‌روزرسانی نرم‌افزار یا تغییر پیکربندی گفته می‌شود. مطالعات مبتنی بر GPT روی LOGEVOL و همچنین LogLLM و FlexLog، این مسئله را با انتقال میان نسخه‌ها، مدل زبانی یا ترکیب چند مدل بررسی کرده‌اند [۴، ۱۰، ۱۱]. بی‌جی‌ال در این پایان‌نامه یک مجموعه ثابت است و آزمون انتقال میان نسخه‌های نرم‌افزار در دامنه پژوهش قرار ندارد.

۲-۲-۱۵ چالش‌های روش‌شناختی و اجرایی

نامتوازن بودن کلاس‌ها نخستین چالش روش‌شناختی است. در بی‌جی‌ال تنها حدود ۷،۳۴ درصد پیام‌ها ناهنجارند [۲، ۱۹]. در چنین وضعی، مدلی که بیشتر پیام‌ها را عادی اعلام کند ممکن است صحت ظاهراً بالایی داشته باشد، اما بخش بزرگی از ناهنجاری‌ها را از دست بدهد. به همین سبب BERT-Log و Hybrid Prompting دقت، بازخوانی و امتیازافیک را در کنار صحت یا به‌جای اتکای صرف به آن گزارش می‌کنند [۳، ۱۸].

چالش دوم، انتقال خطای تجزیه‌گر به مرحله تشخیص است. اگر یک پارامتر به‌اشتباه واژه ثابت تشخیص داده شود یا برعکس، قالب نادرستی به آشکارساز می‌رسد. LogPPT و LogParser-LLM برای سنجش این مسئله از معیارهای صحت گروه‌بندی، صحت تجزیه و دانه‌بندی قالب استفاده می‌کنند [۲۳، ۲۴]. در این پایان‌نامه نیز قواعد نرمال‌سازی باید مستقل از کیفیت طبقه‌بندی ممیزی شوند.

نشت داده ممکن است از ورود برچسب مرجع به متن، هم‌پوشانی آموزش و آزمون یا تکرار یک قالب در دو بخش ایجاد شود. ADALog پیام‌های یکتای عادی را میان آموزش، تعیین آستانه و آزمون جدا می‌کند [۲۲]. در پژوهش حاضر، برچسب بی‌جی‌ال پیش از ساخت دستور حذف می‌شود و حافظه نهان نیز فقط در محدوده اجرای تعریف‌شده و با کلید نسخه‌بندی‌شده به کار می‌رود.

پاسخ یک مدل مولد ممکن است از قرارداد تعیین‌شده پیروی نکند یا میان اجراها تغییر کند. مطالعات مبتنی بر دستور نشان داده‌اند که نحوه بیان وظیفه و درخواست توضیح بر نتیجه اثر می‌گذارد [۱، ۲، ۶، ۲۵]. استفاده از دمای صفر، ساختار جی‌سان، اعتبارسنجی برچسب و ثبت پاسخ نامعتبر، این رفتار را در پژوهش حاضر قابل اندازه‌گیری می‌کند [۲۹].

تبیین‌پذیری در منابع معنای واحدی ندارد. LogPrompt از مدل می‌خواهد دلیل تصمیم را بنویسد [۱، ۶]؛ LLM-LADE تشخیص و توضیح را هم‌زمان آموزش می‌دهد [۷]؛ و LogLAA پس از آشکارسازی، از مدل زبانی برای تولید شرح استفاده می‌کند [۱۷]. خروجی این پایان‌نامه عمداً دودویی است؛ بنابراین تبیین در سطح ثبت منبع تصمیم، قالب نرمال‌شده و قاعده فعال‌شده دنبال می‌شود، نه در قالب توضیح آزاد مدل.

محرمانگی، بازتولیدپذیری و هزینه به یکدیگر وابسته‌اند. در خدمات تجاری، نسخه مدل یا محدودیت نرخ ممکن است تغییر کند؛ در مقابل، استقرار محلی کنترل بیشتری بر مدل و داده فراهم می‌سازد [۲، ۲۰]. البته بازتولید نتیجه محلی نیز مستلزم ثبت سخت‌افزار، شیوه کوانتیزه‌سازی، نسخه اولاما و پارامترهای تولید است [۲۸، ۲۹].

۲-۳ پیشینه تحقیق

۲-۳-۱ دامنه و شیوه مرور مطالعات

پیشینه این فصل همه ۲۷ مقاله موجود در پوشه پژوهش را در بر می گیرد. برای آنکه تفاوت نقش‌ها روشن بماند، مطالعات در شش گروه سامان یافته‌اند: روش‌های ترتیبی و پیش‌آموزش‌دیده؛ آموزش و انتقال مدل زبانی بزرگ؛ روش‌های مبتنی بر دستور؛ بازیابی و مهار هزینه؛ تجزیه لاگ؛ و سرانجام مرورها، معیارها، مدل‌های پایه و مطالعات استقرار. این تقسیم‌بندی با محورهای مرور نظام‌مند لاگ [۱۴] و مرور کاربرد مدل‌های زبانی بزرگ در تشخیص ناهنجاری [۲۷] هم‌خوان است.

منابع [۱] و [۶] دو نسخه هم‌پوشان از یک مسیر پژوهشی با نام LogPrompt هستند. هر دو منبع، برای پوشش کامل مقالات، جداگانه معرفی و در جدول ثبت شده‌اند؛ با این حال در جمع‌بندی، دو روش مستقل محسوب نمی‌شوند. همچنین [۲۵] OpsEval و [۲۶] YuLan مستقیماً آشکارساز لاگ نیستند. اولی برای بحث ارزیابی مدل در عملیات فناوری اطلاعات و دومی برای توضیح مراحل ساخت و دستورپذیر کردن یک مدل متن‌باز استفاده می‌شود.

۲-۳-۲ روش‌های ترتیبی و مدل‌های زبانی پیش‌آموزش‌دیده

دو و همکاران در مقاله DeepLog، لاگ را همچون یک دنباله از رخدادها مدل کردند. شبکه حافظه کوتاه‌مدت بلند با تاریخچه رخدادهای عادی آموزش می‌بیند و چند رخداد محتمل بعدی را پیش‌بینی می‌کند. اگر رخداد واقعی در میان گزینه‌های محتمل نباشد، توالی مشکوک تلقی می‌شود. مقاله علاوه بر تشخیص، به‌روزرسانی تدریجی مدل و ساخت جریان‌های اجرایی برای کمک به عیب‌یابی را نیز توضیح می‌دهد [۲۱].

DeepLog روی HDFS و OpenStack ارزیابی شده و نشان داده است که مدل‌سازی ترتیب رخدادها می‌تواند وابستگی‌هایی را ثبت کند که روش‌های آماری ساده از دست می‌دهند [۲۱]. با این حال، روش به استخراج کلید رخداد و ساخت توالی معتبر وابسته است و برای هر خط به‌طور مستقل تصمیم نمی‌گیرد. از این‌رو در این پایان‌نامه DeepLog یک مبنای مفهومی برای خانواده ترتیبی است، نه روشی با پروتکل ارزیابی یکسان.

گوئو، یوان و وو در LogBERT چارچوبی خودنظارتی با دو هدف طراحی کردند: بازسازی کلید رخداد پوشانده‌شده و فشرده‌کردن بازنمایی توالی‌های عادی در یک ابرکره. زمینه دوسویه BERT اجازه می‌دهد هر رخداد با توجه به رخدادهای پیش و پس از خود بازنمایی شود؛ هدف دوم نیز نمایش توالی‌های عادی را در فضای ویژگی به یکدیگر نزدیک می‌کند [۱۹].

LogBERT روی HDFS، بی‌جی‌ال و Thunderbird آزمایش شده است. در بی‌جی‌ال، پنجره‌های پنج‌دقیقه‌ای ساخته می‌شوند، حدود پنج هزار توالی عادی برای آموزش به کار می‌رود و میانگین طول هر توالی ۵۶۲ رخداد گزارش شده است [۱۹]. نیاز به آموزش با داده عادی و تشکیل پنجره، دو تفاوت اصلی این روش با اجرای بدون تنظیم کوئن و تصمیم خط‌به‌خط پژوهش حاضرند.

چن و لیاو در BERT-Log ابتدا پیام‌های تجزیه‌شده را با BERT بازنمایی کردند و سپس مدل را همراه یک لایه تمام‌متصل برای طبقه‌بندی تنظیم نمودند. توالی‌ها در HDFS با شناسه بلوک و در بی‌جی‌ال با شناسه گره،

اندازه پنجره و گام ساخته می‌شوند. بدین ترتیب، مدل هم محتوای متن و هم زمینه توالی را برای جداسازی رفتار عادی از ناهنجار به کار می‌گیرد [۱۸].

BERT-Log در پروتکل مقاله، امتیاز افیک ۹۹۰۳ درصد برای HDFS و ۹۹۰۴ درصد برای بی‌جی‌ال گزارش کرده است [۱۸]. این اعداد حاصل آموزش نظارت‌شده، تجزیه پیام و پنجره‌بندی ویژه همان مطالعه‌اند و با تشخیص خط‌محور بدون تنظیم دقیق مقایسه مستقیم ندارند. اهمیت این مقاله برای پژوهش حاضر، نشان‌دادن توان بازنمایی زبانی در بی‌جی‌ال و ضرورت گزارش دقیق پروتکل پنجره‌بندی است.

آمودوار و همکاران در LogFit مدل زبانی را با وظیفه مدل‌سازی زبان پوشانده‌شده^۳ و فقط با لاگ‌های عادی سازگار کردند. هنگام آزمون، مدل باید توکن‌های پوشانده‌شده پیام یا توالی را پیش‌بینی کند. اگر توکن واقعی در میان k گزینه برتر^۴ نباشد، شواهد ناهنجاری افزایش می‌یابد [۸].

LogFit روی HDFS، بی‌جی‌ال و Thunderbird بررسی شده و هدف آن کاهش وابستگی به نمونه ناهنجار برچسب‌خورده است [۸]. هرچند این روش از یک مدل زبانی استفاده می‌کند، مدل آن مولد و دستورمحور نیست و باید با لاگ مقصد تنظیم شود. در مقابل، پژوهش حاضر وزن‌های کوئن را ثابت نگه می‌دارد و برچسب دودویی را از پاسخ دستور متنی استخراج می‌کند.

پوسپیشنی و همکاران در ADALog روشی تطبیقی و بدون نظارت برای تحلیل مستقل پیام‌های خام پیشنهاد کردند. DistilBERT با وظیفه مدل‌سازی زبان پوشانده‌شده روی پیام‌های عادی تنظیم می‌شود. سپس احتمال بازسازی توکن‌ها به امتیازی در سطح پیام تبدیل و آستانه با توجه به توزیع خطای داده عادی تعیین می‌گردد. روش به توالی پیوسته یا یک تجزیه‌گر کلاسیک وابسته نیست [۲۲].

ADALog روی بی‌جی‌ال، Thunderbird و Spirit ارزیابی شده و اثر نرخ پوشاندن، پاک‌سازی و جایگاه توکن‌ها را با حذف اجزای روش بررسی کرده است [۲۲]. نزدیکی واحد تصمیم آن به سطح خط، این مقاله را برای پایان‌نامه مهم می‌کند؛ اما سازوکار تصمیم متفاوت است. ADALog به تنظیم DistilBERT و امتیاز بازسازی متکی است، درحالی‌که پژوهش حاضر از یک مدل دستورمحور، پاسخ ساخت‌یافته و حافظه نهان قالب بهره می‌برد.

۲-۳-۳ آموزش، تنظیم کارآمد پارامترها و انتقال مدل زبانی بزرگ

هان، یوان و ترابلسی در پژوهش خود درباره تشخیص ناهنجاری لاگ با GPT، مدلی با نام LogGPT ارائه کردند. مدل ابتدا برای پیش‌بینی رخداد بعدی آموزش می‌بیند و سپس با یادگیری تقویتی، رفتار تولیدی آن به هدف تشخیص ناهنجاری نزدیک می‌شود. بنابراین روش هم از توان مدل خودبازگشتی برای فراگیری توالی بهره می‌برد و هم با پاداش، مرز تصمیم را اصلاح می‌کند [۵].

این روش روی HDFS، بی‌جی‌ال و Thunderbird ارزیابی شده است [۵]. تشابه نام آن با مقاله [۲] نباید موجب یکسان‌انگاری شود: منبع [۵] به آموزش مدل و یادگیری تقویتی می‌پردازد، اما منبع [۲] توان ChatGPT را از طریق دستور متنی می‌سنجد. پژوهش حاضر، از نظر ثابت‌بودن وزن‌ها، به مطالعه دوم نزدیک‌تر است.

Masked Language Modeling (MLM)^۳
Top-k^۴