

سید علی



معاونت پژوهش و فن‌آوری

به نام خدا

منشور اخلاق پژوهش

با یاری از خداوند سبحان و اعتقاد به این که عالم محضر خداست و همواره ناظر بر اعمال انسان و به منظور پاس داشت مقام بلند دانش و پژوهش و نظر به اهمیت جایگاه دانشگاه در اعتلای فرهنگ و تمدن بشری، ما دانشجویان و اعضا هیأت علمی واحدهای دانشگاه آزاد اسلامی متعهد می گردیم اصول زیر را در انجام فعالیت های پژوهشی مد نظر قرار داده و از آن تخطی نکنیم:

- ۱- اصل حقیقت جویی: تلاش در راستای پی جویی حقیقت و وفاداری به آن و دوری از هرگونه پنهان سازی حقیقت.
- ۲- اصل رعایت حقوق: التزام به رعایت کامل حقوق پژوهشگران و پژوهیدگان (انسان، حیوان و نبات) و سایر صاحبان حق.
- ۳- اصل مالکیت مادی و معنوی: تعهد به رعایت کامل حقوق مادی و معنوی دانشگاه و کلیه همکاران پژوهش.
- ۴- اصل منافع ملی: تعهد به رعایت مصالح ملی و در نظر داشتن پیشبرد و توسعه کشور در کلیه مراحل پژوهش.
- ۵- اصل رعایت انصاف و امانت: تعهد به اجتناب از هرگونه جانب داری غیرعلمی و حفاظت از اموال، تجهیزات و منابع در اختیار.
- ۶- اصل رازداری: تعهد به صیانت از اسرار و اطلاعات محرمانه افراد، سازمان‌ها و کشور و کلیه افراد و نهادهای مرتبط با تحقیق.
- ۷- اصل احترام: تعهد به رعایت حریم‌ها و حرمت‌ها در انجام تحقیقات و رعایت جانب نقد و خودداری از هرگونه حرمت شکنی.
- ۸- اصل ترویج: تعهد به رواج دانش و اشاعه نتایج تحقیقات و انتقال آن به همکاران علمی و دانشجویان به غیر از مواردی که منع قانونی دارد.
- ۹- اصل برائت: التزام به برائت جویی از هرگونه رفتار غیر حرفه ای و اعلام موضع نسبت به کسانی که حوزه علم و پژوهش را به شائبه های غیرعلمی می آلاینند.



اسلامی

و تحقیقات (تهران)

مهندنامہ رسالہ یا پایان نامہ تحصیلی

اینجانب مسعود دباغی دانش آموخته مقطع کارشناسی ارشد در رشته مهندسی کامپیوتر گرایش نرم افزار که در تاریخ ۱۴۰۵/۰۱/۰۱ از پایان نامه/رساله خود تحت عنوان بهبود تشخیص ناهنجاری‌ها در لاگ‌های سیستمی مبتنی بر مدل‌های زبانی بزرگ با بهره‌گیری از مهندسی پرامپت با کسب نمره ۰۰ و درجه ۰۰ دفاع نموده‌ام بدینوسیله متعهد می‌شوم:

- (۱) این پایان نامه / رساله حاصل تحقیق و پژوهش انجام شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران (اعم از پایان نامه، کتاب، مقاله و ...) استفاده نموده‌ام، مطابق ضوابط و رویه موجود، نام منبع مورد استفاده و سایر مشخصات آنرا در فهرست مربوطه ذکر و درج کرده‌ام.
- (۲) این پایان نامه / رساله قبلاً برای دریافت هیچ مدرک تحصیلی (هم سطح، پایین تر یا بالاتر) در سایر دانشگاهها و مؤسسات آموزش عالی ارائه نشده است.
- (۳) چنانچه بعد از فراغت از تحصیل، قصد استفاده و هر گونه بهره‌برداری اعم از چاپ کتاب، ثبت اختراع و ... از این پایان نامه یا رساله داشته باشم، از حوزه معاونت پژوهشی واحد مجوزهای مربوطه را اخذ نمایم.
- (۴) چنانچه در هر مقطع زمانی خلاف موارد فوق ثابت شود، عواقب ناشی از آن را می‌پذیرم و دانشگاه آزاد اسلامی واحد علوم و تحقیقات مجاز است با اینجانب مطابق ضوابط و مقررات رفتار نموده و در صورت ابطال مدرک تحصیلی‌ام هیچگونه ادعایی نخواهم داشت.

نام و نام خانوادگی: مسعود دباغی

تاریخ و امضاء



دانشگاه آزاد اسلامی

واحد علوم و تحقیقات (تهران)

دانشکده برق و کامپیوتر، گروه نرم افزار

پایان نامه برای دریافت درجه ی کارشناسی ارشد در رشته کامپیوتر (M.Sc)
گرایش نرم افزار

عنوان:

بهبود تشخیص ناهنجاری ها در لاگ های سیستمی مبتنی بر مدل های زبانی بزرگ با بهره گیری از مهندسی پرامپت

استاد راهنما:

دکتر محمد رضا علی زاده

نگارش :

مسعود دباغی

تابستان ۱۴۰۵

بر خود لازم می‌دانم مراتب سپاس و قدردانی صمیمانه خود را از استاد ارجمند، جناب آقای دکتر محمدرضا علی‌زاده، استاد راهنمای محترم، ابراز نمایم.

راهنمایی‌های علمی و ارزشمند، دقت نظر، صبوری و حمایت‌های دلسوزانه ایشان در تمامی مراحل انجام این پژوهش، نقشی اساسی در شکل‌گیری و به سرانجام رسیدن این پایان‌نامه داشته است.

بی‌تردید، بهره‌مندی از دانش و تجربیات گران‌قدر ایشان، از ارزشمندترین بخش‌های این مسیر علمی برای من بوده است. بدین‌وسیله از تمامی زحمات، همراهی‌ها و راهنمایی‌های ایشان صمیمانه سپاسگزاری می‌نمایم.

تقدیم به

پدر و مادر عزیزم؛

آنان که با مهر بی پایان، صبوری و فداکاری‌های بی دریغشان، همواره استوارترین تکیه‌گاه و روشن‌ترین چراغ مسیر زندگی من بوده‌اند.

این پایان‌نامه را به پاس تمام محبت‌ها، رنج‌ها و حمایت‌های همیشگی‌شان، با نهایت عشق، احترام و قدردانی تقدیم می‌کنم.

فهرست مطالب

فصل اول: کلیات تحقیق	۲
۱-۱ مقدمه	۳
۲-۱ بیان مسئله	۳
۳-۱ اهمیت و ضرورت انجام پژوهش	۵
۴-۱ اهداف مشخص پژوهش	۵
۵-۱ سؤال ها و فرضیه های پژوهش	۶
سؤال های پژوهش	۶
فرضیه های پژوهش	۶
فصل دوم: مروری بر ادبیات و پیشینه تحقیق	۷
۱-۲ مقدمه	۸
۲-۲ مبانی نظری و مفاهیم مورد نیاز	۹
۱-۲-۲ ماهیت و ساختار لاگ سیستمی	۹
۲-۲-۲ مفهوم ناهنجاری و سطوح تحلیل	۹
۳-۲-۲ مجموعه داده ُ بی جی ال	۹
۴-۲-۲ تجزیه، پاک سازی و نرمال سازی	۱۰
۵-۲-۲ پارادایم های یادگیری در تشخیص ناهنجاری لاگ	۱۰
۶-۲-۲ مدل های ترتیبی، معماری ترنسفورمر و مدل های زبانی	۱۱
۷-۲-۲ نقش مدل زبانی بزرگ در فرایند تحلیل لاگ	۱۱
۸-۲-۲ مدل دستور محور کوئن ۲۰۵ با هفت میلیارد پارامتر	۱۲
۹-۲-۲ مهندسی دستور، یادگیری درون متنی و قرارداد خروجی	۱۲
۱۰-۲-۲ بازبایی، کش و کنترل هزینه استنتاج	۱۳
۱۱-۲-۲ استنتاج محلی با اولاما	۱۳
۱۲-۲-۲ دو معماری ترکیبی و صرفاً مبتنی بر دستور در پژوهش حاضر	۱۳
۱۳-۲-۲ معیارهای ارزیابی	۱۴

۱۴	 ۱۴-۲-۲ انواع الگوهای ناهنجاری در لاگ
۱۵	 ۱۵-۲-۲ چالش‌های روش‌شناختی و اجرایی
۱۶	 ۳-۲ پیشینه تحقیق
۱۶	 ۱-۳-۲ دامنه و شیوه مرور مطالعات
۱۶	 ۲-۳-۲ روش‌های ترتیبی و مدل‌های زبانی پیش‌آموزش‌دیده
۱۷	 ۳-۳-۲ آموزش، تنظیم کارآمد پارامترها و انتقال مدل زبانی بزرگ
۱۹	 ۴-۳-۲ مطالعات مبتنی بر دستور متنی
۲۰	 ۵-۳-۲ بازیابی، همکاری مدل‌ها و مهار هزینه‌ی محاسباتی
۲۱	 ۶-۳-۲ مطالعات تجزیه و تولید قالب لاگ
۲۲	 ۷-۳-۲ مرورها، معیارهای ارزیابی، مدل‌های پایه و استقرار واقعی
۲۳	 ۸-۳-۲ جمع‌بندی تحلیلی مسیر پژوهش‌ها
۲۴	 ۴-۲ دسته‌بندی و تحلیل مقایسه‌ای
۲۸	 ۱-۴-۲ مقایسه بر پایه‌ی واحد تحلیل و پروتکل بی‌جی‌ال
۲۸	 ۲-۴-۲ مقایسه براساس نیاز به آموزش
۲۸	 ۳-۴-۲ مقایسه‌ی شیوه‌های مهار هزینه و محل استقرار
۲۹	 ۴-۴-۲ مقایسه بازنمایی ورودی و آماده‌سازی
۲۹	 ۵-۴-۲ مقایسه سازوکار تصمیم و نوع خروجی
۳۰	 ۶-۴-۲ مقایسه تبیین‌پذیری و بازتولیدپذیری
۳۱	 ۵-۲ شکاف پژوهشی و جایگاه پژوهش حاضر
۳۱	 ۱-۵-۲ ناهمگونی پروتکل‌های بی‌جی‌ال
۳۱	 ۲-۵-۲ جدانشدن کیفیت تصمیم از هزینه استنتاج
۳۱	 ۳-۵-۲ محل اعمال دانش دامنه
۳۲	 ۴-۵-۲ کش تصمیم سطح قالب
۳۲	 ۵-۵-۲ استنتاج محلی با یک مدل زبانی بزرگ متن‌باز متوسط
۳۲	 ۶-۵-۲ صورت‌بندی جایگاه پژوهش
۳۲	 ۶-۲ جمع‌بندی

۲-۷ منابع فصل دوم	۳۳
-------------------------	----

فهرست جدول ها

No table of contents entries found.

فهرست نمودار ها

فهرست شکل ها

No table of contents entries found.

چکیده

گسترش سامانه‌های توزیع شده حجم بزرگی از لاگ‌های ناهمگون را پدید آورده است و تشخیص به موقع ناهنجاری در این داده‌ها برای پایداری و امنیت سامانه‌ها ضرورت دارد. روش‌های متعارف اغلب به قواعد دست‌نویس، الگوهای ثابت یا داده‌های برچسب‌خورده وابسته‌اند و در برابر تغییر قالب لاگ و افزایش حجم داده با محدودیت روبه‌رو می‌شوند. این پژوهش چارچوبی برای طبقه‌بندی دودویی پیام‌های مجموعه داده بی‌جی‌ال با یک مدل زبانی بزرگ محلی ارائه می‌کند. در این چارچوب، برچسب مرجع پیش از تشکیل ورودی حذف می‌شود و مقادیر پویایی مانند شناسه‌ها، مسیرها، نشانی‌های شبکه، مقادیر شانزده‌شانزده‌ی و اعداد با جانشین‌های ثابت جایگزین می‌شوند؛ با این حال، تفاوت‌های معناداری مانند صفر و غیرصفر حفظ می‌گردد. مدل کوئن ۲۰۵ نسخه هفت‌میلیارد پارامتری دستورمحور به کمک اولاما و با خروجی ساخت‌یافته اجرا می‌شود. برای جلوگیری از فراخوانی‌های تکراری، تصمیم‌های معتبر در سطح قالب نرمال شده در حافظه نهان نگه‌داری می‌شوند. سامانه در دو حالت «ترکیبی» و «صرفاً مبتنی بر دستور» اجرا می‌شود و کیفیت تصمیم، نرخ پاسخ نامعتبر، زمان اجرا و کارایی حافظه نهان در هر دو حالت سنجیده می‌شود. این طراحی امکان ارزیابی محلی، بازتولیدپذیر و خط‌به‌خط را بدون تنظیم دقیق وزن‌های مدل فراهم می‌کند.

کلمات کلیدی (فارسی)

تشخیص ناهنجاری، لاگ سیستمی، مهندسی دستور، مدل زبانی بزرگ، مجموعه داده بی‌جی‌ال

کلمات کلیدی (انگلیسی)

Anomaly Detection, System Logs, Prompt Engineering, Large Language Models (LLMs)

فصل اول: کلیات تحقیق

۱-۱ مقدمه

سامانه‌های نرم‌افزاری و زیرساخت‌های توزیع‌شده به‌طور پیوسته حجم زیادی از لاگ‌های سیستمی تولید می‌کنند. این داده‌ها وضعیت اجزای سامانه، خطاهای اجرایی و رخدادهای امنیتی را ثبت می‌کنند و از مهم‌ترین منابع پایش و عیب‌یابی به‌شمار می‌روند. با افزایش حجم داده و دگرگونی مداوم قالب پیام‌ها، بررسی دستی یا اتکا به قواعد ثابت پاسخ‌گو نیست. مدل‌های زبانی بزرگ^۱، به سبب توانایی در پردازش متن‌های نیمه‌ساخت‌یافته، می‌توانند بخشی از معنای پیام را بدون طراحی ویژگی‌های فراوان استخراج کنند. در این پژوهش از مهندسی دستور برای بهره‌گیری از این توانایی، بدون بازآموزی یا تنظیم دقیق مدل، استفاده می‌شود. این فصل مسئله، ضرورت، اهداف، پرسش‌ها و فرضیه‌های پژوهش را متناسب با همین دامنه بیان می‌کند.

۲-۱ بیان مسئله

در سامانه‌های توزیع‌شده، لاگ‌ها به‌صورت پیوسته تولید می‌شوند و اطلاعات ضروری برای عیب‌یابی، پایش سلامت و بررسی رخدادهای امنیتی را در خود دارند. تشخیص ناهنجاری در چنین جریانی با سه دشواری اصلی روبه‌رو است: پیام‌ها اغلب نیمه‌ساخت‌یافته‌اند؛ حجم داده بسیار زیاد است؛ و نمونه‌های ناهنجار در مقایسه با رخدادهای عادی سهم اندکی دارند. افزون بر این، بخشی از هر پیام از مقادیر پویایی مانند شناسه^۲ گره، مسیر و عدد تشکیل شده است. اگر این مقادیر بدون پردازش وارد مدل شوند، پیام‌های هم‌معنا به صورت نمونه‌های متفاوت دیده می‌شوند؛ و اگر بیش‌از حد حذف شوند، نشانه‌های معنادار نیز از بین می‌روند. مجموعه داده بی‌جی‌ال نمونه‌ای مناسب برای بررسی هم‌زمان این مسائل در مقیاس بزرگ است.

مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ می‌توانند رابطه^۳ میان واژه‌ها و زمینه^۴ رخداد را از متن استخراج کنند. با این حال، استفاده از آن‌ها برای لاگ لزوماً به معنای حذف پیش‌پردازش نیست؛ زیرا کیفیت پاک‌سازی، نرمال‌سازی و صورت‌بندی دستور، مستقیماً بر ورودی مدل و در نتیجه بر تصمیم آن اثر می‌گذارد.

System Logs^۱
Large Language Model (LLM)^۲
Prompt Engineering^۳
Blue Gene/L (BGL)^۴

پژوهش‌های پیشین از مدل زبانی در نقش‌های گوناگونی استفاده کرده‌اند: تجزیهٔ پیام و استخراج قالب، مدل‌سازی توالی رخداد، طبقه‌بندی مستقیم، بازیابی نمونهٔ مشابه و تولید توضیح. تفاوت این نقش‌ها نشان می‌دهد که صرف ذکر نام مدل برای مقایسهٔ روش‌ها کافی نیست و باید واحد تحلیل، نوع آموزش، شکل ورودی، سازوکار تصمیم و هزینهٔ اجرا نیز روشن باشد.

با توجه به این ملاحظات، مسئلهٔ پژوهش حاضر در سه محور صورت‌بندی می‌شود:

نخست، اجرای یک مدل زبانی بزرگ برای میلیون‌ها پیام هزینه‌بر است. حتی در استقرار محلی، هر فراخوانی به زمان پردازش و منابع سخت‌افزاری نیاز دارد. از این رو، باید پیام‌های هم‌قالب شناسایی شوند و تصمیم‌های معتبر تا حد امکان دوباره به کار روند، بی‌آنکه نتیجهٔ یک نسخهٔ قدیمی مدل یا دستور به اجرای جدید منتقل شود.

دوم، دانش قطعی دامنه را می‌توان بیرون مدل یا در متن دستور به کار گرفت. در مسیر نخست، یک نگهبان قاعده‌محور نمونه‌های روشن را پیش از فراخوانی مدل تعیین تکلیف می‌کند؛ در مسیر دوم، همان دانش در اختیار مدل قرار می‌گیرد تا همهٔ تصمیم‌ها را خود مدل صادر کند. مقایسهٔ منصفانهٔ این دو مسیر مستلزم ثابت‌ماندن داده، مدل، نرمال‌سازی، حافظهٔ نهان و قرارداد خروجی است.

سوم، پاسخ مولد ممکن است از قالب تعیین‌شده پیروی نکند یا در اجراهای مختلف تغییر کند. در یک سامانهٔ خودکار باید میان خطای طبقه‌بندی و پاسخ نامعتبر تمایز گذاشت. بنابراین پاسخ مدل باید با یک قرارداد ساخت‌یافته سنجیده شود و پاسخ‌های نامعتبر نه به‌عنوان عادی یا ناهنجار تعبیر شوند و نه در حافظهٔ نهان قرار گیرند.

برای بررسی این مسئله، مدل کوئن ۲۰۵ نسخهٔ هفت‌میلیارد پارامتری دستورمحور^۵ با وزن‌های ثابت و از طریق اولاما^۶ اجرا می‌شود. دو روش «ترکیبی»^۷ و «صرفاً مبتنی بر دستور»^۸ تنها در محل اعمال دانش قاعده تفاوت دارند. نرمال‌سازی، حافظهٔ نهان^۹ و خروجی ساخت‌یافته^{۱۰} جی‌سان^{۱۱} در هر دو روش یکسان نگه داشته می‌شوند تا منشأ تفاوت نتایج قابل تشخیص باشد.

واحد تصمیم در این پژوهش یک خط از لاگ بی‌جی‌ال است. برچسب مرجع پیش از ساخت ورودی حذف می‌شود و تنها برای ارزیابی به کار می‌رود. افزون بر معیارهای کیفیت طبقه‌بندی، تعداد فراخوانی مدل، نرخ استفاده از حافظهٔ نهان، زمان پاسخ، منبع هر تصمیم و تعداد پاسخ‌های نامعتبر نیز ثبت می‌شود.

برآیند مورد انتظار، یک فرایند روشن و قابل بازتولید برای سنجش توان مدل زبانی محلی در تشخیص ناهنجاری خط‌به‌خط است؛ فرایندی که هم کیفیت تصمیم و هم هزینهٔ عملیاتی آن را نشان دهد.

چنین ارزیابی‌ای می‌تواند مشخص کند که نرمال‌سازی و بازاستفاده از تصمیم‌های سطح قالب تا چه اندازه برای تحلیل مجموعه‌های بزرگ لاگ سودمند است و کدام محل اعمال دانش قاعده برای این مسئله مناسب‌تر عمل می‌کند.

Qwen^۵:۲۰۵B-Instruct^۵

Ollama^۶

Hybrid^۷

Prompt-only^۸

Cache^۹

JavaScript Object Notation (JSON)^{۱۰}

۱-۳ اهمیت و ضرورت انجام پژوهش

سامانه‌های نرم‌افزاری در حوزه‌هایی مانند مالی، سلامت، مخابرات و خدمات ابری به پایش پیوسته وابسته‌اند. تأخیر در شناسایی رخداد غیرعادی می‌تواند به توقف خدمت، افزایش هزینه^۱ نگهداری یا گسترش یک رخداد امنیتی منجر شود. از این رو، تحلیل خودکار لاگ نه تنها یک مسئله^۲ پژوهشی، بلکه یک نیاز عملیاتی است. اهمیت علمی پژوهش در تفکیک عواملی است که معمولاً به صورت هم‌زمان تغییر می‌کنند. در بسیاری از مطالعات، نوع مدل، واحد تحلیل، شیوه^۳ آماده‌سازی و روش کنترل هزینه با یکدیگر متفاوت‌اند و همین امر تفسیر نتایج را دشوار می‌کند. در این پایان‌نامه، دو مسیر تصمیم تحت شرایط یکسان اجرا می‌شوند تا اثر محل اعمال دانش قاعده از اثر سایر اجزا جدا شود.

از دیدگاه کاربردی، چارچوب پیشنهادی می‌تواند پیامدهای زیر را داشته باشد:

- کاهش فراخوانی‌های تکراری مدل از طریق نرمال‌سازی و حافظه^۴ نهان؛
- امکان اجرای محلی و جلوگیری از ارسال لاگ‌های حساس به خدمات بیرونی؛
- ثبت خطبه‌خط منبع تصمیم و فراهم کردن امکان ممیزی و بازتولید آزمایش.

این ویژگی‌ها به‌ویژه برای سازمان‌هایی اهمیت دارند که هم با حجم زیاد لاگ روبه‌رو هستند و هم محدودیت محرمانگی یا منابع محاسباتی دارند.

بنابراین ضرورت پژوهش از یک سو به نیاز عملی برای تحلیل سریع و محلی لاگ و از سوی دیگر به نیاز علمی برای مقایسه^۵ کنترل‌شده^۶ دو محل اعمال دانش دامنه بازمی‌گردد.

۱-۴ اهداف مشخص پژوهش

الف) هدف اصلی

طراحی و ارزیابی چارچوبی محلی برای تشخیص ناهنجاری خطبه‌خط در لاگ‌های بی‌جی‌ال با مدل کوئن ۲۰۵ دستورمحور و مقایسه^۷ کنترل‌شده^۸ روش ترکیبی با روش صرفاً مبتنی بر دستور، بدون تنظیم دقیق مدل.

ب) اهداف فرعی

۱. طراحی قواعد نرمال‌سازی برای تبدیل مقادیر پویا به قالب‌های پایدار، همراه با حفظ نشانه‌های

معنادار؛

۲. پیاده‌سازی حافظه^۹ نهان نسخه‌بندی‌شده در سطح قالب و سنجش اثر آن بر تعداد فراخوانی و زمان

اجرا؛

۳. سنجش صحت^{۱۱}، دقت^{۱۲}، بازخوانی^{۱۳} و امتیاز افیک^{۱۴} در دو مسیر تصمیم و گزارش ماتریس اغتشاش در سطح خط؛

۴. اندازه‌گیری نرخ پاسخ نامعتبر، زمان پاسخ و سهم هر منبع تصمیم در نتیجه^{۱۵} نهایی؛
۵. ثبت تنظیمات مدل، دستور، کلید حافظه^{۱۶} نهان و خروجی خطبه‌خط برای افزایش بازتولیدپذیری.

۱-۵ سؤال‌ها و فرضیه‌های پژوهش

سؤال‌های پژوهش

۱. مدل کوئن ۲،۵ دستورمحور، بدون تنظیم دقیق، تا چه اندازه می‌تواند پیام‌های بی‌جی‌ال را در سطح خط طبقه‌بندی کند؟
۲. نرمال‌سازی و حافظه^{۱۶} نهان سطح قالب چه اثری بر تعداد فراخوانی مدل و زمان پردازش دارند؟
۳. روش ترکیبی و روش صرفاً مبتنی بر دستور از نظر معیارهای کیفیت و نرخ پاسخ نامعتبر چه تفاوتی دارند؟
۴. استقرار محلی مدل با اولاما تا چه اندازه امکان اجرای قابل بازتولید و حفظ محرمانگی داده را فراهم می‌کند؟

فرضیه‌های پژوهش

۱. مدل کوئن ۲،۵ دستورمحور، بدون تنظیم دقیق، قادر است بخشی از ناهنجاری‌های بی‌جی‌ال را در سطح خط تشخیص دهد.
۲. نرمال‌سازی و حافظه^{۱۶} نهان سطح قالب تعداد فراخوانی‌های تکراری و زمان پردازش را کاهش می‌دهند.
۳. میان روش ترکیبی و روش صرفاً مبتنی بر دستور از نظر کیفیت تصمیم و نرخ پاسخ نامعتبر تفاوت قابل اندازه‌گیری وجود دارد.
۴. استقرار محلی با اولاما، در صورت ثبت نسخه‌ها و تنظیمات، بازتولیدپذیری و کنترل داده را نسبت به خدمت بیرونی افزایش می‌دهد.

Accuracy^{۱۱}

Precision^{۱۲}

Recall^{۱۳}

F^۱-score^{۱۴}

فصل دوم: مروری بر ادبیات و پیشینه تحقیق

لاگ سیستمی گزارشی متنی یا نیمه‌ساخت‌یافته از رخدادهای زمان اجراست. این گزارش می‌تواند وضعیت یک مؤلفه، پیام هشدار، نتیجه^{۱۵} یک عملیات یا اطلاعات لازم برای عیب‌یابی را ثبت کند. از آنجا که زیرساخت‌های نرم‌افزاری و محاسباتی در هر لحظه شمار زیادی از این پیام‌ها را تولید می‌کنند، لاگ یکی از منابع اصلی پایش سلامت سامانه، تشخیص خطا و یافتن علت ریشه‌ای رخدادهاست. افزایش مقیاس سامانه و تنوع قالب‌ها سبب شده است که تحلیل دستی دیگر پاسخ‌گوی جریان پیوسته^{۱۶} داده نباشد [۱۴، ۲۰، ۲۱].

پژوهش در زمینه^{۱۷} تشخیص ناهنجاری لاگ، از قواعد ثابت و روش‌های آماری آغاز شده و سپس به مدل‌های ترتیبی، مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ رسیده است. دیپ‌لاگ با شبکه^{۱۸} حافظه^{۱۹} کوتاه‌مدت بلند^{۲۰}توالی رخدادها را مدل می‌کند؛ لاگ‌برت و برت‌لاگ از بازنمایی رمزگذار دوسویه^{۲۱} بهره می‌گیرند؛ و روش‌هایی مانند LogPrompt، LogGPT، RAGLog و Hybrid Prompting توانایی پیروی از دستور و برداشت معنایی مدل زبانی بزرگ را به کار می‌برند [۱-۶، ۱۲، ۱۸، ۱۹، ۲۱].

نقش مدل زبانی در این مطالعات یکسان نیست. گاهی مدل مستقیماً برچسب عادی یا ناهنجار را تولید می‌کند؛ گاهی برای پیش‌بینی رخداد بعدی آموزش می‌بیند؛ و در برخی چارچوب‌ها وظیفه^{۲۲} تولید داده، توضیح نتیجه یا رسیدگی به نمونه‌های دشوار را بر عهده دارد. مرور نظام‌مند پژوهش‌های لاگ و مرور عمومی تشخیص ناهنجاری نیز همین گوناگونی نقش را یکی از محورهای اصلی دسته‌بندی می‌دانند [۱۴، ۲۷].

در نتیجه، مقایسه^{۲۳} روش‌ها نباید به نام مدل محدود شود. شکل ورودی، واحد تصمیم، نیاز به آموزش، شیوه^{۲۴} آماده‌سازی داده، محل استقرار و روش مهار هزینه نیز باید مشخص باشد. برای مثال، امتیازافیک حاصل از طبقه‌بندی یک پیام با نتیجه^{۲۵} یک پنجره^{۲۶} یک‌دقیقه‌ای یا یک نشست چندرخدادی هم‌معنا نیست. همچنین بازیابی نمونه، حافظه^{۲۷} نهان و ارجاع نمونه به مدل کوچک، با وجود هدف مشترک کاهش هزینه، سازوکارهای متفاوتی دارند [۳، ۱۰، ۱۲، ۱۳].

پژوهش حاضر فقط مجموعه داده^{۲۸} بی‌جی‌ال و مدل کوئن ۲٫۵ دستورمحور را بررسی می‌کند. مدل با اولاما و به‌صورت محلی اجرا می‌شود و وزن‌های آن تغییر نمی‌کنند. مقایسه میان دو روش انجام می‌شود: در روش ترکیبی، قواعد قطعی پیش از فراخوانی مدل اعمال می‌شوند؛ در روش صرفاً مبتنی بر دستور، همان دانش دامنه در متن دستور قرار می‌گیرد. قواعد نرمال‌سازی، حافظه^{۲۹} نهان سطح قالب و اعتبارسنجی خروجی در هر دو روش ثابت‌اند.

این فصل ابتدا مفاهیم نظری موردنیاز را توضیح می‌دهد و سپس هر ۲۷ مقاله^{۳۰} موجود در پوشه^{۳۱} پژوهش را به‌طور مستقل مرور می‌کند. دو منبع [۱] و [۶] که دو نسخه^{۳۲} هم‌پوشان از مسیر پژوهشی LogPrompt هستند نیز جداگانه معرفی می‌شوند، اما در جمع‌بندی شواهد دو روش مستقل به‌شمار نمی‌آیند. پس از مرور مطالعات، دسته‌بندی، جدول مقایسه، شکل ارتباط پژوهش‌ها و شکاف پژوهشی ارائه می‌شود. همه^{۳۳} تعریف‌ها و گزارش نتایج به منابع ارجاع دارند و نتیجه^{۳۴} آزمایش‌های ناتمام پروژه وارد این فصل نشده است.

^{۱۵} Long Short-Term Memory (LSTM)

^{۱۶} Bidirectional Encoder Representations from Transformers (BERT)

۲-۲ مبانی نظری و مفاهیم موردنیاز

۲-۲-۱ ماهیت و ساختار لاگ سیستمی

هر پیام لاگ معمولاً از سرآیند و بدنه تشکیل می‌شود. سرآیند ممکن است زمان، سطح شدت، نام مؤلفه، شناسه^{۱۷} فرایند یا گره را در بر گیرد و بدنه شرح رخداد و مقادیر زمان اجرا را بیان کند. در مطالعات LogPPT و LogParser-LLM، بدنه به دو بخش تقسیم می‌شود: واژه‌های ثابت که «قالب لاگ» را می‌سازند و مقادیر متغیر که «پارامتر» نامیده می‌شوند. شناسه^{۱۸} بلوک، نشانی شبکه، مسیر فایل و زمان نمونه‌هایی از پارامترهای متغیرند [۲۳، ۲۴]. لاگ خام، به سبب وجود اختصارها، کدهای خطا، مقادیر پویا و قالب‌های گوناگون، یک متن طبیعی کامل نیست؛ بااین‌حال، واژه‌های ثابت و زمینه^{۱۹} عملیاتی آن اطلاعات معنایی ارزشمندی دارند. مدل‌های زبانی این اطلاعات را از متن یا توالی رخدادهای استخراج می‌کنند، درحالی‌که بسیاری از روش‌های آماری ابتدا پیام را به شناسه^{۲۰} قالب یا بردار فراوانی تبدیل می‌کنند [۴، ۱۴، ۱۸، ۱۹].

۲-۲-۲ مفهوم ناهنجاری و سطوح تحلیل

در تشخیص ناهنجاری، مشاهده زمانی ناهنجار تلقی می‌شود که با الگوی رفتار عادی یا قواعد ازپیش‌تعریف‌شده سازگار نباشد. شو و دینگ میان تغییری که درون دامنه^{۲۱} شناخته‌شده رخ می‌دهد و داده‌ای که از توزیع آموزش بیرون است^{۲۲} تمایز می‌گذارند. آنان کاربرد مدل زبانی بزرگ را نیز به دو گروه «مدل برای تشخیص» و «مدل برای تولید» تقسیم می‌کنند [۲۷]. در لاگ، ناهنجاری ممکن است در متن یک پیام، فراوانی قالب‌ها، ترتیب رخدادهای یا معنای یک پنجره^{۲۳} زمانی آشکار شود [۱۴].

واحد تحلیل در پژوهش‌های این حوزه می‌تواند یک خط، یک قالب، یک پنجره^{۲۴} زمانی، توالی رخدادهای یک گره یا یک نشست کامل باشد. ADALog پیام را مستقل بررسی می‌کند؛ DeepLog و LogBERT بر توالی تکیه دارند؛ BERT-Log در بی‌جی‌ال پنجره^{۲۵} لغزان مبتنی بر گره می‌سازد؛ و Hybrid Prompting از پنجره^{۲۶} یک‌دقیقه‌ای استفاده می‌کند [۳، ۱۸، ۱۹، ۲۱، ۲۲]. انتخاب واحد تحلیل، تعریف مؤلفه‌های ماتریس اغتشاش^{۲۷} و امکان مقایسه^{۲۸} نتایج را تعیین می‌کند.

۲-۲-۳ مجموعه داده بی‌جی‌ال

مجموعه داده بی‌جی‌ال از ابررایانه^{۲۹} Blue Gene/L در آزمایشگاه ملی لارنس لیورمور گردآوری شده است. این مجموعه ۴۰۷۴۷۰۹۶۳ پیام دارد که ۳۴۸۰۴۶۰ پیام، یعنی حدود ۷۰۳۴ درصد، با برچسب هشدار به‌عنوان ناهنجار مشخص شده‌اند [۲، ۱۸، ۱۹]. برچسب مرجع در ابتدای هر خط قرار دارد. این برچسب برای ارزیابی لازم است، اما ورود آن به متن مدل پاسخ را آشکار می‌کند؛ ازاین‌رو پیش از ساخت ورودی حذف می‌شود. شیوه^{۳۰} استفاده از بی‌جی‌ال در مقالات یکسان نیست. LogBERT پنجره‌های زمانی پنج‌دقیقه‌ای با میانگین ۵۶۲ رخداد می‌سازد؛ BERT-Log پیام‌ها را با شناسه^{۳۱} گره، اندازه^{۳۲} پنجره و گام سازمان می‌دهد؛ Hybrid Prompting

^{۱۷} Out-of-Distribution (OOD)

^{۱۸} True Positive (TP), True Negative (TN), False Positive (FP), False Negative (FN)

پنجره^۱ یک دقیقه‌ای و نمونه‌ای متوازن شامل هزار توالی عادی و هزار توالی ناهنجار به کار می‌گیرد؛ و ADALog پس از پاک‌سازی، پیام‌های یکتای عادی و ناهنجار را در سطح خط بررسی می‌کند [۳، ۱۸، ۱۹، ۲۲]. در مطالعه^۲ LogGPT مبتنی بر ChatGPT، محدودیت نرخ رابط برنامه‌نویسی کاربردی^۱ باعث شده است فقط دو هزار پیام متوالی از بخش آزمون انتخاب شود [۲]. RAGLog نیز برای تشکیل خوشه‌ها و پایگاه برداری از نمونه‌گیری و الگوریتم میانگین‌های کا-بهره می‌گیرد [۱۲]. بنابراین عبارت «ارزیابی روی بی‌جی‌ال» تنها زمانی معنا دارد که واحد تحلیل، روش نمونه‌گیری، اندازه^۳ پنجره و نسبت کلاس‌ها نیز گزارش شوند.

۲-۲-۴ تجزیه، پاک‌سازی و نرمال‌سازی

تجزیه^۴ لاگ فرایندی است که پیام خام را به یک قالب ثابت و فهرستی از پارامترهای متغیر تبدیل می‌کند. روش‌های سنتی برای این کار از فراوانی واژه، شباهت پیام و قواعد نحوی بهره می‌برند. LogPPT مدل RoBERTa را با تنظیم مبتنی بر دستور و شمار اندکی نمونه برای شناسایی توکن‌های پارامتر سازگار می‌کند. LogParser-LLM نیز توان معنایی مدل زبانی بزرگ را با درخت پیشوند ترکیب می‌کند تا تنها الگوهای تازه یا مبهم به مدل فرستاده شوند [۲۳، ۲۴].

نرمال‌سازی در این پژوهش جایگزین یک تجزیه‌گر خوشه‌بندی شده^۵ کامل^۶ نیست؛ بلکه مجموعه‌ای از قواعد قطعی است که مقادیر پویا را به جانشین‌های ثابت تبدیل می‌کند تا یک قالب پایدار برای حافظه^۷ نهان ساخته شود. شناسه^۸ گره، نشانی شبکه، مقدار شانزده‌شانزده‌ی، تاریخ، زمان، مسیر و اعداد پویا پوشانده می‌شوند. با این حال، صفر و غیرصفر جدا می‌مانند؛ زیرا در برخی رخدادها همین تفاوت عددی حامل معنای عملیاتی است. این تصمیم با اصل جداسازی قالب و پارامتر در مطالعات تجزیه سازگار است [۲۳، ۲۴].

کیفیت نرمال‌سازی بر دو جنبه اثر می‌گذارد: میزان اطلاعاتی که برای تشخیص باقی می‌ماند و تعداد قالب‌های یکتایی که باید به مدل فرستاده شود. پوشاندن بیش‌ازحد ممکن است نشانه‌ای معنادار را حذف کند؛ پوشاندن کمتر از حد نیز پیام‌های هم‌معنا را به کلیدهای جدا تبدیل می‌کند. LogLAA و LogParser-LLM نیز نشان می‌دهند که دانه‌بندی نامناسب قالب می‌تواند کیفیت تحلیل مرحله^۹ بعد را کاهش دهد [۱۷، ۲۳].

۲-۲-۵ پارادایم‌های یادگیری در تشخیص ناهنجاری لاگ

در یادگیری نظارت‌شده، مرز تصمیم با نمونه‌های عادی و ناهنجار برچسب‌خورده آموخته می‌شود؛ BERT-Log نمونه‌ای از این رویکرد است [۱۸]. یادگیری نیمه‌نظارتی مقدار اندکی داده^{۱۰} برچسب‌خورده را با داده^{۱۱} بدون برچسب ترکیب می‌کند و SemiRALD از همین الگو بهره می‌برد [۱۶]. در یادگیری خودنظارتی، مدل با وظیفه‌ای کمکی، مانند پیش‌بینی بخش پوشانده‌شده^{۱۲} پیام، الگوی عادی را فرا می‌گیرد؛ LogFiT، LogBERT و ADALog در این گروه قرار دارند [۸، ۱۹، ۲۲].

^۱Application Programming Interface (API)

^۲K-means

^۳Log Parser

سازگار کردن مدل زبانی با دامنه می‌تواند به سه صورت انجام شود: تنظیم کامل وزن‌ها، تنظیم کارآمد پارامترها^{۳۳} یا یادگیری از نمونه‌ها و دستورهای داخل متن. LogLLM و LogGPT آموزش اختصاصی دارند. LLM-LADE و مطالعه^{۳۴} لیم و همکاران از سازگارسازی کم‌رتبه^{۳۳}، تنظیم بازنمایی^{۳۴} یا روش‌های مشابه استفاده می‌کنند. در مقابل، LogPrompt و LogGPT مبتنی بر ChatGPT بدون تغییر وزن مدل، وظیفه و نمونه‌ها را در متن دستور قرار می‌دهند [۱، ۲، ۴-۷، ۹].

۶-۲-۲ مدل‌های ترتیبی، معماری ترنسفورمر و مدل‌های زبانی

مدل ترتیبی می‌کوشد احتمال رخداد بعدی یا سازگاری کل توالی را برآورد کند. DeepLog با شبکه^{۳۵} حافظه^{۳۶} کوتاه‌مدت بلند رخداد بعدی را از تاریخچه پیش‌بینی می‌کند و انحراف از رخدادهای محتمل را نشانه^{۳۷} ناهنجاری می‌داند [۲۱]. معماری ترنسفورمر^{۳۸} با سازوکار توجه، استفاده از زمینه^{۳۹} دورتر و پردازش موازی را ممکن می‌سازد. LogBERT با زمینه^{۴۰} دوسویه و دو هدف خودنظارتی، و BERT-Log با بازنمایی زبانی و یک طبقه‌بند، این معماری را برای لاگ به کار گرفته‌اند [۱۸، ۱۹].

مدل‌های زبانی بزرگ دستورمحور معمولاً بر ترنسفورمر خودبازگشتی تکیه دارند و پاسخ را با توجه به دستور متنی تولید می‌کنند. مقاله^{۴۱} YuLan ساخت یک مدل متن‌باز دوازده‌میلیارد پارامتری را در سه مرحله^{۴۲} پیش‌آموزی، تنظیم دستوری و هم‌ترازی انسانی شرح می‌دهد و توانایی یادگیری درون‌متنی را از پیامدهای پس‌آموزی می‌داند [۲۶]. YuLan آشکار ساز لاگ نیست و در این فصل فقط برای توضیح منشأ دستورپذیری مدل‌های زبانی به کار می‌رود.

۷-۲-۲ نقش مدل زبانی بزرگ در فرایند تحلیل لاگ

مدل زبانی بزرگ می‌تواند در زنجیره^{۴۳} تحلیل لاگ نقش تجزیه‌گر، طبقه‌بند، مولد داده، توضیح‌دهنده یا هماهنگ‌کننده را داشته باشد. LogParser-LLM و LogPPT قالب پیام را استخراج می‌کنند [۲۳، ۲۴]. LogGPT، LogPrompt و Hybrid Prompting تصمیم تشخیص را مستقیماً از مدل می‌گیرند [۱-۳، ۶]. LLM-LADE از مدل برای افزایش داده و تولید توضیح استفاده می‌کند و LogLAA پس از تشخیص، شرح رخداد را می‌سازد [۷، ۱۷].

در سامانه‌های چندمدلی، لازم نیست همه^{۴۴} نمونه‌ها به مدل بزرگ فرستاده شوند. AdaptiveLog عدم قطعیت مدل کوچک را ملاک ارجاع قرار می‌دهد [۱۳]. FlexLog خروجی چند مدل یادگیری ماشین را با Mistral، بازیابی و حافظه^{۴۵} نهان ترکیب می‌کند [۱۰]. LogSynergy نیز با تفسیر معنایی رخدادها، بازنمایی ای می‌سازد که میان سامانه‌های گوناگون قابل انتقال باشد [۱۵].

^{۳۳}Parameter-Efficient Fine-Tuning (PEFT)

^{۳۴}Low-Rank Adaptation (LoRA)

^{۳۵}Representation Fine-Tuning (ReFT)

^{۳۶}Transformer

۸-۲-۲ مدل دستورمحور کوئن ۲۰۵ با هفت میلیارد پارامتر

خانواده کوئن ۲۰۵ شامل مدل‌های پایه و دستورمحور با اندازه‌های ۰.۵ تا ۷۲ میلیارد پارامتر است. گزارش فنی این خانواده، پیش‌آموزی بر حدود ۱۸ تریلیون توکن و پس‌آموزی با بیش از یک میلیون نمونه تنظیم دستوری و مراحل تقویت یادگیری را شرح می‌دهد. نسخه هفت میلیارد پارامتری حدود ۶۰۵ میلیارد پارامتر غیرتعبیه‌ای دارد و نسخه دستورمحور برای پیروی از فرمان و تولید پاسخ ساخت‌یافته آماده شده است [۲۸].

در پژوهش حاضر، وزن‌های کوئن ۲۰۵ ثابت می‌مانند و تنظیم دقیق انجام نمی‌شود. نسخه مدل، شیوه کوانتیزه‌سازی^{۲۶}، دما و گزینه‌های تولید نیز در هر دو روش یکسان‌اند؛ زیرا در غیر این صورت نمی‌توان تفاوت خروجی را فقط به محل اعمال قاعده نسبت داد. Hybrid Prompting برای تعبیه از Qwen۳-Embedding-۸B و برای تصمیم از GPT-۴o-mini استفاده کرده است؛ بنابراین نقش و ترکیب مدل‌های آن با پژوهش حاضر یکسان نیست [۳].

۹-۲-۲ مهندسی دستور، یادگیری درون‌متنی و قرارداد خروجی

دستور متنی باید وظیفه، معنای برچسب‌ها، دانش لازم، نمونه‌های احتمالی و قالب پاسخ را روشن کند. مطالعه LogGPT مبتنی بر ChatGPT اثر نوع دستور، اندازه پنجره، دانش انسانی، مقایسه با روش‌های عمیق و توضیح‌پذیری را بررسی می‌کند [۲]. LogPrompt نیز دستور ساده، دستور غنی‌شده با دانش دامنه و زنجیره استدلال را در وظایف تجزیه و تشخیص با یکدیگر می‌سنجد [۱، ۶].

در یادگیری چندنمونه‌ای^{۲۷}، چند نمونه برچسب‌خورده در خود دستور قرار می‌گیرند و وزن مدل تغییر نمی‌کند. RAGLog نمونه عادی مرتبط را از پایگاه برداری بازیابی می‌کند [۱۲] و Hybrid Prompting نزدیک‌ترین نمونه عادی را همراه شواهد رخداد و توالی در اختیار مدل می‌گذارد [۳]. OpsEval نیز اثر خودسازگاری^{۲۸}، زنجیره استدلال^{۲۹} و یادگیری درون‌متنی^{۳۰} را در وظایف عملیات فناوری اطلاعات به‌طور مستقل بررسی می‌کند [۲۵].

در پژوهش حاضر فقط دو پاسخ ساخت‌یافته، با برچسب صفر یا یک، پذیرفته می‌شود. متن افزوده، ساختار ناقص یا برچسبی غیر از این دو «پاسخ نامعتبر»^{۳۱} به‌شمار می‌رود و در حافظه نهان ذخیره نمی‌شود. مستندات اولاما امکان تعیین ساختار پاسخ و استفاده از دمای صفر برای کاهش نویسن را توضیح می‌دهند [۲۹]. برنامه پاسخ را مستقل از ظاهر آن تجزیه و اعتبارسنجی می‌کند.

^{۲۶}Quantization

^{۲۷}Few-shot Learning

^{۲۸}Self-Consistency

^{۲۹}Chain-of-Thought (CoT)

^{۳۰}In-Context Learning (ICL)

^{۳۱}INVALID

۲-۲-۱۰ بازیابی، کش و کنترل هزینه استنتاج

بازیابی و حافظه^۳ نهان دو کار متفاوت انجام می‌دهند. در تولید تقویت‌شده با بازیابی^۳، نمونه یا دانش مرتبط برای غنی کردن زمینه^۳ دستور انتخاب می‌شود؛ RAGLog و AdaptiveLog از این الگو بهره می‌برند [۱۲، ۱۳]. حافظه^۳ نهان، تصمیم معتبر مربوط به یک ورودی پایدار را نگه می‌دارد تا هنگام تکرار همان ورودی، مدل دوباره فراخوانی نشود. FlexLog هر دو سازوکار را در کنار مدل‌های یادگیری ماشین به کار می‌گیرد [۱۰]. حافظه^۳ نهان این پژوهش در سطح قالب نرمال شده عمل می‌کند. کلید آن نسخه^۳ دستور، نام و نسخه^۳ مدل، متن قالب و در صورت فعال بودن، مؤلفه، شدت و دسته^۳ رخداد را در بر می‌گیرد. به این ترتیب، تصمیم یک مدل یا دستور قدیمی به اجرای تازه راه نمی‌یابد. شمار کلیدهای یکتا، تعداد برخورد و عدم برخورد و منبع هر تصمیم جداگانه ثبت می‌شود.

AdaptiveLog با سپردن نمونه‌های نامطمئن به مدل بزرگ، کاهش هزینه^۳ فراخوانی تا ۷۳ درصد را گزارش کرده است [۱۳]. LogParser-LLM نیز با درخت پیشوند و تجمیع پیام‌های مشابه، برای مجموعه‌های LogPub با میانگین ۳۰۶ میلیون پیام، به‌طور متوسط فقط ۲۷۲٫۵ بار مدل زبانی بزرگ را فراخوانده است [۲۳]. این نتایج نشان می‌دهند که شمار فراخوانی و زمان اجرا باید در کنار معیارهای طبقه‌بندی گزارش شوند.

۲-۲-۱۱ استنتاج محلی با اولاما

اولاما اجرای محلی مدل و دسترسی نرم‌افزار از طریق یک رابط برنامه‌نویسی را فراهم می‌کند. پاسخ این رابط می‌تواند زمان کل، زمان بارگذاری، شمار توکن‌های ورودی و خروجی و مدت ارزیابی را گزارش کند [۲۹]. ثبت این اطلاعات امکان می‌دهد زمان بارگذاری مدل از زمان پردازش دستور و تولید پاسخ جدا شود. استقرار محلی مانع ارسال لاگ به یک خدمت بیرونی می‌شود و کنترل نسخه^۳ مدل را در اختیار پژوهشگر قرار می‌دهد. دلا کروز کابل و همکاران نیز LogBERT را در محیطی با محدودیت محرمانگی به‌صورت درون‌سازمانی مستقر کرده‌اند [۲۰]. تفاوت آن مطالعه با پژوهش حاضر در نوع مدل و شیوه^۳ آموزش است: مدل آنان با لاگ‌های عادی سامانه^۳ واقعی آموزش می‌بیند، اما کوئن در این پژوهش بدون تنظیم اختصاصی اجرا می‌شود.

۲-۲-۱۲ دو معماری ترکیبی و صرفاً مبتنی بر دستور در پژوهش حاضر

در روش ترکیبی، پس از استخراج فیلدها، حذف برچسب و نرمال‌سازی، ابتدا حافظه^۳ نهان بررسی می‌شود. اگر کلید وجود نداشته باشد، مجموعه‌ای محدود از قواعد قطعی و پُر اطمینان اجرا می‌شود. تنها نمونه‌هایی که نگهبان قاعده‌محور درباره^۳ آن‌ها تصمیمی ندارد به کوئن فرستاده می‌شوند. پاسخ معتبر در حافظه^۳ نهان قرار می‌گیرد و منبع تصمیم به‌صورت «حافظه^۳ نهان»، «قاعده» یا «مدل زبانی» ثبت می‌شود.

در روش صرفاً مبتنی بر دستور، نگهبان قاعده‌محور غیرفعال است و دانش دامنه در متن دستور نوشته می‌شود. نرمال‌سازی، حافظه^۳ نهان، نسخه^۳ مدل، قرارداد خروجی و ترتیب داده تغییر نمی‌کنند؛ بنابراین متغیر اصلی، محل

اعمال دانش قاعده است. اصطلاح «ترکیبی» در این پایان نامه با Hybrid Prompting تفاوت دارد؛ مقاله [۳] شواهد رخداد، توالی و نمونه بازیابی شده را در یک دستور ترکیب می کند و تصمیم را در سطح توالی می گیرد.

۲-۲-۱۳ معیارهای ارزیابی

در طبقه بندی دودویی، مثبت واقعی به ناهنجاری درست شناسایی شده، منفی واقعی به پیام عادی درست، مثبت کاذب به پیام عادی با برچسب ناهنجار و منفی کاذب به ناهنجاری از دست رفته گفته می شود. صحت نسبت همه تصمیم های درست است؛ دقت سهم پیش بینی های ناهنجاری درست را نشان می دهد؛ بازخوانی سهم ناهنجاری های کشف شده است؛ و امتیاز افیک میانگین هارمونیک دقت و بازخوانی است [۲، ۳، ۱۸].

$$\text{Accuracy} = (TP + TN) / (TP + TN + FP + FN)$$

$$\text{Precision} = TP / (TP + FP) \quad \text{Recall} = TP / (TP + FN) \quad F1 = 2 \times \text{Precision} \times \text{Recall} / (\text{Precision} + \text{Recall})$$

به دلیل نامتوازن بودن بی جی ال، گزارش صحت به تنهایی کافی نیست و باید دقت، بازخوانی، امتیاز افیک و ماتریس اغتشاش نیز ارائه شوند. نرخ پاسخ نامعتبر، زمان پاسخ، شمار فراخوانی مدل، منبع تصمیم و نرخ استفاده از حافظه نهان نیز برای این پژوهش ضروری اند؛ و گرنه ممکن است کاهش فراخوانی ناشی از حافظه نهان یا قاعده با بهبود توان طبقه بندی مدل اشتباه گرفته شود.

۲-۲-۱۴ انواع الگوهای ناهنجاری در لاگ

ناهنجاری رخدادی هنگامی دیده می شود که خود یک پیام یا قالب، مستقل از پیام های پیرامون، نشانه وضعیت غیرعادی باشد. عبارت خطا، توقف مؤلفه، خرابی سخت افزار یا کد بازگشتی غیرمنتظره از نمونه های این نوع اند. ADALog احتمال بازسازی توکن های هر پیام را به امتیازی در سطح خط تبدیل می کند [۲۲]. طبقه بندی خط به خط پژوهش حاضر نیز در درجه نخست همین سطح را هدف می گیرد.

در ناهنجاری ترتیبی، هر رخداد ممکن است به تنهایی عادی باشد، اما ترتیب یا فاصله زمانی رخدادها با الگوی عادی سازگار نیست. DeepLog با پیش بینی رخداد بعدی و LogBERT با یادگیری زمینه دوسویه این نوع انحراف را بررسی می کنند [۱۹، ۲۱]. Hybrid Prompting نیز اطلاعات توالی را همراه رخداد های پیش تر دیده نشده در دستور قرار می دهد [۳].

ناهنجاری کمی به افزایش یا کاهش غیرعادی فراوانی یک یا چند قالب در یک بازه مربوط است. روش های مبتنی بر بردار شمارش و برخی مدل های ترکیبی، فراوانی را در کنار ترتیب یا معنا به کار می گیرند. LogLAA بازنمایی های شمارشی، ترتیبی و معنایی را هم زمان وارد آشکارساز می کند [۱۷]. در این پایان نامه شمارش پنجره مستقیماً به کوئن داده نمی شود و این محدودیت باید هنگام تحلیل خطا در نظر گرفته شود.

ناهنجاری معنایی زمانی رخ می دهد که ساختار ظاهری پیام به نمونه های عادی شبیه باشد، اما واژه یا مقدار موجود در آن معنای نامطلوبی داشته باشد. LogPrompt، RAGLog و LogLLM استفاده از بازنمایی زبانی را برای فهم یا بازیابی چنین تفاوت هایی بررسی کرده اند [۱، ۴، ۶، ۱۲]. جدا نگه داشتن صفر از مقدار غیرصفر در نرمال سازی این پایان نامه با هدف حفظ همین نشانه عملیاتی انجام می شود.

ناپایداری لاگ به تغییر قالب، واژگان یا توزیع رخدادها پس از به‌روزرسانی نرم‌افزار یا تغییر پیکربندی گفته می‌شود. مطالعات مبتنی بر GPT روی LOGEVOL و همچنین LogLLM و FlexLog، این مسئله را با انتقال میان نسخه‌ها، مدل زبانی یا ترکیب چند مدل بررسی کرده‌اند [۴، ۱۰، ۱۱]. بی‌جی‌ال در این پایان‌نامه یک مجموعه ثابت است و آزمون انتقال میان نسخه‌های نرم‌افزار در دامنه پژوهش قرار ندارد.

۲-۲-۱۵ چالش‌های روش‌شناختی و اجرایی

نامتوازن بودن کلاس‌ها نخستین چالش روش‌شناختی است. در بی‌جی‌ال تنها حدود ۷،۳۴ درصد پیام‌ها ناهنجارند [۲، ۱۹]. در چنین وضعی، مدلی که بیشتر پیام‌ها را عادی اعلام کند ممکن است صحت ظاهراً بالایی داشته باشد، اما بخش بزرگی از ناهنجاری‌ها را از دست بدهد. به همین سبب BERT-Log و Hybrid Prompting دقت، بازخوانی و امتیازافیک را در کنار صحت یا به‌جای اتکای صرف به آن گزارش می‌کنند [۳، ۱۸].

چالش دوم، انتقال خطای تجزیه‌گر به مرحله تشخیص است. اگر یک پارامتر به‌اشتباه واژه ثابت تشخیص داده شود یا برعکس، قالب نادرستی به آشکارساز می‌رسد. LogPPT و LogParser-LLM برای سنجش این مسئله از معیارهای صحت گروه‌بندی، صحت تجزیه و دانه‌بندی قالب استفاده می‌کنند [۲۳، ۲۴]. در این پایان‌نامه نیز قواعد نرمال‌سازی باید مستقل از کیفیت طبقه‌بندی ممیزی شوند.

نشت داده ممکن است از ورود برچسب مرجع به متن، هم‌پوشانی آموزش و آزمون یا تکرار یک قالب در دو بخش ایجاد شود. ADALog پیام‌های یکتای عادی را میان آموزش، تعیین آستانه و آزمون جدا می‌کند [۲۲]. در پژوهش حاضر، برچسب بی‌جی‌ال پیش از ساخت دستور حذف می‌شود و حافظه نهان نیز فقط در محدوده اجرای تعریف‌شده و با کلید نسخه‌بندی‌شده به کار می‌رود.

پاسخ یک مدل مولد ممکن است از قرارداد تعیین‌شده پیروی نکند یا میان اجراها تغییر کند. مطالعات مبتنی بر دستور نشان داده‌اند که نحوه بیان وظیفه و درخواست توضیح بر نتیجه اثر می‌گذارد [۱، ۲، ۶، ۲۵]. استفاده از دمای صفر، ساختار جی‌سان، اعتبارسنجی برچسب و ثبت پاسخ نامعتبر، این رفتار را در پژوهش حاضر قابل اندازه‌گیری می‌کند [۲۹].

تبیین‌پذیری در منابع معنای واحدی ندارد. LogPrompt از مدل می‌خواهد دلیل تصمیم را بنویسد [۱، ۶]؛ LLM-LADE تشخیص و توضیح را هم‌زمان آموزش می‌دهد [۷]؛ و LogLAA پس از آشکارسازی، از مدل زبانی برای تولید شرح استفاده می‌کند [۱۷]. خروجی این پایان‌نامه عمداً دودویی است؛ بنابراین تبیین در سطح ثبت منبع تصمیم، قالب نرمال‌شده و قاعده فعال‌شده دنبال می‌شود، نه در قالب توضیح آزاد مدل.

محرمانگی، بازتولیدپذیری و هزینه به یکدیگر وابسته‌اند. در خدمات تجاری، نسخه مدل یا محدودیت نرخ ممکن است تغییر کند؛ در مقابل، استقرار محلی کنترل بیشتری بر مدل و داده فراهم می‌سازد [۲، ۲۰]. البته بازتولید نتیجه محلی نیز مستلزم ثبت سخت‌افزار، شیوه کوانتیزه‌سازی، نسخه اولاما و پارامترهای تولید است [۲۸، ۲۹].

۲-۳ پیشینه تحقیق

۲-۳-۱ دامنه و شیوه مرور مطالعات

پیشینه این فصل همه ۲۷ مقاله موجود در پوشه پژوهش را در بر می گیرد. برای آنکه تفاوت نقش‌ها روشن بماند، مطالعات در شش گروه سامان یافته‌اند: روش‌های ترتیبی و پیش‌آموزش‌دیده؛ آموزش و انتقال مدل زبانی بزرگ؛ روش‌های مبتنی بر دستور؛ بازیابی و مهار هزینه؛ تجزیه لاگ؛ و سرانجام مرورها، معیارها، مدل‌های پایه و مطالعات استقرار. این تقسیم‌بندی با محورهای مرور نظام‌مند لاگ [۱۴] و مرور کاربرد مدل‌های زبانی بزرگ در تشخیص ناهنجاری [۲۷] هم‌خوان است.

منابع [۱] و [۶] دو نسخه هم‌پوشان از یک مسیر پژوهشی با نام LogPrompt هستند. هر دو منبع، برای پوشش کامل مقالات، جداگانه معرفی و در جدول ثبت شده‌اند؛ با این حال در جمع‌بندی، دو روش مستقل محسوب نمی‌شوند. همچنین [۲۵] OpsEval و [۲۶] YuLan مستقیماً آشکارساز لاگ نیستند. اولی برای بحث ارزیابی مدل در عملیات فناوری اطلاعات و دومی برای توضیح مراحل ساخت و دستورپذیر کردن یک مدل متن‌باز استفاده می‌شود.

۲-۳-۲ روش‌های ترتیبی و مدل‌های زبانی پیش‌آموزش‌دیده

دو و همکاران در مقاله DeepLog، لاگ را همچون یک دنباله از رخدادها مدل کردند. شبکه حافظه کوتاه‌مدت بلند با تاریخچه رخدادهای عادی آموزش می‌بیند و چند رخداد محتمل بعدی را پیش‌بینی می‌کند. اگر رخداد واقعی در میان گزینه‌های محتمل نباشد، توالی مشکوک تلقی می‌شود. مقاله علاوه بر تشخیص، به‌روزرسانی تدریجی مدل و ساخت جریان‌های اجرایی برای کمک به عیب‌یابی را نیز توضیح می‌دهد [۲۱].

DeepLog روی HDFS و OpenStack ارزیابی شده و نشان داده است که مدل‌سازی ترتیب رخدادها می‌تواند وابستگی‌هایی را ثبت کند که روش‌های آماری ساده از دست می‌دهند [۲۱]. با این حال، روش به استخراج کلید رخداد و ساخت توالی معتبر وابسته است و برای هر خط به‌طور مستقل تصمیم نمی‌گیرد. از این‌رو در این پایان‌نامه DeepLog یک مبنای مفهومی برای خانواده ترتیبی است، نه روشی با پروتکل ارزیابی یکسان.

گوئو، یوان و وو در LogBERT چارچوبی خودنظارتی با دو هدف طراحی کردند: بازسازی کلید رخداد پوشانده‌شده و فشرده‌کردن بازنمایی توالی‌های عادی در یک ابرکره. زمینه دوسویه BERT اجازه می‌دهد هر رخداد با توجه به رخدادهای پیش و پس از خود بازنمایی شود؛ هدف دوم نیز نمایش توالی‌های عادی را در فضای ویژگی به یکدیگر نزدیک می‌کند [۱۹].

LogBERT روی HDFS، بی‌جی‌ال و Thunderbird آزمایش شده است. در بی‌جی‌ال، پنجره‌های پنج‌دقیقه‌ای ساخته می‌شوند، حدود پنج هزار توالی عادی برای آموزش به کار می‌رود و میانگین طول هر توالی ۵۶۲ رخداد گزارش شده است [۱۹]. نیاز به آموزش با داده عادی و تشکیل پنجره، دو تفاوت اصلی این روش با اجرای بدون تنظیم کوئن و تصمیم خط‌به‌خط پژوهش حاضرند.

چن و لیاو در BERT-Log ابتدا پیام‌های تجزیه‌شده را با BERT بازنمایی کردند و سپس مدل را همراه یک لایه تمام‌متصل برای طبقه‌بندی تنظیم نمودند. توالی‌ها در HDFS با شناسه بلوک و در بی‌جی‌ال با شناسه گره،

اندازه پنجره و گام ساخته می‌شوند. بدین ترتیب، مدل هم محتوای متن و هم زمینه توالی را برای جداسازی رفتار عادی از ناهنجار به کار می‌گیرد [۱۸].

BERT-Log در پروتکل مقاله، امتیاز افیک ۹۹،۳ درصد برای HDFS و ۹۹،۴ درصد برای بی‌جی‌ال گزارش کرده است [۱۸]. این اعداد حاصل آموزش نظارت‌شده، تجزیه پیام و پنجره‌بندی ویژه همان مطالعه‌اند و با تشخیص خط‌محور بدون تنظیم دقیق مقایسه مستقیم ندارند. اهمیت این مقاله برای پژوهش حاضر، نشان‌دادن توان بازنمایی زبانی در بی‌جی‌ال و ضرورت گزارش دقیق پروتکل پنجره‌بندی است.

آمودوار و همکاران در LogFit مدل زبانی را با وظیفه مدل‌سازی زبان پوشانده‌شده^۳ و فقط با لاگ‌های عادی سازگار کردند. هنگام آزمون، مدل باید توکن‌های پوشانده‌شده پیام یا توالی را پیش‌بینی کند. اگر توکن واقعی در میان k گزینه برتر^۴ نباشد، شواهد ناهنجاری افزایش می‌یابد [۸].

LogFit روی HDFS، بی‌جی‌ال و Thunderbird بررسی شده و هدف آن کاهش وابستگی به نمونه ناهنجار برچسب‌خورده است [۸]. هرچند این روش از یک مدل زبانی استفاده می‌کند، مدل آن مولد و دستورمحور نیست و باید با لاگ مقصد تنظیم شود. در مقابل، پژوهش حاضر وزن‌های کوئن را ثابت نگه می‌دارد و برچسب دودویی را از پاسخ دستور متنی استخراج می‌کند.

پوسپیشنی و همکاران در ADALog روشی تطبیقی و بدون نظارت برای تحلیل مستقل پیام‌های خام پیشنهاد کردند. DistilBERT با وظیفه مدل‌سازی زبان پوشانده‌شده روی پیام‌های عادی تنظیم می‌شود. سپس احتمال بازسازی توکن‌ها به امتیازی در سطح پیام تبدیل و آستانه با توجه به توزیع خطای داده عادی تعیین می‌گردد. روش به توالی پیوسته یا یک تجزیه‌گر کلاسیک وابسته نیست [۲۲].

ADALog روی بی‌جی‌ال، Thunderbird و Spirit ارزیابی شده و اثر نرخ پوشاندن، پاک‌سازی و جایگاه توکن‌ها را با حذف اجزای روش بررسی کرده است [۲۲]. نزدیکی واحد تصمیم آن به سطح خط، این مقاله را برای پایان‌نامه مهم می‌کند؛ اما سازوکار تصمیم متفاوت است. ADALog به تنظیم DistilBERT و امتیاز بازسازی متکی است، درحالی‌که پژوهش حاضر از یک مدل دستورمحور، پاسخ ساخت‌یافته و حافظه نهان قالب بهره می‌برد.

۲-۳-۳ آموزش، تنظیم کارآمد پارامترها و انتقال مدل زبانی بزرگ

هان، یوان و ترابلسی در پژوهش خود درباره تشخیص ناهنجاری لاگ با GPT، مدلی با نام LogGPT ارائه کردند. مدل ابتدا برای پیش‌بینی رخداد بعدی آموزش می‌بیند و سپس با یادگیری تقویتی، رفتار تولیدی آن به هدف تشخیص ناهنجاری نزدیک می‌شود. بنابراین روش هم از توان مدل خودبازگشتی برای فراگیری توالی بهره می‌برد و هم با پاداش، مرز تصمیم را اصلاح می‌کند [۵].

این روش روی HDFS، بی‌جی‌ال و Thunderbird ارزیابی شده است [۵]. تشابه نام آن با مقاله [۲] نباید موجب یکسان‌انگاری شود: منبع [۵] به آموزش مدل و یادگیری تقویتی می‌پردازد، اما منبع [۲] توان ChatGPT را از طریق دستور متنی می‌سنجد. پژوهش حاضر، از نظر ثابت‌بودن وزن‌ها، به مطالعه دوم نزدیک‌تر است.

گوان و همکاران LogLLM را از سه جزء ساختند: BERT برای استخراج بردار معنایی، یک لایه نداشت برای انتقال بازنمایی و LLaMA برای طبقه‌بندی. پیام‌ها با قواعد منظم آماده می‌شوند و آموزش چندمرحله‌ای، فضای بازنمایی BERT را با فضای مدل بزرگ هم‌تراز می‌کند [۴].

LogLLM روی HDFS، بی‌جی‌ال، Liberty و Thunderbird و نیز در سناریوهای لاگ ناپایدار ارزیابی شده است [۴]. این معماری نشان می‌دهد که استخراج ویژگی و تصمیم‌نهایی را می‌توان میان یک رمزگذار کوچک و یک مدل زبانی بزرگ تقسیم کرد؛ با این حال، لایه نداشت و LLaMA هر دو به آموزش نیاز دارند. پژوهش حاضر بدون آموزش، قالب نرمال‌شده را مستقیماً به کوئن می‌دهد.

ژانگ و همکاران در LLM-LADE سه مرحله را به هم پیوند دادند: افزایش داده، تنظیم کارآمد پارامترها و بهینه‌سازی برخط. GPT-۴ با چند نمونه درون دستور داده تازه تولید می‌کند و Llama۳-۸B با سازگارسازی کم‌رتبه به‌عنوان آشکارساز تنظیم می‌شود. مدل افزون بر برچسب، توضیح متنی می‌سازد و دانش حاصل از نمونه‌های جدید در یک پایگاه افزایشی نگه‌داری می‌شود [۷].

LLM-LADE تشخیص و توضیح را در یک فرایند مشترک انجام می‌دهد و برای سازگاری با تغییرات، بهینه‌سازی برخط را پیشنهاد می‌کند [۷]. در پایان‌نامه حاضر، به‌منظور حذف ابهام، خروجی به یک برچسب ساخت‌یافته محدود است؛ توضیح آزاد، تنظیم کم‌رتبه و بهینه‌سازی برخط نیز در دامنه قرار ندارند. بنابراین سنجش بر کیفیت دودویی و هزینه استنتاج متمرکز می‌ماند.

لیم، ژو و پنگ روش‌های سازگارسازی کم‌رتبه و تنظیم بازنمایی را روی GPT-۲، RoBERTa و Llama-۳ برای تشخیص ناهنجاری لاگ مقایسه کردند. این مطالعه به ارائه یک مدل منفرد محدود نیست و پایداری اجرا، کارایی نمونه، مقاومت در برابر لاگ ناپایدار و انتقال میان HDFS، بی‌جی‌ال، Spirit و Thunderbird را می‌سنجد [۹]. نتایج نشان می‌دهند که هم مدل پایه و هم روش تنظیم کارآمد پارامترها بر پایداری و انتقال اثر دارند [۹]. ارزش این مطالعه برای پایان‌نامه در روشن کردن تفاوت میان «به‌کارگیری مدل زبانی بزرگ» و «استفاده از مدل بدون تنظیم» است. کوئن در این پژوهش هیچ سازگارسازی پارامتری ندارد و باید به‌عنوان استنتاج صرفاً مبتنی بر دستور ارزیابی شود، نه یک آشکارساز تنظیم‌شده.

هادی و همکاران در پژوهشی درباره تشخیص ناهنجاری در لاگ‌های ناپایدار، تغییر قالب‌ها میان نسخه‌های نرم‌افزار را بررسی کردند. GPT-۳ با لاگ مقصد تنظیم شد، درحالی‌که GPT-۴ از طریق طراحی دستور به کار رفت. داده آزمایش از دو نسخه LOGEVOL-Hadoop تشکیل شده است تا اثر ناپایداری و انتقال میان نسخه‌ها اندازه‌گیری شود [۱۱].

در پروتکل همان مقاله، تنظیم دقیق از مهندسی دستور نتیجه بهتری داشته است [۱۱]. این نتیجه به مدل و داده همان مطالعه وابسته است، اما یادآوری می‌کند که ثابت نگه‌داشتن وزن‌ها ممکن است در مواجهه با تغییر توزیع هزینه عملکرد داشته باشد. پژوهش حاضر انتقال میان نسخه‌ها را آزمایش نمی‌کند و فقط دو محل اعمال قاعده را روی یک مجموعه ثابت می‌سنجد.

سوئی و همکاران در LogSynergy برای انتقال آشکارساز به سامانه‌ای تازه، تفسیر رخداد با مدل زبانی بزرگ را با استخراج ویژگی یکپارچه ترکیب کردند. مدل، رخدادهایی با نگارش متفاوت اما معنای مشابه را به توصیف‌های نزدیک تبدیل می‌کند و ویژگی‌های استاندارد شده سپس به یک طبقه‌بند انتقالی داده می‌شوند [۱۵].

LogSynergy با پنج هزار توالی برچسب‌خورده، امتیاز افیک بیش از ۸۹ درصد روی داده واقعی و بیش از ۸۳ درصد روی داده‌های عمومی گزارش کرده است [۱۵]. مسئله اصلی آن انتقال میان سامانه‌هاست، نه تصمیم بدون آموزش در یک مجموعه. پیوند آن با پژوهش حاضر به نقش نرمال‌سازی معنایی و کاهش ناهمگونی ورودی بازمی‌گردد.

سان و همکاران در SemiRALD چارچوبی نیمه‌نظارتی ارائه کردند. ChatGPT با یادگیری درون‌متنی برای تجزیه لاگ به کار می‌رود و پس از آن، بازنمایی RoBERTa همراه با شبکه BiLSTM توجه‌محور، الگوی توالی را برای طبقه‌بندی می‌آموزد. این طراحی، تجزیه معنایی و طبقه‌بند آموزش‌پذیر را به دو مرحله جدا تقسیم می‌کند [۱۶].

SemiRALD روی HDFS و بی‌جی‌ال ارزیابی شده و میانگین بهبود امتیاز افیک را در مقایسه با دو گروه مبنا به ترتیب ۷۰۳ و ۸۰۲ درصد گزارش کرده است؛ این بهبود با تنها ۰۰۱ درصد داده برچسب‌خورده برجسته‌تر است [۱۶]. واژه ترکیبی در نام این مقاله به ترکیب مدل زبانی و مدل ترتیبی اشاره دارد و با آبشار قاعده و مدل در پایان‌نامه معنای متفاوتی دارد.

گائو و همکاران در LogLAA تجزیه، تشخیص و توضیح را در یک چارچوب تطبیقی گرد آوردند. تجزیه‌گر از طول پیام، فراوانی واژه، جایگزینی متغیر و درخت پیشوند استفاده می‌کند. سپس بازنمایی‌های شمارشی، ترتیبی و معنایی به یک شبکه CNN-LSTM دوتوجهی داده می‌شوند و مدل زبانی بزرگ شرح نتیجه را تولید می‌کند [۱۷].

LogLAA بهبود ۰۰۸ درصدی کیفیت تجزیه، افزایش حدود شش درصدی دقت تشخیص نسبت به میانگین روش‌های مقایسه و امتیاز ۰۰۷ برای کیفیت توضیح گزارش کرده است [۱۷]. این سامانه چندمرحله‌ای و آموزش‌پذیر است؛ در مقابل، پژوهش حاضر مدل ترتیبی و تولید توضیح را کنار می‌گذارد و بر کنترل مسیر تصمیم، حافظه نهان و اجرای محلی یک مدل ثابت تمرکز دارد.

۲-۳-۴ مطالعات مبتنی بر دستور متنی

لیو و همکاران در نسخه نخست LogPrompt، تحلیل برخط و تبیین‌پذیر لاگ را بدون آموزش درون‌دامنه بررسی کردند. روش، وظیفه را به گام‌های روشن تقسیم می‌کند، دانش لازم را در متن دستور می‌نویسد و از مدل می‌خواهد دلیل تصمیم خود را نیز بیان کند [۱].

نسخه سال ۲۰۲۳ چند وظیفه تحلیل لاگ را در یک چارچوب مبتنی بر دستور گرد آورده و پایه مسیر پژوهشی LogPrompt را ساخته است [۱]. مقاله [۶] نسخه گسترش‌یافته همین کار است؛ بنابراین نتایج آن دو شواهد مستقل محسوب نمی‌شوند. معرفی جداگانه هر دو منبع، تحول روش و پوشش کامل فایل‌های موجود را نشان می‌دهد.

چی و همکاران در مطالعه‌ای درباره‌ی تشخیص ناهنجاری لاگ با ChatGPT، توان این مدل را روی بی‌جی‌ال و Spirit سنجیدند. آنان پنج عامل را بررسی کردند: شیوه‌ی نگارش دستور، اندازه‌ی پنجره، افزودن دانش انسانی، مقایسه با مدل‌های عمیق و تبیین‌پذیری. مقاله برای بی‌جی‌ال، ۴۰۷۴۷،۹۶۳ پیام و ۳۴۸،۴۶۰ پیام ناهنجار گزارش می‌کند [۲].

محدودیت نرخ رابط برنامه‌نویسی سبب شد آزمایش فقط بر دو هزار پیام متوالی از بخش آزمون انجام شود و نسبت ناهنجاری به‌طور دستی کنترل گردد [۲]. از این‌رو، نتیجه‌ی مقاله نماینده‌ی اجرای کامل مجموعه نیست. پژوهش حاضر با مدل محلی و حافظه‌ی نهان سطح قالب برای پردازش گسترده‌تر طراحی شده و افزون بر امتیاز افیک، نرخ پاسخ نامعتبر و زمان را ثبت می‌کند.

نسخه‌ی کامل‌تر LogPrompt راهبردهای گوناگون دستور را روی ۹ مجموعه داده و چند وظیفه‌ی تجزیه و تشخیص می‌آزماید. تعریف وظیفه، دانش صریح یا ضمنی و زنجیره‌ی استدلال سه جزء اصلی‌اند که مدل را به سوی تصمیم و توضیح هدایت می‌کنند [۶].

مقاله در برخی تنظیم‌ها تا ۵۵،۹ درصد بهبود نسبت به روش‌های آموزش‌دیده و امتیاز ۴۰،۴۲ از ۵ برای تفسیرپذیری در ارزیابی متخصصان گزارش کرده است [۶]. بررسی حذف اجزا در بی‌جی‌ال نشان می‌دهد افزودن استدلال یا درخواست توضیح می‌تواند امتیاز افیک را در سطح نشست و قالب تغییر دهد. پایان‌نامه‌ی حاضر برای کاهش ابهام، پاسخ را به برجسب ساخت یافته محدود می‌کند.

پارک، چوی و لی در Hybrid Prompting سه نوع شاهد را در یک دستور کنار هم قرار دادند: رخداد پیش‌تر دیده‌نشده، آمار و شباهت توالی، و نزدیک‌ترین نمونه‌ی عادی. Qwen۳-Embedding-۸B برای ساخت بردار تعبیه و GPT-۴o-mini برای طبقه‌بندی استفاده می‌شوند. آزمایش‌ها روی HDFS، بی‌جی‌ال و Thunderbird و در سطح توالی انجام شده‌اند [۳].

Hybrid Prompting در بی‌جی‌ال، با پنجره‌ی یک‌دقیقه‌ای و نمونه‌ی متوازن، دقت ۶۳،۶۵، بازخوانی ۹۹،۶۰ و امتیاز افیک ۷۷،۸۱ درصد گزارش کرده است. میانگین بهبود امتیاز افیک در سه مجموعه ۹۰،۹۳ واحد درصد است [۳]. در آن مقاله «ترکیبی» به ادغام شواهد در متن دستور اشاره دارد؛ در پایان‌نامه، روش ترکیبی آبشاری از قاعده و مدل است و برای هر خط تصمیم می‌گیرد.

۲-۳-۵ بازیابی، همکاری مدل‌ها و مهار هزینه‌ی محاسباتی

پن، وونگ و یوان در RAGLog پایگاه برداری را از نمونه‌های عادی ساختند. برای هر پیام ورودی، نمونه‌ی نزدیک بازیابی و همراه پیام به مدل زبانی بزرگ داده می‌شود. نمونه‌های پایگاه با خوشه‌بندی میانگین‌های کا از بی‌جی‌ال و Thunderbird برگزیده می‌شوند و مدل، بدون دیدن نمونه‌ی ناهنجار، بر پایه‌ی شباهت و تحلیل معنایی تصمیم می‌گیرد [۱۲].

RAGLog در تنظیم گزارش‌شده، دقت ۰،۹۱، بازخوانی ۰،۸۸ و امتیاز افیک ۰،۸۹ به دست آورده و با LogPrompt مقایسه شده است [۱۲]. نویسندگان مصرف منابع و تأخیر تحلیل خطبه‌خط را از محدودیت‌های روش

می‌دانند. در RAGLog پایگاه برداری برای انتخاب زمینه است؛ در پایان‌نامه حافظه^{۱۳} نهان، تصمیم معتبر یک قالب تکراری را دوباره به کار می‌برد.

ما و همکاران در AdaptiveLog همکاری یک مدل زبانی کوچک و یک مدل بزرگ را برای چند وظیفه^{۱۴} تحلیل لاگ پیشنهاد کردند. مدل کوچک ابتدا نمونه را پردازش می‌کند و سنجه^{۱۵} عدم قطعیت مشخص می‌کند کدام نمونه به مدل بزرگ سپرده شود. موارد دشوار مشابه نیز از مخزن خطا بازیابی و به متن دستور افزوده می‌شوند. بازخورد مدل بزرگ برای بهبود تدریجی مدل کوچک به کار می‌رود [۱۳].

AdaptiveLog کاهش هزینه^{۱۶} فراخوانی مدل بزرگ تا ۷۳ درصد را گزارش کرده است [۱۳]. این صرفه‌جویی به یک مدل کوچک آموزش‌پذیر و سنجه^{۱۷} عدم قطعیت وابسته است. در روش ترکیبی پایان‌نامه، چند قاعده^{۱۸} قطعی نقش دروازه را دارند و در روش صرفاً مبتنی بر دستور همان دروازه حذف می‌شود؛ بنابراین به آموزش یک مدل جانبی نیاز نیست.

هادی و همکاران FlexLog را برای تشخیص داده‌کارآمد در لاگ‌های ناپایدار طراحی کردند. خروجی درخت تصمیم، نزدیک‌ترین همسایه و شبکه^{۱۹} پیش‌خور با Mistral، بازیابی نمونه و حافظه^{۲۰} نهان ترکیب می‌شود. مدل‌های کلاسیک نمونه‌های آشنا را پوشش می‌دهند و مدل زبانی بزرگ برای موارد دشوار یا وابسته به معنا فراخوانی می‌شود [۱۰].

آزمایش FlexLog روی SYNEVOL-U، ADFA-U، LOGEVOL-U، SynHDFS-U و SYNEVOL-U انجام شده است. مقاله در برخی تنظیم‌ها حداقل ۱۰۲ واحد درصد بهبود امتیاز افیک با ۶۲،۸۷ واحد درصد داده^{۲۱} برچسب‌خورده^{۲۲} کمتر، تا ۱۳ واحد درصد بهبود و زمان استنتاج کمتر از یک ثانیه برای هر توالی گزارش می‌کند [۱۰]. شباهت آن با پایان‌نامه در حافظه^{۲۳} نهان و آبشار تصمیم است؛ اما داده، واحد تحلیل و ترکیب چند طبقه‌بند متفاوت‌اند.

۲-۳-۶ مطالعات تجزیه و تولید قالب لاگ

له و ژانگ در LogPPT برای تجزیه^{۲۴} لاگ، تنظیم مبتنی بر دستور و یادگیری چندنمونه‌ای را روی RoBERTa به کار بردند. نمونه‌گیری تصادفی تطبیقی، مجموعه‌ای کوچک اما متنوع از پیام‌ها را برمی‌گزیند و مدل یاد می‌گیرد توکن‌های پارامتر را با یک برچسب مجازی مشخص کند. روش به عبارت منظم دستی وابسته نیست و تنظیمات یکسانی را در دامنه‌های مختلف حفظ می‌کند [۲۴].

LogPPT روی ۱۶ مجموعه^{۲۵} عمومی و با ۳۲ نمونه^{۲۶} برچسب‌خورده ارزیابی شده و میانگین صحت گروه‌بندی و صحت تجزیه^{۲۷} بیش از ۰،۹ گزارش کرده است [۲۴]. هدف مقاله تشخیص ناهنجاری نیست؛ با این حال، تعریف قالب و پارامتر در آن پشتوانه^{۲۸} نظری نرمال‌سازی و حافظه^{۲۹} نهان سطح قالب در پژوهش حاضر است.

ژونگ و همکاران در LogParser-LLM توان معنایی مدل زبانی بزرگ را با یک درخت پیشوند برای تجزیه^{۳۰} برخط ترکیب کردند. هر پیام ابتدا با قالب‌های موجود سنجیده می‌شود و فقط الگوهای تازه یا مبهم به مدل فرستاده می‌شوند. مقاله برای کنترل ریز یا درشت‌بودن قالب، یک معیار اختصاصی و امکان بازخورد انسانی نیز پیشنهاد می‌کند [۲۳].

در LogPub، با میانگین ۳٫۶ میلیون پیام در ۱۴ مجموعه، LogParser-LLM به طور متوسط ۲۷۲٫۵ فراخوانی مدل، امتیاز افیک گروه بندی ۹۰٫۶ درصد و صحت تجزیه ۸۱٫۱ درصد گزارش کرده است [۲۳]. این نتیجه نشان می دهد که تجمیع در سطح قالب می تواند فراخوانی ها را به شدت کاهش دهد؛ اما خروجی روش یک قالب است، نه برچسب ناهنجاری.

۲-۳-۷ مرورها، معیارهای ارزیابی، مدل های پایه و استقرار واقعی

دلا کروز کابلو، پرینس سیلز و ماچادو در یک مرور نظام مند، ۳۳ مقاله درباره ٔ عملیات هوشمند فناوری اطلاعات^{۲۵} و تشخیص ناهنجاری لاگ را بررسی کردند. آنان آماده سازی داده، تجزیه، استخراج ویژگی، مدل تشخیص، مجموعه های معیار و شیوه ٔ ارزیابی را دسته بندی و گذار از مدل های عمیق به مدل های زبانی بزرگ را جمع بندی کردند [۱۴].

این مرور روش آزمایشی تازه ای برای بی جی ال ارائه نمی کند. نقش آن در فصل حاضر، فراهم کردن چارچوب دسته بندی و صورت بندی مسائل بازی مانند هزینه، تبیین پذیری، تعمیم و محرمانگی است [۱۴]. ساختار کلی فصل از محورهای این منبع بهره می گیرد، اما جدول مقایسه فقط ۲۷ فایل موجود در پوشه ٔ محلی را پوشش می دهد.

دلا کروز کابلو و همکاران در مطالعه ای میدانی، یک چارچوب خودنظارتی مبتنی بر LogBERT را با لاگ های سامانه ای^{۲۶} عادی آموزش دادند و در محیطی با محدودیت محرمانگی به صورت محلی مستقر کردند. اثر حداقل تعداد توکن، اندازه و هم پوشانی پنجره و نرخ پوشاندن بر کیفیت تشخیص و تأخیر اجرا بررسی شد [۲۰].

پنجره ٔ پانزده ثانیه ای با هم پوشانی ده ثانیه، بهترین موازنه ٔ گزارش شده میان اثربخشی و تأخیر را ایجاد کرد و ارزیابی متخصصان نیز کاربرد عملی روش را تأیید نمود [۲۰]. مقاله از اهمیت استقرار محلی و اندازه گیری تأخیر پشتیبانی می کند، اما مدل آن LogBERT آموزش دیده و داده ٔ آن لاگ واقعی است؛ نه کوئن بدون تنظیم روی بی جی ال.

لیو و همکاران OpsEval را برای سنجش توان مدل های زبانی بزرگ در عملیات فناوری اطلاعات ساختند. این مجموعه ۷۰۳۳۴ پرسش چند گزینه ای و ۱۰۷۳۶ پرسش پاسخ آزاد در چند زیرحوزه دارد و ۲۴ مدل را تحت راهبردهای خودسازگاری، زنجیره ٔ استدلال و یادگیری درون متنی مقایسه می کند [۲۵].

معیار FAE-Score پاسخ آزاد را از نظر روانی، درستی و پشتوانه ٔ شواهد می سنجد و هم بستگی حدود ۰٫۹۱۸۵ با ارزیابی متخصصان گزارش شده است [۲۵]. OpsEval آشکارساز لاگ نیست، اما حساسیت وظایف عملیاتی به نحوه ٔ دستور و ضرورت تناسب معیار با نوع خروجی را نشان می دهد. چون خروجی پایان نامه دودویی است، معیارهای ماتریس اغتشاش و نرخ پاسخ نامعتبر جای معیار ارزیابی متن آزاد را می گیرند.

ژو و همکاران در گزارش فنی YuLan، فرایند توسعه ٔ یک مدل متن باز دوازده میلیارد پارامتری را شرح دادند. مدل با حدود ۱۰۷ تریلیون توکن چندزبانه پیش آموزی شده و سپس تنظیم دستوری و هم ترازای انسانی را پشت سر

گذاشته است. مقاله همچنین برنامه آموزشی آسان به دشوار، معماری، توکن‌ساز^{۳۷} و داده‌های آموزش را توضیح می‌دهد [۲۶].

YuLan روی ۲۲ معیار عمومی ارزیابی شده، اما موضوع آن تشخیص ناهنجاری لاگ نیست [۲۶]. این منبع برای توضیح تفاوت مدل پایه با مدل دستورمحور و مسیر پیش‌آموزی تا هم‌ترازی در فصل گنجانده شده است. مدل عملی پژوهش کوئن ۲۰۵ دستورمحور است و YuLan در آزمایش‌های مقایسه‌ای به کار نمی‌رود. شو و دینگ کاربرد مدل‌های زبانی بزرگ در تشخیص ناهنجاری و داده خارج از توزیع را در حوزه‌های گوناگون مرور کردند. آنان مطالعات را بر پایه نقش مدل به دو گروه «استفاده برای تشخیص» و «استفاده برای تولید» تقسیم و تفاوت تغییر درون‌توزیعی با تغییر معنایی، مجموعه‌های داده و مسیرهای آینده را بررسی کردند [۲۷]. دامنه این مرور فراتر از لاگ و شامل متن، سری زمانی و گونه‌های دیگر داده است [۲۷]. در فصل حاضر، از آن برای تعریف نقش مدل و جداسازی مطالعات تشخیص از پژوهش‌های تولید داده یا توضیح استفاده می‌شود. این مقاله آزمایش مستقیمی درباره کوئن یا بی‌جی‌ال گزارش نمی‌کند.

۲-۳-۸ جمع‌بندی تحلیلی مسیر پژوهش‌ها

نخستین مرحله تحول این حوزه با مدل‌سازی توالی رخدادها شکل گرفت. DeepLog رخداد بعدی را پیش‌بینی می‌کند و LogBERT زمینه دوسویه و وظیفه خودنظارتی را به تحلیل توالی می‌افزاید [۱۹، ۲۱]. BERT-Log مسیر دیگری دارد و بازنمایی زبانی را با طبقه‌بند نظارت‌شده ترکیب می‌کند [۱۸]. این مطالعات تفاوت میان یادگیری الگوی عادی و طبقه‌بندی برچسب‌محور را روشن کرده‌اند.

در مرحله بعد، کاهش وابستگی به نمونه ناهنجار برچسب‌خورده اهمیت یافت. LogFiT و ADALog هر دو با وظیفه مدل‌سازی زبان پوشانده شده و داده عادی کار می‌کنند [۸، ۲۲]، اما واحد تحلیل آن‌ها متفاوت است: اولی الگوی توکن را در پیام یا توالی می‌سنجد و دومی هر پیام را مستقل و با آستانه تطبیقی ارزیابی می‌کند. بنابراین حذف برچسب ناهنجار به تنهایی واحد تصمیم را مشخص نمی‌کند.

مرحله سوم با ورود مدل زبانی بزرگ آموزش‌پذیر شکل گرفت. LogGPT، LogLLM، LLM مبتنی بر GPT، LADE و روش‌های تنظیم کارآمد پارامترها از پیش‌آموزی عمومی آغاز می‌کنند، اما برای دامنه لاگ بخشی از وزن‌ها یا نگاشت‌های مدل را تغییر می‌دهند [۴، ۵، ۷، ۹]. هزینه آموزش و داده انطباق، این خانواده را از روش‌های صرفاً مبتنی بر دستور جدا می‌کند.

مرحله چهارم بر دستورپذیری مدل، بدون تغییر وزن، تکیه دارد. دو نسخه LogPrompt و مطالعه ChatGPT-LogGPT اثر نحوه دستور، دانش دامنه و استدلال را می‌سنجند [۱، ۲، ۶]. Hybrid Prompting این مسیر را با افزودن شواهد سطح توالی و نمونه بازبازی‌شده گسترش می‌دهد [۳]. در این خانواده، متن دستور و شیوه انتخاب زمینه جزئی از سامانه تصمیم‌اند.

مرحله پنجم به هزینه و مقیاس توجه دارد. RAGLog نمونه عادی مشابه را بازبازی می‌کند؛ AdaptiveLog فقط نمونه‌های نامطمئن را به مدل بزرگ می‌سپارد؛ و FlexLog مدل‌های کلاسیک، بازبازی و حافظه نهان را در

یک سامانه ترکیب می‌کند [۱۰، ۱۲، ۱۳]. LogParser-LLM نیز در وظیفه تجزیه نشان می‌دهد که یک ساختار پیشوندی می‌تواند فراخوانی مدل را در مقیاس میلیون‌ها پیام محدود کند [۲۳].

یک مسیر موازی بر تبیین‌پذیری متمرکز است. LogPrompt توضیح را در پاسخ مستقیم مدل می‌گیرد [۱]، LLM-LADE توضیح را هم‌زمان با تشخیص آموزش می‌دهد [۷]؛ و LogLAA آشکارساز عمیق و مولد توضیح را در دو جزء جدا کنار هم قرار می‌دهد [۱۷]. پس تبیین‌پذیری می‌تواند خروجی زبانی، هدف آموزشی یا مرحله پس از تشخیص باشد.

مطالعات انتقال و ناپایداری یادآوری می‌کنند که ارزیابی روی یک توزیع ثابت همه رفتار سامانه را نشان نمی‌دهد. پژوهش GPT روی LOGEVOL تغییر نسخه را مستقیماً می‌آزماید [۱۱]؛ LogSynergy بازنمایی مشترکی میان سامانه‌ها می‌سازد [۱۵]؛ و FlexLog داده‌های ناپایدار واقعی و مصنوعی را بررسی می‌کند [۱۰]. پایان‌نامه حاضر این محور را به‌صورت تجربی پوشش نمی‌دهد و به بی‌جی‌ال ثابت محدود است.

پژوهش‌های تجزیه نشان می‌دهند که آماده‌سازی ورودی خود یک مسئله مستقل است. LogPPT با یادگیری چندنمونه‌ای و LogParser-LLM با مدل زبانی بزرگ و درخت پیشوند، کیفیت قالب را خروجی اصلی می‌دانند [۲۳، ۲۴]. بنابراین اگر پس از تغییر تجزیه‌گر، کیفیت آشکارساز بهتر شود، باید اثر این دو مرحله از هم جدا شود. در پایان‌نامه، قواعد نرمال‌سازی در هر دو روش ثابت‌اند.

مطالعه میدانی عملیات هوشمند فاصله میان نتیجه آزمایشگاهی و استقرار واقعی را آشکار می‌کند: اندازه پنجره و تأخیر اجرا به اندازه دقت برای کاربرد اهمیت دارند [۲۰]. OpsEval نیز نشان می‌دهد ارزیابی مدل زبانی در وظایف عملیاتی به دستور و معیار متناسب نیازمند است [۲۵]. این دو منبع پشتوانه گزارش زمان، نسخه مدل و قرارداد خروجی در کنار امتیاز افیک هستند.

دو مقاله مروری مرز دامنه را روشن می‌کنند. مرور نظام‌مند لاگ، مراحل زنجیره پردازش و مسائل باز عملیات هوشمند را استخراج می‌کند [۱۴]؛ مرور تشخیص ناهنجاری و داده خارج از توزیع نیز نقش مدل را به تشخیص و تولید تقسیم می‌کند [۲۷]. هیچ‌یک نتیجه آزمایشی روی بی‌جی‌ال محسوب نمی‌شوند.

YuLan نیز در گروه نتایج تشخیص قرار نمی‌گیرد، اما مراحل ساخت مدل پایه، تنظیم دستوری و هم‌ترازی را مستند می‌کند [۲۶]. این تمایز اهمیت دارد، زیرا کوئن ۲۰۵ دستورمحور حاصل چنین مراحل عمومی است، ولی وزن‌های آن در پروژه تغییر نمی‌کنند و فقط در مرحله استنتاج به کار می‌روند [۲۸].

از مجموع این ۲۷ مقاله می‌توان پنج تصمیم طراحی را استخراج کرد: واحد تحلیل، شیوه سازگار کردن مدل، روش آماده‌سازی ورودی، سازوکار مهار هزینه و محل استقرار. در پایان‌نامه فقط یکی از این تصمیم‌ها، یعنی محل اعمال دانش قاعده، میان دو روش تغییر می‌کند و سایر عوامل برای مقایسه ثابت می‌مانند.

۲-۴ دسته‌بندی و تحلیل مقایسه‌ای

شکل ۱-۲ هر ۲۷ مقاله را در شش مسیر روش‌شناختی جای می‌دهد و سپس نشان می‌دهد کدام مؤلفه‌ها در طراحی پژوهش حاضر به یکدیگر می‌رسند. شماره‌های شکل با شماره فایل‌های پوشه و ارجاع‌های این فصل

یکسان‌اند. قرار گرفتن یک مقاله در یک گروه به معنای نداشتن مؤلفه‌های گروه دیگر نیست؛ برای نمونه، FlexLog هم از مدل‌های کلاسیک و مدل زبانی بزرگ بهره می‌برد و هم بازیابی و حافظهٔ نهان را به کار می‌گیرد [۱۰].

نقشه مطالعات بررسی‌شده در فصل دوم (۲۷ مقاله)			
ترتیبی و پیش‌آموزش‌دیده	آموزش، تنظیم و انتقال مدل زبانی بزرگ	دستور متنی و استدلال درون‌متنی	
DeepLog [۲۱]؛ LogBERT [۱۹]؛ LogFiT [۸]؛ BERT-Log [۱۸]؛ ADALog [۲۲]	LogGPT [۵]؛ مدل زبانی بزرگ [۴]؛ LLM-LADE [۷]؛ PEFT [۹]؛ GPT ناپایدار [۱۱]؛ LogSynergy [۱۵]؛ SemiRALD [۱۶]؛ LogLAA [۱۷]	ChatGPT-LogPrompt [۱، ۶]؛ Hybrid Prompting [۳]؛ LogGPT [۲]	
بازیابی، همکاری و کنترل هزینه	تجزیه و ساخت قالب	مرور، معیار و استقرار	
AdaptiveLog [۱۳]؛ RAGLog [۱۲]؛ FlexLog [۱۰]	LogPPT [۲۴]؛ LogParser-مدل زبانی بزرگ [۲۳]	OpsEval [۲۰]؛ AI Ops واقعی [۱۴]؛ SLR [۲۵]؛ YuLan [۲۶]؛ Anomaly/OOD [۲۷]؛ مرور	
ترکیب شواهد ادبیات برای طراحی پژوهش حاضر: معناشناسی مدل زبانی + قالب پایدار + کنترل تصمیم + استنتاج محلی			
دامنه و واحد تحلیل	متغیر مستقل مقایسه	کارایی	استقرار و سنجش
فقط BGL؛ طبقه‌بندی خط‌به‌خط؛ حذف برچسب از ورودی	Hybrid LLM: نگهبان قاعده‌محور قطعی پیش از صرفاً مبتنی بر دستور: انتقال دانش قاعده به دستور متنی	نرمال‌سازی و کش سطح قالب؛ رد پاسخ نامعتبر	Qwen۲.۵:۷B-Instruct روی Ollama؛ کیفیت، زمان و منبع تصمیم

شکل ۲-۱: ارتباط ۲۷ مقالهٔ بررسی‌شده با یکدیگر و جایگاه پژوهش حاضر

بخش بالایی شکل، گذار فنی از مدل‌های ترتیبی و BERT به مدل‌های زبانی بزرگ، دستور متنی، بازیابی و استقرار واقعی را نمایش می‌دهد. بخش پایینی، نوآوری عملیاتی مورد سنجش را خلاصه می‌کند: مدل و پیش‌پردازش ثابت می‌مانند و فقط محل اعمال دانش قاعده، میان نگهبان بیرونی و متن دستور، تغییر می‌کند. شکل برای نمایش رابطهٔ اجزای برگرفته از منابع است و دربارهٔ برتری هیچ مسیر داوری نمی‌کند.

جدول ۱-۲: ویژگی‌ها و نتایج گزارش‌شده در ۲۷ مقاله موجود در پوشه پژوهش

شماره و مطالعه	س ال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش‌شده
[۱] LogPrompt اولیه	۲۰ ۲۳	دستور متنی	مدل زبانی بزرگ + راهبرد دستور و تبیین	چند مجموعه لاگ	قالب/توالی	نسخه اولیه تحلیل بدون آموزش درون‌دامنه
[۲] ChatGPT- LogGPT	۲۰ ۲۳	دستور متنی	ChatGPT و دانش دامنه	BGL, Spirit	خط/پنجره	بررسی دستور متنی، پنجره و تبیین روی نمونه ۲۰۰۰ تایی
[۳] Hybrid Prompting	۲۰ ۲۵	دستور متنی ترکیبی	رخداد + توالی + بازایی	.HDFS, BGL Thunderbird	توالی یک دقیقه ی	BGL: $P=۶۳.۶۵$, $R=۹۹.۶۰$ افیک=۷۷.۸۱
[۴] LogLLM	۲۰ ۲۴	آموزش LLM	BERT + لایه نگاشت + LLaMA	.HDFS, BGL Liberty Thunderbird	توالی	ترکیب بازنمایی رمزگذار و طبقه‌بند LLM
[۵] LogGPT via GPT	۲۰ ۲۳	آموزش/RL	GPT پیش‌بینی رخداد + RL	.HDFS, BGL Thunderbird	توالی	هم‌راستاسازی پیش‌بینی رخداد با هدف تشخیص
[۶] LogPrompt توسعه‌یافته	۲۰ ۲۴	دستور متنی	zero-shot, CoT و تبیین	۹ مجموعه	قالب/توالی	تا ۵۵/۹٪ بهبود؛ تفسیرپذیری ۵/۴/۴۲
[۷] LLM-LADE	۲۰ ۲۵	PEFT/تبی ین	افزایش داده + LoRA + بهینه‌سازی برخط	مجموعه‌های عمومی	پیام/توالی	تشخیص و توضیح هم‌زمان با پایگاه دانش
[۸] LogFit	۲۰ ۲۵	خودنظارتی	مدل زبانی ماسک‌شده و گزینه‌های برتر	.HDFS, BGL Thunderbird	توالی	آموزش فقط روی لاگ عادی
[۹] PEFT-LAD	۲۰ ۲۵	PEFT	LoRA/ReFT روی .RoBERTa, GPT-۲ Llama-۳	.HDFS, BGL .Spirit Thunderbird	توالی	تحلیل پایداری، کارایی نمونه و انتقال
[۱۰] FlexLog	۲۰ ۲۴ ۲۵	ترکیبی	+ ML ensemble + Mistral + RAG cache	چهار مجموعه ناپایدار	توالی	داده کمتر؛ تا ۱۳ واحد درصد بهبود؛ کمتر از ۱ ثانیه
[۱۱] Unstable Logs GPT	۲۰ ۲۴	تنظیم/دس تور متنی	GPT-۳ تنظیم‌شده و GPT-۴ دستور متنی	LOGEVOL- Hadoop	توالی	برتری تنظیم دقیق در پروتکل مطالعه
[۱۲] RAGLog	۲۰ ۲۳ ۲۴	بازایی	پایگاه برداری عادی + LLM	.BGL Thunderbird	خط/توالی	دقت=۰.۹۱، بازخوانی=۰.۸۸، افیک=۰.۸۹
[۱۳] AdaptiveLog	۲۰ ۲۵	همکاری مدل	مدل کوچک + مدل زبانی بزرگ + بازایی	چند وظیفه لاگ	وابسته به وظیفه	تا ۷۳٪ کاهش هزینه فراخوانی LLM

شماره و مطالعه	س ال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش‌شده
[۱۴] مرور نظام‌مند AIOps	۲۰ ۲۵	مرور	SLR و طبقه‌بندی ۳۳ مقاله	ادبیات حوزه	مطالعه	چارچوب مراحل، داده‌ها، مدل‌ها و شکاف‌ها
[۱۵] LogSynergy	۲۰ ۲۵	انتقال	تفسیر مدل زبانی بزرگ + ویژگی یکپارچه	عمومی و واقعی	توالی	افیک بیش از ۸۳٪ عمومی و ۸۹٪ واقعی
[۱۶] SemiRALD	۲۰ ۲۵	نیمه‌نظارتی	+ ChatGPT parsing RoBERTa + BiLSTM	HDFS, BGL	توالی	بهبود متوسط افیک برابر ۷/۳ و ۸/۲٪
[۱۷] LogLAA	۲۰ ۲۶	یکپارچه	تجزیه‌گر + CNN-LSTM مدل زبانی بزرگ + explanation	چند مجموعه	توالی	بهبود تجزیه‌گر، دقت و تولید توضیح
[۱۸] BERT-Log	۲۰ ۲۲	نظارت‌شده	BERT + طبقه‌بند	HDFS, BGL	پنجره/توالی	افیک گزارش‌شده ۹۹/۴٪ روی BGL
[۱۹] LogBERT	۲۰ ۲۱	خودنظارتی	BERT با مدل‌سازی زبان پوشانده‌شده و ابرکره	HDFS, BGL Thunderbird	توالی	یادگیری الگوی عادی با دو هدف خودنظارتی
[۲۰] AIOps واقعی	۲۰ ۲۶	استقرار	LogBERT محلی	Linux syslog واقعی	پنجره زمانی	پنجره ۱۵ ثانیه با هم‌پوشانی ۱۰ ثانیه
[۲۱] DeepLog	۲۰ ۱۷	ترتیبی	LSTM و پیش‌بینی رخداد بعدی	HDFS OpenStack	توالی	تشخیص برخط، به‌روزرسانی و جریان عیب‌یابی
[۲۲] ADALog	۲۰ ۲۵	بدون نظارت	DistilBERT مدل‌سازی زبان پوشانده‌شده + آستانه تطبیقی	BGL Thunderbird Spirit	خط	بدون تجزیه‌گر و مستقل از توالی
[۲۳] LogParser- LLM	۲۰ ۲۴	تجزیه	مدل زبانی بزرگ + درخت پیشوند	Loghub-۲k LogPub	خط/قالب	۲۲۲/۵ فراخوانی؛ افیک گروه‌بندی ۹۰/۶٪
[۲۴] LogPPT	۲۰ ۲۳	تجزیه	چندنمونه‌ای prompt tuning RoBERTa روی	۱۶ مجموعه	خط/قالب	بیش از ۰/۹ با ۳۲ نمونه برچسب‌خورده
[۲۵] OpsEval	۲۰ ۲۵	معیار	چندگزینه‌ای/پاسخ آزاد + استدلال/یادگیری FAE- + درون‌متنی Score	۹۰۷۰ Ops	پرسش	۲۴ مدل زبانی بزرگ؛ هم‌بستگی FAE حدود ۰/۹۱۸۵
[۲۶] YuLan	۲۰ ۲۴	مدل پایه	مدل زبانی بزرگ متن‌باز ۱۲B و سه مرحله آموزش	۱/۷T توکن؛ ۲۲ معیار	متن	مرجع ساخت مدل دستورمحور؛ نه آشکارساز لاگ
[۲۷] Anomaly/OOD	۲۰ ۲۵	مرور	رده‌بندی مدل زبانی بزرگ برای تشخیص/تولید	چند حوزه داده	مطالعه	تفکیک anomaly و OOD و نقش‌های LLM

جدول ۱-۲ حضور همه ۲۷ فایل را قابل پیگیری می‌کند. منابع [۱۴]، [۲۵]، [۲۶] و [۲۷] نتیجه تشخیص روی بی‌جی‌ال ندارند؛ زیرا به ترتیب مرور نظام‌مند، معیار عملیات، گزارش مدل پایه و مرور عمومی هستند. این منابع برای روشن کردن مبانی نظری و معیارهای مقایسه در جدول آمده‌اند، نه به عنوان آزمایش مستقیم آشکارساز.

۲-۴-۱ مقایسه بر پایه واحد تحلیل و پروتکل بی‌جی‌ال

در مطالعاتی که بی‌جی‌ال را به کار برده‌اند، واحد تحلیل از یک پیام تا پنجره و توالی تغییر می‌کند. ADALog از نظر تصمیم در سطح پیام به پژوهش حاضر نزدیک‌تر است [۲۲]. BERT-Log، LogBERT و Hybrid Prompting پنجره یا توالی می‌سازند [۳، ۱۸، ۱۹] و LogGPT مبتنی بر ChatGPT فقط بخشی نمونه‌گیری شده از آزمون را بررسی می‌کند [۲]. بنابراین مقایسه عددی تنها هنگامی معتبر است که واحد تصمیم و نمونه ارزیابی یکسان باشند.

نسبت کلاس‌ها نیز در پروتکل‌ها متفاوت است. در بی‌جی‌ال اصلی حدود ۷،۳۴ درصد پیام‌ها ناهنجارند [۲، ۱۹]، اما Hybrid Prompting هزار توالی از هر کلاس انتخاب می‌کند [۳]. صحت روی داده متوازن و نامتوازن رفتار یکسانی ندارد؛ از این رو پایان‌نامه دقت، بازخوانی، امتیاز افیک و ماتریس اغتشاش را در سطح خط گزارش می‌کند.

۲-۴-۲ مقایسه براساس نیاز به آموزش

ADALog، DeepLog، BERT-Log، LogBERT، LogFiT با داده مقصد آموزش یا تنظیم می‌شوند [۸]، [۱۸، ۱۹، ۲۱، ۲۲]. LogLLM و LogGPT مبتنی بر GPT آموزش چندمرحله‌ای یا یادگیری تقویتی دارند [۴، ۵]. LLM-LADE، مطالعه تنظیم کارآمد پارامترها، LogSynergy و SemiRALD نیز از تنظیم کم‌پارامتر، انتقال یا آموزش نیمه‌نظارتی بهره می‌گیرند [۷، ۹، ۱۵، ۱۶].

در مقابل، Hybrid Prompting، ChatGPT-LogGPT، LogPrompt و RAGLog برای تصمیم‌گیری، تغییر وزن طبقه‌بند را شرط اصلی نمی‌دانند و از دستور و زمینه استفاده می‌کنند [۱-۳، ۶، ۱۲]. پژوهش حاضر در همین خانواده قرار می‌گیرد، با این تفاوت که حافظه نهان سطح قالب و مقایسه نگهبان بیرونی با دانش درون دستور را نیز به پروتکل می‌افزاید.

۲-۴-۳ مقایسه شیوه‌های مهار هزینه و محل استقرار

سه الگوی اصلی برای مهار هزینه در منابع دیده می‌شود. RAGLog با بازبازی، زمینه مرتبط را انتخاب می‌کند [۱۲]. AdaptiveLog نمونه‌های نامطمئن مدل کوچک را به مدل بزرگ می‌سپارد [۱۳]. FlexLog و LogParser LLM نیز با حافظه نهان یا ساختار تجمیعی از پردازش دوباره جلوگیری می‌کنند [۱۰، ۲۳]. هدف این سازوکارها مشترک است، اما آنچه ذخیره می‌شود و منطق تصمیم هر کدام تفاوت دارد.

استقرار محلی به‌طور صریح در مطالعه میدانی عملیات هوشمند مطرح شده است [۲۰]. بسیاری از پژوهش‌های مبتنی بر دستور از GPT-۴، ChatGPT، GPT-۴o-mini یا GPT-۴ استفاده کرده‌اند [۲، ۳، ۱۱] و برخی دیگر LLaMA یا Mistral را آموزش یا تنظیم کرده‌اند [۴، ۷، ۱۰]. ترکیب مورد سنجش این پایان‌نامه عبارت است از اجرای محلی کوئن ۲،۵ دستورمحور با اولاما، بدون تنظیم دقیق، همراه با ثبت زمان و پاسخ نامعتبر [۲۸، ۲۹].

۲-۴-۴ مقایسه بازنمایی ورودی و آماده‌سازی

روش‌های ترتیبی معمولاً پیام خام را مستقیماً به مدل نمی‌دهند. DeepLog پیام را به کلید رخداد تبدیل می‌کند و LogBERT توالی کلیدهای تجزیه‌شده را در اختیار BERT می‌گذارد [۱۹، ۲۱]. BERT-Log نیز با تجزیه و پنجره‌بندی، پیام‌ها را برای مدل آماده می‌کند [۱۸]. از این رو خطای تجزیه‌گر می‌تواند به مرحله تشخیص منتقل شود.

ADALog و LogLLM برای کاهش وابستگی به تجزیه‌گر کلاسیک، متن را با پاک‌سازی یا قواعد منظم آماده می‌کنند [۴، ۲۲]. ADALog مسیر، عدد و نشانی را با جانشین عمومی جایگزین می‌کند و LogLLM از متن پردازش‌شده بردار معنایی BERT می‌سازد. بنابراین عبارت «بدون تجزیه‌گر» به معنای حذف همه مراحل پیش‌پردازش نیست.

در روش‌های مبتنی بر دستور، آماده‌سازی علاوه بر پاک‌سازی، انتخاب زمینه را نیز در بر می‌گیرد. RAGLog یک نمونه عادی مشابه را می‌افزاید [۱۲]، Hybrid Prompting ویژگی‌های رخداد و توالی را محاسبه می‌کند [۳] و LogPrompt دانش وظیفه را در متن دستور می‌نویسد [۱، ۶]. پس بخشی از توان سامانه نه در خود مدل، بلکه در ساخت ورودی آن قرار دارد.

در پایان‌نامه، هر پیام به یک قالب نرمال‌شده تبدیل می‌شود، اما نمونه بازیابی‌شده یا پنجره زمانی به دستور افزوده نمی‌شود. این بازنمایی در دو روش ثابت است تا اختلاف نتیجه از تغییر آماده‌سازی ناشی نشود. تعداد قالب‌های یکتا و نرخ استفاده از حافظه نهان نیز اثر عملی نرمال‌سازی را نشان می‌دهند.

۲-۴-۵ مقایسه سازوکار تصمیم و نوع خروجی

در روش‌های پیش‌بینی‌محور، تصمیم از احتمال رخداد یا توکن به دست می‌آید. DeepLog رخداد بعدی را پیش‌بینی می‌کند و LogFiT و ADALog توکن پوشانده‌شده را بازسازی می‌کنند [۸، ۲۱، ۲۲]. سپس یک آستانه یا قرار گرفتن رخداد واقعی در میان گزینه‌های برتر، خروجی پیوسته را به برچسب دودویی تبدیل می‌کند. بنابراین انتخاب آستانه بخشی از روش است، نه یک جزئیات فرعی.

در روش‌های طبقه‌بندی، یک سر طبقه‌بند یا مدل زبانی تنظیم‌شده مستقیماً احتمال کلاس را تولید می‌کند. BERT-Log، LogLLM، LLM-LADE و SemiRALD نمونه‌های این خانواده‌اند [۴، ۷، ۱۶، ۱۸]. کیفیت تصمیم در این روش‌ها به داده آموزش، تابع زیان و شیوه تنظیم وابسته است.

در روش‌های مبتنی بر دستور، پاسخ متنی باید به برچسب تبدیل شود. LogPrompt و ChatGPT-LogGPT می‌توانند همراه برچسب، توضیح نیز تولید کنند [۱، ۲، ۶] و OpsEval برای پاسخ آزاد معیار جداگانه دارد [۲۵]. در یک سامانه خودکار، متن اضافه یا برچسب مبهم پردازش بعدی را مختل می‌کند؛ از این رو پایان‌نامه فقط خروجی دودویی در قالب جی‌سان را معتبر می‌داند.

ثبت پاسخ نامعتبر، خطای پیروی از قرارداد را از خطای طبقه‌بندی جدا می‌کند. اگر پاسخ نامعتبر به‌طور پیش‌فرض عادی یا ناهنجار فرض شود، صحت و امتیاز افیک رفتار واقعی مدل را نشان نخواهند داد. همچنین پاسخ نامعتبر در حافظه نهان ذخیره نمی‌شود تا یک خطای مربوط به قالب در پیام‌های تکراری تکثیر نشود.

۲-۴-۶ مقایسه تبیین‌پذیری و بازتولیدپذیری

توضیح آزاد مدل برای کاربر خواندنی است، اما سنجش کیفیت آن به معیار اختصاصی یا نظر متخصص نیاز دارد. LogPrompt از ارزیابی متخصصان، LLM-LADE از آموزش هم‌زمان تشخیص و توضیح، و LogLAA از امتیاز کیفیت شرح استفاده می‌کنند [۱، ۶، ۷، ۱۷]. این امتیازها هدفی متفاوت از امتیاز افیک طبقه‌بندی دارند و نباید با آن یکسان تفسیر شوند.

تبیین ساختاری، به جای متن آزاد، می‌تواند شناسه قالب، منبع تصمیم، قاعده فعال و زمان پاسخ را ثبت کند. این داده‌ها برای هر خط ذخیره و مقایسه می‌شوند. پایان‌نامه همین شکل از تبیین را برمی‌گزیند تا خروجی دو روش هم‌ساختار بماند و تفاوت طول توضیح، مقایسه زمان را مخدوش نکند.

بازتولیدپذیری در خدمات تجاری، به دلیل تغییر نسخه و محدودیت نرخ رابط، دشوارتر است. مطالعه ChatGPT-LogGPT به نمونه‌گیری محدود شده و Hybrid Prompting نیز به نسخه مشخصی از یک مدل تجاری وابسته است [۲، ۳]. در استقرار محلی می‌توان فایل مدل، شیوه کوانتیزه‌سازی و نسخه محیط اجرا را ثبت کرد؛ البته مشخصات سخت‌افزار و پارامترهای تولید همچنان باید گزارش شوند [۲۰، ۲۸، ۲۹].

برای مقایسه دو روش، ترتیب داده، دما، نسخه مدل و دستور، مهلت انتظار، شمار تلاش مجدد و سیاست حافظه نهان باید ثابت باشند. ثبت این متغیرها همراه شناسه اجرا و خروجی خطبه‌خط، بازسازی آزمایش و یافتن منشأ اختلاف را ممکن می‌سازد. مرور نظام‌مند و OpsEval نیز بر ضرورت چنین ارزیابی عملی و قابل بازتولیدی تأکید دارند [۱۴، ۲۵].

جدول ۲-۲: دسته‌های اصلی مطالعات و ارتباط آن‌ها با طراحی پژوهش حاضر

دسته	مقالات	نقش مدل زبانی	نیاز غالب به آموزش	ارتباط با پژوهش حاضر
ترتیبی/پیش‌آموزش دیده	[۸، ۱۸، ۱۹، ۲۱، ۲۲]	رمزگذار یا مدل توالی	بله؛ عادی یا برچسب‌خورده	تعریف BGL، واحد تحلیل و خط پایه زبانی
آموزش/تنظیم/انتقال ال LLM	[۴، ۵، ۷، ۹، ۱۱، ۱۵، ۱۶، ۱۷]	طبقه‌بند، مولد داده یا تبیین	آموزش، PEFT یا انتقال	مرز تمایز با Qwen بدون تنظیم
دستور متنی	[۱، ۲، ۳، ۶]	تصمیم‌گیر مستقیم	بدون تغییر وزن	نزدیک‌ترین خانواده به صرفاً مبتنی بر دستور
بازیابی/همکاری/هزینه	[۱۰، ۱۲، ۱۳]	جزء آبشار یا RAG	متغیر	مبنای مقایسه کش، دروازه و فراخوانی
تجزیه	[۲۳، ۲۴]	استخراج قالب	بدون آموزش گسترده یا چندنمونه‌ای	مبنای نرمال‌سازی و کش قالب
مرور/معیار/مدل/اس/تقرار	[۱۴، ۲۰، ۲۵، ۲۶، ۲۷]	چارچوب نظری یا زیرساخت	وابسته به منبع	رده‌بندی، محرمانگی، ارزیابی و مدل دستورمحور

۲-۵ شکاف پژوهشی و جایگاه پژوهش حاضر

۲-۵-۱ ناهمگونی پروتکل‌های بی‌جی‌ال

پژوهش‌های مبتنی بر بی‌جی‌ال از واحدهایی مانند پیام، توالی، پنجرهٔ مبتنی بر گره، پنجرهٔ زمانی و نمونهٔ متوازن استفاده کرده‌اند [۲-۵، ۸، ۹، ۱۲، ۱۶، ۱۸، ۱۹، ۲۲]. بنابراین یک عدد، بدون دانستن واحد تصمیم و شیوهٔ نمونه‌گیری، قابل انتقال به پروتکل دیگر نیست. پژوهش حاضر واحد تصمیم را یک خط تعریف می‌کند، برچسب را از ورودی حذف می‌نماید و ماتریس اغتشاش را در همان سطح محاسبه می‌کند.

۲-۵-۲ جدانشدن کیفیت تصمیم از هزینه استنتاج

FlexLog، AdaptiveLog و LogParser-LLM با حافظهٔ نهان، ارجاع انتخابی یا تجمیع، هزینه را کاهش می‌دهند [۱۰، ۱۳، ۲۳] و RAGLog بازیابی را به زمینهٔ تصمیم می‌افزاید [۱۲]. با این حال، همهٔ مطالعات نرخ استفاده از حافظهٔ نهان، منبع تک‌تک تصمیم‌ها، شمار پاسخ‌های نامعتبر و زمان کل را همراه معیارهای کیفیت گزارش نمی‌کنند. پایان‌نامه این دو بُعد، یعنی کیفیت و هزینه، را هم‌زمان ثبت می‌کند.

۲-۵-۳ محل اعمال دانش دامنه

در LogPrompt و ChatGPT-LogGPT دانش دامنه در متن دستور قرار دارد [۱، ۲، ۶]. Hybrid Prompting شواهد رخداد، توالی و نمونه را در همان متن ترکیب می‌کند [۳]. FlexLog و AdaptiveLog نیز از یک جزء بیرونی برای تصمیم‌گیری دربارهٔ ارجاع به مدل بزرگ بهره می‌برند [۱۰، ۱۳]. در مطالعات مرور شده،

مقایسه‌ای کنترل‌شده میان یک نگهبان قاعده‌محور بیرون مدل و انتقال همان دانش به متن دستور، با مدل، داده، نرمال‌سازی و حافظهٔ نهان یکسان، گزارش نشده است.

۲-۵-۴ کش تصمیم سطح قالب

RAGLog پایگاه نمونه می‌سازد [۱۲]، LogParser-LLM از ساختار قالب برای کاهش فراخوانی استفاده می‌کند [۲۳] و FlexLog حافظهٔ نهان را در سامانه‌ای چندمدلی به کار می‌گیرد [۱۰]. با این حال، بازاستفادهٔ نسخه‌بندی‌شده از یک تصمیم دودویی در سطح قالب نرمال‌شده، همراه با کنار گذاشتن پاسخ نامعتبر و مقایسهٔ دو مسیر تصمیم، در پژوهش‌های بی‌جی‌ال به‌عنوان محور آزمایشی مستقل بررسی نشده است.

۲-۵-۵ استنتاج محلی با یک مدل زبانی بزرگ متن‌باز متوسط

مطالعات مبتنی بر دستور بیشتر از خدمات GPT استفاده کرده‌اند [۲، ۳، ۱۱، ۱۲]. روش‌های مبتنی بر LLaMA یا Mistral نیز معمولاً به آموزش یا ترکیب چند مدل وابسته‌اند [۴، ۷، ۱۰]. مطالعهٔ محلی عملیات هوشمند، LogBERT آموزش‌دیده را به کار می‌گیرد [۲۰]. از این رو، اجرای کوئن ۲۰۵ دستورمحور با وزن ثابت و اولاما برای طبقه‌بندی خطبه‌خط بی‌جی‌ال، شکاف استقرار موردنظر این پایان‌نامه را تشکیل می‌دهد [۲۸، ۲۹].

۲-۵-۶ صورت‌بندی جایگاه پژوهش

جایگاه پژوهش با پنج جزء مشخص می‌شود: تصمیم خط‌محور روی بی‌جی‌ال؛ نرمال‌سازی حساس به معنا؛ حافظهٔ نهان نسخه‌بندی‌شده در سطح قالب؛ خروجی ساخت‌یافته و اعتبارسنجی‌شده؛ و مقایسهٔ روش ترکیبی با روش صرفاً مبتنی بر دستور در شرایط ثابت. این صورت‌بندی از پیش برتری هیچ روش را فرض نمی‌کند و نتیجه باید از اجرای کامل هر دو مسیر روی یک پروتکل یکسان به دست آید.

۲-۶ جمع‌بندی

در این فصل، ساختار لاگ، سطوح ناهنجاری، مجموعه‌دادهٔ بی‌جی‌ال، تجزیه و نرمال‌سازی، شیوه‌های یادگیری، مدل‌های ترتیبی، معماری ترنسفورمر، نقش مدل زبانی بزرگ، کوئن ۲۰۵، مهندسی دستور، بازیابی، حافظهٔ نهان، اولاما و معیارهای ارزیابی توضیح داده شدند. سپس هر ۲۷ مقالهٔ موجود در پوشهٔ پژوهش به‌طور مستقل مرور و در جدول مقایسه ثبت شد.

مرور مطالعات نشان داد که این حوزه از مدل‌سازی توالی به مدل‌های زبانی پیش‌آموزش‌دیده، تنظیم مدل‌های بزرگ، راهبردهای مبتنی بر دستور، بازیابی و چارچوب‌های چندمدلی گسترش یافته است. در عین حال، تفاوت در واحد تحلیل، شیوهٔ آموزش، نمونه‌گیری، محل استقرار و کنترل هزینه سبب می‌شود نتایج عددی فقط در پروتکل‌های همسان قابل مقایسه باشند.

بر پایهٔ این پیشینه، جای خالی پژوهشی عبارت است از مقایسهٔ مستقیم و کنترل‌شدهٔ یک نگهبان قاعده‌محور بیرون مدل با انتقال همان دانش به متن دستور، همراه با کوئن محلی، حافظهٔ نهان سطح قالب و خروجی اعتبارسنجی‌شده در طبقه‌بندی خطبه‌خط بی‌جی‌ال. فصل بعد باید معماری نرم‌افزار، قواعد نرمال‌سازی، متن دستورها،

ساخت کلید حافظهٔ نهان، تنظیمات اولاما، شیوهٔ اجرای دو روش و محاسبهٔ معیارها را با جزئیات عملیاتی بیان کند.

۷-۲ منابع فصل دوم

- [۱] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies. ۲۰۲۳.
- [۲] Qi, J.; Huang, S.; Luan, Z.; Fung, C.; Yang, H.; Qian, D. LogGPT: Exploring ChatGPT for Log-Based Anomaly Detection. ۲۰۲۳.
- [۳] Park, J.; Choi, E.; Lee, J. Hybrid Prompting for LLM-based Log Anomaly Detection. Journal of KIISE, ۵۲(۱۲), ۲۰۲۵. DOI: ۱۰.۵۶۲۶/JOK.۲۰۲۵.۵۲.۱۲.۱۰۶۷.
- [۴] Guan, W.; Cao, J.; Qian, S.; Gao, J.; Ouyang, C. LogLLM: Log-based Anomaly Detection Using Large Language Models. ۲۰۲۴.
- [۵] Han, X.; Yuan, S.; Trabelsi, M. LogGPT: Log Anomaly Detection via GPT. ۲۰۲۳.
- [۶] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Prompt Engineering Towards Zero-Shot and Interpretable Log Analysis. ۲۰۲۴.
- [۷] Zhang, Z.; Li, S.; Zhang, L.; Ye, J.; Hu, C.; Yan, L. LLM-LADE: Large language model-based log anomaly detection with explanation. Knowledge-Based Systems, ۳۲۶, Article ۱۱۴۰۶۴, ۲۰۲۵.
- [۸] Almodovar, C.; Sabrina, F.; Karimi, S.; Azad, S. LogFiT: Log Anomaly Detection using Fine-Tuned Language Models. ۲۰۲۵.
- [۹] Lim, Y. F.; Zhu, J.; Pang, G. Adapting Large Language Models for Parameter-Efficient Log Anomaly Detection. ۲۰۲۵.
- [۱۰] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. LLM meets ML: Data-efficient Anomaly Detection on Unstable Logs. ۲۰۲۴–۲۰۲۵.
- [۱۱] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. Anomaly Detection on Unstable Logs with GPT Models. ۲۰۲۴.
- [۱۲] Pan, J.; Wong, S. L.; Yuan, Y. RAGLog: Log Anomaly Detection using Retrieval Augmented Generation. ۲۰۲۳–۲۰۲۴.
- [۱۳] Ma, L.; Yang, W.; Li, Y.; Fei, B.; Zhou, M.; Li, S.; Jiang, S.; Xu, B.; Xiao, Y. AdaptiveLog: An Adaptive Log Analysis Framework with the Collaboration of Large and Small Language Model. arXiv:۲۵۰۱.۱۱۰۳۱, ۲۰۲۵.
- [۱۴] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. AIOps for log anomaly detection in the era of LLMs: A systematic literature review. Intelligent Systems with Applications, ۲۸, Article ۲۰۰۶۰۸, ۲۰۲۵.
- [۱۵] Sui, Y.; Wang, X.; Cui, T.; Xiao, T.; He, C.; Zhang, S.; Zhang, Y.; Yang, X.; Sun, Y.; Pei, D. Bridging the Gap: LLM-Powered Transfer Learning for Log Anomaly Detection in New Software Systems. ۲۰۲۵.
- [۱۶] Sun, Y.; Keung, J. W.; Yang, Z.; Liu, S.; Yu, H. K. SemiRALD: A semi-supervised hybrid language model for robust Anomalous Log Detection. Information and Software Technology, ۱۸۳, ۱۰۷۷۴۳, ۲۰۲۵. DOI: ۱۰.۱۰۱۶/j.infsof.۲۰۲۵.۱۰۷۷۴۳.
- [۱۷] Gao, Y.; Luo, T.; Huang, K.; Tang, J.; Li, X. LogLAA: an adaptive integrated log anomaly analysis framework. Cybersecurity, ۹:۱۴۱, ۲۰۲۶. DOI: ۱۰.۱۱۸۶/s۴۲۴۰۰۰۰۲۶۰۰۰۵۷۳-۸.
- [۱۸] Chen, S.; Liao, H. BERT-Log: Anomaly Detection for System Logs Based on Pre-trained Language Model. Applied Artificial Intelligence, ۳۶(۱), ۲۰۲۲. DOI: ۱۰.۱۰۸۰/۰۸۸۳۹۵۱۴, ۲۰۲۲, ۲۱۴۵۶۴۲.
- [۱۹] Guo, H.; Yuan, S.; Wu, X. LogBERT: Log Anomaly Detection via BERT. arXiv:۲۱۰۳.۰۴۴۷۵, ۲۰۲۱.
- [۲۰] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. Log anomaly detection in AIOps: A real-world implementation using Large Language Models. Systems and Soft Computing, ۸, Article ۲۰۰۴۷۵, ۲۰۲۶.

- [21] Du, M.; Li, F.; Zheng, G.; Srikumar, V. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. ACM CCS, 2017. DOI: 10.1145/3133956.3134010.
- [22] Pospieszny, P.; Mormul, W.; Szyndler, K.; Kumar, S. ADALog: Adaptive Unsupervised Anomaly Detection in Logs with Self-attention Masked Language Model. arXiv:2005.13496, 2020.
- [23] Zhong, A.; Mo, D.; Liu, G.; Liu, J.; Lu, Q.; Zhou, Q.; Wu, J.; Li, Q.; Wen, Q. LogParser-LLM: Advancing Efficient Log Parsing with Large Language Models. arXiv:2308.13727, 2023.
- [24] Le, V.-H.; Zhang, H. Log Parsing with Prompt-based Few-shot Learning. arXiv:2302.07430, 2023.
- [25] Liu, Y.; Pei, C.; Xu, L.; et al. OpsEval: A Comprehensive Benchmark Suite for Evaluating Large Language Models' Capability in IT Operations Domain. FSE Companion, 2020. DOI: 10.1145/3696630.3728872.
- [26] Zhu, Y.; Zhou, K.; Mao, K.; et al. YuLan: An Open-source Large Language Model. arXiv:2306.19803, 2024.
- [27] Xu, R.; Ding, K. Large Language Models for Anomaly and Out-of-Distribution Detection: A Survey. arXiv:2309.01980, 2020.
- [28] Qwen Team. Qwen2.0 Technical Report. arXiv:2312.10110, 2023.
- [29] Ollama. API Introduction; Structured Outputs; Usage Metrics. Official documentation. Accessed 14 August 2026.