

جدول ۱-۲ حضور همه ۲۷ فایل را قابل پیگیری می‌کند. منابع [۱۴]، [۲۵]، [۲۶] و [۲۷] نتیجه تشخیص روی بی‌جی‌ال ندارند؛ زیرا به ترتیب مرور نظام‌مند، معیار عملیات، گزارش مدل پایه و مرور عمومی هستند. این منابع برای روشن کردن مبانی نظری و معیارهای مقایسه در جدول آمده‌اند، نه به عنوان آزمایش مستقیم آشکارساز.

۲-۴-۱ مقایسه بر پایه واحد تحلیل و پروتکل بی‌جی‌ال

در مطالعاتی که بی‌جی‌ال را به کار برده‌اند، واحد تحلیل از یک پیام تا پنجره و توالی تغییر می‌کند. ADALog از نظر تصمیم در سطح پیام به پژوهش حاضر نزدیک‌تر است [۲۲]. BERT-Log، LogBERT و Hybrid Prompting پنجره یا توالی می‌سازند [۳، ۱۸، ۱۹] و LogGPT مبتنی بر ChatGPT فقط بخشی نمونه‌گیری شده از آزمون را بررسی می‌کند [۲]. بنابراین مقایسه عددی تنها هنگامی معتبر است که واحد تصمیم و نمونه ارزیابی یکسان باشند.

نسبت کلاس‌ها نیز در پروتکل‌ها متفاوت است. در بی‌جی‌ال اصلی حدود ۷،۳۴ درصد پیام‌ها ناهنجارند [۲، ۱۹]، اما Hybrid Prompting هزار توالی از هر کلاس انتخاب می‌کند [۳]. صحت روی داده متوازن و نامتوازن رفتار یکسانی ندارد؛ از این رو پایان‌نامه دقت، بازخوانی، امتیاز افیک و ماتریس اغتشاش را در سطح خط گزارش می‌کند.

۲-۴-۲ مقایسه براساس نیاز به آموزش

ADALog، DeepLog، BERT-Log، LogBERT، LogFiT با داده مقصد آموزش یا تنظیم می‌شوند [۸]، [۱۸، ۱۹، ۲۱، ۲۲]. LogLLM و LogGPT مبتنی بر GPT آموزش چندمرحله‌ای یا یادگیری تقویتی دارند [۴، ۵]. LLM-LADE، مطالعه تنظیم کارآمد پارامترها، LogSynergy و SemiRALD نیز از تنظیم کم‌پارامتر، انتقال یا آموزش نیمه‌نظارتی بهره می‌گیرند [۷، ۹، ۱۵، ۱۶].

در مقابل، RAGLog، LogPrompt، ChatGPT-LogGPT، Hybrid Prompting برای تصمیم‌گیری، تغییر وزن طبقه‌بند را شرط اصلی نمی‌دانند و از دستور و زمینه استفاده می‌کنند [۱-۳، ۶، ۱۲]. پژوهش حاضر در همین خانواده قرار می‌گیرد، با این تفاوت که حافظه نهان سطح قالب و مقایسه نگهبان بیرونی با دانش درون دستور را نیز به پروتکل می‌افزاید.

۲-۴-۳ مقایسه شیوه‌های مهار هزینه و محل استقرار

سه الگوی اصلی برای مهار هزینه در منابع دیده می‌شود. RAGLog با بازبازی، زمینه مرتبط را انتخاب می‌کند [۱۲]. AdaptiveLog نمونه‌های نامطمئن مدل کوچک را به مدل بزرگ می‌سپارد [۱۳]. FlexLog و LogParser LLM نیز با حافظه نهان یا ساختار تجمیعی از پردازش دوباره جلوگیری می‌کنند [۱۰، ۲۳]. هدف این سازوکارها مشترک است، اما آنچه ذخیره می‌شود و منطق تصمیم هر کدام تفاوت دارد.

استقرار محلی به‌طور صریح در مطالعه میدانی عملیات هوشمند مطرح شده است [۲۰]. بسیاری از پژوهش‌های مبتنی بر دستور از GPT-۴، ChatGPT، یا GPT-۴o-mini استفاده کرده‌اند [۲، ۳، ۱۱] و برخی دیگر LLaMA یا Mistral را آموزش یا تنظیم کرده‌اند [۴، ۷، ۱۰]. ترکیب مورد سنجش این پایان‌نامه عبارت است از اجرای محلی کوئن ۲،۵ دستورمحور با اولاما، بدون تنظیم دقیق، همراه با ثبت زمان و پاسخ نامعتبر [۲۸، ۲۹].

۲-۴-۴ مقایسه بازنمایی ورودی و آماده‌سازی

روش‌های ترتیبی معمولاً پیام خام را مستقیماً به مدل نمی‌دهند. DeepLog پیام را به کلید رخداد تبدیل می‌کند و LogBERT توالی کلیدهای تجزیه‌شده را در اختیار BERT می‌گذارد [۱۹، ۲۱]. BERT-Log نیز با تجزیه و پنجره‌بندی، پیام‌ها را برای مدل آماده می‌کند [۱۸]. از این رو خطای تجزیه‌گر می‌تواند به مرحله تشخیص منتقل شود.

ADALog و LogLLM برای کاهش وابستگی به تجزیه‌گر کلاسیک، متن را با پاک‌سازی یا قواعد منظم آماده می‌کنند [۴، ۲۲]. ADALog مسیر، عدد و نشانی را با جانشین عمومی جایگزین می‌کند و LogLLM از متن پردازش‌شده بردار معنایی BERT می‌سازد. بنابراین عبارت «بدون تجزیه‌گر» به معنای حذف همه مراحل پیش‌پردازش نیست.

در روش‌های مبتنی بر دستور، آماده‌سازی علاوه بر پاک‌سازی، انتخاب زمینه را نیز در بر می‌گیرد. RAGLog یک نمونه عادی مشابه را می‌افزاید [۱۲]، Hybrid Prompting ویژگی‌های رخداد و توالی را محاسبه می‌کند [۳] و LogPrompt دانش وظیفه را در متن دستور می‌نویسد [۱، ۶]. پس بخشی از توان سامانه نه در خود مدل، بلکه در ساخت ورودی آن قرار دارد.

در پایان‌نامه، هر پیام به یک قالب نرمال‌شده تبدیل می‌شود، اما نمونه بازیابی‌شده یا پنجره زمانی به دستور افزوده نمی‌شود. این بازنمایی در دو روش ثابت است تا اختلاف نتیجه از تغییر آماده‌سازی ناشی نشود. تعداد قالب‌های یکتا و نرخ استفاده از حافظه نهان نیز اثر عملی نرمال‌سازی را نشان می‌دهند.

۲-۴-۵ مقایسه سازوکار تصمیم و نوع خروجی

در روش‌های پیش‌بینی‌محور، تصمیم از احتمال رخداد یا توکن به دست می‌آید. DeepLog رخداد بعدی را پیش‌بینی می‌کند و LogFiT و ADALog توکن پوشانده‌شده را بازسازی می‌کنند [۸، ۲۱، ۲۲]. سپس یک آستانه یا قرار گرفتن رخداد واقعی در میان گزینه‌های برتر، خروجی پیوسته را به برچسب دودویی تبدیل می‌کند. بنابراین انتخاب آستانه بخشی از روش است، نه یک جزئیات فرعی.

در روش‌های طبقه‌بندی، یک سر طبقه‌بند یا مدل زبانی تنظیم‌شده مستقیماً احتمال کلاس را تولید می‌کند. BERT-Log، LogLLM، LLM-LADE و SemiRALD نمونه‌های این خانواده‌اند [۴، ۷، ۱۶، ۱۸]. کیفیت تصمیم در این روش‌ها به داده آموزش، تابع زیان و شیوه تنظیم وابسته است.

در روش‌های مبتنی بر دستور، پاسخ متنی باید به برچسب تبدیل شود. LogPrompt و ChatGPT-LogGPT می‌توانند همراه برچسب، توضیح نیز تولید کنند [۱، ۲، ۶] و OpsEval برای پاسخ آزاد معیار جداگانه دارد [۲۵]. در یک سامانه خودکار، متن اضافه یا برچسب مبهم پردازش بعدی را مختل می‌کند؛ از این رو پایان‌نامه فقط خروجی دودویی در قالب جی‌سان را معتبر می‌داند.

ثبت پاسخ نامعتبر، خطای پیروی از قرارداد را از خطای طبقه‌بندی جدا می‌کند. اگر پاسخ نامعتبر به‌طور پیش‌فرض عادی یا ناهنجار فرض شود، صحت و امتیاز افیک رفتار واقعی مدل را نشان نخواهند داد. همچنین پاسخ نامعتبر در حافظه نهان ذخیره نمی‌شود تا یک خطای مربوط به قالب در پیام‌های تکراری تکثیر نشود.

۲-۴-۶ مقایسه تبیین‌پذیری و بازتولیدپذیری

توضیح آزاد مدل برای کاربر خواندنی است، اما سنجش کیفیت آن به معیار اختصاصی یا نظر متخصص نیاز دارد. LogPrompt از ارزیابی متخصصان، LLM-LADE از آموزش هم‌زمان تشخیص و توضیح، و LogLAA از امتیاز کیفیت شرح استفاده می‌کنند [۱، ۶، ۷، ۱۷]. این امتیازها هدفی متفاوت از امتیاز افیک طبقه‌بندی دارند و نباید با آن یکسان تفسیر شوند.

تبیین ساختاری، به جای متن آزاد، می‌تواند شناسه قالب، منبع تصمیم، قاعده فعال و زمان پاسخ را ثبت کند. این داده‌ها برای هر خط ذخیره و مقایسه می‌شوند. پایان‌نامه همین شکل از تبیین را برمی‌گزیند تا خروجی دو روش هم‌ساختار بماند و تفاوت طول توضیح، مقایسه زمان را مخدوش نکند.

بازتولیدپذیری در خدمات تجاری، به دلیل تغییر نسخه و محدودیت نرخ رابط، دشوارتر است. مطالعه ChatGPT-LogGPT به نمونه‌گیری محدود شده و Hybrid Prompting نیز به نسخه مشخصی از یک مدل تجاری وابسته است [۲، ۳]. در استقرار محلی می‌توان فایل مدل، شیوه کوانتیزه‌سازی و نسخه محیط اجرا را ثبت کرد؛ البته مشخصات سخت‌افزار و پارامترهای تولید همچنان باید گزارش شوند [۲۰، ۲۸، ۲۹].

برای مقایسه دو روش، ترتیب داده، دما، نسخه مدل و دستور، مهلت انتظار، شمار تلاش مجدد و سیاست حافظه نهان باید ثابت باشند. ثبت این متغیرها همراه شناسه اجرا و خروجی خطبه‌خط، بازسازی آزمایش و یافتن منشأ اختلاف را ممکن می‌سازد. مرور نظام‌مند و OpsEval نیز بر ضرورت چنین ارزیابی عملی و قابل بازتولیدی تأکید دارند [۱۴، ۲۵].

جدول ۲-۲: دسته‌های اصلی مطالعات و ارتباط آن‌ها با طراحی پژوهش حاضر

دسته	مقالات	نقش مدل زبانی	نیاز غالب به آموزش	ارتباط با پژوهش حاضر
ترتیبی/پیش‌آموزش دیده	[۸، ۱۸، ۱۹، ۲۱، ۲۲]	رمزگذار یا مدل توالی	بله؛ عادی یا برچسب‌خورده	تعریف BGL، واحد تحلیل و خط پایه زبانی
آموزش/تنظیم/انتقال ال LLM	[۴، ۵، ۷، ۹، ۱۱، ۱۵، ۱۶، ۱۷]	طبقه‌بند، مولد داده یا تبیین	آموزش، PEFT یا انتقال	مرز تمایز با Qwen بدون تنظیم
دستور متنی	[۱، ۲، ۳، ۶]	تصمیم‌گیر مستقیم	بدون تغییر وزن	نزدیک‌ترین خانواده به صرفاً مبتنی بر دستور
بازیابی/همکاری/هزینه	[۱۰، ۱۲، ۱۳]	جزء آبشار یا RAG	متغیر	مبنای مقایسه کش، دروازه و فراخوانی
تجزیه	[۲۳، ۲۴]	استخراج قالب	بدون آموزش گسترده یا چندنمونه‌ای	مبنای نرمال‌سازی و کش قالب
مرور/معیار/مدل/اس/تقرار	[۱۴، ۲۰، ۲۵، ۲۶، ۲۷]	چارچوب نظری یا زیرساخت	وابسته به منبع	رده‌بندی، محرمانگی، ارزیابی و مدل دستورمحور

۲-۵ شکاف پژوهشی و جایگاه پژوهش حاضر

۲-۵-۱ ناهمگونی پروتکل‌های بی‌جی‌ال

پژوهش‌های مبتنی بر بی‌جی‌ال از واحدهایی مانند پیام، توالی، پنجرهٔ مبتنی بر گره، پنجرهٔ زمانی و نمونهٔ متوازن استفاده کرده‌اند [۲-۵، ۸، ۹، ۱۲، ۱۶، ۱۸، ۱۹، ۲۲]. بنابراین یک عدد، بدون دانستن واحد تصمیم و شیوهٔ نمونه‌گیری، قابل انتقال به پروتکل دیگر نیست. پژوهش حاضر واحد تصمیم را یک خط تعریف می‌کند، برچسب را از ورودی حذف می‌نماید و ماتریس اغتشاش را در همان سطح محاسبه می‌کند.

۲-۵-۲ جدانشدن کیفیت تصمیم از هزینه استنتاج

FlexLog، AdaptiveLog و LogParser-LLM با حافظهٔ نهان، ارجاع انتخابی یا تجمیع، هزینه را کاهش می‌دهند [۱۰، ۱۳، ۲۳] و RAGLog بازیابی را به زمینهٔ تصمیم می‌افزاید [۱۲]. با این حال، همهٔ مطالعات نرخ استفاده از حافظهٔ نهان، منبع تک‌تک تصمیم‌ها، شمار پاسخ‌های نامعتبر و زمان کل را همراه معیارهای کیفیت گزارش نمی‌کنند. پایان‌نامه این دو بُعد، یعنی کیفیت و هزینه، را هم‌زمان ثبت می‌کند.

۲-۵-۳ محل اعمال دانش دامنه

در LogPrompt و ChatGPT-LogGPT دانش دامنه در متن دستور قرار دارد [۱، ۲، ۶]. Hybrid Prompting شواهد رخداد، توالی و نمونه را در همان متن ترکیب می‌کند [۳]. FlexLog و AdaptiveLog نیز از یک جزء بیرونی برای تصمیم‌گیری دربارهٔ ارجاع به مدل بزرگ بهره می‌برند [۱۰، ۱۳]. در مطالعات مرور شده،

مقایسه‌ای کنترل‌شده میان یک نگهبان قاعده‌محور بیرون مدل و انتقال همان دانش به متن دستور، با مدل، داده، نرمال‌سازی و حافظهٔ نهان یکسان، گزارش نشده است.

۲-۵-۴ کش تصمیم سطح قالب

RAGLog پایگاه نمونه می‌سازد [۱۲]، LogParser-LLM از ساختار قالب برای کاهش فراخوانی استفاده می‌کند [۲۳] و FlexLog حافظهٔ نهان را در سامانه‌ای چندمدلی به کار می‌گیرد [۱۰]. با این حال، بازاستفادهٔ نسخه‌بندی‌شده از یک تصمیم دودویی در سطح قالب نرمال‌شده، همراه با کنارگذاشتن پاسخ نامعتبر و مقایسهٔ دو مسیر تصمیم، در پژوهش‌های بی‌جی‌ال به‌عنوان محور آزمایشی مستقل بررسی نشده است.

۲-۵-۵ استنتاج محلی با یک مدل زبانی بزرگ متن‌باز متوسط

مطالعات مبتنی بر دستور بیشتر از خدمات GPT استفاده کرده‌اند [۲، ۳، ۱۱، ۱۲]. روش‌های مبتنی بر LLaMA یا Mistral نیز معمولاً به آموزش یا ترکیب چند مدل وابسته‌اند [۴، ۷، ۱۰]. مطالعهٔ محلی عملیات هوشمند، LogBERT آموزش‌دیده را به کار می‌گیرد [۲۰]. از این رو، اجرای کوئن ۲۰۵ دستورمحور با وزن ثابت و اولاما برای طبقه‌بندی خطبه‌خط بی‌جی‌ال، شکاف استقرار موردنظر این پایان‌نامه را تشکیل می‌دهد [۲۸، ۲۹].

۲-۵-۶ صورت‌بندی جایگاه پژوهش

جایگاه پژوهش با پنج جزء مشخص می‌شود: تصمیم خط‌محور روی بی‌جی‌ال؛ نرمال‌سازی حساس به معنا؛ حافظهٔ نهان نسخه‌بندی‌شده در سطح قالب؛ خروجی ساخت‌یافته و اعتبارسنجی‌شده؛ و مقایسهٔ روش ترکیبی با روش صرفاً مبتنی بر دستور در شرایط ثابت. این صورت‌بندی از پیش برتری هیچ روش را فرض نمی‌کند و نتیجه باید از اجرای کامل هر دو مسیر روی یک پروتکل یکسان به دست آید.

۲-۶ جمع‌بندی

در این فصل، ساختار لاگ، سطوح ناهنجاری، مجموعه‌دادهٔ بی‌جی‌ال، تجزیه و نرمال‌سازی، شیوه‌های یادگیری، مدل‌های ترتیبی، معماری ترنسفورمر، نقش مدل زبانی بزرگ، کوئن ۲۰۵، مهندسی دستور، بازیابی، حافظهٔ نهان، اولاما و معیارهای ارزیابی توضیح داده شدند. سپس هر ۲۷ مقالهٔ موجود در پوشهٔ پژوهش به‌طور مستقل مرور و در جدول مقایسه ثبت شد.

مرور مطالعات نشان داد که این حوزه از مدل‌سازی توالی به مدل‌های زبانی پیش‌آموزش‌دیده، تنظیم مدل‌های بزرگ، راهبردهای مبتنی بر دستور، بازیابی و چارچوب‌های چندمدلی گسترش یافته است. در عین حال، تفاوت در واحد تحلیل، شیوهٔ آموزش، نمونه‌گیری، محل استقرار و کنترل هزینه سبب می‌شود نتایج عددی فقط در پروتکل‌های همسان قابل مقایسه باشند.

بر پایهٔ این پیشینه، جای خالی پژوهشی عبارت است از مقایسهٔ مستقیم و کنترل‌شدهٔ یک نگهبان قاعده‌محور بیرون مدل با انتقال همان دانش به متن دستور، همراه با کوئن محلی، حافظهٔ نهان سطح قالب و خروجی اعتبارسنجی‌شده در طبقه‌بندی خطبه‌خط بی‌جی‌ال. فصل بعد باید معماری نرم‌افزار، قواعد نرمال‌سازی، متن دستورها،

ساخت کلید حافظهٔ نهان، تنظیمات اولاما، شیوهٔ اجرای دو روش و محاسبهٔ معیارها را با جزئیات عملیاتی بیان کند.

۷-۲ منابع فصل دوم

- [۱] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies. ۲۰۲۳.
- [۲] Qi, J.; Huang, S.; Luan, Z.; Fung, C.; Yang, H.; Qian, D. LogGPT: Exploring ChatGPT for Log-Based Anomaly Detection. ۲۰۲۳.
- [۳] Park, J.; Choi, E.; Lee, J. Hybrid Prompting for LLM-based Log Anomaly Detection. Journal of KIISE, ۵۲(۱۲), ۲۰۲۵. DOI: ۱۰.۵۶۲۶/JOK.۲۰۲۵.۵۲.۱۲.۱۰۶۷.
- [۴] Guan, W.; Cao, J.; Qian, S.; Gao, J.; Ouyang, C. LogLLM: Log-based Anomaly Detection Using Large Language Models. ۲۰۲۴.
- [۵] Han, X.; Yuan, S.; Trabelsi, M. LogGPT: Log Anomaly Detection via GPT. ۲۰۲۳.
- [۶] Liu, Y.; Tao, S.; Meng, W.; Wang, J.; Ma, W.; Chen, Y.; Zhao, Y.; Yang, H.; Jiang, Y. Prompt Engineering Towards Zero-Shot and Interpretable Log Analysis. ۲۰۲۴.
- [۷] Zhang, Z.; Li, S.; Zhang, L.; Ye, J.; Hu, C.; Yan, L. LLM-LADE: Large language model-based log anomaly detection with explanation. Knowledge-Based Systems, ۳۲۶, Article ۱۱۴۰۶۴, ۲۰۲۵.
- [۸] Almodovar, C.; Sabrina, F.; Karimi, S.; Azad, S. LogFiT: Log Anomaly Detection using Fine-Tuned Language Models. ۲۰۲۵.
- [۹] Lim, Y. F.; Zhu, J.; Pang, G. Adapting Large Language Models for Parameter-Efficient Log Anomaly Detection. ۲۰۲۵.
- [۱۰] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. LLM meets ML: Data-efficient Anomaly Detection on Unstable Logs. ۲۰۲۴–۲۰۲۵.
- [۱۱] Hadadi, F.; Xu, Q.; Bianculli, D.; Briand, L. Anomaly Detection on Unstable Logs with GPT Models. ۲۰۲۴.
- [۱۲] Pan, J.; Wong, S. L.; Yuan, Y. RAGLog: Log Anomaly Detection using Retrieval Augmented Generation. ۲۰۲۳–۲۰۲۴.
- [۱۳] Ma, L.; Yang, W.; Li, Y.; Fei, B.; Zhou, M.; Li, S.; Jiang, S.; Xu, B.; Xiao, Y. AdaptiveLog: An Adaptive Log Analysis Framework with the Collaboration of Large and Small Language Model. arXiv:۲۵۰۱.۱۱۰۳۱, ۲۰۲۵.
- [۱۴] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. AIOps for log anomaly detection in the era of LLMs: A systematic literature review. Intelligent Systems with Applications, ۲۸, Article ۲۰۰۶۰۸, ۲۰۲۵.
- [۱۵] Sui, Y.; Wang, X.; Cui, T.; Xiao, T.; He, C.; Zhang, S.; Zhang, Y.; Yang, X.; Sun, Y.; Pei, D. Bridging the Gap: LLM-Powered Transfer Learning for Log Anomaly Detection in New Software Systems. ۲۰۲۵.
- [۱۶] Sun, Y.; Keung, J. W.; Yang, Z.; Liu, S.; Yu, H. K. SemiRALD: A semi-supervised hybrid language model for robust Anomalous Log Detection. Information and Software Technology, ۱۸۳, ۱۰۷۷۴۳, ۲۰۲۵. DOI: ۱۰.۱۰۱۶/j.infsof.۲۰۲۵.۱۰۷۷۴۳.
- [۱۷] Gao, Y.; Luo, T.; Huang, K.; Tang, J.; Li, X. LogLAA: an adaptive integrated log anomaly analysis framework. Cybersecurity, ۹:۱۴۱, ۲۰۲۶. DOI: ۱۰.۱۱۸۶/s۴۲۴۰۰۰۰۲۶۰۰۰۵۷۳-۸.
- [۱۸] Chen, S.; Liao, H. BERT-Log: Anomaly Detection for System Logs Based on Pre-trained Language Model. Applied Artificial Intelligence, ۳۶(۱), ۲۰۲۲. DOI: ۱۰.۱۰۸۰/۰۸۸۳۹۵۱۴, ۲۰۲۲, ۲۱۴۵۶۴۲.
- [۱۹] Guo, H.; Yuan, S.; Wu, X. LogBERT: Log Anomaly Detection via BERT. arXiv:۲۱۰۳.۰۴۴۷۵, ۲۰۲۱.
- [۲۰] De la Cruz Cabello, M.; Prince Sales, T.; Machado, M. R. Log anomaly detection in AIOps: A real-world implementation using Large Language Models. Systems and Soft Computing, ۸, Article ۲۰۰۴۷۵, ۲۰۲۶.

- [21] Du, M.; Li, F.; Zheng, G.; Srikumar, V. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. ACM CCS, 2017. DOI: 10.1145/3133956.3134010.
- [22] Pospieszny, P.; Mormul, W.; Szyndler, K.; Kumar, S. ADALog: Adaptive Unsupervised Anomaly Detection in Logs with Self-attention Masked Language Model. arXiv:2005.13496, 2020.
- [23] Zhong, A.; Mo, D.; Liu, G.; Liu, J.; Lu, Q.; Zhou, Q.; Wu, J.; Li, Q.; Wen, Q. LogParser-LLM: Advancing Efficient Log Parsing with Large Language Models. arXiv:2308.13727, 2023.
- [24] Le, V.-H.; Zhang, H. Log Parsing with Prompt-based Few-shot Learning. arXiv:2302.07430, 2023.
- [25] Liu, Y.; Pei, C.; Xu, L.; et al. OpsEval: A Comprehensive Benchmark Suite for Evaluating Large Language Models' Capability in IT Operations Domain. FSE Companion, 2020. DOI: 10.1145/3696630.3728872.
- [26] Zhu, Y.; Zhou, K.; Mao, K.; et al. YuLan: An Open-source Large Language Model. arXiv:2306.19803, 2024.
- [27] Xu, R.; Ding, K. Large Language Models for Anomaly and Out-of-Distribution Detection: A Survey. arXiv:2309.01980, 2020.
- [28] Qwen Team. Qwen2.0 Technical Report. arXiv:2312.10110, 2023.
- [29] Ollama. API Introduction; Structured Outputs; Usage Metrics. Official documentation. Accessed 14 August 2026.