

گوان و همکاران LogLLM را از سه جزء ساختند: BERT برای استخراج بردار معنایی، یک لایه نداشت برای انتقال بازنمایی و LLaMA برای طبقه‌بندی. پیام‌ها با قواعد منظم آماده می‌شوند و آموزش چندمرحله‌ای، فضای بازنمایی BERT را با فضای مدل بزرگ هم‌تراز می‌کند [۴].

LogLLM روی HDFS، بی‌جی‌ال، Liberty و Thunderbird و نیز در سناریوهای لاگ ناپایدار ارزیابی شده است [۴]. این معماری نشان می‌دهد که استخراج ویژگی و تصمیم‌نهایی را می‌توان میان یک رمزگذار کوچک و یک مدل زبانی بزرگ تقسیم کرد؛ با این حال، لایه نداشت و LLaMA هر دو به آموزش نیاز دارند. پژوهش حاضر بدون آموزش، قالب نرمال شده را مستقیماً به کوئن می‌دهد.

ژانگ و همکاران در LLM-LADE سه مرحله را به هم پیوند دادند: افزایش داده، تنظیم کارآمد پارامترها و بهینه‌سازی برخط. GPT-۴ با چند نمونه درون دستور داده تازه تولید می‌کند و Llama۳-۸B با سازگارسازی کم‌رتبه به‌عنوان آشکارساز تنظیم می‌شود. مدل افزون بر برچسب، توضیح متنی می‌سازد و دانش حاصل از نمونه‌های جدید در یک پایگاه افزایشی نگه‌داری می‌شود [۷].

LLM-LADE تشخیص و توضیح را در یک فرایند مشترک انجام می‌دهد و برای سازگاری با تغییرات، بهینه‌سازی برخط را پیشنهاد می‌کند [۷]. در پایان‌نامه حاضر، به‌منظور حذف ابهام، خروجی به یک برچسب ساخت‌یافته محدود است؛ توضیح آزاد، تنظیم کم‌رتبه و بهینه‌سازی برخط نیز در دامنه قرار ندارند. بنابراین سنجش بر کیفیت دودویی و هزینه استنتاج متمرکز می‌ماند.

لیم، ژو و پنگ روش‌های سازگارسازی کم‌رتبه و تنظیم بازنمایی را روی GPT-۲، RoBERTa و Llama-۳ برای تشخیص ناهنجاری لاگ مقایسه کردند. این مطالعه به ارائه یک مدل منفرد محدود نیست و پایداری اجرا، کارایی نمونه، مقاومت در برابر لاگ ناپایدار و انتقال میان HDFS، بی‌جی‌ال، Spirit و Thunderbird را می‌سنجد [۹]. نتایج نشان می‌دهند که هم مدل پایه و هم روش تنظیم کارآمد پارامترها بر پایداری و انتقال اثر دارند [۹]. ارزش این مطالعه برای پایان‌نامه در روشن کردن تفاوت میان «به‌کارگیری مدل زبانی بزرگ» و «استفاده از مدل بدون تنظیم» است. کوئن در این پژوهش هیچ سازگارسازی پارامتری ندارد و باید به‌عنوان استنتاج صرفاً مبتنی بر دستور ارزیابی شود، نه یک آشکارساز تنظیم‌شده.

هادی و همکاران در پژوهشی درباره تشخیص ناهنجاری در لاگ‌های ناپایدار، تغییر قالب‌ها میان نسخه‌های نرم‌افزار را بررسی کردند. GPT-۳ با لاگ مقصد تنظیم شد، درحالی‌که GPT-۴ از طریق طراحی دستور به کار رفت. داده آزمایش از دو نسخه LOGEVOL-Hadoop تشکیل شده است تا اثر ناپایداری و انتقال میان نسخه‌ها اندازه‌گیری شود [۱۱].

در پروتکل همان مقاله، تنظیم دقیق از مهندسی دستور نتیجه بهتری داشته است [۱۱]. این نتیجه به مدل و داده همان مطالعه وابسته است، اما یادآوری می‌کند که ثابت نگه‌داشتن وزن‌ها ممکن است در مواجهه با تغییر توزیع هزینه عملکرد داشته باشد. پژوهش حاضر انتقال میان نسخه‌ها را آزمایش نمی‌کند و فقط دو محل اعمال قاعده را روی یک مجموعه ثابت می‌سنجد.

سوئی و همکاران در LogSynergy برای انتقال آشکارساز به سامانه‌ای تازه، تفسیر رخداد با مدل زبانی بزرگ را با استخراج ویژگی یکپارچه ترکیب کردند. مدل، رخدادهایی با نگارش متفاوت اما معنای مشابه را به توصیف‌های نزدیک تبدیل می‌کند و ویژگی‌های استاندارد شده سپس به یک طبقه‌بند انتقالی داده می‌شوند [۱۵].

LogSynergy با پنج هزار توالی برچسب‌خورده، امتیاز افیک بیش از ۸۹ درصد روی داده واقعی و بیش از ۸۳ درصد روی داده‌های عمومی گزارش کرده است [۱۵]. مسئله اصلی آن انتقال میان سامانه‌هاست، نه تصمیم بدون آموزش در یک مجموعه. پیوند آن با پژوهش حاضر به نقش نرمال‌سازی معنایی و کاهش ناهمگونی ورودی بازمی‌گردد.

سان و همکاران در SemiRALD چارچوبی نیمه‌نظارتی ارائه کردند. ChatGPT با یادگیری درون‌متنی برای تجزیه لاگ به کار می‌رود و پس از آن، بازنمایی RoBERTa همراه با شبکه BiLSTM توجه‌محور، الگوی توالی را برای طبقه‌بندی می‌آموزد. این طراحی، تجزیه معنایی و طبقه‌بند آموزش‌پذیر را به دو مرحله جدا تقسیم می‌کند [۱۶].

SemiRALD روی HDFS و بی‌جی‌ال ارزیابی شده و میانگین بهبود امتیاز افیک را در مقایسه با دو گروه مبنا به ترتیب ۷۰۳ و ۸۰۲ درصد گزارش کرده است؛ این بهبود با تنها ۰۰۱ درصد داده برچسب‌خورده برجسته‌تر است [۱۶]. واژه ترکیبی در نام این مقاله به ترکیب مدل زبانی و مدل ترتیبی اشاره دارد و با آبشار قاعده و مدل در پایان‌نامه معنای متفاوتی دارد.

گائو و همکاران در LogLAA تجزیه، تشخیص و توضیح را در یک چارچوب تطبیقی گرد آوردند. تجزیه‌گر از طول پیام، فراوانی واژه، جایگزینی متغیر و درخت پیشوند استفاده می‌کند. سپس بازنمایی‌های شمارشی، ترتیبی و معنایی به یک شبکه CNN-LSTM دوتوجهی داده می‌شوند و مدل زبانی بزرگ شرح نتیجه را تولید می‌کند [۱۷].

LogLAA بهبود ۰۰۸ درصدی کیفیت تجزیه، افزایش حدود شش درصدی دقت تشخیص نسبت به میانگین روش‌های مقایسه و امتیاز ۰۰۷ برای کیفیت توضیح گزارش کرده است [۱۷]. این سامانه چندمرحله‌ای و آموزش‌پذیر است؛ در مقابل، پژوهش حاضر مدل ترتیبی و تولید توضیح را کنار می‌گذارد و بر کنترل مسیر تصمیم، حافظه نهان و اجرای محلی یک مدل ثابت تمرکز دارد.

۲-۳-۴ مطالعات مبتنی بر دستور متنی

لیو و همکاران در نسخه نخست LogPrompt، تحلیل برخط و تبیین‌پذیر لاگ را بدون آموزش درون‌دامنه بررسی کردند. روش، وظیفه را به گام‌های روشن تقسیم می‌کند، دانش لازم را در متن دستور می‌نویسد و از مدل می‌خواهد دلیل تصمیم خود را نیز بیان کند [۱].

نسخه سال ۲۰۲۳ چند وظیفه تحلیل لاگ را در یک چارچوب مبتنی بر دستور گرد آورده و پایه مسیر پژوهشی LogPrompt را ساخته است [۱]. مقاله [۶] نسخه گسترش‌یافته همین کار است؛ بنابراین نتایج آن دو شواهد مستقل محسوب نمی‌شوند. معرفی جداگانه هر دو منبع، تحول روش و پوشش کامل فایل‌های موجود را نشان می‌دهد.

چی و همکاران در مطالعه‌ای درباره‌ی تشخیص ناهنجاری لاگ با ChatGPT، توان این مدل را روی بی‌جی‌ال و Spirit سنجیدند. آنان پنج عامل را بررسی کردند: شیوه‌ی نگارش دستور، اندازه‌ی پنجره، افزودن دانش انسانی، مقایسه با مدل‌های عمیق و تبیین‌پذیری. مقاله برای بی‌جی‌ال، ۴۰۷۴۷،۹۶۳ پیام و ۳۴۸،۴۶۰ پیام ناهنجار گزارش می‌کند [۲].

محدودیت نرخ رابط برنامه‌نویسی سبب شد آزمایش فقط بر دو هزار پیام متوالی از بخش آزمون انجام شود و نسبت ناهنجاری به‌طور دستی کنترل گردد [۲]. از این‌رو، نتیجه‌ی مقاله نماینده‌ی اجرای کامل مجموعه نیست. پژوهش حاضر با مدل محلی و حافظه‌ی نهان سطح قالب برای پردازش گسترده‌تر طراحی شده و افزون بر امتیاز افیک، نرخ پاسخ نامعتبر و زمان را ثبت می‌کند.

نسخه‌ی کامل‌تر LogPrompt راهبردهای گوناگون دستور را روی ۹ مجموعه داده و چند وظیفه‌ی تجزیه و تشخیص می‌آزماید. تعریف وظیفه، دانش صریح یا ضمنی و زنجیره‌ی استدلال سه جزء اصلی‌اند که مدل را به سوی تصمیم و توضیح هدایت می‌کنند [۶].

مقاله در برخی تنظیم‌ها تا ۵۵،۹ درصد بهبود نسبت به روش‌های آموزش‌دیده و امتیاز ۴۰،۴۲ از ۵ برای تفسیرپذیری در ارزیابی متخصصان گزارش کرده است [۶]. بررسی حذف اجزا در بی‌جی‌ال نشان می‌دهد افزودن استدلال یا درخواست توضیح می‌تواند امتیاز افیک را در سطح نشست و قالب تغییر دهد. پایان‌نامه‌ی حاضر برای کاهش ابهام، پاسخ را به برجسب ساخت یافته محدود می‌کند.

پارک، چوی و لی در Hybrid Prompting سه نوع شاهد را در یک دستور کنار هم قرار دادند: رخداد پیش‌تر دیده‌نشده، آمار و شباهت توالی، و نزدیک‌ترین نمونه‌ی عادی. Qwen۳-Embedding-۸B برای ساخت بردار تعبیه و GPT-۴o-mini برای طبقه‌بندی استفاده می‌شوند. آزمایش‌ها روی HDFS، بی‌جی‌ال و Thunderbird و در سطح توالی انجام شده‌اند [۳].

Hybrid Prompting در بی‌جی‌ال، با پنجره‌ی یک‌دقیقه‌ای و نمونه‌ی متوازن، دقت ۶۳،۶۵، بازخوانی ۹۹،۶۰ و امتیاز افیک ۷۷،۸۱ درصد گزارش کرده است. میانگین بهبود امتیاز افیک در سه مجموعه ۹۰،۹۳ واحد درصد است [۳]. در آن مقاله «ترکیبی» به ادغام شواهد در متن دستور اشاره دارد؛ در پایان‌نامه، روش ترکیبی آبشاری از قاعده و مدل است و برای هر خط تصمیم می‌گیرد.

۲-۳-۵ بازیابی، همکاری مدل‌ها و مهار هزینه‌ی محاسباتی

پن، وونگ و یوان در RAGLog پایگاه برداری را از نمونه‌های عادی ساختند. برای هر پیام ورودی، نمونه‌ی نزدیک بازیابی و همراه پیام به مدل زبانی بزرگ داده می‌شود. نمونه‌های پایگاه با خوشه‌بندی میانگین‌های کا از بی‌جی‌ال و Thunderbird برگزیده می‌شوند و مدل، بدون دیدن نمونه‌ی ناهنجار، بر پایه‌ی شباهت و تحلیل معنایی تصمیم می‌گیرد [۱۲].

RAGLog در تنظیم گزارش‌شده، دقت ۰،۹۱، بازخوانی ۰،۸۸ و امتیاز افیک ۰،۸۹ به دست آورده و با LogPrompt مقایسه شده است [۱۲]. نویسندگان مصرف منابع و تأخیر تحلیل خطبه‌خط را از محدودیت‌های روش

می‌دانند. در RAGLog پایگاه برداری برای انتخاب زمینه است؛ در پایان‌نامه حافظه^{۱۱} نهان، تصمیم معتبر یک قالب تکراری را دوباره به کار می‌برد.

ما و همکاران در AdaptiveLog همکاری یک مدل زبانی کوچک و یک مدل بزرگ را برای چند وظیفه^{۱۲} تحلیل لاگ پیشنهاد کردند. مدل کوچک ابتدا نمونه را پردازش می‌کند و سنجه^{۱۳} عدم قطعیت مشخص می‌کند کدام نمونه به مدل بزرگ سپرده شود. موارد دشوار مشابه نیز از مخزن خطا بازیابی و به متن دستور افزوده می‌شوند. بازخورد مدل بزرگ برای بهبود تدریجی مدل کوچک به کار می‌رود [۱۳].

AdaptiveLog کاهش هزینه^{۱۴} فراخوانی مدل بزرگ تا ۷۳ درصد را گزارش کرده است [۱۳]. این صرفه‌جویی به یک مدل کوچک آموزش‌پذیر و سنجه^{۱۵} عدم قطعیت وابسته است. در روش ترکیبی پایان‌نامه، چند قاعده^{۱۶} قطعی نقش دروازه را دارند و در روش صرفاً مبتنی بر دستور همان دروازه حذف می‌شود؛ بنابراین به آموزش یک مدل جانبی نیاز نیست.

هادی و همکاران FlexLog را برای تشخیص داده‌کارآمد در لاگ‌های ناپایدار طراحی کردند. خروجی درخت تصمیم، نزدیک‌ترین همسایه و شبکه^{۱۷} پیش‌خور با Mistral، بازیابی نمونه و حافظه^{۱۸} نهان ترکیب می‌شود. مدل‌های کلاسیک نمونه‌های آشنا را پوشش می‌دهند و مدل زبانی بزرگ برای موارد دشوار یا وابسته به معنا فراخوانی می‌شود [۱۰].

آزمایش FlexLog روی SYNEVOL-U، ADFA-U، LOGEVOL-U، SynHDFS-U و SYNEVOL-U انجام شده است. مقاله در برخی تنظیم‌ها حداقل ۱۰۲ واحد درصد بهبود امتیاز افیک با ۶۲،۸۷ واحد درصد داده^{۱۹} برچسب‌خورده^{۲۰} کمتر، تا ۱۳ واحد درصد بهبود و زمان استنتاج کمتر از یک ثانیه برای هر توالی گزارش می‌کند [۱۰]. شباهت آن با پایان‌نامه در حافظه^{۲۱} نهان و آبشار تصمیم است؛ اما داده، واحد تحلیل و ترکیب چند طبقه‌بند متفاوت‌اند.

۲-۳-۶ مطالعات تجزیه و تولید قالب لاگ

له و ژانگ در LogPPT برای تجزیه^{۲۲} لاگ، تنظیم مبتنی بر دستور و یادگیری چندنمونه‌ای را روی RoBERTa به کار بردند. نمونه‌گیری تصادفی تطبیقی، مجموعه‌ای کوچک اما متنوع از پیام‌ها را برمی‌گزیند و مدل یاد می‌گیرد توکن‌های پارامتر را با یک برچسب مجازی مشخص کند. روش به عبارت منظم دستی وابسته نیست و تنظیمات یکسانی را در دامنه‌های مختلف حفظ می‌کند [۲۴].

LogPPT روی ۱۶ مجموعه^{۲۳} عمومی و با ۳۲ نمونه^{۲۴} برچسب‌خورده ارزیابی شده و میانگین صحت گروه‌بندی و صحت تجزیه^{۲۵} بیش از ۰،۹ گزارش کرده است [۲۴]. هدف مقاله تشخیص ناهنجاری نیست؛ با این حال، تعریف قالب و پارامتر در آن پشتوانه^{۲۶} نظری نرمال‌سازی و حافظه^{۲۷} نهان سطح قالب در پژوهش حاضر است.

ژونگ و همکاران در LogParser-LLM توان معنایی مدل زبانی بزرگ را با یک درخت پیشوند برای تجزیه^{۲۸} برخط ترکیب کردند. هر پیام ابتدا با قالب‌های موجود سنجیده می‌شود و فقط الگوهای تازه یا مبهم به مدل فرستاده می‌شوند. مقاله برای کنترل ریز یا درشت‌بودن قالب، یک معیار اختصاصی و امکان بازخورد انسانی نیز پیشنهاد می‌کند [۲۳].

در LogPub، با میانگین ۳٫۶ میلیون پیام در ۱۴ مجموعه، LogParser-LLM به طور متوسط ۲۷۲٫۵ فراخوانی مدل، امتیاز افیک گروه بندی ۹۰٫۶ درصد و صحت تجزیه ۸۱٫۱ درصد گزارش کرده است [۲۳]. این نتیجه نشان می دهد که تجمیع در سطح قالب می تواند فراخوانی ها را به شدت کاهش دهد؛ اما خروجی روش یک قالب است، نه برچسب ناهنجاری.

۲-۳-۷ مرورها، معیارهای ارزیابی، مدل های پایه و استقرار واقعی

دلا کروز کابلو، پرنس سیلز و ماچادو در یک مرور نظام مند، ۳۳ مقاله درباره عملیات هوشمند فناوری اطلاعات^{۲۵} و تشخیص ناهنجاری لاگ را بررسی کردند. آنان آماده سازی داده، تجزیه، استخراج ویژگی، مدل تشخیص، مجموعه های معیار و شیوه ارزیابی را دسته بندی و گذار از مدل های عمیق به مدل های زبانی بزرگ را جمع بندی کردند [۱۴].

این مرور روش آزمایشی تازه ای برای بی جی ال ارائه نمی کند. نقش آن در فصل حاضر، فراهم کردن چارچوب دسته بندی و صورت بندی مسائل بازی مانند هزینه، تبیین پذیری، تعمیم و محرمانگی است [۱۴]. ساختار کلی فصل از محورهای این منبع بهره می گیرد، اما جدول مقایسه فقط ۲۷ فایل موجود در پوشه^{۲۶} محلی را پوشش می دهد.

دلا کروز کابلو و همکاران در مطالعه ای میدانی، یک چارچوب خودنظارتی مبتنی بر LogBERT را با لاگ های سامانه ای^{۲۷} عادی آموزش دادند و در محیطی با محدودیت محرمانگی به صورت محلی مستقر کردند. اثر حداقل تعداد توکن، اندازه و هم پوشانی پنجره و نرخ پوشاندن بر کیفیت تشخیص و تأخیر اجرا بررسی شد [۲۰].

پنجره^{۲۸} پانزده ثانیه ای با هم پوشانی ده ثانیه، بهترین موازنه گزارش شده میان اثربخشی و تأخیر را ایجاد کرد و ارزیابی متخصصان نیز کاربرد عملی روش را تأیید نمود [۲۰]. مقاله از اهمیت استقرار محلی و اندازه گیری تأخیر پشتیبانی می کند، اما مدل آن LogBERT آموزش دیده و داده^{۲۹} آن لاگ واقعی است؛ نه کوئن بدون تنظیم روی بی جی ال.

لیو و همکاران OpsEval را برای سنجش توان مدل های زبانی بزرگ در عملیات فناوری اطلاعات ساختند. این مجموعه ۷۰۳۳۴ پرسش چند گزینه ای و ۱۰۷۳۶ پرسش پاسخ آزاد در چند زیرحوزه دارد و ۲۴ مدل را تحت راهبردهای خودسازگاری، زنجیره^{۳۰} استدلال و یادگیری درون متنی مقایسه می کند [۲۵].

معیار FAE-Score پاسخ آزاد را از نظر روانی، درستی و پشتوانه^{۳۱} شواهد می سنجد و هم بستگی حدود ۰٫۹۱۸۵ با ارزیابی متخصصان گزارش شده است [۲۵]. OpsEval آشکارساز لاگ نیست، اما حساسیت وظایف عملیاتی به نحوه^{۳۲} دستور و ضرورت تناسب معیار با نوع خروجی را نشان می دهد. چون خروجی پایان نامه دودویی است، معیارهای ماتریس اغتشاش و نرخ پاسخ نامعتبر جای معیار ارزیابی متن آزاد را می گیرند.

ژو و همکاران در گزارش فنی YuLan، فرایند توسعه^{۳۳} یک مدل متن باز دوازده میلیارد پارامتری را شرح دادند. مدل با حدود ۱۰۷ تریلیون توکن چندزبانه پیش آموزی شده و سپس تنظیم دستوری و هم ترازای انسانی را پشت سر

گذاشته است. مقاله همچنین برنامه آموزشی آسان به دشوار، معماری، توکن ساز^{۳۷} و داده های آموزش را توضیح می دهد [۲۶].

YuLan روی ۲۲ معیار عمومی ارزیابی شده، اما موضوع آن تشخیص ناهنجاری لاگ نیست [۲۶]. این منبع برای توضیح تفاوت مدل پایه با مدل دستور محور و مسیر پیش آموزی تا هم تراز در فصل گنجانده شده است. مدل عملی پژوهش کوئن ۲۰۵ دستور محور است و YuLan در آزمایش های مقایسه ای به کار نمی رود. شو و دینگ کاربرد مدل های زبانی بزرگ در تشخیص ناهنجاری و داده خارج از توزیع را در حوزه های گوناگون مرور کردند. آنان مطالعات را بر پایه نقش مدل به دو گروه «استفاده برای تشخیص» و «استفاده برای تولید» تقسیم و تفاوت تغییر درون توزیعی با تغییر معنایی، مجموعه های داده و مسیرهای آینده را بررسی کردند [۲۷]. دامنه این مرور فراتر از لاگ و شامل متن، سری زمانی و گونه های دیگر داده است [۲۷]. در فصل حاضر، از آن برای تعریف نقش مدل و جداسازی مطالعات تشخیص از پژوهش های تولید داده یا توضیح استفاده می شود. این مقاله آزمایش مستقیمی درباره کوئن یا بی جی ال گزارش نمی کند.

۲-۳-۸ جمع بندی تحلیلی مسیر پژوهش ها

نخستین مرحله تحول این حوزه با مدل سازی توالی رخدادها شکل گرفت. DeepLog رخداد بعدی را پیش بینی می کند و LogBERT زمینه دوسویه و وظیفه خود نظارتی را به تحلیل توالی می افزاید [۱۹، ۲۱]. BERT-Log مسیر دیگری دارد و بازنمایی زبانی را با طبقه بند نظارت شده ترکیب می کند [۱۸]. این مطالعات تفاوت میان یادگیری الگوی عادی و طبقه بندی برچسب محور را روشن کرده اند.

در مرحله بعد، کاهش وابستگی به نمونه ناهنجار برچسب خورده اهمیت یافت. LogFiT و ADALog هر دو با وظیفه مدل سازی زبان پوشانده شده و داده عادی کار می کنند [۸، ۲۲]، اما واحد تحلیل آن ها متفاوت است: اولی الگوی توکن را در پیام یا توالی می سنجد و دومی هر پیام را مستقل و با آستانه تطبیقی ارزیابی می کند. بنابراین حذف برچسب ناهنجار به تنهایی واحد تصمیم را مشخص نمی کند.

مرحله سوم با ورود مدل زبانی بزرگ آموزش پذیر شکل گرفت. LogGPT، LogLLM، LLM مبتنی بر GPT، LADE و روش های تنظیم کارآمد پارامترها از پیش آموزی عمومی آغاز می کنند، اما برای دامنه لاگ بخشی از وزن ها یا نگاشت های مدل را تغییر می دهند [۴، ۵، ۷، ۹]. هزینه آموزش و داده انطباق، این خانواده را از روش های صرفاً مبتنی بر دستور جدا می کند.

مرحله چهارم بر دستور پذیری مدل، بدون تغییر وزن، تکیه دارد. دو نسخه LogPrompt و مطالعه ChatGPT-LogGPT اثر نحوه دستور، دانش دامنه و استدلال را می سنجد [۱، ۲، ۶]. Hybrid Prompting این مسیر را با افزودن شواهد سطح توالی و نمونه بازبازی شده گسترش می دهد [۳]. در این خانواده، متن دستور و شیوه انتخاب زمینه جزئی از سامانه تصمیم اند.

مرحله پنجم به هزینه و مقیاس توجه دارد. RAGLog نمونه عادی مشابه را بازبازی می کند؛ AdaptiveLog فقط نمونه های نامطمئن را به مدل بزرگ می سپارد؛ و FlexLog مدل های کلاسیک، بازبازی و حافظه نهان را در

یک سامانه ترکیب می‌کند [۱۰، ۱۲، ۱۳]. LogParser-LLM نیز در وظیفه تجزیه نشان می‌دهد که یک ساختار پیشوندی می‌تواند فراخوانی مدل را در مقیاس میلیون‌ها پیام محدود کند [۲۳].

یک مسیر موازی بر تبیین‌پذیری متمرکز است. LogPrompt توضیح را در پاسخ مستقیم مدل می‌گیرد [۱]، LLM-LADE توضیح را هم‌زمان با تشخیص آموزش می‌دهد [۷]؛ و LogLAA آشکارساز عمیق و مولد توضیح را در دو جزء جدا کنار هم قرار می‌دهد [۱۷]. پس تبیین‌پذیری می‌تواند خروجی زبانی، هدف آموزشی یا مرحله پس از تشخیص باشد.

مطالعات انتقال و ناپایداری یادآوری می‌کنند که ارزیابی روی یک توزیع ثابت همه رفتار سامانه را نشان نمی‌دهد. پژوهش GPT روی LOGEVOL تغییر نسخه را مستقیماً می‌آزماید [۱۱]؛ LogSynergy بازنمایی مشترکی میان سامانه‌ها می‌سازد [۱۵]؛ و FlexLog داده‌های ناپایدار واقعی و مصنوعی را بررسی می‌کند [۱۰]. پایان‌نامه حاضر این محور را به‌صورت تجربی پوشش نمی‌دهد و به بی‌جی‌ال ثابت محدود است.

پژوهش‌های تجزیه نشان می‌دهند که آماده‌سازی ورودی خود یک مسئله مستقل است. LogPPT با یادگیری چندنمونه‌ای و LogParser-LLM با مدل زبانی بزرگ و درخت پیشوند، کیفیت قالب را خروجی اصلی می‌دانند [۲۳، ۲۴]. بنابراین اگر پس از تغییر تجزیه‌گر، کیفیت آشکارساز بهتر شود، باید اثر این دو مرحله از هم جدا شود. در پایان‌نامه، قواعد نرمال‌سازی در هر دو روش ثابت‌اند.

مطالعه میدانی عملیات هوشمند فاصله میان نتیجه آزمایشگاهی و استقرار واقعی را آشکار می‌کند: اندازه پنجره و تأخیر اجرا به اندازه دقت برای کاربرد اهمیت دارند [۲۰]. OpsEval نیز نشان می‌دهد ارزیابی مدل زبانی در وظایف عملیاتی به دستور و معیار متناسب نیازمند است [۲۵]. این دو منبع پشتوانه گزارش زمان، نسخه مدل و قرارداد خروجی در کنار امتیاز افیک هستند.

دو مقاله مروری مرز دامنه را روشن می‌کنند. مرور نظام‌مند لاگ، مراحل زنجیره پردازش و مسائل باز عملیات هوشمند را استخراج می‌کند [۱۴]؛ مرور تشخیص ناهنجاری و داده خارج از توزیع نیز نقش مدل را به تشخیص و تولید تقسیم می‌کند [۲۷]. هیچ‌یک نتیجه آزمایشی روی بی‌جی‌ال محسوب نمی‌شوند.

YuLan نیز در گروه نتایج تشخیص قرار نمی‌گیرد، اما مراحل ساخت مدل پایه، تنظیم دستوری و هم‌ترازی را مستند می‌کند [۲۶]. این تمایز اهمیت دارد، زیرا کوئن ۲۰۵ دستورمحور حاصل چنین مراحل عمومی است، ولی وزن‌های آن در پروژه تغییر نمی‌کنند و فقط در مرحله استنتاج به کار می‌روند [۲۸].

از مجموع این ۲۷ مقاله می‌توان پنج تصمیم طراحی را استخراج کرد: واحد تحلیل، شیوه سازگار کردن مدل، روش آماده‌سازی ورودی، سازوکار مهار هزینه و محل استقرار. در پایان‌نامه فقط یکی از این تصمیم‌ها، یعنی محل اعمال دانش قاعده، میان دو روش تغییر می‌کند و سایر عوامل برای مقایسه ثابت می‌مانند.

۲-۴ دسته‌بندی و تحلیل مقایسه‌ای

شکل ۱-۲ هر ۲۷ مقاله را در شش مسیر روش‌شناختی جای می‌دهد و سپس نشان می‌دهد کدام مؤلفه‌ها در طراحی پژوهش حاضر به یکدیگر می‌رسند. شماره‌های شکل با شماره فایل‌های پوشه و ارجاع‌های این فصل

یکسان‌اند. قرار گرفتن یک مقاله در یک گروه به معنای نداشتن مؤلفه‌های گروه دیگر نیست؛ برای نمونه، FlexLog هم از مدل‌های کلاسیک و مدل زبانی بزرگ بهره می‌برد و هم بازیابی و حافظهٔ نهان را به کار می‌گیرد [۱۰].

نقشه مطالعات بررسی‌شده در فصل دوم (۲۷ مقاله)			
ترتیبی و پیش‌آموزش‌دیده	آموزش، تنظیم و انتقال مدل زبانی بزرگ	دستور متنی و استدلال درون‌متنی	
DeepLog [۲۱]؛ LogBERT [۱۹]؛ LogFiT [۸]؛ BERT-Log [۱۸]؛ ADALog [۲۲]	LogGPT [۵]؛ مدل زبانی بزرگ [۴]؛ LLM-LADE [۷]؛ PEFT [۹]؛ GPT ناپایدار [۱۱]؛ LogSynergy [۱۵]؛ SemiRALD [۱۶]؛ LogLAA [۱۷]	ChatGPT-LogPrompt [۱، ۶]؛ Hybrid Prompting [۳]؛ LogGPT [۲]	
بازیابی، همکاری و کنترل هزینه	تجزیه و ساخت قالب	مرور، معیار و استقرار	
AdaptiveLog [۱۳]؛ RAGLog [۱۲]؛ FlexLog [۱۰]	LogPPT [۲۴]؛ LogParser-مدل زبانی بزرگ [۲۳]	OpsEval [۲۰]؛ AI Ops واقعی [۱۴]؛ SLR [۲۵]؛ YuLan [۲۶]؛ Anomaly/OOD [۲۷]؛ مرور	
ترکیب شواهد ادبیات برای طراحی پژوهش حاضر: معناشناسی مدل زبانی + قالب پایدار + کنترل تصمیم + استنتاج محلی			
دامنه و واحد تحلیل	متغیر مستقل مقایسه	کارایی	استقرار و سنجش
فقط BGL؛ طبقه‌بندی خط‌به‌خط؛ حذف برچسب از ورودی	Hybrid LLM: نگهبان قاعده‌محور قطعی پیش از صرفاً مبتنی بر دستور: انتقال دانش قاعده به دستور متنی	نرمال‌سازی و کش سطح قالب؛ رد پاسخ نامعتبر	Qwen۲.۵:۷B-Instruct روی Ollama؛ کیفیت، زمان و منبع تصمیم

شکل ۲-۱: ارتباط ۲۷ مقالهٔ بررسی‌شده با یکدیگر و جایگاه پژوهش حاضر

بخش بالایی شکل، گذار فنی از مدل‌های ترتیبی و BERT به مدل‌های زبانی بزرگ، دستور متنی، بازیابی و استقرار واقعی را نمایش می‌دهد. بخش پایینی، نوآوری عملیاتی مورد سنجش را خلاصه می‌کند: مدل و پیش‌پردازش ثابت می‌مانند و فقط محل اعمال دانش قاعده، میان نگهبان بیرونی و متن دستور، تغییر می‌کند. شکل برای نمایش رابطهٔ اجزای برگرفته از منابع است و دربارهٔ برتری هیچ مسیر داوری نمی‌کند.

جدول ۱-۲: ویژگی‌ها و نتایج گزارش‌شده در ۲۷ مقاله موجود در پوشه پژوهش

شماره و مطالعه	س ال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش‌شده
[۱] LogPrompt اولیه	۲۰ ۲۳	دستور متنی	مدل زبانی بزرگ + راهبرد دستور و تبیین	چند مجموعه لاگ	قالب/توالی	نسخه اولیه تحلیل بدون آموزش درون‌دامنه
[۲] ChatGPT- LogGPT	۲۰ ۲۳	دستور متنی	ChatGPT و دانش دامنه	BGL, Spirit	خط/پنجره	بررسی دستور متنی، پنجره و تبیین روی نمونه ۲۰۰۰ تایی
[۳] Hybrid Prompting	۲۰ ۲۵	دستور متنی ترکیبی	رخداد + توالی + بازایی	.HDFS, BGL Thunderbird	توالی یک دقیقه ی	BGL: $P=۶۳.۶۵$, $R=۹۹.۶۰$ افیک=۷۷.۸۱
[۴] LogLLM	۲۰ ۲۴	آموزش LLM	BERT + لایه نگاشت + LLaMA	.HDFS, BGL Liberty Thunderbird	توالی	ترکیب بازنمایی رمزگذار و طبقه‌بند LLM
[۵] LogGPT via GPT	۲۰ ۲۳	آموزش/RL	GPT پیش‌بینی رخداد + RL	.HDFS, BGL Thunderbird	توالی	هم‌راستاسازی پیش‌بینی رخداد با هدف تشخیص
[۶] LogPrompt توسعه‌یافته	۲۰ ۲۴	دستور متنی	zero-shot, CoT و تبیین	۹ مجموعه	قالب/توالی	تا ۵۵/۹٪ بهبود؛ تفسیرپذیری ۵/۴/۴۲
[۷] LLM-LADE	۲۰ ۲۵	PEFT/تبی ین	افزایش داده + LoRA + بهینه‌سازی برخط	مجموعه‌های عمومی	پیام/توالی	تشخیص و توضیح هم‌زمان با پایگاه دانش
[۸] LogFit	۲۰ ۲۵	خودنظارتی	مدل زبانی ماسک‌شده و گزینه‌های برتر	.HDFS, BGL Thunderbird	توالی	آموزش فقط روی لاگ عادی
[۹] PEFT-LAD	۲۰ ۲۵	PEFT	LoRA/ReFT روی .RoBERTa, GPT-۲ Llama-۳	.HDFS, BGL Spirit Thunderbird	توالی	تحلیل پایداری، کارایی نمونه و انتقال
[۱۰] FlexLog	۲۰ ۲۴ ۲۵	ترکیبی	+ ML ensemble + Mistral + RAG cache	چهار مجموعه ناپایدار	توالی	داده کمتر؛ تا ۱۳ واحد درصد بهبود؛ کمتر از ۱ ثانیه
[۱۱] Unstable Logs GPT	۲۰ ۲۴	تنظیم/دس تور متنی	GPT-۳ تنظیم‌شده و GPT-۴ دستور متنی	LOGEVOL- Hadoop	توالی	برتری تنظیم دقیق در پروتکل مطالعه
[۱۲] RAGLog	۲۰ ۲۳ ۲۴	بازایی	پایگاه برداری عادی + LLM	.BGL Thunderbird	خط/توالی	دقت=۰.۹۱، بازخوانی=۰.۸۸، افیک=۰.۸۹
[۱۳] AdaptiveLog	۲۰ ۲۵	همکاری مدل	مدل کوچک + مدل زبانی بزرگ + بازایی	چند وظیفه لاگ	وابسته به وظیفه	تا ۷۳٪ کاهش هزینه فراخوانی LLM

شماره و مطالعه	س ال	دسته	روش/مدل	داده‌ها	واحد تحلیل	نتیجه یا نقش گزارش‌شده
[۱۴] مرور نظام‌مند AIOps	۲۰ ۲۵	مرور	SLR و طبقه‌بندی ۳۳ مقاله	ادبیات حوزه	مطالعه	چارچوب مراحل، داده‌ها، مدل‌ها و شکاف‌ها
[۱۵] LogSynergy	۲۰ ۲۵	انتقال	تفسیر مدل زبانی بزرگ + ویژگی یکپارچه	عمومی و واقعی	توالی	افیک بیش از ۸۳٪ عمومی و ۸۹٪ واقعی
[۱۶] SemiRALD	۲۰ ۲۵	نیمه‌نظارتی	+ ChatGPT parsing RoBERTa + BiLSTM	HDFS, BGL	توالی	بهبود متوسط افیک برابر ۷/۳ و ۸/۲٪
[۱۷] LogLAA	۲۰ ۲۶	یکپارچه	تجزیه‌گر + CNN-LSTM مدل زبانی بزرگ + explanation	چند مجموعه	توالی	بهبود تجزیه‌گر، دقت و تولید توضیح
[۱۸] BERT-Log	۲۰ ۲۲	نظارت‌شده	BERT + طبقه‌بند	HDFS, BGL	پنجره/توالی	افیک گزارش‌شده ۹۹/۴٪ روی BGL
[۱۹] LogBERT	۲۰ ۲۱	خودنظارتی	BERT با مدل‌سازی زبان پوشانده‌شده و ابرکره	HDFS, BGL Thunderbird	توالی	یادگیری الگوی عادی با دو هدف خودنظارتی
[۲۰] AIOps واقعی	۲۰ ۲۶	استقرار	LogBERT محلی	Linux syslog واقعی	پنجره زمانی	پنجره ۱۵ ثانیه با هم‌پوشانی ۱۰ ثانیه
[۲۱] DeepLog	۲۰ ۱۷	ترتیبی	LSTM و پیش‌بینی رخداد بعدی	HDFS OpenStack	توالی	تشخیص برخط، به‌روزرسانی و جریان عیب‌یابی
[۲۲] ADALog	۲۰ ۲۵	بدون نظارت	DistilBERT مدل‌سازی زبان پوشانده‌شده + آستانه تطبیقی	BGL Thunderbird Spirit	خط	بدون تجزیه‌گر و مستقل از توالی
[۲۳] LogParser- LLM	۲۰ ۲۴	تجزیه	مدل زبانی بزرگ + درخت پیشوند	Loghub-۲k LogPub	خط/قالب	۲۷۲/۵ فراخوانی؛ افیک گروه‌بندی ۹۰/۶٪
[۲۴] LogPPT	۲۰ ۲۳	تجزیه	چندنمونه‌ای prompt tuning RoBERTa روی	۱۶ مجموعه	خط/قالب	بیش از ۰/۹ با ۳۲ نمونه برچسب‌خورده
[۲۵] OpsEval	۲۰ ۲۵	معیار	چندگزینه‌ای/پاسخ آزاد + استدلال/یادگیری FAE- + درون‌متنی Score	۹۰۷۰ Ops	پرسش	۲۴ مدل زبانی بزرگ؛ هم‌بستگی FAE حدود ۰/۹۱۸۵
[۲۶] YuLan	۲۰ ۲۴	مدل پایه	مدل زبانی بزرگ متن‌باز ۱۲B و سه مرحله آموزش	۱/۷T توکن؛ ۲۲ معیار	متن	مرجع ساخت مدل دستورمحور؛ نه آشکارساز لاگ
[۲۷] Anomaly/OOD	۲۰ ۲۵	مرور	رده‌بندی مدل زبانی بزرگ برای تشخیص/تولید	چند حوزه داده	مطالعه	تفکیک anomaly و OOD و نقش‌های LLM