

فرم طرح پیشنهادی پژوهش

درخواست تصویب عنوان پایان نامه کارشناسی ارشد

عنوان پایان نامه (فارسی)

بهبود تشخیص ناهنجاری‌ها در لاگ‌های سیستمی مبتنی بر مدل‌های زبانی بزرگ با بهره‌گیری از مهندسی پرامپت

عنوان پایان نامه (انگلیسی)

Improving Anomaly Detection in System Logs Based on Large Language Models Using Prompt Engineering

کلمات کلیدی (فارسی)

تشخیص ناهنجاری، لاگ‌های سیستمی، مهندسی پرامپت، مدل‌های زبانی بزرگ

کلمات کلیدی (انگلیسی)

Anomaly Detection, System Logs, Prompt Engineering, Large Language Models (LLMs)

نوع پژوهش: کاربردی

تعداد واحد پایان نامه: ۶ واحد

نام و نام خانوادگی استاد (اساتید) راهنما:	نام و نام خانوادگی استاد (اساتید) مشاور:
۱- دکتر محمدرضا علی‌زاده	۱-

۱- اطلاعات مربوط به دانشجو

نام: مسعود	نام خانوادگی: دباغی	شماره دانشجویی: ۴۰۱۱۲۳۴۱۰۰۲۰۶۹
مقطع تحصیلی: کارشناسی ارشد	رشته تحصیلی: مهندسی کامپیوتر	گرایش: نرم افزار
گروه آموزشی: کامپیوتر - نرم افزار	نام دانشکده: مکانیک، برق و کامپیوتر	سال ورود: ۱۴۰۱
تلفن ثابت: ۰۳۱-۳۳۵۹۰۰۱۵	تلفن همراه: ۰۹۳۹-۲۳۲-۲۱۵۹	نیمسال اخذ پایان نامه: ۱۴۰۴/۱
نشانی پستی: اصفهان خیابان پاسداران شرقی کوی صبا کوچه گل سرخ پلاک ۵۶		
پست الکترونیک (Email):		Masoudd2159@gmail.com

۲- اطلاعات مربوط به استاد راهنما

نام و نام خانوادگی: محمدرضا علی زاده	آخرین مدرک تحصیلی (دانشگاهی/حوزوی): دکتری
تخصص اصلی: سیستم‌های توزیع شده و سلامت الکترونیک	عضو هیأت علمی: دانشگاه آزاد اسلامی واحد علوم و تحقیقات تهران
رتبه و پایه دانشگاهی (مرتبه علمی): استادیار	تلفن همراه: ۰۹۳۶-۰۱۲-۳۲۵۳
آدرس محل کار: تهران- انتهای بزرگراه شهید ستاری- بلوار شهدای حصارک- دانشگاه آزاد اسلامی واحد علوم و تحقیقات	
تلفن محل کار:	پست الکترونیک (Email): Mralizadeh.uni@gmail.com
نحوه همکاری با واحد دانشگاهی: تمام وقت	

۳- اطلاعات مربوط به استاد مشاور

نام و نام خانوادگی:	آخرین مدرک تحصیلی (دانشگاهی/حوزوی):
تخصص اصلی:	عضو هیأت علمی:
رتبه و پایه دانشگاهی (مرتبه علمی):	تلفن همراه:
آدرس محل کار:	
تلفن محل کار:	پست الکترونیک (Email):
نحوه همکاری با واحد دانشگاهی:	

۱- بیان مسأله (شامل تشریح مسأله و معرفی آن، بیان جنبه‌های مجهول و مبهم، بیان متغیرهای مربوطه و سؤال کلی پژوهش)

در سامانه‌های مدرن با معماری توزیع شده، حجم عظیمی از لاگ‌های سیستمی به صورت پیوسته تولید می‌شود که حاوی اطلاعات مهمی برای عیب‌یابی، پایش سلامت و بررسی حوادث امنیتی هستند. کشف ناهنجاری‌ها در این لاگ‌ها نقش کلیدی در افزایش پایداری و قابلیت اطمینان سیستم دارد. با این حال، چند ویژگی مشکل‌ساز وجود دارد: ساختار نامنظم لاگ‌ها (متن آزاد همراه با پارامترها و شناسه‌ها)، حجم بسیار بالا و پویایی سریع الگوهای آن‌ها و تعداد کم رخدادها ناهنجار نسبت به رویدادهای عادی. روش‌های سنتی مبتنی بر قوانین دست‌نویس یا الگوریتم‌های آماری، که اغلب به الگوهای ثابت یا داده‌های پارس شده نیاز دارند، در مواجهه با این چالش‌ها کارآمدی خود را از دست می‌دهند. برای مثال، LogLLM نشان می‌دهد که روش‌های معمول نیاز به استخراج الگو دستی دارند اما مدل‌های زبانی بزرگ می‌توانند با پیش‌پردازش ساده مانند عبارات با قاعده، فرایند را ساده کنند و به دقت بالا در تشخیص ناهنجاری برسند [۱].

مدل‌های زبانی بزرگ (مانند GPT، BERT، LLaMa و...) توانایی قوی در پردازش متون غیرساختاریافته و یادگیری روابط معنایی دارند. این مدل‌ها می‌توانند پیام‌های لاگ را مانند جمله‌های طبیعی در نظر گرفته و معنا و زمینه آن‌ها را استخراج کنند [۱].

همچنین استفاده از LLMها فراتر از خود تشخیص ناهنجاری رفته و در فرایندهای پیشین مانند تجزیه لاگ نیز تأثیرگذار بوده است. به عنوان نمونه، LogParser-LLM نشان می‌دهد که با ادغام دانش معنایی مدل‌های زبانی در فرایند پارس لاگ، می‌توان بدون نیاز به داده‌های برچسب‌دار یا تنظیمات دقیق، ساختار لاگ را استخراج کرد [۲]. این کار با بهره‌گیری هم‌زمان از اطلاعات معنایی و ویژگی‌های آماری، دقت بالایی در تشخیص الگوها ایجاد می‌کند. در کل، این مطالعات همگی حکایت از این دارند که مدل‌های زبانی بزرگ می‌توانند محدودیت روش‌های سنتی را با درک عمیق‌تر متن لاگ و تشخیص ناهنجاری حتی در شرایط تغییر الگو برطرف سازند [۳].

با وجود موفقیت اولیه، چندین چالش و سؤال پژوهشی باقی مانده است که باید بررسی شوند:

یکی از موانع اصلی در بکارگیری مدل‌های زبانی بزرگ، پارامترهای فراوان و محاسبات سنگینی است که منجر به افزایش تأخیر اجرا و هزینه‌های عملیاتی می‌شود. اکثر رویکردهای فعلی مانند LogLLM [۱] یا روش‌های مبتنی بر تنظیم دقیق^۱ مانند LogBERT [۴]، نیازمند زیرساخت‌های پردازشی قدرتمند (GPU) و زمان آموزش طولانی هستند. از سوی دیگر، در محیط‌های صنعتی، سرعت تشخیص ناهنجاری حیاتی است.

برای مقابله با این چالش، پژوهش‌هایی مانند AdaptiveLog [۵] استراتژی همکاری میان مدل‌های کوچک و بزرگ (SLM/LLM) را پیشنهاد داده‌اند تا تنها در موارد پیچیده از توان محاسباتی مدل بزرگ استفاده شود. با این حال، حتی در این مدل‌ها نیز نیاز به داده‌های برچسب‌دار و فرآیند آموزش همچنان پابرجاست.

علاوه بر چالش‌های محاسباتی و داده‌ای، یکی از موانع جدی در به کارگیری مدل‌های زبانی بزرگ در محیط‌های عملیاتی حساس، مسئله «توهم»^۲ و «شکاف دانش دامنه»^۳ است. مدل‌های زبانی عمومی اغلب بر روی داده‌های عمومی اینترنت آموزش دیده‌اند و

^۱ Fine-tuning

^۲ Hallucination

^۳ Domain Knowledge Gap

ممکن است فاقد دانش تخصصی عمیق در مورد معماری‌های خاص سازمانی، کدهای خطای اختصاصی و وابستگی‌های پیچیده میان میکروسرویس‌ها باشند. این محدودیت می‌تواند منجر به تولید توضیحات نادرست اما با ظاهر موجه شود که در فرآیند عیب‌یابی سیستم‌های حیاتی، ریسک عملیاتی را افزایش می‌دهد. پژوهش‌های اخیر نشان می‌دهند که صرفاً تکیه بر دانش درونی مدل برای تشخیص ریشه خطا کافی نیست و مدل‌ها در مواجهه با لاگ‌های ناشناخته، ممکن است روابط علی و معلولی را به اشتباه استنتاج کنند [۶]. از این رو، مبحث تلفیق مدل‌های زبانی با پایگاه‌های دانش خارجی از طریق تکنیک‌هایی مانند «تولید افزوده به بازیابی»^۱ (RAG) مطرح شده است. سوال اساسی اینجا است که چگونه می‌توان مستندات فنی، سوابق تیکت‌های گذشته و گراف دانش سیستم را به صورت پویا در اختیار مدل قرار داد تا خروجی آن واقعیت‌محور باقی بماند. مطالعاتی نظیر OpsEval نشان داده‌اند که مدل‌های فعلی بدون دسترسی به دانش زمینه، در وظایف استدلال منطقی پیچیده دچار افت عملکرد می‌شوند [۷]. بنابراین، بررسی راهکارهایی که بتوانند دانش زمینه را بدون نیاز به بازآموزی سنگین به مدل تزریق کنند و نرخ توهم را در تشخیص ناهنجاری به حداقل برسانند، یک خلأ پژوهشی آشکار است که نیازمند تحقیقات متمرکز می‌باشد.

در این پژوهش، شکاف موجود با استفاده از «مهندسی پرامپت هوشمند»^۲ و تکنیک‌های یادگیری با مثال‌های محدود^۳ پر می‌شود. این رویکرد به جای بازآموزی مدل یا استفاده از معماری‌های دوگانه پیچیده، بر استفاده بهینه از توانایی‌های ذاتی مدل‌های پیش‌آموزش‌دیده تمرکز دارد. هدف این است که با طراحی استراتژی‌های پرامپت‌دهی کارآمد [۸]، دقت تشخیص در سطح مدل‌های ریزتنظیم‌شده حفظ شود، در حالی که هزینه محاسباتی و نیاز به داده‌های آموزشی برچسب‌دار به حداقل برسد.

هدف اصلی، دستیابی به سیستمی است که بتواند به صورت مؤثر ناهنجاری‌های معنایی و ترتیبی را در لاگ‌های سیستمی تشخیص دهد، به گونه‌ای که دقت تشخیص در سطح مدل‌های پیچیده حفظ شده، اما نیاز به داده‌های برچسب‌دار و هزینه‌های محاسباتی به حداقل برسد. این سیستم با استفاده از استراتژی‌های پرامپت‌دهی کارآمد (مانند زنجیره افکار [۱۰])، اختلالات واقعی را از هشدارهای کاذب تفکیک کرده و برخلاف روش‌های سنتی، در مواجهه با تغییرات ناگهانی در الگوهای لاگ، پویایی و تعمیم‌پذیری بالایی از خود نشان می‌دهد.

نتایج مورد انتظار این تحقیق شامل ارائه راهکاری سبک و قابل پیاده‌سازی در محیط‌های واقعی است که علاوه بر بهبود پایداری و امنیت سامانه‌ها، زمان و هزینه‌های اشکال‌یابی را از طریق ارائه توضیحات قابل فهم برای ناهنجاری‌ها کاهش دهد.

در نهایت، این تحقیق می‌تواند به توسعه سامانه‌های مانیتورینگ خودکار و پایدار در مقیاس بزرگ کمک کند، طوری که پایداری و امنیت سامانه‌ها بهبود یابد و زمان و هزینه‌های اشکال‌یابی کاهش پیدا کند.

^۱ Retrieval-Augmented Generation

^۲ Prompt Engineering

^۳ Few-shot

۲- اهمیت و ضرورت انجام پژوهش (شامل اختلاف نظرها و خلاءهای پژوهش‌های موجود، میزان نیاز به موضوع، فواید احتمالی نظری و عملی آن و همچنین مواد، روش و یا فرآیند پژوهشی احتمالاً جدیدی که در پژوهش مورد استفاده قرار می‌گیرد و همچنین بیان ضرورت و اهمیت تحقیق در جامعه مورد مطالعه)

در دنیای امروز، سیستم‌های نرم‌افزاری و زیرساخت‌های توزیع شده به ستون فقرات صنایع گوناگون از جمله مالی، سلامت، مخابرات و سرویس‌های ابری تبدیل شده‌اند. پایداری و امنیت این سیستم‌ها وابستگی مستقیم به توانایی تشخیص سریع و دقیق ناهنجاری‌ها در لاگ‌های سیستمی دارد. با توجه به اینکه حجم و تنوع لاگ‌ها به‌طور مداوم در حال افزایش است، استفاده از روش‌های سنتی نظیر قواعد دست‌نویس یا الگوریتم‌های آماری دیگر پاسخگوی نیازهای فعلی نیست.

از نظر علمی، خلاءهای تحقیقاتی قابل توجهی در این حوزه وجود دارد. نخست، بیشتر پژوهش‌های گذشته یا بر جنبه‌های آماری و ساختاری لاگ‌ها تمرکز داشته‌اند یا تنها به مدل‌سازی مبتنی بر توالی رویدادها پرداخته‌اند و کمتر به ترکیب ابعاد معنایی و زمانی توجه شده است. دوم، اگرچه مطالعات اخیر استفاده از مدل‌های زبانی بزرگ (LLMs) را پیشنهاد کرده‌اند، اما همچنان پرسش‌های مهمی درباره میزان کارایی، هزینه محاسباتی و قابلیت تعمیم‌پذیری LLM‌ها در محیط‌های عملیاتی بدون پاسخ مانده است. اختلاف نظرهایی نیز درباره روش بهینه تنظیم این مدل‌ها (تنظیم پرامپت در مقابل فاین تیونینگ) و نیاز به داده‌های برجسب‌دار وجود دارد.

از جنبه کاربردی، اهمیت این تحقیق در افزایش پایداری و امنیت سیستم‌ها آشکار است. یک چارچوب هوشمند می‌تواند:

- زمان تشخیص و رفع خطا را به شکل چشمگیری کاهش دهد،
- هزینه‌های ناشی از توقف سیستم یا حملات سایبری را کم کند،
- و ابزار قدرتمندی برای تیم‌های عملیات و نگهداری فراهم آورد.

علاوه بر این، نتایج تحقیق می‌تواند به توسعه روش‌هایی منجر شود که حتی در محیط‌هایی با منابع محاسباتی محدود یا داده‌های برجسب‌دار اندک، عملکرد مؤثر و مقیاس‌پذیر داشته باشند. این موضوع به‌ویژه برای سازمان‌هایی که امکان استفاده از منابع ابری گسترده ندارند، اهمیت حیاتی خواهد داشت.

بنابراین، ضرورت این پژوهش هم در پاسخ به نیازهای عملی صنعت و هم در پر کردن شکاف‌های نظری موجود در ادبیات علمی نهفته است.

۳- مرور ادبیات و سوابق مربوط (بیان مختصر پیشینه پژوهش‌های انجام شده در داخل و خارج کشور پیرامون موضوع پژوهش و نتایج آن‌ها و مرور ادبیات و چارچوب نظری پژوهش)

وی گان و همکاران [۱] در سال ۲۰۲۴ با انتشار پژوهشی پیرامون تشخیص ناهنجاری مبتنی بر لاگ، چارچوبی نوین را معرفی کردند که از ترکیب دو مدل زبانی بزرگ بهره می‌برد. در این روش، برخلاف رویکردهای سنتی که متکی بر استخراج الگو از طریق پارسرها بودند، از ترکیب دو مدل زبانی بزرگ یعنی BERT برای استخراج ویژگی‌های معنایی و LLaMA برای طبقه‌بندی

توالی‌های لاگ استفاده شد. پژوهشگران برای هم‌ترازی فضای بردارهای معنایی این دو مدل، یک لایه واسط طراحی کردند و با بهره‌گیری از یک فرآیند آموزشی سه‌مرحله‌ای، توانستند دقت و سازگاری روش را به‌طور قابل توجهی ارتقا دهند. نتایج آزمایش‌ها بر روی چهار مجموعه داده‌ی عمومی نشان داد که LogLLM نسبت به روش‌های پیشین عملکرد بهتری داشته و توانسته است با دقت بالا، حتی در شرایطی که لاگ‌ها ناپایدار و متغیر هستند، ناهنجاری‌ها را شناسایی کند.

با هدف ارتقای کارایی پردازش لاگ، ژائو و تیم تحقیقاتی‌اش [۲] در سال ۲۰۲۴ رویکردی تازه را برای بهبود فرآیند تجزیه لاگ پیشنهاد دادند. آن‌ها با استفاده از توانایی مدل‌های زبانی بزرگ در درک زبان طبیعی، سیستمی طراحی نمودند که می‌تواند بدون نیاز به قواعد سخت‌گیرانه یا وابستگی به الگوهای از پیش تعریف‌شده، لاگ‌ها را به‌صورت پویا و انعطاف‌پذیر پردازش کند. این روش برخلاف تجزیه‌کننده‌های سنتی که در مواجهه با تغییر قالب لاگ‌ها دچار افت دقت می‌شوند، توانست پایداری و سازگاری بالاتری نشان دهد. نتایج آزمایش‌ها روی مجموعه داده‌های متنوع نشان داد که LogParser-LLM هم از نظر سرعت و هم از نظر دقت در استخراج الگوهای لاگ عملکرد بهتری نسبت به ابزارهای متداول داشت و توانست کارایی کل فرایند تحلیل و تشخیص ناهنجاری‌های سیستمی را ارتقا دهد.

سونگ چن و های لیاو [۳] در سال ۲۰۲۲ با اتخاذ دیدگاهی نوین که توالی لاگ را به‌عنوان یک دنباله زبانی طبیعی در نظر می‌گرفت، روشی جدید برای تحلیل لاگ‌ها ارائه کردند. آن‌ها با در نظر گرفتن توالی لاگ به‌عنوان یک دنباله زبانی طبیعی، از مدل پیش‌آموزش‌دیده BERT برای استخراج نمایش‌های معنایی لاگ‌ها بهره گرفتند و سپس با ریزتنظیم این مدل در کنار یک شبکه عصبی تمام‌متصل، توانستند ناهنجاری‌ها را با دقت بالا تشخیص دهند. این روش برخلاف مدل‌های مبتنی بر LSTM یا Word2Vec، قادر بود وابستگی‌های معنایی، ترتیب کلمات و موقعیت آن‌ها را در توالی لاگ‌ها به‌خوبی مدل‌سازی کند. نتایج آزمایش‌ها روی دو مجموعه داده عمومی HDFS و BGL نشان داد که BERT-Log نسبت به بسیاری از روش‌های موجود عملکرد برتری داشته و توانسته است به F1-Score بالای ۹۹٪ دست یابد. این پژوهش نشان داد که استفاده از مدل‌های زبانی پیش‌آموزش‌دیده می‌تواند بهبود چشمگیری در دقت، تعمیم‌پذیری و کارایی تشخیص ناهنجاری‌های سیستمی فراهم آورد.

لی‌پنگ ما و همکاران [۵] در پژوهشی که سال ۲۰۲۵ منتشر شد، با تمرکز بر تعامل مدل‌های زبانی کوچک و بزرگ، چارچوبی تطبیقی به نام AdaptiveLog را توسعه دادند. این تحقیق با توجه به محدودیت‌های مدل‌های زبانی کوچک (مانند BERT) در دقت و مدل‌های زبانی بزرگ (مانند ChatGPT) در هزینه و کارایی، چارچوبی به نام AdaptiveLog معرفی می‌کند که همکاری میان این دو نوع مدل را ممکن می‌سازد. در این روش، لاگ‌های ساده ابتدا توسط مدل کوچک تحلیل می‌شوند و تنها در صورت عدم اطمینان، مدل بزرگ فراخوانی می‌گردد. همچنین، برای بهبود توان استدلالی مدل بزرگ، یک راهبرد جدید مبتنی بر بازیابی نمونه‌های خطاپذیر گذشته به کار گرفته شده است. نتایج آزمایش‌ها بر روی شش وظیفه‌ی مختلف تحلیل لاگ نشان داد که AdaptiveLog ضمن دستیابی به دقت بالاتر، هزینه استفاده از LLM را تا ۷۳٪ کاهش داده و در سناریوهای کم‌منبع و انتقال یادگیری نیز عملکرد مطلوبی ارائه کرده است.

نقش نوظهور مدل‌های زبانی بزرگ در حوزه‌ی تشخیص ناهنجاری و داده‌های خارج از توزیع (OOD)^۱، موضوع پژوهش جامعی است که توسط رویائو شو و کایزه دینگ [۹] در سال ۲۰۲۵ انجام شد. این مطالعه ابتدا محدودیت‌های رویکردهای سنتی را توضیح

^۱ Out Of Distribution

داده و سپس یک طبقه‌بندی جدید برای روش‌های مبتنی بر LLM ارائه می‌دهد. نویسندگان این روش‌ها را در دو دسته کلی تقسیم کرده‌اند: ۱- استفاده از LLMها برای تشخیص (با تکیه بر روش‌های مبتنی بر پرامپت و مقایسه‌ای) و ۲- استفاده از LLMها برای تولید (از جمله تولید داده کمکی، برچسب‌های شبه‌مصنوعی و توضیحات قابل فهم). مقاله علاوه بر بررسی کارهای انجام‌شده در این حوزه، مجموعه‌ای از داده‌های مرجع و معیارهای ارزیابی را معرفی می‌کند و چالش‌های مهمی همچون تفسیرپذیری، اعتمادپذیری، و پردازش داده‌های چندوجهی را مطرح می‌سازد. در نهایت، نویسندگان مسیرهای آینده‌ی پژوهش را برای توسعه‌ی سیستم‌های هوش مصنوعی مقاوم‌تر و شفاف‌تر ترسیم کرده‌اند.

بهره‌گیری از معماری تولید پاسخ مبتنی بر بازیابی (RAG) برای غلبه بر محدودیت‌های حافظه و توهم در مدل‌های زبانی، محور اصلی پژوهش پن و همکاران [۶] بوده است. آن‌ها با طراحی سیستمی تحت عنوان RAGLog، رویکردی نوین برای تشخیص ناهنجاری در لاگ‌ها بدون نیاز به داده‌های آموزشی ناهنجار (Zero-shot) ارائه کردند. در این روش، برخلاف متدهای نظارت‌شده که نیازمند حجم زیادی از داده‌های خطا هستند، تنها نمونه‌های لاگ «نرمال» در یک پایگاه داده برداری ذخیره می‌شوند. هنگام ورود یک لاگ جدید، سیستم با بازیابی نمونه‌های مشابه نرمال و ارائه آن به مدل زبانی (در اینجا GPT-۳.۵)، از مدل می‌خواهد تا وضعیت لاگ جدید را تحلیل کند. استفاده از خوشه‌بندی K-means برای انتخاب نمونه‌های نرمال متنوع، باعث شد تا RAGLog بر روی مجموعه داده‌های BGL و Thunderbird به ترتیب به امتیاز F1 برابر با ۰.۸۹ و ۰.۹۹ دست یابد که به مراتب بالاتر از روش‌های پیشین مانند LogPrompt است.

گسترش روزافزون کاربرد مدل‌های زبانی بزرگ در مدیریت سیستم‌های نرم‌افزاری، لیو و همکاران [۷] را بر آن داشت تا در سال ۲۰۲۵ با معرفی OpsEval، یک معیار جامع برای ارزیابی توانایی این مدل‌ها در حوزه عملیات فناوری اطلاعات (IT Ops) ارائه دهند. این پژوهش با انتقاد از ناکارآمدی معیارهای سنتی مانند BLEU و ROUGE در سنجش پاسخ‌های تخصصی، متریک جدیدی به نام FAE-Score (شامل روانی، دقت و شواهد) را توسعه داده است که همبستگی بسیار بالاتری (۰.۹۱) با قضاوت متخصصان انسانی دارد. مجموعه داده‌ی تدوین شده در این طرح شامل بیش از ۷۰۰۰ سوال چندگزینه‌ای و ۱۷۰۰ سوال تشریحی در ۹ زیردانه مختلف (از جمله شبکه G5 و پایگاه‌داده اوراکل) است. نتایج ارزیابی ۲۴ مدل زبانی نشان داد که اگرچه مدل‌های منبع‌بسته مانند GPT-۴ عملکرد خوبی دارند، اما مدل‌های منبع‌باز در وظایف تخصصی همچنان نیازمند تنظیم دقیق هستند و استفاده از تکنیک‌های مهندسی پرامپت مانند "زنجیره افکار" (CoT) می‌تواند دقت آن‌ها را به‌طور چشمگیری افزایش دهد.

در یکی از پژوهش‌های بنیادین سال ۲۰۱۷، مین دو و همکاران [۱۰] چارچوبی نوآورانه به نام «دیپ لاگ» را برای عیب‌یابی و تشخیص ناهنجاری ارائه کردند. در این روش، لاگ‌ها مشابه توالی زبان طبیعی در نظر گرفته شده و با استفاده از شبکه‌های حافظه بلندمدت (LSTM)^۱ الگوهای رفتاری نرمال سیستم مدل‌سازی می‌شوند. زمانی که توالی لاگ‌های جدید از این الگوها انحراف داشته باشد، به‌عنوان ناهنجاری شناسایی می‌شود. دیپ لاگ علاوه بر تشخیص ناهنجاری، امکان به‌روزرسانی تدریجی مدل در حالت آنلاین را فراهم می‌سازد تا بتواند با الگوهای جدید سازگار شود. همچنین با ساخت مدل‌های جریان کاری از لاگ‌ها، ابزار مؤثری برای عیب‌یابی و تحلیل ریشه‌ای خطاها در اختیار کاربر قرار می‌دهد. نتایج آزمایش‌ها روی مجموعه داده‌های بزرگ (HDFS و

^۱ Long Short-Term Memory

OpenStack) نشان داده است که دیپ‌لاگ دقت بالاتری نسبت به روش‌های سنتی مبتنی بر داده‌کاوی داشته و قادر به تشخیص تقریباً تمامی ناهنجاری‌ها با نرخ خطای بسیار پایین است.

گوا و همکاران [۴] در سال ۲۰۲۱ با بهره‌گیری از رویکرد خودنظارتی^۱، چارچوبی موسوم به LogBERT را توسعه دادند. این روش بر اساس مدل زبان بزرگ BERT عمل می‌کند که برای گرفتن الگوهای دنباله‌های لاگ عادی آموزش داده می‌شود. LogBERT با استفاده از دو وظیفه آموزشی جدید، پیش‌بینی کلید لاگ ماسک‌شده (برای درک زمینه دوسویه لاگ) و کمینه‌سازی حجم ابرکره^۲ (برای متمرکز کردن نمایش بردارهای لاگ‌های عادی در فضای جاسازی)، این الگوها را فرا می‌گیرد. این مکانیزم تضمین می‌کند که دنباله‌های لاگ عادی به هم نزدیک شوند، در حالی که دنباله‌های غیرعادی که از این الگوها منحرف شده‌اند، در فضای ویژگی دورتر قرار می‌گیرند و به این ترتیب، ناهنجاری‌ها شناسایی می‌شوند. نتایج آزمایش‌ها بر روی سه مجموعه داده عمومی لاگ نشان داد که LogBERT عملکرد بهتری نسبت به روش‌های پیشرفته قبلی در تشخیص ناهنجاری لاگ دارد.

توسعه چارچوبی نوین برای تشخیص همزمان ناهنجاری و تولید توضیحات علی، دستاورد پژوهش ژانگ و همکاران [۱۱] در سال ۲۰۲۵ با عنوان LLM-LADE است. این چارچوب برای غلبه بر مشکل محدودیت‌های قابلیت تفسیر در روش‌های سنتی و کمبود دانش دامنه در مدل‌های زبان بزرگ، یک معماری هماهنگ سه‌مرحله‌ای شامل «افزایش داده - تنظیم دقیق با بهره‌وری پارامتر (PEFT) - بهینه‌سازی آنلاین» را معرفی می‌کند. در مرحله افزایش داده، با استفاده از قابلیت یادگیری چندنمونه‌ای (few-shot learning) مدل GPT-۴، یک مجموعه داده غنی از جفت‌های «برچسب-علت»^۳ ایجاد می‌شود تا تلاش دستی برای برچسب‌گذاری به حداقل برسد. در مرحله تنظیم دقیق، مدل LLAMA۳-۸B با استفاده از الگوریتم LoRA و یک تابع زیان وزن‌دهی شده تنظیم می‌شود تا علاوه بر تشخیص دقیق، توضیحات علی قابل تفسیر نیز تولید کند. در نهایت، یک مکانیزم پایگاه دانش افزایش‌دهنده مبتنی بر تطبیق متن طراحی شده است تا نمونه‌های اشتباه تشخیص داده‌شده را در زمان واقعی ضبط کرده و از طریق بازخورد متخصصان انسانی، بدون نیاز به به‌روزرسانی پارامترهای مدل، به‌طور آنلاین دقت تشخیص را بهینه‌سازی کند و سازگاری با محیط‌های پویای لاگ را تضمین نماید. نتایج تجربی بر روی سه مجموعه داده محک^۴ نشان داد که LLM-LADE از الگوریتم‌های پیشرفته فعلی عملکرد بهتری دارد و توضیحات تولید شده آن از نظر اطلاع‌رسانی و خوانایی، قابلیت استفاده در سطح حرفه‌ای را دارند.

در راستای ارائه راهکاری سازگار و بدون نظارت برای لاگ‌های ناهمگن، پوسپیزنی و همکاران [۱۲] در سال ۲۰۲۵ مدلی تحت عنوان ADALog را پیشنهاد کردند. این روش، برخلاف متدهای سنتی که متکی بر تجزیه لاگ یا وابستگی‌های دقیق دنباله‌ای هستند، به جای کل دنباله، بر روی لاگ‌های منفرد و بدون ساختار کار می‌کند و روابط زمینه‌ای درون یک لاگ را استخراج می‌نماید. ADALog از یک رمزگذار دوسویه مبتنی بر ترانسفورمر که از قبل آموزش داده شده و با وظیفه مدل‌سازی زبان پوشیده (MLM)^۵ بر روی لاگ‌های عادی تنظیم دقیق^۶ شده، استفاده می‌کند. این تنظیم دقیق به مدل کمک می‌کند تا الگوهای نحوی و معنایی خاص دامنه را برای تشخیص دقیق ناهنجاری در محیط‌های پیچیده یاد بگیرد. ناهنجاری‌ها از طریق احتمالات بازسازی در سطح توکن شناسایی می‌شوند که به یک امتیاز در سطح لاگ تجمیع شده و سپس با استفاده از یک آستانه تطبیقی مبتنی بر صدک،

^۱ Self-supervised

^۲ Hypersphere Volume Minimization

^۳ Label-Cause

^۴ Benchmark

^۵ Masked Language Modeling

^۶ Fine-tuned

که تنها بر روی داده‌های عادی کالیبره شده است، تصمیم‌گیری نهایی صورت می‌گیرد. این رویکرد تضمین می‌کند که مدل به‌طور پویا با تغییرات در توزیع داده‌های عادی سازگار شده و در محیط‌های واقعی کاربرپذیری بالایی داشته باشد.

چالش حیاتی ناپایداری لاگ‌ها در سیستم‌های نرم‌افزاری در حال تکامل، محور اصلی پژوهش حدادی و همکاران [۱۳] در سال ۲۰۲۴ بود. هدف اصلی این پژوهش، ارزیابی این مسئله است که آیا مدل‌های زبان بزرگ (LLM) که بر روی مجموعه داده‌های گسترده از پیش آموزش داده شده‌اند، می‌توانند با فهم قوی از الگوها و اطلاعات زمینه‌ای خود، بر مشکل کمبود داده در تشخیص ناهنجاری بر روی نسخه‌های جدید نرم‌افزار غلبه کنند. پژوهشگران با انجام یک مقایسه تجربی بین یک مدل LLM تنظیم دقیق شده و مدل‌های جایگزین سنتی‌تر، کارایی آن‌ها را برای تشخیص ناهنجاری در شرایط لاگ‌های ناپایدار، مورد بررسی قرار دادند. نتایج این مطالعه نشان داد که مدل‌های GPT تنظیم دقیق شده می‌توانند به‌طور مؤثری عملکرد مدل‌های قبلی در تشخیص ناهنجاری لاگ را در شرایط ناپایداری داده‌ها بهبود بخشند، به ویژه هنگامی که داده‌های آموزشی کافی برای نسخه‌های جدید نرم‌افزار در دسترس نیست. این امر به دلیل توانایی LLM‌ها در درک عمیق‌تر روابط متنی و الگوهای متنوعی است که در طول پیش‌آموزش فرا گرفته‌اند.

کاوش در زمینه مهندسی پرامپت با هدف تحلیل لاگ به صورت تفسیرپذیر و بدون نیاز به داده‌های آموزشی قبلی، رویکردی است که لیو و همکاران [۸] در سال ۲۰۲۴ اتخاذ کردند. آن‌ها برای اولین بار یک کتابخانه استراتژی پرامپت ساختند که به‌طور خاص برای وظایف مختلف تحلیل لاگ، شامل تجزیه لاگ^۱، تشخیص ناهنجاری^۲ و تولید پاسخ^۳، طراحی شده است. این استراتژی‌های پرامپت، دانش ضمنی LLM‌ها در مورد لاگ‌ها را استخراج کرده و نتایج تحلیلی را در یک قالب ساختاریافته و قابل درک تولید می‌کنند. نتایج تجربی بر روی شش مجموعه داده لاگ عمومی و سه مدل LLM (شامل LLaMA^{۲-۷B}) نشان داد که رویکرد مبتنی بر مهندسی پرامپت، در مقایسه با روش‌های سنتی که به حجم زیادی از داده‌های برچسب‌گذاری شده یا تنظیم دقیق نیاز دارند، می‌تواند نتایج تجزیه و تحلیل لاگ با کیفیت بالا را در سناریوی صفر شات به دست آورد، که کارایی و قابلیت تعمیم را در محیط‌های لاگ متغیر و پویای امروزی به‌طور قابل توجهی بهبود می‌بخشد.

لیم و همکاران [۱۴] در سال ۲۰۲۵ با تمرکز بر مسئله هزینه‌های گزاف تنظیم دقیق، به بررسی انطباق مدل‌های زبانی بزرگ برای تشخیص ناهنجاری لاگ پرداختند. پژوهشگران استفاده از تکنیک‌های تنظیم دقیق با بهره‌وری پارامتر (PEFT)، به‌ویژه LoRA (Low-Rank Adaptation) و ReFT^۴ را برای انطباق مدل‌های مختلف از جمله GPT-۲، ROBERTa و Llama-۳ برای LAD بررسی کردند. هدف این کار، پر کردن شکاف تحقیقاتی موجود و ارائه بینش‌های مهم در مورد پیاده‌سازی مؤثر LLM‌ها در این زمینه است. آزمایش‌های جامع بر روی چهار مجموعه داده عمومی لاگ، کارایی، پایداری، بهره‌وری نمونه، مقاومت در برابر لاگ‌های ناپایدار و قابلیت تعمیم بین مجموعه داده‌ای این روش‌های مبتنی بر PEFT را اثبات کرد و مسیرهای جدیدی را برای استفاده عملی از LLM‌ها در تشخیص ناهنجاری سیستم‌ها گشود.

با معرفی چارچوب LogGPT در سال ۲۰۲۳، هان و همکاران [۱۵] تلاشی برای پر کردن شکاف میان مدل‌سازی زبان و تشخیص ناهنجاری انجام دادند. این روش با هدف پر کردن شکاف بین مدل‌سازی زبان و تشخیص ناهنجاری، ابتدا مدل GPT را برای پیش‌بینی ورودی لاگ بعدی بر اساس دنباله پیشین، آموزش می‌دهد. برای ارتقاء بیشتر عملکرد، نویسندگان یک استراتژی یادگیری

^۱ Log Parsing

^۲ Anomaly Detection

^۳ Response Generation

^۴ Representation Fine-tuning

تقویتی^۱ نوین را برای تنظیم دقیق مدل، به طور خاص برای وظیفه تشخیص ناهنجاری لاگ، معرفی کردند. این رویکرد تضمین می کند که هدف آموزشی مدل به طور مستقیم با هدف نهایی تشخیص ناهنجاری همسو باشد. نتایج آزمایش ها بر روی سه مجموعه داده عمومی نشان داد که LogGPT به طور قابل توجهی از روش های پیشرفته موجود در تشخیص ناهنجاری لاگ، عملکرد بهتری دارد.

لی و ژانگ [۱۶] در سال ۲۰۲۳ با تمرکز ویژه بر گام نخست تحلیل خود کار یعنی تجزیه لاگ، روشی به نام LogPPT را پیشنهاد دادند. این روش برای غلبه بر مشکل نادیده گرفتن معنای معنایی^۲ لاگ ها و نیاز به دانش خاص دامنه در روش های سنتی، از یادگیری چند نمونه ای مبتنی بر پرامپت استفاده می کند. LogPPT از طریق یک متد تنظیم پرامپت نوین، قادر است الگوهای لاگ ها را بر اساس تنها تعداد کمی از داده های لاگ بر چسب گذاری شده تشخیص دهد. علاوه بر این، یک الگوریتم نمونه گیری تصادفی تطبیقی برای انتخاب یک مجموعه آموزشی کوچک اما متنوع، طراحی شده است. نتایج آزمایش های گسترده بر روی ۱۶ مجموعه داده عمومی لاگ، نشان داد که LogPPT یک روش مؤثر و کارآمد برای استخراج الگوهای صحیح و پارامترها است.

تسهیل انتقال یادگیری در سیستم های نرم افزاری جدید، هدفی بود که سویی و همکاران [۱۷] در سال ۲۰۲۵ با ارائه چارچوب LogSynergy دنبال کردند. این چارچوب برای رفع مشکلاتی مانند تفاوت های نحوی لاگ ها و کمبود دانش سیستم-خاص در روش های سنتی انتقال، از مدل های زبان بزرگ (LLM) استفاده می کند. LogSynergy شامل دو بخش اصلی است: (۱) یک مکانیسم استخراج الگو معنایی لاگ مبتنی بر LLM برای غلبه بر تفاوت های نحوی و ساختاری لاگ ها بین سیستم های مبدأ و مقصد، و (۲) یک ماژول شبکه های گرافی با توجه متقابل^۳ برای مدل سازی وابستگی های متنی بین الگوهای استخراج شده و جذب دانش سیستم-خاص. این رویکرد امکان انتقال دانش از سیستم های بالغ با داده های فراوان به سیستم های جدید با داده های محدود را فراهم می آورد. نتایج تجربی بر روی مجموعه های داده متعدد نشان داد که LogSynergy عملکرد مدل های تشخیص ناهنجاری لاگ را در سیستم های جدید به طور چشمگیری بهبود می بخشد.

در تلاشی برای توسعه منابع متن باز، ژو و همکاران [۱۸] در سال ۲۰۲۴ به معرفی مدل YuLan، یک سری مدل زبان بزرگ با ۱۲ میلیارد پارامتر پرداختند. هدف این مقاله، رفع کمبود جزئیات آموزش منتشر شده در مورد بسیاری از مدل های منبع باز و تسهیل تحقیقات بیشتر در این زمینه بود. مدل پایه YuLan بر روی تقریباً ۱.۷ تریلیون توکن از یک مجموعه داده متنوع شامل متون انگلیسی، چینی، و چندزبانه آموزش اولیه^۴ داده شده است. نویسندگان یک فرآیند پیش آموزش سه مرحله ای طراحی کردند و جزئیات دقیق تنظیمات آموزشی، از جمله پیکربندی سخت افزاری و تکنیک های بهینه سازی، را به اشتراک گذاشتند. این مدل، که شامل نسخه های پایه و دستورالعمل محور^۵ است، نتایج رقابتی را در ارزیابی های گسترده بر روی معیارهای مختلف، از جمله درک مطلب، دانش عمومی، و حل مسائل ریاضی (مانند MMLU، C-Eval، و GSM^۸K)، در مقایسه با سایر مدل های منبع باز هم اندازه، نشان داد. این پژوهش یک منبع ارزشمند برای جامعه تحقیقاتی LLM به شمار می رود.

^۱ Reinforcement Learning

^۲ Semantic Meaning

^۳ Cross-Attention Graph Networks

^۴ Pre-trained

^۵ Instruction-tuned

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
مدل‌های زبانی بزرگ برای تشخیص ناهنجاری و داده‌های خارج از توزیع	پن یان، بینگ‌لی چن، زینگ‌وی چن، ژو یانگ وو، چینگ‌سونگ ون	۲۰۲۵	استفاده از مدل‌های زبانی بزرگ (مانند GPT و LLaMA) برای تشخیص ناهنجاری و داده‌های خارج از توزیع با استفاده از منطق استدلال زنجیره‌ای و امتیازدهی احتمالاتی	چند مجموعه داده استاندارد از حوزه‌های مختلف (متن، تصویر، و لاگ)	عملکرد بالا در تشخیص داده‌های غیرمعمول بدون نیاز به داده برچسب‌خورده، تعمیم‌پذیری بالا در حوزه‌های مختلف، تفسیرپذیری مناسب	هزینه محاسباتی بسیار زیاد، دشواری در تنظیم پارامترها، حساسیت به prompt و نوع سؤال ورودی
مدل‌های زبانی بزرگ برای تشخیص ناهنجاری و داده‌های خارج از توزیع	رویانو شو، کایزه دینگ	۲۰۲۵	مرور پژوهش‌های استفاده از مدل‌های زبانی بزرگ (مانند GPT، LLaMA، CLIP) در تشخیص ناهنجاری و داده‌های خارج از توزیع؛ دسته‌بندی روش‌ها به دو رویکرد «LLM برای تشخیص» و «LLM برای تولید داده و توضیح»	مجموعه داده‌های چندرسانه‌ای شامل تصویر (MVTEC-AD، ImageNet)، ویدیو (UCF-101، Crime)، متن (NG۲۰، CLINC۱۵۰)، و سری زمانی (ODDS، Yahoo)	پوشش جامع حوزه‌ها، معرفی طبقه‌بندی جدید روش‌ها، تبیین کاربردهای چندرسانه‌ای، و بررسی چالش‌های آینده	مطالعه مروری است (فاقد روش تجربی جدید)، جزئیات ارزیابی محدود، و برخی روش‌های جدید پوشش داده نشده‌اند
تشخیص ناهنجاری تطبیقی و بدون نظارت در لاگ‌ها با مدل زبانی ماسک‌شده مبتنی بر خودتوجهی	پرزمیک پُسیشنی، وویچک مورمول، کارولینا شایندلر، سانچو کومار	۲۰۲۵	استفاده از مدل DistilBERT برای یادگیری بدون نظارت از لاگ‌های خام و تشخیص ناهنجاری با روش Masked Language Modeling و آستانه‌گذاری تطبیقی	Spirit، Thunderbird، BGL	- بدون نیاز به داده برچسب‌خورده یا پارس لاگ - عملکرد بالا در مجموعه داده‌های متنوع (F۱ تا ۰.۹۵) - قابلیت تطبیق با تغییرات در ساختار لاگ	- هزینه محاسباتی بالا در آموزش و استنتاج - مناسب‌تر برای تحلیل آفلاین نسبت به تشخیص بلادرنگ - نیاز به منابع قوی برای پردازش داده‌های حجیم
بکارگیری مدل‌های زبانی بزرگ برای تشخیص ناهنجاری لاگ با تنظیم کارآمد پارامترها	ینگ فو لیم، جیاون جو، گوانسونگ پانگ	۲۰۲۵	استفاده از روش‌های تنظیم پارامتر کارآمد (PEFT) شامل LoRA و ReFT برای انطباق مدل‌های زبانی بزرگ (GPT-۲، RoBERTa، LLaMA-۳) با تشخیص ناهنجاری لاگ‌ها به صورت نظارت‌شده.	چهار دیتاست عمومی لاگ: Spirit، BGL، HDF، Thunderbird (۸۰٪ آموزش، ۲۰٪ تست).	- عملکرد بالا در دقت و F۱ نسبت به روش‌های کلاسیک (DeepLog، LogBERT، LogAnomaly) - کاهش نیاز به منابع محاسباتی با حفظ کارایی بالا - روش ReFT پایدار، کارایی نمونه‌ای و تعمیم‌پذیری بهتری دارد - قابلیت استفاده روی مدل‌های مختلف و مقیاس‌پذیری مناسب	- روش ReFT زمان آموزش بالاتری نسبت به LoRA دارد - حساسیت بیشتر ReFT به تغییرات واژگان (لاگ‌های ناپایدار) - محدودیت تعمیم به دیتاست‌های کاملاً جدید (F۱ حدود ۰.۵ در تست بین دیتاستی)
یک مجموعه معیار جامع برای ارزیابی قابلیت مدل‌های زبان بزرگ در حوزه عملیات فناوری اطلاعات	یوخه لیو و چانگهوا پی، مینگزه سان	۲۰۲۵	طراحی معیار جامع OpsEval برای ارزیابی LLM‌ها در حوزه Ops. معرفی معیار ارزیابی جدید -FAE- Score (شامل روانی، دقت، شواهد) که همبستگی بالایی با قضاوت متخصصان دارد. ارزیابی بیش از ۲۴ مدل زبان بزرگ با استفاده از تکنیک‌های CoT و ICL.	مجموعه داده دوزبانه و چندوظیفه‌ای شامل ۹۰۷۰ پرسش (۷۳۳۴ چهارگزینه‌ای و ۱۷۳۶ تشریحی). داده‌ها از منابع تخصصی و گواهینامه‌های IT Ops در ۹ زیردسته مختلف (مانند G5 و پایگاه داده اوراکل) جمع‌آوری شده‌اند.	اولین مجموعه معیار جامع و دوزبانه در حوزه عملیات IT -FAE- Score عملکرد مدل را در کارهای تخصصی بسیار بهتر از معیارهای سنتی مانند BLEU منعکس می‌کند؛ کمک به شناسایی نقاط ضعف و قوت مدل‌ها در زمینه‌های تخصصی Ops.	اعتبار خارجی محدود به زیردسته‌های انتخابی در مجموعه داده است؛ عملکرد نهایی متأثر از پارامترهای پیاده‌سازی مدل و پرامپت‌های (Prompts) مورد استفاده است؛ ملاحظات حفظ حریم خصوصی مانع از استفاده گسترده از داده‌های واقعی شرکت‌ها می‌شود.

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
تشخیص ناهنجاری مبتنی بر لاگ با استفاده از مدل‌های زبانی بزرگ	وی گوان، جیان کائو، شی‌یو چیان، جیان‌چی گائو، چون اوینگ	۲۰۲۴	ترکیب BERT و LLaMA برای تشخیص ناهنجاری در لاگ‌ها با آموزش سه مرحله‌ای	Liberty، BGL، HDF، Thunderbird	دقت بالا، بدون نیاز به parser، درک معناشناسی لاگ‌ها	هزینه محاسباتی زیاد، نیاز به داده برچسب‌خورده
ارتقای کارایی در تجزیه‌ی لاگ با استفاده از مدل‌های زبانی بزرگ	آوشیانو ژونگ، دینگ‌یانو مو، گویانگ لیو، جینیو لیو، چینگ‌دا لو، چی ژو، جی شنگ وو،	۲۰۲۴	ترکیب LLM با درخت پیشوندی (Prefix Tree) برای استخراج قالب لاگ به صورت خودکار و کاهش تعداد فراخوانی مدل	LogPub و Loghub-۲k	- دقت بسیار بالا در شناسایی الگوها (F۱ تا ۹۰٪) - نیاز نداشتن به داده برچسب‌خورده	- مصرف زمان و منابع زیاد در مدل‌های بزرگ مثل GPT-۴ - نیاز به تنظیم سطح گرانولاریتی با مداخله انسانی

کوانتینگ لی، چینگسونگ ون			کاهش چشمگیر هزینه فراخوانی LLM (تنها ۲۷۲ بار برای میلیون‌ها لاگ) - سازگار با انواع فرمت‌های لاگ و مقیاس‌پذیر	- عملکرد وابسته به کیفیت مدل زبانی مورد استفاده
چارچوب تحلیلی تطبیقی لاگ با همکاری مدل‌های زبانی بزرگ و کوچک	دینگ‌یانو مو، جیان چن، یینگ‌لی چن، چون‌جون شیا، لیانگ چن، ژیاوجیانگ هوانگ، زی‌یونگ شو	۲۰۲۴	ترکیب LLM (برای درک معنانشناسی) و مدل کوچک‌تر تطبیقی (برای تحلیل سریع) با انتخاب پویا بین مدل‌ها بر اساس پیچیدگی لاگ	BGL, HDFS, LogHub
تشخیص ناهنجاری لاگ با استفاده از تولید تقویت‌شده	جانائان پن، سوی لیانگ وونگ، ییدی یوآن	۲۰۲۴	استفاده از معماری تولید تقویت‌شده بازایی (RAG) مبتنی بر مدل‌های زبان بزرگ ذخیره لاگ‌های «نرمال» در پایگاه داده برداری و بازایی نمونه‌های مشابه برای تحلیل لاگ ورودی توسط LLM (روش Zero-shot) استفاده از خوشه‌بندی K-means برای انتخاب نمونه‌های بازایی متنوع و کارآمد.	حل مشکل اساسی نبود یا کمبود نمونه‌های لاگ ناهنجار برای آموزش مدل‌های نظارت‌شده؛ غلبه بر چالش‌های انسانی ناشی از حجم، تنوع و سرعت بالای لاگ‌ها با استفاده از هوش مصنوعی؛ دستیابی به عملکرد بالا در تشخیص ناهنجاری در سناریوی Zero-shot.
تشخیص ناهنجاری داده‌کارا بر روی لاگ‌های ناپایدار با ترکیب مدل‌های زبانی بزرگ و یادگیری ماشین	چون‌بی ژو، چن‌بی لی، چون‌یوان وو، جی‌بی لی، چون‌فنگ یو	۲۰۲۴	ترکیب مدل زبانی بزرگ (LLM) با مدل یادگیری ماشین سبک برای تشخیص ناهنجاری در لاگ‌های ناپایدار با داده کم	Spirit, BGL, HDFS
یادگیری انتقالی مبتنی بر مدل‌های زبانی بزرگ برای تشخیص ناهنجاری در سامانه‌های نرم‌افزاری جدید	یو کینگ‌یانگ، دینگ‌یانو مو، چون اویانگ، لی‌چوان‌گو	۲۰۲۴	استفاده از یادگیری انتقالی با LLM برای سازگاری مدل تشخیص ناهنجاری با سامانه‌های جدید بدون نیاز به بازآموزی کامل	Spirit, BGL, HDFS
تحلیل برخط و قابل تفسیر لاگ‌ها با استفاده از مدل‌های زبانی بزرگ و راهبردهای پرامپت	شی‌یو چیان، چون اویانگ، جیان‌چی گائو، وی گوان	۲۰۲۴	استفاده از مدل‌های زبانی بزرگ (LLM) با طراحی پرامپت‌های پویا برای تحلیل بلادرنگ و تفسیرپذیر لاگ‌ها	Thunderbird, BGL, HDFS
			- نیاز کمتر به داده آموزشی - عملکرد پایدار در لاگ‌های ناپایدار - دقت بالا حتی در داده‌های محدود	- نیاز به تنظیم دقیق بین LLM و مدل سبک - پیچیدگی در هماهنگی مدل‌ها - هزینه زیاد در مرحله آموزش اولیه
			- کاهش هزینه و زمان آموزش - عملکرد قوی در دامنه‌های جدید - تعمیم‌پذیری بالا	- حساسیت به تفاوت دامنه داده‌ها - کاهش دقت در داده‌های بسیار متفاوت - نیاز به تنظیم دقیق پرامپت‌ها
			- تفسیرپذیری بالا نسبت به روش‌های مبتنی بر یادگیری عمیق - توانایی تحلیل برخط و بلادرنگ - دقت و انعطاف بالا در محیط‌های متغیر	- هزینه محاسباتی بالا برای LLM - نیاز به طراحی دقیق پرامپت‌ها - دشواری در کنترل خروجی مدل در شرایط نویزی

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
مدل زبانی بزرگ متن‌باز	یوتانو جو و همکاران	۲۰۲۴	طراحی و آموزش یک مدل زبانی بزرگ (LLM) متن‌باز با ۱۲ میلیارد پارامتر، شامل سه مرحله‌ی آموزشی: ۱. پیش‌آموزش (Pre-training) روی ۱.۷ تریلیون توکن از داده‌های چندزبانه ۲. تنظیم با دستور (Instruction-tuning) با ۴۲ میلیون داده مصنوعی آموزشی ۳. هم‌ترازسازی انسانی (Human Alignment) با ۲۰۰ هزار داده برچسب‌خورده انسانی	ترکیبی از منابع متنوع شامل: وب‌سایت‌ها، کتاب‌ها، اخبار، مقالات علمی، ویکی‌پدیا، کدهای برنامه‌نویسی (GitHub)، متون حقوقی، پنت‌ها و ارزیابی‌های آموزشی. مجموعاً حدود ۱.۷ تریلیون توکن.	- مدل کاملاً متن‌باز با کد و وزن‌ها در GitHub - پشتیبانی از زبان انگلیسی و چینی و داده‌های چندزبانه - عملکرد قابل مقایسه با مدل‌های بزرگ معروف مثل LLaMA۲ و Baichuan - بهبود در وظایف منطقی و ریاضی با استفاده از روش یادگیری مرحله‌به‌مرحله (Curriculum Learning) - طراحی tokenizer بهینه برای چینی و انگلیسی	- مصرف بالای منابع محاسباتی (نیاز به ۹۶ عدد GPU از نوع A۸۰۰) - عملکرد نسبتاً ضعیف‌تر در وظایف مربوط به دانش واقعی (Factual Knowledge) نسبت به مدل‌های بزرگ‌تر مثل GPT-۴ - داده‌های آموزشی محدود در برخی زبان‌های غیرچینی/انگلیسی - نبود fine-tuning گسترده برای کاربردهای تخصصی
تشخیص ناهنجاری در لاگ‌ها با استفاده از مدل GPT	شیاو هان، شوهان یوان، محمد ترابالسی	۲۰۲۳	استفاده از مدل GPT با یادگیری تقویتی و معیار Top-K برای تشخیص ناهنجاری در توالی لاگ‌ها	Thunderbird, BGL, HDFS	- دقت بسیار بالا (F۱ تا ۹۸٪) - توانایی یادگیری وابستگی بلندمدت در لاگ‌ها - بهبود نسبت به LogBERT و DeepLog	- هزینه محاسباتی زیاد به دلیل GPT - نیاز به تنظیم دقیق پارامتر K - زمان آموزش طولانی
تجزیه لاگ با استفاده از یادگیری کم‌نمونه مبتنی بر پرامپت	ژی‌لیانگ ژانگ، دینگ‌یانو مو، چی ژو، جیان چن، چون اویانگ، لی چوآن گو	۲۰۲۳	استفاده از یادگیری کم‌نمونه (Few-shot) با پرامپت‌گذاری در LLM برای شناسایی و استخراج الگوهای لاگ	Spirit, BGL, HDFS	- کاهش نیاز به داده آموزشی زیاد - دقت بالا در قالب‌بندی لاگ‌های جدید - سازگاری با ساختارهای متنوع لاگ	- حساسیت به طراحی پرامپت - کارایی پایین در لاگ‌های بسیار پیچیده - هزینه زمانی زیاد در تنظیم مدل
تشخیص ناهنجاری لاگ‌های سیستمی بر اساس مدل زبانی از پیش آموزش‌دیده	س۱۴ ونگ چن، های لیائو	۲۰۲۲	استفاده از مدل ازپیش‌آموزش‌دیده‌ی BERT با ریزتنظیم برای شناسایی ناهنجاری در توالی لاگ‌ها	BGL, HDFS	دقت بسیار بالا (F۱ تا ۹۹.۴٪)، توانایی درک معناشناسی و وابستگی توالی رویدادها، پایداری در اندازه داده‌های مختلف	نیاز به برچسب‌گذاری داده‌ها، هزینه محاسباتی بالا، وابستگی به مرحله‌ی پیش‌پردازش Drain
تشخیص ناهنجاری در لاگ‌ها با استفاده از مدل BERT	هایشوان گو، شوهان یوان، شین تائو وو	۲۰۲۱	استفاده از مدل BERT با دو وظیفه خودنظارتی (پیش‌بینی کلیدهای ماسک‌شده و کمینه‌سازی حجم کره) برای یادگیری الگوهای لاگ نرمال و تشخیص ناهنجاری‌ها	Thunderbird, BGL, HDFS	- دقت بسیار بالا نسبت به روش‌های RNN - عدم نیاز به داده برچسب‌خورده - درک دوطرفه از متن لاگ	- هزینه محاسباتی بالا - نیاز به تنظیم دقیق هاپرپارامترها - حساس به نسبت ماسک در داده‌ها
تشخیص و عیب‌یابی ناهنجاری از لاگ‌های سیستمی با استفاده از یادگیری عمیق	مین دو، ژیهان ژو، فی شو، جان ژو، چنگ کی ژانگ، پنگجی رن	۲۰۱۷	استفاده از مدل LSTM برای تشخیص خودکار ناهنجاری‌ها از توالی لاگ‌های سیستم بدون نیاز به ویژگی‌سازی دستی	HDFS	- حذف نیاز به مهندسی ویژگی دستی - عملکرد بهتر از روش‌های سنتی مبتنی بر قانون - توانایی یادگیری الگوهای زمانی در لاگ‌ها	- نیاز به داده برچسب‌خورده برای آموزش - کاهش دقت در داده‌های نویزی یا متنوع - عدم تفسیرپذیری کامل نتایج

۴- جنبه جدید بودن و نوآوری در پژوهش

این پژوهش با هدف بهبود تشخیص ناهنجاری‌های لاگ‌های سیستمی از طریق بهره‌گیری از مدل‌های زبانی بزرگ پیش‌آموزش‌دیده همچون GPT-۵ Nano طراحی شده است. برخلاف رویکردهای سنتی و همچنین روش‌های مبتنی بر تنظیم دقیق که معمولاً متکی بر پیش‌آموزش مدل‌ها، بازآموزی با داده‌های برجسب‌گذاری شده و صرف هزینه‌های محاسباتی بالا هستند، در این تحقیق نشان داده می‌شود که مهندسی پرامپت بهینه می‌تواند بدون نیاز به داده‌های برجسب‌گذاری شده، ناهنجاری‌ها را با دقت بالاتر و سرعت بیشتر شناسایی کند.

جایگزینی فرآیندهای سنگین آموزش مدل با مهندسی پرامپت، علاوه بر کاهش چشمگیر هزینه‌های برجسب‌گذاری و محاسباتی، موجب افزایش قابل توجه سرعت پردازش و تشخیص خطا شده و امکان نظارت سریع‌تر و نزدیک به بلادرنگ را در محیط‌های واقعی فراهم می‌سازد. این ویژگی، پژوهش حاضر را از بسیاری از روش‌های پیشین که با کندی اجرا و پیچیدگی عملیاتی مواجه هستند، متمایز می‌کند.

از منظر دقت، رویکرد پیشنهادی صرفاً به الگوهای آماری یا ویژگی‌های سطحی لاگ‌ها متکی نیست، بلکه با بهره‌گیری از درک معنایی عمیق مدل‌های زبانی بزرگ، قادر است ناهنجاری‌های پیچیده، پنهان و وابسته به زمینه را با دقت بسیار بالاتری شناسایی کرده و در عین حال نرخ هشدارهای کاذب را کاهش دهد. افزون بر این، ترکیب همزمان اطلاعات معنایی و ترتیبی لاگ‌ها در این چارچوب، امکان بهبود شناسایی هر دو نوع ناهنجاری‌های نقطه‌ای و شرطی را فراهم کرده و تحلیل جامع‌تری از رفتار سیستم ارائه می‌دهد.

افزون بر موارد فوق، پژوهش حاضر یک چارچوب سیستماتیک برای طراحی، ارزیابی و بهینه‌سازی پرامپت‌ها در حوزه تشخیص ناهنجاری معرفی می‌کند. این چارچوب به گونه‌ای طراحی شده است که بتواند تفاوت‌های ساختاری میان انواع مختلف لاگ‌های سیستمی را پوشش داده و قابلیت تطبیق‌پذیری مدل‌های زبانی را در سناریوهای متنوع عملیاتی و صنعتی تضمین کند. در نتیجه، فرآیند تحلیل لاگ‌ها تا حد زیادی خودکار شده و نیاز به مداخله انسانی در شناسایی و تفسیر ناهنجاری‌ها به‌طور محسوسی کاهش می‌یابد.

پژوهش حاضر نوآوری خود را از چند جنبه متمایز می‌سازد:

- به کارگیری مهندسی پرامپت بهینه به عنوان جایگزینی کارآمد برای آموزش و Fine-tuning در تشخیص ناهنجاری‌ها
- ترکیب همزمان اطلاعات معنایی و ترتیبی لاگ‌ها برای شناسایی دقیق‌تر ناهنجاری‌های نقطه‌ای و شرطی
- افزایش هم‌زمان سرعت و دقت در تشخیص خطا و ناهنجاری نسبت به روش‌های پیشین
- کاهش وابستگی به مداخله انسانی در تحلیل و پایش لاگ‌های سیستمی

در مجموع، این پژوهش با بهره‌گیری از مدل‌های زبانی بزرگ و مهندسی پرامپت، رویکردی نوین، سریع، دقیق و مقرون به صرفه برای تشخیص ناهنجاری‌های سیستمی ارائه می‌دهد؛ رویکردی که می‌تواند شکاف‌های موجود در ادبیات پیشین را پوشش داده و گامی مؤثر در جهت توسعه نسل جدید سیستم‌های پایش و نظارت هوشمند در محیط‌های صنعتی و تجاری بردارد.

۵- اهداف مشخص پژوهش

الف) هدف اصلی:

طراحی و ارائه یک چارچوب تشخیص ناهنجاری در لاگ‌های سیستمی مبتنی بر مهندسی پرامپت بهینه و مدل‌های زبانی بزرگ، با هدف دستیابی هم‌زمان به دقت و سرعت بالا و حذف نیاز به فرآیند پرهزینه تنظیم دقیق و داده‌های برجسب‌گذاری شده.

ب) اهداف فرعی:

۱. طراحی استراتژی‌های پرامپت‌دهی ساختاریافته برای استخراج هم‌زمان ویژگی‌های معنایی و ترتیبی از لاگ‌های سیستمی.
۲. ارزیابی و سنجش میزان افزایش سرعت پردازش و تشخیص خطا در روش پیشنهادی نسبت به روش‌های مبتنی بر تنظیم دقیق.
۳. تحلیل و ارزیابی دقت تشخیص ناهنجاری‌های پیچیده و شرطی در روش پیشنهادی در مقایسه با روش‌های سنتی و آماری.
۴. کاهش وابستگی به داده‌های آموزشی برجسب‌دار و بررسی کارایی مدل در شرایط محدودیت داده.
۵. کاهش نیاز به مداخله انسانی و دانش خبره در فرآیند تحلیل و تفسیر لاگ‌ها.

۶- در صورت داشتن هدف کاربردی نام بهره‌وران (اعم سازمان‌ها، صنایع و یا گروه بهره‌وران) ذکر شود.

با توجه به ماهیت تحقیق، بهره‌وران اصلی و محل‌های بالقوه اجرای مطالعه موردی عبارت‌اند از:

۱- مراکز داده و ارائه‌دهندگان سرویس‌های ابری (Cloud Providers & Data Centers)

- شرکت‌های ارائه‌دهنده سرویس‌های ابری مانند AWS، Azure، Google Cloud یا نمونه‌های داخلی.
- مراکز داده سازمانی که نیازمند مانیتورینگ بلادرنگ و تشخیص ناهنجاری برای حفظ پایداری سرویس‌ها هستند.

۲- صنایع مالی و بانکی

- بانک‌ها و مؤسسات مالی که لاگ‌های گسترده‌ای از تراکنش‌ها، درخواست‌های کاربران و سامانه‌های امنیتی تولید می‌کنند.
- بهره‌گیری از این تحقیق می‌تواند به کاهش ریسک حملات سایبری و جلوگیری از اختلال در سرویس‌های مالی منجر شود.

۳- صنایع مخابراتی و شبکه‌ای

- اپراتورهای تلفن همراه و شرکت‌های ارائه‌دهنده اینترنت^۱ که نیازمند تحلیل سریع لاگ‌های حجیم شبکه برای کشف اختلالات و حملات هستند.

^۱ Internet Service Provider

۴- بیمارستان‌ها و صنایع سلامت دیجیتال

- سیستم‌های سلامت الکترونیک^۱ و بیمارستان‌های هوشمند که به دلیل حساسیت بالای داده‌ها، نیاز به پایش دقیق و جلوگیری از خطاهای سیستمی دارند.

۵- سازمان‌های دولتی و امنیت سایبری

- نهادهای مسئول امنیت شبکه و زیرساخت‌های حیاتی کشور.
- استفاده از چارچوب پیشنهادی می‌تواند در تشخیص نفوذ^۲ و پایش امنیتی کاربرد داشته باشد.

۶- شرکت‌های فناوری اطلاعات و توسعه‌دهندگان نرم‌افزار

- تیم‌های DevOps و SRE^۳ که به ابزارهای خودکار برای تحلیل لاگ و کاهش زمان شناسایی و رفع خطا نیازمند هستند.

۷- محیط‌های آموزشی و پژوهشی

- دانشگاه‌ها و مراکز تحقیقاتی فعال در حوزه هوش مصنوعی، امنیت سایبری و سیستم‌های توزیع شده که می‌توانند از نتایج پژوهش برای توسعه تحقیقات آینده بهره بگیرند.
- بهره‌وران اصلی این تحقیق شامل مراکز داده، بانک‌ها و صنایع مالی، اپراتورهای مخابراتی، بیمارستان‌ها و صنایع سلامت، سازمان‌های امنیت سایبری، شرکت‌های فناوری اطلاعات و همچنین دانشگاه‌ها و مراکز تحقیقاتی هستند.

۷- سؤال‌ها یا فرضیه‌های پژوهش

سؤالات پژوهش

۱. آیا استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش‌آموزش دیده مانند GPT-۵ Nano و LLaMA۳-۳۳B می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد؟
۲. آیا ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش‌آموزش دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود؟
۳. آیا استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد؟
۴. آیا استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود یابد؟

^۱ E-Health

^۲ Intrusion Detection

^۳ Site Reliability Engineering

۱. استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش آموزش دیده مانند GPT-۵ Nano و LLaMA۳-۳۳B می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد.
۲. ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش آموزش دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود.
۳. استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد.
۴. استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود می‌یابد.

۸- تعاریف نظری و عملیاتی متغیرها/ پدیده مورد مطالعه

۱- ناهنجاری (Anomaly)

- مفهومی: رخدادی که با الگوهای عادی و انتظاری سیستم مطابقت ندارد و می‌تواند نشان‌دهنده خطا، حمله امنیتی، یا اختلال عملکرد باشد. [۱]
- عملیاتی: هر پیام یا توالی پیام در لاگ سیستمی که توسط مدل به‌عنوان غیرعادی تشخیص داده شود. در این تحقیق ناهنجاری‌ها با معیارهای Recall، Precision و F۱ سنجیده می‌شوند.

۲- لاگ سیستمی (System Log)

- مفهومی: فایل یا جریان داده‌ای که شامل پیام‌های متنی و رویدادهای ثبت‌شده از سوی نرم‌افزار، سخت‌افزار یا سیستم عامل است. [۱]
- عملیاتی: مجموعه‌ای از رکوردهای متنی (دارای زمان، شناسه و محتوای رویداد) که در آزمایش‌ها برای آموزش و ارزیابی مدل مورد استفاده قرار می‌گیرند.

۳- مدل‌های زبانی بزرگ (Large Language Models - LLMs)

- مفهومی: شبکه‌های عصبی عمیق مبتنی بر معماری ترنسفورمر که روی حجم عظیمی از داده‌های متنی آموزش دیده‌اند و قادر به درک و تولید زبان طبیعی هستند. [۱۸]
- عملیاتی: در این پژوهش مدل‌هایی مانند GPT-۵ Nano، LLaMA۳-۳۳B برای تحلیل لاگ‌های سیستمی و تشخیص ناهنجاری‌ها استفاده خواهند شد.

۴- تحلیل معنایی (Semantic Analysis)

- مفهومی: فرآیند استخراج و درک معنا از متن، فراتر از سطح نحوی و ظاهری. [۱۶]
- عملیاتی: توانایی مدل در شناسایی ناهنجاری‌هایی که ممکن است از نظر ساختاری مشابه لاگ‌های عادی باشند، اما معنای متفاوتی دارند.

۵- تنظیم پرامپت (Prompt Tuning)

- مفهومی: روشی برای بهینه‌سازی استفاده از LLMها بدون تغییر وزن‌های اصلی مدل، از طریق طراحی و تنظیم ورودی‌ها (پرامپت‌ها). [۸]
- عملیاتی: در این تحقیق به‌عنوان یکی از استراتژی‌های بهینه‌سازی مدل‌ها بررسی و با تنظیم دقیق مقایسه خواهد شد.

۹- روش شناسی پژوهش:

الف - شرح کامل روش تحقیق بر حسب هدف، نوع داده‌ها و نحوه اجراء (شامل مواد، تجهیزات و استانداردهای مورد استفاده در قالب مراحل اجرایی تحقیق به تفکیک):

۱- نوع و هدف تحقیق

این تحقیق از نظر هدف، کاربردی - توسعه‌ای محسوب می‌شود، چراکه به دنبال طراحی و پیاده‌سازی یک چارچوب عملی برای تشخیص ناهنجاری‌ها در لاگ‌های سیستمی بر مبنای مدل‌های زبانی بزرگ (LLMs) است.

از نظر ماهیت و روش، تحقیق به صورت تحلیلی-تطبیقی و آزمایشگاهی انجام خواهد شد. در این راستا:

- داده‌های واقعی (لاگ‌های سیستمی) جمع‌آوری می‌شوند،
- روش‌های مختلف مبتنی بر LLM و روش‌های سنتی مقایسه می‌گردند،
- و چارچوب پیشنهادی از نظر دقت، مقیاس‌پذیری و تفسیرپذیری مورد ارزیابی قرار خواهد گرفت.

۲- نوع داده‌ها

داده‌های مورد استفاده در این پژوهش شامل لاگ‌های سیستمی هستند که از منابع مختلف گردآوری خواهند شد:

مجموعه داده‌های عمومی (Benchmark datasets):

- HDFS log dataset (از کلاستر Hadoop File System)،
- BGL (Blue Gene/L supercomputer logs)

داده‌های شبیه‌سازی شده یا سازمانی (در صورت دسترسی):

لاگ‌های تولیدشده توسط ابزارهای شبیه‌ساز یا داده‌های واقعی یک سیستم سازمانی (با رعایت ملاحظات امنیتی و محرمانگی) نیز به‌عنوان مکمل استفاده می‌شوند.

ویژگی داده‌ها:

- غیر ساختاریافته و متنی (شامل پیام‌ها، شناسه‌ها، پارامترها، timestamp)،
- دارای برچسب ناهنجاری/عادی (در داده‌های عمومی)،
- و دارای توالی زمانی.

۳- مراحل اجرای تحقیق

فرآیند اجرایی این پژوهش با هدف توسعه یک چارچوب هوشمند و مقیاس‌پذیر برای تشخیص ناهنجاری در لاگ‌های سیستمی، در پنج گام متوالی طراحی شده است. هسته اصلی این طرح، بهره‌گیری از توانایی استدلال مدل‌های زبانی بزرگ (LLMs) در کنار یک معماری ذخیره‌سازی پایدار مبتنی بر پایگاه داده‌های غیررابطه‌ای است. در ادامه، شرح مراحل با تأکید ویژه بر طراحی معماری و پیاده‌سازی فنی ارائه می‌گردد.

مرحله اول: مطالعات نظری، امکان‌سنجی و آماده‌سازی زیرساخت داده‌ای

گام نخستین این پژوهش به تثبیت مبانی نظری و آماده‌سازی زیرساخت داده‌ای اختصاص دارد. در ابتدا، با مرور سیستماتیک ادبیات موضوع در حوزه عملیات هوشمند فناوری اطلاعات (AIOps)، جدیدترین راهکارهای مبتنی بر مدل‌های زبانی نظیر LogLLM و LogPPT مورد واکاوی قرار می‌گیرند تا ضمن شناسایی خلاءهای پژوهشی، برتری رویکردهای نوین نسبت به روش‌های یادگیری عمیق سنتی شفاف‌سازی شود. هم‌زمان، فرآیند گردآوری داده‌ها با تمرکز بر مجموعه‌های داده‌ای مرجع و استاندارد جهانی، شامل HDFS (سیستم فایل توزیع‌شده هادوپ) و BGL (ابرایانه BlueGene/L)، انجام می‌پذیرد. این داده‌ها به دلیل حجم بالا و تنوع رخدادهای، بستری مناسب برای ارزیابی مدل فراهم می‌کنند.

مرحله دوم: پیش‌پردازش داده‌ها و طراحی استراتژی نمونه‌برداری

پس از گردآوری، داده‌های خام که ماهیتی متنی و غیرساختاریافته دارند، وارد چرخه پیش‌پردازش می‌شوند. در این مرحله، عملیات پاک‌سازی و نرمال‌سازی با هدف حذف نویزها و جداسازی بخش‌های متغیر (مانند آدرس‌های IP و شناسه‌های عددی) از بخش‌های ثابت قالب لاگ انجام می‌شود. اگرچه مدل‌های زبانی توانایی درک متن کامل را دارند، اما این ساده‌سازی اولیه به تمرکز بیشتر مدل بر الگوهای معنایی و کاهش سربار توکن‌ها کمک می‌کند. در نهایت، داده‌ها با رعایت ترتیب زمانی به دسته‌های آموزشی و آزمون تقسیم می‌شوند تا از نشت اطلاعات آینده به فرآیند آموزش جلوگیری شده و ارزیابی مدل در شرایطی واقع‌گرایانه صورت گیرد.

مرحله سوم: طراحی معماری سیستم مبتنی بر LogPrompt و زیرساخت ذخیره‌سازی

این مرحله، قلب تپنده پژوهش و نقطه تمرکز نوآوری آن است. هدف در اینجا، گذار از روش‌های سنتی که صرفاً بر روی فایل‌های متنی کار می‌کردند، به سمت یک معماری پایگاه داده محور و مقاوم در برابر خطا است. طراحی این سیستم بر دو ستون اصلی استوار است: استراتژی مهندسی پرامپت پیشرفته و معماری ذخیره‌سازی مبتنی بر MongoDB.

در بخش طراحی الگوریتم هوشمند، به جای استفاده از روش‌های پرهزینه تنظیم دقیق، از استراتژی «یادگیری درون‌متنی» (In-Context Learning) بهره گرفته می‌شود. در این رویکرد، دانش مدل زبانی بزرگ تغییر نمی‌کند، بلکه نحوه فراخوانی آن بهینه‌سازی می‌شود. طراحی پرامپت‌ها در این پژوهش فراتر از یک دستور ساده است و به صورت یک ساختار سه‌لایه مهندسی می‌شود. لایه اول، «توصیف نقش» است که در آن به مدل دستور داده می‌شود تا به عنوان یک متخصص امنیت و تحلیل سیستم عمل کند. لایه دوم، «نمونه‌های آموزشی»^۱ است؛ در این بخش، سیستم به صورت پویا چند نمونه از لاگ‌های نرمال و ناهنجار را به همراه استدلال منطقی آن‌ها در متن پرامپت قرار می‌دهد. این کار به مدل کمک می‌کند تا با دیدن مثال‌ها، الگوی صحیح تحلیل را بدون نیاز به تغییر وزن‌های شبکه عصبی فرا بگیرد. لایه سوم، «تکنیک زنجیره افکار»^۲ است که مدل را ملزم می‌کند پیش از اعلام برچسب نهایی (نرمال یا ناهنجار)، دلیل خود را به زبان طبیعی بیان کند. این ویژگی، جعبه سیاه مدل‌های هوش مصنوعی را شفاف کرده و به مدیران سیستم اجازه می‌دهد چرایی یک هشدار را درک کنند.

در موازات طراحی الگوریتم، زیرساخت ذخیره‌سازی داده‌ها با رویکردی مدرن بازطراحی شده است. تحلیل لاگ‌های سیستمی فرآیندی زمان‌بر است و در مقیاس‌های بزرگ (چند میلیون رکورد)، ذخیره نتایج در فایل‌های CSV یا متنی ساده با ریسک‌های بالایی نظیر از دست رفتن داده‌ها در صورت قطع برق یا کرش کردن برنامه همراه است. برای رفع این چالش، از پایگاه داده غیررابطه‌ای MongoDB استفاده می‌شود. انتخاب MongoDB به دلیل انعطاف‌پذیری بالای آن در ذخیره اسناد JSON است که همخوانی کاملی با ساختار پاسخ‌های مدل‌های زبانی دارد.

در این معماری، سه مجموعه^۳ مجزا در پایگاه داده طراحی شده است. مجموعه اول، logs_raw نام دارد که وظیفه نگهداری لاگ‌های ورودی و وضعیت پردازش آن‌ها را بر عهده دارد. مجموعه دوم، analysis_results است که نتایج خروجی مدل شامل برچسب تشخیص داده شده، متن استدلال مدل و زمان پردازش را ذخیره می‌کند. مجموعه سوم، templates نام دارد که برای ذخیره‌سازی الگوهای استخراج شده از متن لاگ‌ها تعبیه شده است. یکی از ویژگی‌های حیاتی این طراحی، قابلیت «چک‌پوینت‌گذاری»^۴ است؛ به این معنا که سیستم در هر لحظه وضعیت آخرین لاگ پردازش شده را در دیتابیس ثبت می‌کند. بدین ترتیب، اگر فرآیند پردازش به هر دلیلی متوقف شود، در اجرای بعدی نیازی به شروع از صفر نیست و سیستم دقیقاً از همان نقطه‌ای که متوقف شده بود، کار را ادامه می‌دهد. این معماری پایداری سیستم را در محیط‌های عملیاتی تضمین می‌کند.

^۱ Demonstrations

^۲ Chain-of-Thought

^۳ Collection

^۴ Checkpointing

مرحله چهارم: پیاده‌سازی فنی، یکپارچه‌سازی و مدیریت فرآیند پردازش

پس از تکمیل طراحی معماری، مرحله پیاده‌سازی فنی آغاز می‌شود که در آن منطق‌های طراحی شده به کدهای اجرایی تبدیل می‌گردند. این مرحله با راه‌اندازی محیط توسعه پایتون و نصب کتابخانه‌های تخصصی نظیر pymongo برای تعامل با پایگاه داده و کتابخانه‌های کلانت مدل‌های زبانی (مانند OpenAI API یا HuggingFace) شروع می‌شود. پیاده‌سازی سیستم شامل توسعه چندین ماژول کلیدی است که به صورت هماهنگ با یکدیگر عمل می‌کنند.

نخستین و شاید پیچیده‌ترین ماژول، «سازنده پرامپت پویا»^۱ است. این ماژول وظیفه دارد برای هر لاگ ورودی، بهترین و مرتبط‌ترین نمونه‌های آموزشی را انتخاب کند. برخلاف روش‌های ایستا که از یک مجموعه ثابت مثال استفاده می‌کنند، در این پیاده‌سازی از الگوریتم‌های شباهت معنایی استفاده می‌شود تا نمونه‌هایی که از نظر ساختار یا محتوا به لاگ جاری نزدیک‌تر هستند، در پرامپت گنجانده شوند. این کار باعث می‌شود مدل زبانی در مواجهه با لاگ‌های متنوع، همواره مثال‌هایی مرتبط را در حافظه کوتاه‌مدت خود داشته باشد و دقت تشخیص به طرز چشمگیری افزایش یابد.

ماژول دوم، «مدیریت تعامل با پایگاه داده» است که منطق را پیاده‌سازی می‌کند. در این بخش، توابعی توسعه داده می‌شوند که از عملیات Upsert (بروزرسانی در صورت وجود، درج در صورت عدم وجود) استفاده می‌کنند. این رویکرد از تکرار داده‌ها جلوگیری کرده و یکپارچگی پایگاه داده را حفظ می‌کند. زمانی که اسکریپت اصلی اجرا می‌شود، ابتدا با یک کوئری به پایگاه داده، لیست لاگ‌هایی که هنوز فیلد processed: true ندارند را استخراج می‌کند. این مکانیزم صف‌بندی هوشمند، تضمین می‌کند که هیچ لاگی جا نیفتاده و هیچ لاگی دو بار پردازش نمی‌شود.

ماژول سوم، «حلقه اصلی پردازش و مدیریت خطا» است. با توجه به اینکه فراخوانی API مدل‌های زبانی ممکن است با خطاهای شبکه‌ای، محدودیت نرخ درخواست^۲ یا کندی مواجه شود، یک مکانیزم تلاش مجدد^۳ با تأخیر نمایی^۴ در کد تعبیه می‌شود. این مکانیزم در صورت بروز خطا، به جای توقف کل برنامه، مدت کوتاهی صبر کرده و درخواست را مجدداً ارسال می‌کند. همچنین، پاسخ‌های دریافتی از مدل که به زبان طبیعی هستند، باید به فرمت ماشین‌خوان تبدیل شوند. بدین منظور، یک پارسر^۵ مبتنی بر عبارات باقاعده^۶ نوشته می‌شود که از میان توضیحات متنی مدل، برچسب نهایی (مانند Anomaly یا Normal) را استخراج کرده و در فیلد مخصوص دیتابیس ذخیره می‌کند.

در نهایت، تمام این ماژول‌ها در یک اسکریپت اجرایی یکپارچه می‌شوند. این اسکریپت قابلیت اجرا بر روی سرورهای پردازشی را دارد و می‌تواند به صورت موازی^۷ چندین درخواست را مدیریت کند تا سرعت پردازش لاگ‌های حجیم افزایش یابد. لاگ‌های پردازش شده بلافاصله در MongoDB ذخیره می‌شوند و داشبوردهای مدیریتی می‌توانند به صورت بلادرنگ^۸ تغییرات را نمایش دهند.

^۱ Dynamic Prompt Builder

^۲ Rate Limit

^۳ Retry Mechanism

^۴ Exponential Backoff

^۵ Parser


^۶ Regex

^۷ Multi-threading

^۸ Real-time

مرحله پنجم: ارزیابی و اعتبارسنجی مدل

پس از اتمام پردازش تمامی داده‌ها، نتایج ذخیره شده در پایگاه داده استخراج و وارد فاز ارزیابی می‌شوند. در این مرحله، با مقایسه خروجی مدل و برجسب‌های واقعی موجود در دیتاست، ماتریس درهم‌ریختگی تشکیل شده و معیارهای کلیدی شامل دقت (Precision)، فراخوانی (Recall) و امتیاز F_1 محاسبه می‌گردند. همچنین تحلیل کیفی بر روی دلایل ارائه شده توسط مدل برای لاگ‌های ناهنجار انجام می‌شود تا از منطقی بودن استدلال‌های هوش مصنوعی اطمینان حاصل گردد. این ارزیابی نهایی، میزان موفقیت چارچوب پیشنهادی را در مقایسه با روش‌های پیشین اثبات خواهد کرد.



۴- مواد، تجهیزات و استانداردهای مورد استفاده

اجرای این پژوهش که بر تشخیص ناهنجاری در لاگ‌های سیستمی با استفاده از مدل‌های زبانی بزرگ تمرکز دارد، نیازمند تأمین زیرساخت‌های زیر است:

الف) مواد و داده‌های اساسی

- مجموعه داده‌های مرجع^۱: استفاده از مجموعه‌های استاندارد HDFS و BGL برای آموزش، اعتبارسنجی و آزمون مدل، جهت تضمین اعتبار و قابلیت مقایسه نتایج پژوهش.
- مدل‌های زبانی بزرگ (LLMs): دسترسی به API مدل‌های تجاری مانند GPT-۵ Nano یا استفاده از مدل‌های متن‌باز مانند LLaMA۳-۳۳B به عنوان ابزار اصلی تحلیل معنایی و استدلال.

^۱ Benchmark Datasets

زیرساخت نرم‌افزاری:

- زبان برنامه‌نویسی: پایتون (Python) به همراه کتابخانه‌های علمی استاندارد و کتابخانه‌های تعامل با مدل‌های زبانی.
- پایگاه داده: استفاده از MongoDB به عنوان پایگاه داده غیررابطه‌ای برای ذخیره‌سازی مقیاس‌پذیر لاگ‌ها و نتایج تحلیل، و امکان پیاده‌سازی مکانیزم چک‌پوینت‌گذاری.

زیرساخت سخت‌افزاری:

- منابع محاسباتی: نیازمند دسترسی به زیرساخت پردازشی قوی (مانند Cloud Computing یا ایستگاه کاری مجهز به GPU) برای اجرای بهینه مدل‌های زبانی و پردازش سریع حجم عظیم داده‌ها.

ج) استانداردها و معیارهای ارزیابی

- معیارهای ارزیابی عملکرد: از معیارهای استاندارد بر پایه ماتریس درهم‌ریختگی استفاده خواهد شد. معیار اصلی ارزیابی و مقایسه، امتیاز F_1 (F_1 -Score) است که همراه با Precision (دقت) و Recall (فراخوانی) محاسبه خواهد شد.
- استاندارد گزارش‌دهی: نتایج به‌دست‌آمده با استفاده از فرمت‌های آماری و بصری رایج در مقالات معتبر AI Ops (عملیات هوشمند فناوری اطلاعات) گزارش و با سایر روش‌های موجود مقایسه می‌شوند.

ب - متغیرهای مورد بررسی در قالب یک مدل مفهومی و شرح چگونگی بررسی و اندازه‌گیری متغیرها:

مدل مفهومی این پژوهش بر پایه جریان پردازش اطلاعات در سیستم‌های مبتنی بر مدل‌های زبانی بزرگ (LLM) طراحی شده است. در این مدل، لاگ‌های سیستمی خام به عنوان ورودی وارد چرخه می‌شوند. این داده‌ها ابتدا توسط ماژول پیش‌پردازشگر پاک‌سازی شده و سپس وارد مرحله «مهندسی پرامپت» می‌شوند. در این مرحله، بر اساس نوع استراتژی انتخاب‌شده (متغیر مستقل)، ساختار پرسش از مدل شکل می‌گیرد (مثلاً افزودن نمونه‌های مشابه بازیابی‌شده از پایگاه داده). سپس پرامپت نهایی به مدل زبانی ارسال شده و خروجی تولید شده توسط یک پارسر (تحلیل‌گر متن) پردازش می‌شود تا برچسب نهایی و استدلال استخراج گردد. در نهایت، خروجی‌ها با معیارهای استاندارد مقایسه شده و نتایج (متغیرهای وابسته) در پایگاه داده MongoDB ذخیره می‌شوند.

متغیرهای پژوهش در این تحقیق، متغیرها به سه دسته مستقل، وابسته و کنترلی تقسیم می‌شوند که به شرح زیر هستند:

متغیرهای مستقل^۱: این متغیرها عواملی هستند که توسط پژوهشگر تغییر داده می‌شوند تا اثر آن‌ها بر نتیجه نهایی سنجیده شود:

- استراتژی مهندسی پرامپت^۲: این متغیر اصلی‌ترین عامل مداخله‌گر در پژوهش است که شامل سه سطح مختلف می‌باشد: (۱) روش بدون مثال (Zero-shot) که در آن مدل تنها با دستورالعمل کلی عمل می‌کند، (۲) روش چندمثالی (Few-shot) که

^۱ Independent Variables

^۲ Prompt Engineering Strategy

در آن تعدادی نمونه آموزشی مشابه در متن پرامپت گنجانده می‌شود، و (۳) روش زنجیره افکار (Chain-of-Thought) که مدل ملزم به ارائه استدلال قدم‌به‌قدم پیش از نتیجه‌گیری است.

- نوع مدل زبانی^۱: شامل مدل‌هایی که برای پردازش استفاده می‌شوند، نظیر GPT-۵ Nano (به عنوان نماینده مدل‌های تجاری) و LLaMA۳-۳۳B (به عنوان نماینده مدل‌های متن‌باز).
- تعداد نمونه‌های آموزشی (K-shot): تعداد مثال‌هایی که در استراتژی Few-shot به مدل داده می‌شود (مثلاً ۱، ۳ یا ۵ مثال) که بر اساس الگوریتم شباهت انتخاب می‌شوند.

متغیرهای وابسته^۲: این متغیرها نتایجی هستند که در اثر تغییر متغیرهای مستقل تغییر کرده و اندازه‌گیری می‌شوند:

- دقت تشخیص^۳: میزان موفقیت مدل در تفکیک صحیح لاگ‌های عادی از ناهنجار.
- کارایی محاسباتی^۴: مدت زمان صرف شده برای دریافت پاسخ از مدل و میزان مصرف منابع.
- قابلیت تفسیرپذیری^۵: وجود یا عدم وجود توضیحات منطقی و علی برای ناهنجاری‌های تشخیص داده شده در خروجی مدل.

متغیرهای کنترلی^۶:

- مجموعه داده‌ها^۷: استفاده ثابت از دیتاست‌های استاندارد HDFS و BGL برای تمامی آزمایش‌ها جهت یکسان‌سازی شرایط.
- روش پیش‌پردازش: اعمال یکسان تکنیک‌های نرمال‌سازی و ماسک‌گذاری پارامترها روی تمام داده‌های ورودی.

چگونگی بررسی و اندازه‌گیری متغیرها بر اساس پیاده‌سازی فنی انجام شده در کد پروژه، اندازه‌گیری‌ها به شیوه زیر انجام می‌پذیرد:

سنجش متغیرهای دقت (Precision, Recall, F1-Score): برای اندازه‌گیری این متغیرها، پاسخ متنی دریافت شده از مدل زبانی توسط یک کد پایتون تحلیل می‌شود. سیستم به صورت خودکار برچسب پیش‌بینی شده (predicted_label) را با برچسب واقعی (ground_truth) موجود در پایگاه داده مقایسه می‌کند. سپس با تشکیل ماتریس درهم‌ریختگی (Confusion Matrix)، مقادیر مثبت صحیح (TP)، مثبت کاذب (FP) و منفی کاذب (FN) شمارش شده و امتیاز F1 به عنوان معیار نهایی محاسبه و در کالکشن analysis_results در MongoDB ثبت می‌شود.

سنجش کارایی محاسباتی (Latency): در اسکریپت اجرایی، برای هر درخواست ارسالی به API مدل زبانی، زمان دقیق ارسال (start_time) و زمان دقیق دریافت پاسخ (end_time) ثبت می‌شود. تفاضل این دو زمان بر حسب میلی‌ثانیه محاسبه شده و به عنوان متغیر تأخیر (Latency) برای هر رکورد لاگ ذخیره می‌گردد. این داده‌ها امکان مقایسه سرعت روش‌های مختلف (مثلاً سربار زمانی روش زنجیره افکار نسبت به روش ساده) را فراهم می‌کند.

^۱ LLM Type

^۲ Dependent Variables

^۳ Detection Accuracy

^۴ Computational Efficiency

^۵ Interpretability

^۶ Control Variables

^۷ Datasets

بررسی تفسیرپذیری: این متغیر به صورت کیفی و با بررسی فیلد reasoning (استدلال) ذخیره شده در دیتابیس ارزیابی می‌شود. حضور کلیدواژه‌های مرتبط با علت خطا و انطباق آن با دانش خبره، معیاری برای سنجش توانایی مدل در توضیح چرایی وقوع ناهنجاری است.

پ - جامعه آماری حوزه پژوهش، روش نمونه‌گیری و روش برآورد حجم نمونه

در این پژوهش که ماهیت کاربردی دارد و بر پایه‌ی آزمایش و شبیه‌سازی متمرکز است، جامعه آماری به جای افراد، شامل داده‌ها (لاگ‌های سیستمی) و آزمایش‌ها است.

۱. جامعه آماری حوزه پژوهش

جامعه آماری این پژوهش، مجموعه تمام لاگ‌های سیستمی است که در محیط‌های رایانش ابری و خوشه‌های محاسباتی بزرگ تولید می‌شوند و نیاز به پایش برای کشف ناهنجاری دارند.

به صورت عملیاتی، جامعه مورد مطالعه عبارت است از:

- لاگ‌های رویداد واقعی^۱: شامل میلیون‌ها رکورد لاگ که از سیستم‌های توزیع شده بزرگ و محیط‌های عملیاتی جمع‌آوری شده‌اند. این مجموعه شامل تمامی پیام‌های سیستمی، از رویدادهای عادی گرفته تا موارد ناهنجار و خطاها، در طول یک دوره زمانی مشخص است.

- بستر آزمایشی: با توجه به موضوع پژوهش (تشخیص ناهنجاری در لاگ‌ها) و لزوم مقایسه عینی نتایج، جامعه آماری محدود به دو مجموعه داده استاندارد و عمومی می‌شود:

- مجموعه داده HDFS: لاگ‌های جمع‌آوری شده از یک سیستم فایل توزیع شده واقعی.
- مجموعه داده BGL: لاگ‌های جمع‌آوری شده از یک ابررایانه IBM (Supercomputer).

این دو مجموعه به دلیل ماهیت عمومی، دارا بودن برچسب‌های ناهنجاری^۲ و استفاده گسترده در تحقیقات قبلی، به عنوان نماینده کل جامعه آماری لاگ‌های بزرگ انتخاب می‌شوند.

۲. روش نمونه‌گیری و برآورد حجم نمونه

از آنجا که این پژوهش یک تحقیق کمی و تجربی است، روش‌های رایج نمونه‌گیری آماری که در تحقیقات پیمایشی استفاده می‌شوند (مانند نمونه‌گیری تصادفی ساده) کاربرد مستقیمی ندارند.

الف) روش نمونه‌گیری

روش نمونه‌گیری در این پژوهش از نوع نمونه‌گیری هدفمند (Purposive Sampling) و تمام‌شماری آزمایشی است:

^۱ Real-world Event Logs

^۲ Ground Truth

- انتخاب هدفمند مجموعه داده: ابتدا دو مجموعه داده استاندارد BGL و HDFS به صورت هدفمند انتخاب می‌شوند تا قابلیت تعمیم^۱ یافته‌ها به سیستم‌های بزرگ حفظ شود.
- نمونه‌گیری از لاگ‌ها^۲: کل مجموعه داده‌های BGL و HDFS به دلیل حجم بسیار بالا (میلیون‌ها رکورد) مورد استفاده قرار می‌گیرند. در فازهای آزمایشی اولیه و همچنین در زمان اجرای روش Few-shot Prompting، از زیرمجموعه‌های نماینده و متوازن از هر دو کلاس (عادی و ناهنجار) استفاده می‌شود تا از سوگیری مدل جلوگیری شده و زمان آموزش/تست مدیریت شود. به عبارت دیگر، نمونه‌های آموزشی (Shots) برای پرامپت‌ها به گونه‌ای انتخاب و بازایی می‌شوند که تنوع و توازن کلاس‌ها را حفظ کنند.

(ب) روش برآورد حجم نمونه

در پژوهش‌های مبتنی بر یادگیری ماشین و آزمایشی، به جای برآورد حجم نمونه با فرمول‌های آماری (مانند کوکران)، حجم نمونه (اندازه دیتاست) باید آنقدر بزرگ باشد که مدل قادر به یادگیری الگوها باشد و از لحاظ محاسباتی قابل مدیریت باشد.

روش برآورد حجم نمونه به شرح زیر است:

پایبندی به استانداردهای پژوهشی: حجم نمونه بر اساس حجم کل مجموعه داده‌های BGL و HDFS تعیین می‌شود که به ترتیب شامل ۱۱ میلیون و حدود ۴.۷ میلیون رکورد هستند.

تقسیم‌بندی سه‌گانه: کل حجم نمونه به سه بخش تقسیم می‌شود تا اعتبار داخلی پژوهش تضمین شود:

- مجموعه آموزش (Training Set): برای تولید الگوها و بردارها (Embeddings) و آموزش مدل‌های پایه (در صورت لزوم) یا تنظیم هایپرپارامترهای بازایی پرامپت استفاده می‌شود (معمولاً ۶۰ تا ۷۰ درصد کل داده).
- مجموعه اعتبارسنجی (Validation Set): برای بهینه‌سازی پارامترهای مدل پرامپتینگ استفاده می‌شود (معمولاً ۱۰ تا ۲۰ درصد کل داده).
- مجموعه تست (Test Set): نتایج نهایی و معیار F1-Score منحصراً بر روی این مجموعه که کاملاً جدید و دیده نشده است، سنجیده می‌شود. (معمولاً ۲۰ درصد کل داده).

حجم نهایی نمونه همان کل لاگ‌های موجود در مجموعه داده‌های استاندارد BGL و HDFS خواهد بود.

^۱ Generalizability

^۲ Log Sampling

ج - روش‌های گردآوری داده‌ها: (میدانی، کتابخانه‌ای و غیره) و ابزار گردآوری داده‌ها (پرسشنامه، مصاحبه، مشاهده، اسناد، تکالیف، تجهیزات آزمایشگاهی و بانک‌های اطلاعاتی و شبکه‌های کامپیوتری و ماهواره‌ای و غیره)

۱- نوع روش گردآوری داده‌ها

روش گردآوری داده‌ها در این تحقیق به صورت ترکیبی از کتابخانه‌ای و آزمایشگاهی/میدانی انجام خواهد شد:

روش کتابخانه‌ای:

- مطالعه منابع علمی، مقالات معتبر، کتاب‌ها و گزارش‌های پژوهشی در حوزه تشخیص ناهنجاری و کاربرد مدل‌های زبانی بزرگ (LLM) در داده‌های غیرساختاریافته.
- بررسی مجموعه داده‌های عمومی استاندارد (Benchmark datasets) و مستندات فنی مربوط به آن‌ها.
- استخراج شاخص‌ها، معیارها و چارچوب‌های مقایسه‌ای از مطالعات قبلی.

روش آزمایشگاهی/میدانی:

- استفاده از مجموعه داده‌های واقعی شامل لاگ‌های سیستمی سازمان‌ها یا شبیه‌سازی لاگ‌ها در محیط آزمایشگاهی.
- انجام آزمایش‌های عملی روی داده‌ها با استفاده از مدل‌های مختلف زبانی (BERT, GPT, LLaMA, LogBERT و ...).
- مقایسه عملکرد مدل‌ها در شرایط یکسان و ثبت نتایج.

۲- ابزار گردآوری داده‌ها

الف) ابزارهای کتابخانه‌ای

- گردآوری و مرور منابع علمی: از پایگاه‌های علمی مانند Elsevier, Springer, ACM Digital Library, IEEE Xplore و arXiv برای دسترسی به پژوهش‌های مرتبط.
- مرور سیستماتیک (Systematic Review): شناسایی روش‌های موجود تشخیص ناهنجاری و نقاط ضعف آن‌ها برای مقایسه با چارچوب پیشنهادی.

ب) ابزارهای آزمایشگاهی/میدانی

- مشاهده و آزمون (Experimentation & Observation): اجرای مدل‌ها روی داده‌های واقعی و مشاهده رفتار سیستم در شناسایی ناهنجاری‌ها.
- مجموعه داده‌های استاندارد: مانند BGL, HDFS به عنوان داده‌های مرجع.
- ابزارهای نرم‌افزاری:

▪ زبان برنامه‌نویسی Python،

▪ کتابخانه‌های TensorFlow, PyTorch, HuggingFace Transformers.

- ابزارهای پردازش داده مانند Numpy و Pandas.
- ابزارهای ارزیابی و مصورسازی نتایج مانند Matplotlib، Seaborn و MLflow.

د- روش اجرا

- گردآوری داده‌های اولیه (Raw logs): دریافت و استخراج لاگ‌های سیستمی از منابع عمومی یا سازمانی.
 - فیلتراسیون و پیش‌پردازش: حذف داده‌های زائد، ناهماهنگ و بی‌کیفیت.
 - ساخت مجموعه داده‌های آزمایشی: تقسیم داده‌ها به دو بخش Train / Test برای آموزش و ارزیابی مدل‌ها.
 - استفاده از منابع کتابخانه‌ای: مرور و استخراج مفاهیم نظری و چارچوب‌های مقایسه‌ای از پژوهش‌های پیشین.
- این تحقیق از روش ترکیبی کتابخانه‌ای و آزمایشگاهی بهره می‌گیرد. در بخش کتابخانه‌ای، داده‌ها از منابع علمی و مجموعه داده‌های مرجع استخراج می‌شوند. در بخش آزمایشگاهی، داده‌های لاگ واقعی و عمومی گردآوری و پردازش شده و از طریق ابزارهایی مانند Python، PyTorch و HuggingFace مورد آزمون و مشاهده قرار می‌گیرند.

ه- روش‌های تجزیه و تحلیل داده‌ها

۱- روش‌های تجزیه و تحلیل داده‌ها

الف) پیش‌پردازش داده‌ها

- پاک‌سازی داده‌ها: حذف داده‌های ناقص، تکراری یا نویزی.
- نرمال‌سازی و قطعه‌بندی: تقسیم لاگ‌ها به رخدادهای معنادار (log events).
- نمایش داده‌ها: استفاده از روش‌های برداری‌سازی (Tokenization, Sentence Embedding, Word Embedding).

ب) روش‌های تحلیل مبتنی بر یادگیری عمیق و LLM

- مدل‌های زبانی بزرگ (LLM):
 - استفاده از GPT-۵ Nano، LLaMA۳-۳۳B برای استخراج الگوهای معنایی.
 - بهره‌گیری از Fine-tuning، Prompt-tuning یا In-context learning.
- مدل‌های ترتیبی (Sequential Models):
 - تحلیل وابستگی زمانی میان رخدادها با لاگ با LSTM، Transformer یا Attention-based models.
- مدل‌های تشخیص ناهنجاری:
 - Unsupervised: مانند PCA، Isolation Forest، Autoencoder.
 - Supervised/Semi-supervised: مبتنی بر داده‌های برچسب‌دار (Classification models).

ج) ارزیابی عملکرد مدل‌ها

استفاده از معیارهای استاندارد در حوزه تشخیص ناهنجاری:

- Precision (دقت)، Recall (بازخوانی)، F₁-score، Accuracy
- AUC-ROC (مساحت زیر منحنی ROC)
- Latency (زمان پردازش) و مقیاس پذیری (Scalability).

۲- ابزارهای تجزیه و تحلیل داده‌ها

- زبان برنامه‌نویسی:
 - Python به عنوان زبان اصلی.
- کتابخانه‌ها و چارچوب‌ها:
 - TensorFlow و PyTorch برای پیاده‌سازی مدل‌های یادگیری عمیق،
 - HuggingFace Transformers برای استفاده و تنظیم مدل‌های LLM،
 - Scikit-learn برای الگوریتم‌های کلاسیک یادگیری ماشین،
 - Pandas و Numpy برای مدیریت و پردازش داده‌ها،
 - Matplotlib و Seaborn برای مصورسازی نتایج.
- ابزارهای مدیریت و ارزیابی:
 - MLflow یا Weights & Biases (W&B) برای ثبت و مقایسه آزمایش‌ها،
 - Jupyter Notebook برای تحلیل تعاملی داده‌ها.

۳- روند تحلیل داده‌ها

- مرحله اول: آماده‌سازی داده‌ها (پاک‌سازی، پیش‌پردازش، embedding).
 - مرحله دوم: آموزش مدل‌های LLM و مدل‌های مقایسه‌ای.
 - مرحله سوم: ارزیابی مدل‌ها بر اساس معیارهای کمی (Precision، Recall و ...).
 - مرحله چهارم: تحلیل نتایج و مقایسه چارچوب پیشنهادی با روش‌های مرجع.
 - مرحله پنجم: استخراج نتایج نهایی و تبیین نقاط قوت و ضعف مدل پیشنهادی.
- روش تحلیل داده‌ها ترکیبی از تحلیل آماری، یادگیری ماشین و یادگیری عمیق خواهد بود. ابزارهای اصلی شامل Python، PyTorch، HuggingFace، Scikit-learn و MLflow هستند. داده‌ها ابتدا پیش‌پردازش می‌شوند، سپس مدل‌های مختلف روی آن‌ها اجرا و نتایج بر اساس معیارهای استاندارد مقایسه و تحلیل می‌شوند.

۱۱- استفاده از امکانات آزمایشگاهی و کارگاهی واحد

- آیا برای انجام تحقیقات نیاز به استفاده از امکانات آزمایشگاهی واحد علوم و تحقیقات می باشد؟ خیر

در صورت نیاز به امکانات آزمایشگاهی لازم است نوع آزمایشگاه، تجهیزات، مواد و وسایل مورد نیاز در این قسمت مشخص گردد.

نوع آزمایشگاه	تجهیزات مورد نیاز	مواد و وسایل	مقدار مورد نیاز

- آیا برای انجام تحقیقات نیاز به حمایت از سایر مراکز خارج از واحد علوم و تحقیقات می باشید؟ خیر

در صورت نیاز نام مراکز و نحوه حمایت (مالی، امکانات و تجهیزات و ..) مشخص گردد.

- [۱] W. Guan, J. Cao, S. Qian, J. Gao, and C. Ouyang, "LogLLM: Log-based Anomaly Detection Using Large Language Models," Apr. ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۴۱۱.۰۸۵۶۱>
- [۲] A. Brasoveanu, M. Moodie, and R. Agrawal, "Textual evidence for the perfunctoriness of independent medical reviews," in *CEUR Workshop Proceedings*, CEUR-WS, ۲۰۲۰, pp. ۱-۹. doi: ۱۰.۱۱۴۵/nnnnnnnn.nnnnnnnn.
- [۳] S. Chen and H. Liao, "BERT-Log: Anomaly Detection for System Logs Based on Pre-trained Language Model," *Applied Artificial Intelligence*, vol. ۳۶, no. ۱, ۲۰۲۲, doi: ۱۰.۱۰۸۰/۰۸۸۳۹۵۱۴.۲۰۲۲.۲۱۴۵۶۴۲.
- [۴] L. Ma *et al.*, "AdaptiveLog: An Adaptive Log Analysis Framework with the Collaboration of Large and Small Language Model," Jan. ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۵۰۱.۱۱۰۳۱>
- [۵] R. Xu and K. Ding, "Large Language Models for Anomaly and Out-of-Distribution Detection: A Survey," Feb. ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۴۰۹.۰۱۹۸۰>
- [۶] J. Pan, S. Liang Wong, and Y. Yuan, "RAGLog: Log Anomaly Detection using Retrieval Augmented Generation," ۲۰۲۳.
- [۷] Y. Liu *et al.*, "OpsEval: A Comprehensive Benchmark Suite for Evaluating Large Language Models' Capability in IT Operations Domain," in *Proceedings of the ACM SIGSOFT Symposium on the Foundations of Software Engineering*, Association for Computing Machinery, Jul. ۲۰۲۵, pp. ۵۰۳-۵۱۳. doi: ۱۰.۱۱۴۵/۳۶۹۶۶۳۰.۳۷۲۸۵۷۲.
- [۸] M. Du, F. Li, G. Zheng, and V. Srikumar, "DeepLog: Anomaly detection and diagnosis from system logs through deep learning," in *Proceedings of the ACM Conference on Computer and Communications Security*, Association for Computing Machinery, Oct. ۲۰۱۷, pp. ۱۲۸۵-۱۲۹۸. doi: ۱۰.۱۱۴۵/۳۱۳۳۹۵۶.۳۱۳۴۰۱۵.
- [۹] H. Guo, S. Yuan, and X. Wu, "LogBERT: Log Anomaly Detection via BERT," Mar. ۲۰۲۱, [Online]. Available: <http://arxiv.org/abs/۲۱۰۳.۰۴۴۷۵>
- [۱۰] Z. Zhang, S. Li, L. Zhang, J. Ye, C. Hu, and L. Yan, "LLM-LADE: Large language model-based log anomaly detection with explanation," *Knowl Based Syst*, vol. ۳۲۶, Sep. ۲۰۲۵, doi: ۱۰.۱۰۱۶/j.knosys.۲۰۲۵.۱۱۴۰۶۴.
- [۱۱] P. Pospieszny, W. Mormul, K. Szyndler, and S. Kumar, "ADALog: Adaptive Unsupervised Anomaly detection in Logs with Self-attention Masked Language Model," May ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۵۰۵.۱۳۴۹۶>
- [۱۲] F. Hadadi, Q. Xu, D. Bianculli, and L. Briand, "LLM meets ML: Data-efficient Anomaly Detection on Unstable Logs," Aug. ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۴۰۶.۰۷۴۶۷>
- [۱۳] Y. Liu *et al.*, "Interpretable Online Log Analysis Using Large Language Models with Prompt Strategies," Jan. ۲۰۲۴, [Online]. Available: <http://arxiv.org/abs/۲۳۰۸.۰۷۶۱۰>
- [۱۴] Y. F. Lim, J. Zhu, and G. Pang, "Adapting Large Language Models for Parameter-Efficient Log Anomaly Detection," Mar. ۲۰۲۵, [Online]. Available: <http://arxiv.org/abs/۲۵۰۳.۰۸۰۴۵>
- [۱۵] X. Han, S. Yuan, and M. Trabelsi, "LogGPT: Log Anomaly Detection via GPT," Dec. ۲۰۲۳, [Online]. Available: <http://arxiv.org/abs/۲۳۰۹.۱۴۴۸۲>

- [16] V.-H. Le and H. Zhang, “Log Parsing with Prompt-based Few-shot Learning,” Feb. 2023, [Online]. Available: <http://arxiv.org/abs/2302.07430>
- [17] Y. Sui *et al.*, “Bridging the Gap: LLM-Powered Transfer Learning for Log Anomaly Detection in New Software Systems,” 2020. [Online]. Available: <https://anonymous.4open.science/r/LogSynergy-320D/>.
- [18] Y. Zhu *et al.*, “YuLan: An Open-source Large Language Model,” Jun. 2023, [Online]. Available: <http://arxiv.org/abs/2306.19803>

۱۳- زمان بندی انجام پژوهش پس از زمان تصویب پروپوزال تا دفاع نهایی

تاریخ شروع پژوهش	مدت زمان انجام تحقیق (ماه)	تاریخ اتمام و دفاع نهایی
۱۴۰۴/۱۰/۰۱	۶	۱۴۰۵/۰۴/۰۱

۱۴- پیش بینی زمان بندی فعالیت ها و مراحل اجرایی پژوهش از زمان تصویب تا دفاع نهایی

ردیف	شرح فعالیت	زمان کل	زمان اجرا به ماه							
			۱	۲	۳	۴	۵	۶	۷	۸
۱	جمع آوری و آماده سازی داده ها	۱ (ماه)								
۲	پیش پردازش و نمایش داده ها	۱ (ماه)								
۳	طراحی چارچوب پیشنهادی مبتنی بر LLM	۲ (ماه)								
۴	ارائه چارچوب نهایی	۲ (ماه)								
۵	ارزیابی و تحلیل نتایج	۱ (ماه)								
۶										
۷										
۸										

توجه

- ۱) زمان و نوع فعالیت های اجرایی پایان نامه، حتی الامکان باید با مندرجات جدول منطبق باشد.
- ۲) حداقل زمان قابل قبول برای پیش بینی مراحل مطالعاتی و اجرایی پایان نامه کارشناسی ارشد ۶ ماه و حداکثر ۱۲ ماه می باشد.

این فرم باید توسط دانشجو تکمیل شود

فرم سازمان مرکزی دانشگاه آزاد اسلامی

فرم الف - فرم اطلاعات پایان نامه کارشناسی ارشد

نام واحد دانشگاهی: واحد علوم و تحقیقات تهران	
عنوان پایان نامه کارشناسی ارشد:	
نام و نام خانوادگی دانشجو:	نیمسال تحصیلی:
شماره دانشجویی:	تعداد واحد پایان نامه:
رشته تحصیلی:	گرایش:
کد رشته:	فنی و مهندسی
نام و نام خانوادگی استاد راهنما:	رشته تحصیلی:
مرتبه علمی:	کد شناسایی استاد راهنما:
نام و نام خانوادگی استاد مشاور:	رشته تحصیلی:
مرتبه علمی:	کد شناسایی استاد راهنما:

با توجه به اینکه پژوهش‌های انجام شده در حیطه زیست پزشکی به منظور رعایت و بکارگیری اصول و موازین اخلاقی در پژوهش‌های انسانی و حیوانی، حفظ حقوق پژوهشگران و آزمودنی‌ها در بررسی‌های انجام شده و انتشار نتایج، چاپ مقالات در تعدادی از مجلات داخلی و خارجی و همچنین اخذ حمایت‌های تشویقی از برخی نهادها نیاز به اخذ کد اخلاق دارند. برخی از موضوعات نیازمند به اخذ کد اخلاق عبارتند از:

۱- موضوعات مشتمل بر آزمودنی انسان

- * موضوعات مرتبط با بررسی‌های مستقیم یا غیر مستقیم فیزیولوژیکی بر روی انسان‌ها (بررسی اثرات داروهای مختلف، کارآزمایی‌های بالینی)، مکمل‌های غذایی و فعالیت‌های ورزشی بر روی انسان)
- * موضوعات مرتبط با بررسی اعضا و نمونه‌های جدا شده از انسان (پژوهش در مورد گامت و رویان، ژنتیک پزشکی، سلول‌های بنیادی و اخذ نمونه‌های خون، سلول، مایع مغزی نخاعی و اسپرم)
- * موضوعات مرتبط با بررسی‌های مستقیم یا غیر مستقیم روانی و ذهنی بر روی انسان‌ها (مداخلات آموزشی، مطالعات رفتاری، سبک زندگی، عملکردی و مدیریتی)
- * موضوعات مرتبط با در معرض خطر قرار گرفتن انسان‌ها و محیط زیست آن‌ها مانند کار بر روی بیماری‌های عفونی، مواد سرطان‌زا و ترکیبات زیان‌آور.
- * موضوعات مرتبط با مطالعه بر روی گروه‌های آسیب‌پذیر (مانند بررسی‌های انجام شده روی بیماران اسکیزوفرنی، سندرم داون و ...)

۲- موضوعات مشتمل بر آزمودنی حیوان

- * این موضوعات شامل استفاده از هر نوع و هر تعداد حیوان آزمایشگاهی برای تمامی بررسی‌های مستقیم و غیر مستقیم، اخذ نمونه‌های مختلف، استفاده از مواد زیان‌آور برای پژوهشگر و آسیب‌های محیط زیستی ناشی از پژوهش می‌باشد.
- لذا خواهشمند است با در نظر گرفتن مطالب فوق، مجریان محترم در روند اخذ کد اخلاق قرار گیرند. لطفاً در نظر داشته باشید:
- * در صورت نیاز به اخذ کد اخلاق، بلافاصله بعد از تصویب پروپوزال و قبل از شروع کار عملی مدارک مورد نیاز به یکی از کمیته‌های اخلاق تابعه وزارت بهداشت، درمان و آموزش پزشکی ارجاع شود.
- * عطف به نامه شماره ۷۰۰/۵۰۱۴/د مورخ ۱۳۹۷/۱۱/۲۳ دبیرخانه کمیته ملی اخلاق در پژوهش‌های زیست پزشکی، کد اخلاق برای پژوهش‌های در حال انجام، پایان یافته و یا مقالات آماده چاپ به هیچ عنوان صادر نمی‌شود.
- * کد اخلاق در واحدها، از طریق کمیته اخلاق پزشکی مستقر در واحد، صادر می‌گردد.



فرم تعهد استاد راهنما، مشاور و دانشجو

در انتشار نتایج حاصل از پایان نامه دانشجو

اینجانب استاد راهنما پایان نامه آقای/ خانم دانشجوی رشته مقطع کارشناسی ارشد متعهد می‌شوم جهت حفظ و رعایت حقوق دانشگاه و نیز تعلق گرفتن امتیاز پژوهشی، انتشار نتایج حاصل از پایان نامه را به نام دانشگاه انجام دهم و نام دانشگاه را دقیقاً بعنوان آدرس اصلی بصورت زیر ذکر نمایم:

گروه مکانیک، برق و کامپیوتر، واحد علوم و تحقیقات، دانشگاه آزاد اسلامی، تهران، ایران

Department of Science and Research Branch, S R C, Islamic Azad University, Tehran, Iran

تاریخ و امضاء استاد راهنما

تاریخ و امضاء دانشجو

- استعلام موضوع از سایت ایران داک/ اصالت سنج دانشگاه آزاد/ سیکا، مورد بررسی قرار گرفت و موضوع طرح پیشنهادی پژوهش با پژوهش‌های قبلی مشابهت ندارد.

- رعایت کامل منشور اخلاق پژوهش از جمله اصالت طرح پیشنهادی پژوهش و پایان نامه، عدم انجام هرگونه سرقت علمی و کپی برداری.

تاریخ و امضاء

تأیید اساتید راهنما

نظر شورای بخش دانشی (گروه تخصصی)

ردیف	نام و نام خانوادگی	مرتبه	پایه	نظر	امضا
۱				تأیید	
				رد	
				تأیید با اصلاح	
۲				تأیید	
				رد	
				تأیید با اصلاح	
۳				تأیید	
				رد	
				تأیید با اصلاح	
۴				تأیید	
				رد	
				تأیید با اصلاح	
۵				تأیید	
				رد	
				تأیید با اصلاح	

دلایل عدم تأیید

رئیس بخش دانشی (مدیر گروه تخصصی)	تاریخ	امضا