



سپریم کورٹ

معاونت پژوهش و فن آوری

بہ نام خدا

مشور اخلاق پژوهش



رجان و اعتقاد بر این که عالم محضر خداست و همواره ناظر بر اعمال انسان و به منظور پاس داشت مقام بلند دانش و پژوهش و نظر به اهمیت جایگاه دانشگاه در اعتلای فرهنگ و تمدن بشری، مادیان و اعضا بنات علمی واحد های دانشگاه آزاد اسلامی متعهد می گردیم اصول زیر را در انجام فعالیت های پژوهشی مد نظر قرار داده و از آن تخطی نکنیم:

- ۱- اصل حقیقت جویی: تلاش در راستای پی جویی حقیقت و وفاداری به آن و دوری از هرگونه پنهان سازی حقیقت.
- ۲- اصل رعایت حقوق: التزام به رعایت کامل حقوق پژوهشگران و پژوهیدگان (انسان، حیوان و نبات) و سایر صاحبان حق.
- ۳- اصل مالکیت مادی و معنوی: تعهد به رعایت کامل حقوق مادی و معنوی دانشگاه و کلیه بهکاران پژوهش.
- ۴- اصل منافع ملی: تعهد به رعایت مصالح ملی و در نظر داشتن پیشبرد و توسعه کشور و کلیه مراحل پژوهش.
- ۵- اصل رعایت انصاف و امانت: تعهد به اجتناب از هرگونه جانب داری غیر علمی و حفاظت از اموال، تجهیزات و منابع در اختیار.
- ۶- اصل رازداری: تعهد به صیانت از اسرار و اطلاعات محرمانه افراد، سازمان ها و کشورهای مربوط با تحقیق.
- ۷- اصل احترام: تعهد به رعایت حریم ها و حرمت ها در انجام تحقیقات و رعایت جانب تقد و خودداری از هرگونه حرمت شکنی.
- ۸- اصل ترویج: تعهد به رواج دانش و اشاعه نتایج تحقیقات و انتقال آن به بهکاران علمی و دانشجویان به غیر از مواردی که منع قانونی دارد.
- ۹- اصل برانست: التزام به برانست جویی از هرگونه رفتار غیر حرفه ای و اعلام موضع نسبت به کسانی که حوزه علم و پژوهش را به شبه های غیر علمی می آلائند.

دانشگاه آزاد اسلامی

واحد علوم و تحقیقات (تهران)

تعهدنامه اصالت رساله یا پایان نامه تحصیلی

اینجانب مسعود دباغی دانش آموخته مقطع کارشناسی ارشد در رشته مهندسی کامپیوتر گرایش نرم افزار که در تاریخ ۱۴۰۵/۰۱/۰۱ از پایان نامه/رساله خود تحت عنوان بهبود تشخیص ناهنجاری ها در لاگ های سیستمی مبتنی بر مدل های زبانی بزرگ با بهره گیری از مهندسی پرامپت با کسب نمره ۰۰ و درجه ۰۰ دفاع نموده ام بدینوسیله متعهد می شوم:

- (۱) این پایان نامه / رساله حاصل تحقیق و پژوهش انجام شده توسط اینجانب بوده و در مواردی که از دستاوردهای علمی و پژوهشی دیگران (اعم از پایان نامه، کتاب، مقاله و ...) استفاده نموده ام، مطابق ضوابط و رویه موجود، نام منبع مورد استفاده و سایر مشخصات آنرا در فهرست مربوطه ذکر و درج کرده ام.
- (۲) این پایان نامه / رساله قبلاً برای دریافت هیچ مدرک تحصیلی (هم سطح، پایین تر یا بالاتر) در سایر دانشگاهها و مؤسسات آموزش عالی ارائه نشده است.
- (۳) چنانچه بعد از فراغت از تحصیل، قصد استفاده و هر گونه بهره برداری اعم از چاپ کتاب، ثبت اختراع و ... از این پایان نامه یا رساله داشته باشم، از حوزه معاونت پژوهشی واحد مجوزهای مربوطه را اخذ نمایم.
- (۴) چنانچه در هر مقطع زمانی خلاف موارد فوق ثابت شود، عواقب ناشی از آن را می پذیرم و دانشگاه آزاد اسلامی واحد علوم و تحقیقات مجاز است با اینجانب مطابق ضوابط و مقررات رفتار نموده و در صورت ابطال مدرک تحصیلی ام هیچگونه ادعایی نخواهم داشت.



نام و نام خانوادگی: مسعود دباغی

تاریخ و امضاء

دانشگاه آزاد اسلامی

واحد علوم و تحقیقات (تهران)

دانشکده برق و کامپیوتر، گروه نرم افزار

پایان نامه برای دریافت درجه ی کارشناسی ارشد در رشته کامپیوتر (M.Sc)

گرایش نرم افزار

عنوان:

بهبود تشخیص ناهنجاری ها در لاگ های سیستمی مبتنی بر مدل های زبانی بزرگ با بهره گیری از مهندسی پرامپت

استاد راهنما:

دکتر محمدرضا علی زاده

نگارش :

مسعود دباغی

تابستان ۱۴۰۵

بر خود لازم می‌دانم مراتب سپاس و قدردانی صمیمانه خود را از استاد ارجمند، جناب آقای دکتر محمدرضا علی‌زاده، استاد راهنمای محترم، ابراز نمایم.

راهنمایی‌های علمی و ارزشمند، دقت نظر، صبوری و حمایت‌های دلسوزانه ایشان در تمامی مراحل انجام این پژوهش، نقشی اساسی در شکل‌گیری و به سرانجام رسیدن این پایان‌نامه داشته است.

بی‌تردید، بهره‌مندی از دانش و تجربیات گران‌قدر ایشان، از ارزشمندترین بخش‌های این مسیر علمی برای من بوده است. بدین‌وسیله از تمامی زحمات، همراهی‌ها و راهنمایی‌های ایشان صمیمانه سپاسگزاری می‌نمایم.

تقدیم به

پدر و مادر عزیزم؛

آنان که با مهر بی‌پایان، صبوری و فداکاری‌های بی‌دریغشان، همواره استوارترین تکیه‌گاه و روشن‌ترین چراغ مسیر زندگی من بوده‌اند.

این پایان‌نامه را به پاس تمام محبت‌ها، رنج‌ها و حمایت‌های همیشگی‌شان، با نهایت عشق، احترام و قدردانی تقدیم می‌کنم.

فهرست مطالب

فصل اول: کلیات تحقیق.....	۳
مقدمه ۱-۱.....	۴
بیان مسئله ۱-۲.....	۴
اهمیت و ضرورت انجام پژوهش ۱-۳.....	۶
اهداف مشخص پژوهش ۱-۴.....	۷
سؤال‌ها و فرضیه‌های پژوهش ۱-۵.....	۷
سؤال‌های پژوهش.....	۷
فرضیه‌های پژوهش.....	۸
فصل دوم: مروری بر ادبیات و پیشینه تحقیق.....	۱۰
مقدمه ۲-۱.....	۱۱
مرور ادبیات و سوابق مرتبط ۲-۲.....	۱۲

فهرست جدول‌ها

جدول ۱-۲: مقایسه پژوهش‌های مرتبط با تشخیص ناهنجاری لاگ.....	۱۷
---	----

فهرست نمودارها

فهرست شکل ها

چکیده

رشد سامانه‌های توزیع شده موجب تولید حجم عظیمی از لاگ‌های ناهمگون شده است و تشخیص سریع ناهنجاری در آن‌ها برای افزایش پایداری و امنیت سامانه‌ها اهمیت دارد. روش‌های سنتی معمولاً به قواعد دست‌نویس، الگوهای ثابت یا داده‌های برچسب‌خورده وابسته‌اند و در مواجهه با تغییر ساختار لاگ‌ها و حجم بالای داده محدودیت دارند. هدف این پژوهش، ارائه چارچوبی مبتنی بر مدل زبانی بزرگ و مهندسی پرامپت برای طبقه‌بندی دودویی رویدادهای مجموعه داده Blue Gene/L، بدون ریزتنظیم مدل است. در روش پیشنهادی، برچسب واقعی از ورودی مدل حذف شده و مقادیر پویایی مانند شناسه‌ها، مسیرها، نشانی‌های شبکه، مقادیر هگزادسیمال و اعداد به قالب‌های قابل‌بازاستفاده تبدیل می‌شوند؛ درعین حال، تفاوت‌های معنایی مهم مانند مقادیر صفر و غیرصفر حفظ می‌گردد. سپس مدل محلی Qwen2.5:7B-Instruct از طریق Ollama و با خروجی ساخت‌یافته، هر لاگ را عادی یا ناهنجار طبقه‌بندی می‌کند. برای کاهش هزینه استنتاج، نتایج معتبر در سطح قالب ذخیره شده و پیش از ورود به حافظه نهان اعتبارسنجی می‌شوند. سامانه در دو حالت ترکیبی قواعد قطعی و مدل زبانی، و حالت صرفاً مبتنی بر پرامپت پیاده‌سازی شده و نتایج خطبه‌خط در MongoDB ذخیره می‌شوند. ارزیابی با معیارهای صحت، دقت، بازخوانی، امتیاز F1، نرخ خروجی نامعتبر، زمان پاسخ و آمار حافظه نهان انجام شد. نتایج نشان داد نرمال‌سازی قالب‌ها و استفاده از حافظه نهان، فراخوانی‌های تکراری مدل و زمان پردازش را کاهش می‌دهد، درحالی‌که ثبت خطبه‌خط، قابلیت ارزیابی و ممیزی را حفظ می‌کند. چارچوب پیشنهادی راهکاری سبک و قابل‌استقرار برای تحلیل لاگ‌های سیستمی بدون آموزش مجدد مدل فراهم می‌سازد.

کلمات کلیدی(فارسی)

تشخیص ناهنجاری، لاگ‌های سیستمی، مهندسی پرامپت، مدل‌های زبانی بزرگ

کلمات کلیدی(انگلیسی)

Anomaly Detection, System Logs, Prompt Engineering, Large Language Models (LLMs)

فصل اول: کلیات تحقیق

مقدمه ۱-۱

گسترش سامانه‌های نرم‌افزاری و معماری‌های توزیع‌شده، موجب تولید پیوسته حجم زیادی از لاگ‌های سیستمی شده است. این لاگ‌ها اطلاعات ارزشمندی درباره وضعیت عملکرد، خطاها و رخدادهای امنیتی سامانه‌ها در اختیار قرار می‌دهند. از این رو، تشخیص سریع و دقیق ناهنجاری‌ها در آن‌ها نقش مهمی در افزایش پایداری و قابلیت اطمینان سیستم‌ها دارد. با این حال، حجم بالا، ساختار نامنظم و تغییرپذیری الگوهای لاگ، کارایی روش‌های سنتی را محدود می‌سازد. مدل‌های زبانی بزرگ، به دلیل توانایی درک متون غیرساختاریافته و روابط معنایی، ظرفیت مناسبی برای تحلیل این داده‌ها دارند. در این پژوهش، از مهندسی پرامپت برای بهره‌گیری از توانایی مدل‌های زبانی، بدون نیاز به آموزش مجدد و داده‌های برچسب‌خورده گسترده استفاده می‌شود. در ادامه این فصل، بیان مسأله، اهمیت و ضرورت، اهداف، پرسش‌ها و فرضیه‌های تحقیق تشریح می‌شوند.

بیان مسئله ۱-۲

در سامانه‌های مدرن با معماری توزیع‌شده، حجم عظیمی از لاگ‌های سیستمی به صورت پیوسته تولید می‌شود که حاوی اطلاعات مهمی برای عیب‌یابی، پایش سلامت و بررسی حوادث امنیتی هستند. کشف ناهنجاری‌ها در این لاگ‌ها نقش کلیدی در افزایش پایداری و قابلیت اطمینان سیستم دارد. با این حال، چند ویژگی مشکل‌ساز وجود دارد: ساختار نامنظم لاگ‌ها (متن آزاد همراه با پارامترها و شناسه‌ها)، حجم بسیار بالا و پویایی سریع الگوهای آن‌ها و تعداد کم رخدادهای ناهنجار نسبت به رویدادهای عادی. روش‌های سنتی مبتنی بر قوانین دست‌نویس یا الگوریتم‌های آماری، که اغلب به الگوهای ثابت یا داده‌های پارس شده نیاز دارند، در مواجهه با این چالش‌ها کارآمدی خود را از دست می‌دهند. برای مثال، LogLLM نشان می‌دهد که روش‌های معمول نیاز به استخراج الگو دستی دارند اما مدل‌های زبانی بزرگ می‌توانند با پیش‌پردازش ساده مانند عبارات با قاعده، فرایند را ساده کنند و به دقت بالا در تشخیص ناهنجاری برسند [۱].

مدل‌های زبانی بزرگ (مانند GPT، BERT، LLaMa و...) توانایی قوی در پردازش متون غیرساختاریافته و یادگیری روابط معنایی دارند. این مدل‌ها می‌توانند پیام‌های لاگ را مانند جمله‌های طبیعی در نظر گرفته و معنا و زمینه آن‌ها را استخراج کنند [۱].

همچنین استفاده از LLMها فراتر از خود تشخیص ناهنجاری رفته و در فرایندهای پیشین مانند تجزیه لاگ نیز تأثیرگذار بوده است. به عنوان نمونه، LogParser-LLM نشان می‌دهد که با ادغام دانش معنایی مدل‌های زبانی در فرایند پارس لاگ، می‌توان بدون نیاز به داده‌های برچسب‌دار یا تنظیمات دقیق، ساختار لاگ را استخراج کرد [۲].

این کار با بهره‌گیری هم‌زمان از اطلاعات معنایی و ویژگی‌های آماری، دقت بالایی در تشخیص الگوها ایجاد می‌کند. در کل، این مطالعات همگی حکایت از این دارند که مدل‌های زبانی بزرگ می‌توانند محدودیت روش‌های سنتی را با درک عمیق‌تر متن لاگ و تشخیص ناهنجاری حتی در شرایط تغییر الگو برطرف سازند [۳].

با وجود موفقیت اولیه، چندین چالش و سؤال پژوهشی باقی مانده است که باید بررسی شوند:

یکی از موانع اصلی در بکارگیری مدل‌های زبانی بزرگ، پارامترهای فراوان و محاسبات سنگینی است که منجر به افزایش تأخیر اجرا و هزینه‌های عملیاتی می‌شود. اکثر رویکردهای فعلی مانند LogLLM [۱] یا روش‌های مبتنی بر تنظیم دقیق^۱ مانند LogBERT [۴]، نیازمند زیرساخت‌های پردازشی قدرتمند (GPU) و زمان آموزش طولانی هستند. از سوی دیگر، در محیط‌های صنعتی، سرعت تشخیص ناهنجاری حیاتی است.

برای مقابله با این چالش، پژوهش‌هایی مانند AdaptiveLog [۵] استراتژی همکاری میان مدل‌های کوچک و بزرگ (SLM/LLM) را پیشنهاد داده‌اند تا تنها در موارد پیچیده از توان محاسباتی مدل بزرگ استفاده شود. با این حال، حتی در این مدل‌ها نیز نیاز به داده‌های برچسب‌دار و فرآیند آموزش همچنان پابرجاست.

علاوه بر چالش‌های محاسباتی و داده‌ای، یکی از موانع جدی در به‌کارگیری مدل‌های زبانی بزرگ در محیط‌های عملیاتی حساس، مسئله «توهم»^۲ و «شکاف دانش دامنه»^۳ است. مدل‌های زبانی عمومی اغلب بر روی داده‌های عمومی اینترنت آموزش دیده‌اند و ممکن است فاقد دانش تخصصی عمیق در مورد معماری‌های خاص سازمانی، کدهای خطای اختصاصی و وابستگی‌های پیچیده میان میکروسرویس‌ها باشند. این محدودیت می‌تواند منجر به تولید توضیحات نادرست اما با ظاهر موجه شود که در فرآیند عیب‌یابی سیستم‌های حیاتی، ریسک عملیاتی را افزایش می‌دهد. پژوهش‌های اخیر نشان می‌دهند که صرفاً تکیه بر دانش درونی مدل برای تشخیص ریشه خطا کافی نیست و مدل‌ها در مواجهه با لاگ‌های ناشناخته، ممکن است روابط علی و معلولی را به اشتباه استنتاج کنند [۶]. از این رو، مبحث تلفیق مدل‌های زبانی با پایگاه‌های دانش خارجی از طریق تکنیک‌هایی مانند «تولید افزوده به بازیابی»^۴ (RAG) مطرح شده است. سوال اساسی اینجاست که چگونه می‌توان مستندات فنی، سوابق تیکت‌های گذشته و گراف دانش سیستم را به صورت پویا در اختیار مدل قرار داد تا خروجی آن واقعیت‌محور باقی بماند. مطالعاتی نظیر OpsEval نشان داده‌اند که مدل‌های فعلی بدون دسترسی به دانش زمینه، در وظایف استدلال منطقی پیچیده دچار افت عملکرد می‌شوند [۷]. بنابراین، بررسی راهکارهایی که بتوانند دانش زمینه را بدون نیاز به بازآموزی سنگین به مدل تزریق کنند و نرخ توهم را در تشخیص ناهنجاری به حداقل برسانند، یک خلأ پژوهشی آشکار است که نیازمند تحقیقات متمرکز می‌باشد.

در این پژوهش، شکاف موجود با استفاده از «مهندسی پرامپت هوشمند»^۵ و تکنیک‌های یادگیری با مثال‌های محدود^۶ پر می‌شود. این رویکرد به جای بازآموزی مدل یا استفاده از معماری‌های دوگانه پیچیده، بر استفاده بهینه از توانایی‌های ذاتی مدل‌های پیش‌آموزش‌دیده تمرکز دارد. هدف این است که با طراحی استراتژی‌های پرامپت‌دهی کارآمد [۸]،

^۱ Fine-tuning

^۲ Hallucination

^۳ Domain Knowledge Gap

^۴ Retrieval-Augmented Generation

^۵ Prompt Engineering

^۶ Few-shot

دقت تشخیص در سطح مدل‌های ریزتنظیم‌شده حفظ شود، در حالی که هزینه محاسباتی و نیاز به داده‌های آموزشی برچسب‌دار به حداقل برسد.

هدف اصلی، دستیابی به سیستمی است که بتواند به‌صورت مؤثر ناهنجاری‌های معنایی و ترتیبی را در لاگ‌های سیستمی تشخیص دهد، به‌گونه‌ای که دقت تشخیص در سطح مدل‌های پیچیده حفظ شده، اما نیاز به داده‌های برچسب‌دار و هزینه‌های محاسباتی به حداقل برسد. این سیستم با استفاده از استراتژی‌های پرامپت‌دهی کارآمد (مانند زنجیره افکار [۱۰])، اختلالات واقعی را از هشدارهای کاذب تفکیک کرده و برخلاف روش‌های سنتی، در مواجهه با تغییرات ناگهانی در الگوهای لاگ، پویایی و تعمیم‌پذیری بالایی از خود نشان می‌دهد.

نتایج مورد انتظار این تحقیق شامل ارائه راهکاری سبک و قابل پیاده‌سازی در محیط‌های واقعی است که علاوه بر بهبود پایداری و امنیت سامانه‌ها، زمان و هزینه‌های اشکال‌یابی را از طریق ارائه توضیحات قابل فهم برای ناهنجاری‌ها کاهش دهد.

در نهایت، این تحقیق می‌تواند به توسعه سامانه‌های مانیتورینگ خودکار و پایدار در مقیاس بزرگ کمک کند، طوری که پایداری و امنیت سامانه‌ها بهبود یابد و زمان و هزینه‌های اشکال‌یابی کاهش پیدا کند.

اهمیت و ضرورت انجام پژوهش ۱-۳

در دنیای امروز، سیستم‌های نرم‌افزاری و زیرساخت‌های توزیع‌شده به ستون فقرات صنایع گوناگون از جمله مالی، سلامت، مخابرات و سرویس‌های ابری تبدیل شده‌اند. پایداری و امنیت این سیستم‌ها وابستگی مستقیم به توانایی تشخیص سریع و دقیق ناهنجاری‌ها در لاگ‌های سیستمی دارد. با توجه به اینکه حجم و تنوع لاگ‌ها به‌طور مداوم در حال افزایش است، استفاده از روش‌های سنتی نظیر قواعد دست‌نویس یا الگوریتم‌های آماری دیگر پاسخگوی نیازهای فعلی نیست.

از نظر علمی، خلأهای تحقیقاتی قابل‌توجهی در این حوزه وجود دارد. نخست، بیشتر پژوهش‌های گذشته یا بر جنبه‌های آماری و ساختاری لاگ‌ها تمرکز داشته‌اند یا تنها به مدل‌سازی مبتنی بر توالی رویدادها پرداخته‌اند و کمتر به ترکیب ابعاد معنایی و زمانی توجه شده است. دوم، اگرچه مطالعات اخیر استفاده از مدل‌های زبانی بزرگ (LLMs) را پیشنهاد کرده‌اند، اما همچنان پرسش‌های مهمی درباره میزان کارایی، هزینه محاسباتی و قابلیت تعمیم‌پذیری LLM‌ها در محیط‌های عملیاتی بدون پاسخ مانده است. اختلاف‌نظرهایی نیز درباره روش بهینه تنظیم این مدل‌ها (تنظیم پرامپت در مقابل فاین‌تیونینگ) و نیاز به داده‌های برچسب‌دار وجود دارد.

از جنبه کاربردی، اهمیت این تحقیق در افزایش پایداری و امنیت سیستم‌ها آشکار است. یک چارچوب هوشمند می‌تواند:

- زمان تشخیص و رفع خطا را به شکل چشمگیری کاهش دهد،
- هزینه‌های ناشی از توقف سیستم یا حملات سایبری را کم کند،
- و ابزار قدرتمندی برای تیم‌های عملیات و نگهداری فراهم آورد.

علاوه بر این، نتایج تحقیق می‌تواند به توسعه روش‌هایی منجر شود که حتی در محیط‌هایی با منابع محاسباتی محدود یا داده‌های برچسب‌دار اندک، عملکرد مؤثر و مقیاس‌پذیر داشته باشند. این موضوع به‌ویژه برای سازمان‌هایی که امکان استفاده از منابع ابری گسترده ندارند، اهمیت حیاتی خواهد داشت. بنابراین، ضرورت این پژوهش هم در پاسخ به نیازهای عملی صنعت و هم در پر کردن شکاف‌های نظری موجود در ادبیات علمی نهفته است.

اهداف مشخص پژوهش ۴-۱

الف) هدف اصلی:

طراحی و ارائه یک چارچوب تشخیص ناهنجاری در لاگ‌های سیستمی مبتنی بر مهندسی پرامپت بهینه و مدل‌های زبانی بزرگ، با هدف دستیابی هم‌زمان به دقت و سرعت بالا و حذف نیاز به فرآیند پرهزینه تنظیم دقیق و داده‌های برچسب‌گذاری شده.

ب) اهداف فرعی:

۱. طراحی استراتژی‌های پرامپت‌دهی ساختاریافته برای استخراج هم‌زمان ویژگی‌های معنایی و ترتیبی از لاگ‌های سیستمی.
۲. ارزیابی و سنجش میزان افزایش سرعت پردازش و تشخیص خطا در روش پیشنهادی نسبت به روش‌های مبتنی بر تنظیم دقیق.
۳. تحلیل و ارزیابی دقت تشخیص ناهنجاری‌های پیچیده و شرطی در روش پیشنهادی در مقایسه با روش‌های سنتی و آماری.
۴. کاهش وابستگی به داده‌های آموزشی برچسب‌دار و بررسی کارایی مدل در شرایط محدودیت داده.
۵. کاهش نیاز به مداخله انسانی و دانش خبره در فرآیند تحلیل و تفسیر لاگ‌ها.

سؤال‌ها و فرضیه‌های پژوهش ۵-۱

سؤال‌های پژوهش

۱. آیا استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش‌آموزش‌دیده مانند Qwen2.5:7B-Instruct می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد؟
۲. آیا ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش‌آموزش‌دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود؟
۳. آیا استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد؟

۴. آیا استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود یابد؟

فرضیه‌های پژوهش

۱. استفاده از روش‌های تنظیم پرامپت در مدل‌های زبانی پیش‌آموزش‌دیده مانند Qwen2.5:7B-Instruct می‌تواند دقت و کارایی سیستم‌های تشخیص ناهنجاری لاگ را بهبود بخشد.
۲. ترکیب اطلاعات معنایی و ترتیبی لاگ‌ها در مدل‌های زبانی پیش‌آموزش‌دیده موجب بهبود تشخیص ناهنجاری‌های نقطه‌ای و شرطی می‌شود.
۳. استفاده از داده‌های محدود در یک پرامپت می‌تواند مشکل عدم تعادل کلاس‌ها در داده‌های لاگ را کاهش داده و دقت تشخیص ناهنجاری‌های کمتر متداول را افزایش دهد.
۴. استفاده از روش‌های تنظیم پرامپت می‌تواند هزینه‌ها و زمان موردنیاز برای برچسب‌گذاری داده‌های لاگ را کاهش دهد، در حالی که دقت تشخیص ناهنجاری‌ها حفظ یا حتی بهبود می‌یابد.

فصل دوم: مروری بر ادبیات و پیشینه تحقیق

تشخیص ناهنجاری در لاگ‌های سیستمی طی سال‌های اخیر به یکی از موضوعات مهم در حوزه پایش و عیب‌یابی سامانه‌های نرم‌افزاری تبدیل شده است. روش‌های اولیه این حوزه عمدتاً بر قواعد دست‌نویس، تحلیل‌های آماری و استخراج الگوهای ثابت متکی بودند، اما با افزایش حجم و تنوع لاگ‌ها، محدودیت‌های آن‌ها آشکار شد. در ادامه، روش‌های یادگیری ماشین و یادگیری عمیق با هدف شناسایی روابط ساختاری و ترتیبی میان رویدادهای لاگ توسعه یافتند. ظهور مدل‌های زبانی پیش‌آموزش‌دیده و مدل‌های زبانی بزرگ، امکان تحلیل معنایی متن لاگ و تشخیص الگوهای پیچیده‌تر را فراهم کرده است. پژوهش‌هایی مانند LogBERT، LogLLM، LLM-LogParser و AdaptiveLog، قابلیت این مدل‌ها را در بهبود دقت، انعطاف‌پذیری و تعمیم‌پذیری نشان داده‌اند. با این حال، هزینه محاسباتی، نیاز به داده‌های آموزشی، وابستگی به کیفیت پرامپت و احتمال تولید خروجی‌های نادرست همچنان از چالش‌های اصلی این روش‌ها محسوب می‌شوند. در این فصل، مفاهیم پایه، روش‌های پیشین و پژوهش‌های مرتبط بررسی و مقایسه می‌شوند تا جایگاه پژوهش حاضر و خلأهای موجود در ادبیات موضوع مشخص گردد.

مرور ادبیات و سوابق مرتبط ۲-۲

وی گان و همکاران [۱] در سال ۲۰۲۴ با انتشار پژوهشی پیرامون تشخیص ناهنجاری مبتنی بر لاگ، چارچوبی نوین را معرفی کردند که از ترکیب دو مدل زبانی بزرگ بهره می برد. در این روش، برخلاف رویکردهای سنتی که متکی بر استخراج الگو از طریق پارسرها بودند، از ترکیب دو مدل زبانی بزرگ یعنی BERT برای استخراج ویژگی های معنایی و LLaMA برای طبقه بندی توالی های لاگ استفاده شد. پژوهشگران برای هم ترازی فضای بردارهای معنایی این دو مدل، یک لایه واسط طراحی کردند و با بهره گیری از یک فرآیند آموزشی سه مرحله ای، توانستند دقت و سازگاری روش را به طور قابل توجهی ارتقا دهند. نتایج آزمایش ها بر روی چهار مجموعه داده ی عمومی نشان داد که LogLLM نسبت به روش های پیشین عملکرد بهتری داشته و توانسته است با دقت بالا، حتی در شرایطی که لاگ ها ناپایدار و متغیر هستند، ناهنجاری ها را شناسایی کند.

با هدف ارتقای کارایی پردازش لاگ، ژائو و تیم تحقیقاتی اش [۲] در سال ۲۰۲۴ رویکردی تازه را برای بهبود فرآیند تجزیه لاگ پیشنهاد دادند. آن ها با استفاده از توانایی مدل های زبانی بزرگ در درک زبان طبیعی، سیستمی طراحی نمودند که می تواند بدون نیاز به قواعد سخت گیرانه یا وابستگی به الگوهای از پیش تعریف شده، لاگ ها را به صورت پویا و انعطاف پذیر پردازش کند. این روش برخلاف تجزیه کننده های سنتی که در مواجهه با تغییر قالب لاگ ها دچار افت دقت می شوند، توانست پایداری و سازگاری بالاتری نشان دهد. نتایج آزمایش ها روی مجموعه داده های متنوع نشان داد که LogParser-LLM هم از نظر سرعت و هم از نظر دقت در استخراج الگوهای لاگ عملکرد بهتری نسبت به ابزارهای متداول داشت و توانست کارایی کل فرایند تحلیل و تشخیص ناهنجاری های سیستمی را ارتقا دهد.

سونگ چن و های لیائو [۳] در سال ۲۰۲۲ با اتخاذ دیدگاهی نوین که توالی لاگ را به عنوان یک دنباله زبانی طبیعی در نظر می گرفت، روشی جدید برای تحلیل لاگ ها ارائه کردند. آن ها با در نظر گرفتن توالی لاگ به عنوان یک دنباله زبانی طبیعی، از مدل پیش آموزش دیده BERT برای استخراج نمایش های معنایی لاگ ها بهره گرفتند و سپس با ریزتنظیم این مدل در کنار یک شبکه عصبی تمام متصل، توانستند ناهنجاری ها را با دقت بالا تشخیص دهند. این روش برخلاف مدل های مبتنی بر LSTM یا Word2Vec، قادر بود وابستگی های معنایی، ترتیب کلمات و موقعیت آن ها را در توالی لاگ ها به خوبی مدل سازی کند. نتایج آزمایش ها روی دو مجموعه داده عمومی HDFS و BGL نشان داد که BERT-Log نسبت به بسیاری از روش های موجود عملکرد برتری داشته و توانسته است به $F1$ - Score بالای ۹۹٪ دست یابد. این پژوهش نشان داد که استفاده از مدل های زبانی پیش آموزش دیده می تواند بهبود چشمگیری در دقت، تعمیم پذیری و کارایی تشخیص ناهنجاری های سیستمی فراهم آورد.

لی پنگ ما و همکاران [۵] در پژوهشی که سال ۲۰۲۵ منتشر شد، با تمرکز بر تعامل مدل های زبانی کوچک و بزرگ، چارچوبی تطبیقی به نام AdaptiveLog را توسعه دادند. این تحقیق با توجه به محدودیت های مدل های زبانی کوچک (مانند BERT) در دقت و مدل های زبانی بزرگ (مانند ChatGPT) در هزینه و کارایی، چارچوبی به نام AdaptiveLog معرفی می کند که همکاری میان این دو نوع مدل را ممکن می سازد. در این روش، لاگ های ساده ابتدا توسط مدل کوچک تحلیل می شوند و تنها در صورت عدم اطمینان، مدل بزرگ فراخوانی می گردد. همچنین، برای بهبود توان استدلالی مدل بزرگ، یک راهبرد جدید مبتنی بر بازیابی نمونه های خطا پذیر گذشته به کار گرفته شده است. نتایج آزمایش ها بر روی شش وظیفه ی مختلف تحلیل لاگ نشان داد که AdaptiveLog ضمن دستیابی

به دقت بالاتر، هزینه استفاده از LLM ها را تا ۷۳٪ کاهش داده و در سناریوهای کم‌منبع و انتقال یادگیری نیز عملکرد مطلوبی ارائه کرده است.

نقش نوظهور مدل‌های زبانی بزرگ در حوزه‌ی تشخیص ناهنجاری و داده‌های خارج از توزیع (OOD)^۷، موضوع پژوهش جامعی است که توسط رویا‌شو و کایزه دینگ [۹] در سال ۲۰۲۵ انجام شد. این مطالعه ابتدا محدودیت‌های رویکردهای سنتی را توضیح داده و سپس یک طبقه‌بندی جدید برای روش‌های مبتنی بر LLM ارائه می‌دهد. نویسندگان این روش‌ها را در دو دسته کلی تقسیم کرده‌اند: ۱- استفاده از LLM ها برای تشخیص (با تکیه بر روش‌های مبتنی بر پرامپت و مقایسه‌ای) و ۲- استفاده از LLM ها برای تولید (از جمله تولید داده کمکی، برچسب‌های شبه‌مصنوعی و توضیحات قابل فهم). مقاله علاوه بر بررسی کارهای انجام‌شده در این حوزه، مجموعه‌ای از داده‌های مرجع و معیارهای ارزیابی را معرفی می‌کند و چالش‌های مهمی همچون تفسیرپذیری، اعتمادپذیری، و پردازش داده‌های چندوجهی را مطرح می‌سازد. در نهایت، نویسندگان مسیرهای آینده‌ی پژوهش را برای توسعه‌ی سیستم‌های هوش مصنوعی مقاوم‌تر و شفاف‌تر ترسیم کرده‌اند.

بهره‌گیری از معماری تولید پاسخ مبتنی بر بازیابی (RAG) برای غلبه بر محدودیت‌های حافظه و توهم در مدل‌های زبانی، محور اصلی پژوهش پن و همکاران [۶] بوده است. آن‌ها با طراحی سیستمی تحت عنوان RAGLog، رویکردی نوین برای تشخیص ناهنجاری در لاگ‌ها بدون نیاز به داده‌های آموزشی ناهنجار (Zero-shot) ارائه کردند. در این روش، برخلاف متدهای نظارت‌شده که نیازمند حجم زیادی از داده‌های خطا هستند، تنها نمونه‌های لاگ «نرمال» در یک پایگاه داده برداری ذخیره می‌شوند. هنگام ورود یک لاگ جدید، سیستم با بازیابی نمونه‌های مشابه نرمال و ارائه آن به مدل زبانی (در اینجا GPT-۳.۵)، از مدل می‌خواهد تا وضعیت لاگ جدید را تحلیل کند. استفاده از خوشه‌بندی K-means برای انتخاب نمونه‌های نرمال متنوع، باعث شد تا RAGLog بر روی مجموعه داده‌های BGL و Thunderbird به ترتیب به امتیاز F1 برابر با ۰.۸۹ و ۰.۹۹ دست یابد که به مراتب بالاتر از روش‌های پیشین مانند LogPrompt است.

گسترش روزافزون کاربرد مدل‌های زبانی بزرگ در مدیریت سیستم‌های نرم‌افزاری، لیو و همکاران [۷] را بر آن داشت تا در سال ۲۰۲۵ با معرفی OpsEval، یک معیار جامع برای ارزیابی توانایی این مدل‌ها در حوزه عملیات فناوری اطلاعات (IT Ops) ارائه دهند. این پژوهش با انتقاد از ناکارآمدی معیارهای سنتی مانند BLEU و ROUGE در سنجش پاسخ‌های تخصصی، متریک جدیدی به نام FAE-Score (شامل روانی، دقت و شواهد) را توسعه داده است که همبستگی بسیار بالاتری (۰.۹۱) با قضاوت متخصصان انسانی دارد. مجموعه داده‌ی تدوین شده در این طرح شامل بیش از ۷۰۰۰ سوال چندگزینه‌ای و ۱۷۰۰ سوال تشریحی در ۹ زیردانه مختلف (از جمله شبکه G5 و پایگاه داده اوراکل) است. نتایج ارزیابی ۲۴ مدل زبانی نشان داد که اگرچه مدل‌های منبع‌بسته مانند GPT-۴ عملکرد خوبی دارند، اما مدل‌های منبع‌باز در وظایف تخصصی همچنان نیازمند تنظیم دقیق هستند و استفاده از تکنیک‌های مهندسی پرامپت مانند "زنجیره افکار" (CoT) می‌تواند دقت آن‌ها را به‌طور چشمگیری افزایش دهد.

در یکی از پژوهش‌های بنیادین سال ۲۰۱۷، مین دو و همکاران [۱۰] چارچوبی نوآورانه به نام «دیپ‌لاگ» را برای عیب‌یابی و تشخیص ناهنجاری ارائه کردند. در این روش، لاگ‌ها مشابه توالی زبان طبیعی در نظر گرفته شده و با

^۷ Out Of Distribution

استفاده از شبکه‌های حافظه بلندمدت (LSTM)^۸ الگوهای رفتاری نرمال سیستم مدل‌سازی می‌شوند. زمانی که توالی لاگ‌های جدید از این الگوها انحراف داشته باشد، به‌عنوان ناهنجاری شناسایی می‌شود. دیپ‌لاگ علاوه بر تشخیص ناهنجاری، امکان به‌روزرسانی تدریجی مدل در حالت آنلاین را فراهم می‌سازد تا بتواند با الگوهای جدید سازگار شود. همچنین با ساخت مدل‌های جریان کاری از لاگ‌ها، ابزار مؤثری برای عیب‌یابی و تحلیل ریشه‌ای خطاها در اختیار کاربر قرار می‌دهد. نتایج آزمایش‌ها روی مجموعه داده‌های بزرگ (HDFS و OpenStack) نشان داده است که دیپ‌لاگ دقت بالاتری نسبت به روش‌های سنتی مبتنی بر داده‌کاوی داشته و قادر به تشخیص تقریباً تمامی ناهنجاری‌ها با نرخ خطای بسیار پایین است.

گوا و همکاران [۴] در سال ۲۰۲۱ با بهره‌گیری از رویکرد خودنظارتی^۹، چارچوبی موسوم به LogBERT را توسعه دادند. این روش بر اساس مدل زبان بزرگ BERT عمل می‌کند که برای گرفتن الگوهای دنباله‌های لاگ عادی آموزش داده می‌شود. LogBERT با استفاده از دو وظیفه آموزشی جدید، پیش‌بینی کلید لاگ ماسک‌شده (برای درک زمینه دوسویه لاگ) و کمینه‌سازی حجم ابرکره^{۱۰} (برای متمرکز کردن نمایش بردارهای لاگ‌های عادی در فضای جاسازی)، این الگوها را فرا می‌گیرد. این مکانیزم تضمین می‌کند که دنباله‌های لاگ عادی به هم نزدیک شوند، در حالی که دنباله‌های غیرعادی که از این الگوها منحرف شده‌اند، در فضای ویژگی دورتر قرار می‌گیرند و به این ترتیب، ناهنجاری‌ها شناسایی می‌شوند. نتایج آزمایش‌ها بر روی سه مجموعه داده عمومی لاگ نشان داد که LogBERT عملکرد بهتری نسبت به روش‌های پیشرفته قبلی در تشخیص ناهنجاری لاگ دارد.

توسعه چارچوبی نوین برای تشخیص همزمان ناهنجاری و تولید توضیحات علی، دستاورد پژوهش ژانگ و همکاران [۱۱] در سال ۲۰۲۵ با عنوان LLM-LADE است. این چارچوب برای غلبه بر مشکل محدودیت‌های قابلیت تفسیر در روش‌های سنتی و کمبود دانش دامنه در مدل‌های زبان بزرگ، یک معماری هماهنگ سه‌مرحله‌ای شامل «افزایش داده - تنظیم دقیق با بهره‌وری پارامتر (PEFT) - بهینه‌سازی آنلاین» را معرفی می‌کند. در مرحله افزایش داده، با استفاده از قابلیت یادگیری چندنمونه‌ای (few-shot learning) مدل GPT-۴، یک مجموعه داده غنی از جفت‌های «برچسب-علت»^{۱۱} ایجاد می‌شود تا تلاش دستی برای برچسب‌گذاری به حداقل برسد. در مرحله تنظیم دقیق، مدل LLAMA۳-۸B با استفاده از الگوریتم LoRA و یک تابع زیان وزن‌دهی شده تنظیم می‌شود تا علاوه بر تشخیص دقیق، توضیحات علی قابل تفسیر نیز تولید کند. در نهایت، یک مکانیزم پایگاه دانش افزاینده مبتنی بر تطبیق متن طراحی شده است تا نمونه‌های اشتباه تشخیص داده‌شده را در زمان واقعی ضبط کرده و از طریق بازخورد متخصصان انسانی، بدون نیاز به به‌روزرسانی پارامترهای مدل، به‌طور آنلاین دقت تشخیص را بهینه‌سازی کند و سازگاری با محیط‌های پویای لاگ را تضمین نماید. نتایج تجربی بر روی سه مجموعه داده محک^{۱۲} نشان داد که LLM-LADE از الگوریتم‌های پیشرفته فعلی عملکرد بهتری دارد و توضیحات تولید شده آن از نظر اطلاع‌رسانی و خوانایی، قابلیت استفاده در سطح حرفه‌ای را دارند.

^۸ Long Short-Term Memory

^۹ Self-supervised

^{۱۰} Hypersphere Volume Minimization

^{۱۱} Label-Cause

^{۱۲} Benchmark

در راستای ارائه راهکاری سازگار و بدون نظارت برای لاگ‌های ناهمگن، پوسپیزنی و همکاران [۱۲] در سال ۲۰۲۵ مدلی تحت عنوان ADALog را پیشنهاد کردند. این روش، برخلاف متدهای سنتی که متکی بر تجزیه لاگ یا وابستگی‌های دقیق دنباله‌ای هستند، به جای کل دنباله، بر روی لاگ‌های منفرد و بدون ساختار کار می‌کند و روابط زمینه‌ای درون یک لاگ را استخراج می‌نماید. ADALog از یک رمزگذار دوسویه مبتنی بر ترانسفورمر که از قبل آموزش داده شده و با وظیفه مدل‌سازی زبان پوشیده (MLM)^{۱۳} بر روی لاگ‌های عادی تنظیم دقیق^{۱۴} شده، استفاده می‌کند. این تنظیم دقیق به مدل کمک می‌کند تا الگوهای نحوی و معنایی خاص دامنه را برای تشخیص دقیق ناهنجاری در محیط‌های پیچیده یاد بگیرد. ناهنجاری‌ها از طریق احتمالات بازسازی در سطح توکن شناسایی می‌شوند که به یک امتیاز در سطح لاگ تجمیع شده و سپس با استفاده از یک آستانه تطبیقی مبتنی بر صدک، که تنها بر روی داده‌های عادی کالیبره شده است، تصمیم‌گیری نهایی صورت می‌گیرد. این رویکرد تضمین می‌کند که مدل به‌طور پویا با تغییرات در توزیع داده‌های عادی سازگار شده و در محیط‌های واقعی کاربردپذیری بالایی داشته باشد. چالش حیاتی ناپایداری لاگ‌ها در سیستم‌های نرم‌افزاری در حال تکامل، محور اصلی پژوهش حدادی و همکاران [۱۳] در سال ۲۰۲۴ بود. هدف اصلی این پژوهش، ارزیابی این مسئله است که آیا مدل‌های زبان بزرگ (LLM) که بر روی مجموعه داده‌های گسترده از پیش آموزش داده شده‌اند، می‌توانند با فهم قوی از الگوها و اطلاعات زمینه‌ای خود، بر مشکل کمبود داده در تشخیص ناهنجاری بر روی نسخه‌های جدید نرم‌افزار غلبه کنند. پژوهشگران با انجام یک مقایسه تجربی بین یک مدل LLM تنظیم دقیق شده و مدل‌های جایگزین سنتی‌تر، کارایی آن‌ها را برای تشخیص ناهنجاری در شرایط لاگ‌های ناپایدار، مورد بررسی قرار دادند. نتایج این مطالعه نشان داد که مدل‌های GPT تنظیم دقیق شده می‌توانند به‌طور مؤثری عملکرد مدل‌های قبلی در تشخیص ناهنجاری لاگ را در شرایط ناپایداری داده‌ها بهبود بخشند، به ویژه هنگامی که داده‌های آموزشی کافی برای نسخه‌های جدید نرم‌افزار در دسترس نیست. این امر به دلیل توانایی LLM‌ها در درک عمیق‌تر روابط متنی و الگوهای متنوعی است که در طول پیش‌آموزش فرا گرفته‌اند.

کاوش در زمینه مهندسی پرامپت با هدف تحلیل لاگ به صورت تفسیرپذیر و بدون نیاز به داده‌های آموزشی قبلی، رویکردی است که لیو و همکاران [۸] در سال ۲۰۲۴ اتخاذ کردند. آن‌ها برای اولین بار یک کتابخانه استراتژی پرامپت ساختند که به‌طور خاص برای وظایف مختلف تحلیل لاگ، شامل تجزیه لاگ^{۱۵}، تشخیص ناهنجاری^{۱۶} و تولید پاسخ^{۱۷}، طراحی شده است. این استراتژی‌های پرامپت، دانش ضمنی LLM‌ها در مورد لاگ‌ها را استخراج کرده و نتایج تحلیلی را در یک قالب ساختاریافته و قابل درک تولید می‌کنند. نتایج تجربی بر روی شش مجموعه داده لاگ عمومی و سه مدل LLM (شامل LLaMA۲-۷B) نشان داد که رویکرد مبتنی بر مهندسی پرامپت، در مقایسه با روش‌های سنتی که به حجم زیادی از داده‌های برچسب‌گذاری شده یا تنظیم دقیق نیاز دارند، می‌تواند نتایج تجزیه و تحلیل لاگ با کیفیت بالا را در سناریوی صفر شات به دست آورد، که کارایی و قابلیت تعمیم را در محیط‌های لاگ متغیر و پویای امروزی به‌طور قابل توجهی بهبود می‌بخشد.

^{۱۳} Masked Language Modeling

^{۱۴} Fine-tuned

^{۱۵} Log Parsing

^{۱۶} Anomaly Detection

^{۱۷} Response Generation

لیم و همکاران [۱۴] در سال ۲۰۲۵ با تمرکز بر مسئله هزینه‌های گزاف تنظیم دقیق، به بررسی انطباق مدل‌های زبانی بزرگ برای تشخیص ناهنجاری لاگ پرداختند. پژوهشگران استفاده از تکنیک‌های تنظیم دقیق با بهره‌وری پارامتر (PEFT)، به‌ویژه LoRA (Low-Rank Adaptation) و ReFT^{۱۸}، را برای انطباق مدل‌های مختلف از جمله GPT-۲، ROBERTa و Llama-۳ برای LAD بررسی کردند. هدف این کار، پر کردن شکاف تحقیقاتی موجود و ارائه بینش‌های مهم در مورد پیاده‌سازی مؤثر LLMها در این زمینه است. آزمایش‌های جامع بر روی چهار مجموعه داده عمومی لاگ، کارایی، پایداری، بهره‌وری نمونه، مقاومت در برابر لاگ‌های ناپایدار و قابلیت تعمیم بین مجموعه داده‌ای این روش‌های مبتنی بر PEFT را اثبات کرد و مسیرهای جدیدی را برای استفاده عملی از LLMها در تشخیص ناهنجاری سیستم‌ها گشود.

با معرفی چارچوب LogGPT در سال ۲۰۲۳، هان و همکاران [۱۵] تلاشی برای پر کردن شکاف میان مدل‌سازی زبان و تشخیص ناهنجاری انجام دادند. این روش با هدف پر کردن شکاف بین مدل‌سازی زبان و تشخیص ناهنجاری، ابتدا مدل GPT را برای پیش‌بینی ورودی لاگ بعدی بر اساس دنباله پیشین، آموزش می‌دهد. برای ارتقاء بیشتر عملکرد، نویسندگان یک استراتژی یادگیری تقویتی^{۱۹} نوین را برای تنظیم دقیق مدل، به طور خاص برای وظیفه تشخیص ناهنجاری لاگ، معرفی کردند. این رویکرد تضمین می‌کند که هدف آموزشی مدل به طور مستقیم با هدف نهایی تشخیص ناهنجاری همسو باشد. نتایج آزمایش‌ها بر روی سه مجموعه داده عمومی نشان داد که LogGPT به طور قابل توجهی از روش‌های پیشرفته موجود در تشخیص ناهنجاری لاگ، عملکرد بهتری دارد.

لی و ژانگ [۱۶] در سال ۲۰۲۳ با تمرکز ویژه بر گام نخست تحلیل خودکار یعنی تجزیه لاگ، روشی به نام LogPPT را پیشنهاد دادند. این روش برای غلبه بر مشکل نادیده گرفتن معنای معنایی^{۲۰} لاگ‌ها و نیاز به دانش خاص دامنه در روش‌های سنتی، از یادگیری چندنمونه‌ای مبتنی بر پرامپت استفاده می‌کند. LogPPT از طریق یک متد تنظیم پرامپت نوین، قادر است الگوهای لاگ‌ها را بر اساس تنها تعداد کمی از داده‌های لاگ برچسب‌گذاری شده تشخیص دهد. علاوه بر این، یک الگوریتم نمونه‌گیری تصادفی تطبیقی برای انتخاب یک مجموعه آموزشی کوچک اما متنوع، طراحی شده است. نتایج آزمایش‌های گسترده بر روی ۱۶ مجموعه داده عمومی لاگ، نشان داد که LogPPT یک روش مؤثر و کارآمد برای استخراج الگوهای صحیح و پارامترها است.

تسهیل انتقال یادگیری در سیستم‌های نرم‌افزاری جدید، هدفی بود که سویی و همکاران [۱۷] در سال ۲۰۲۵ با ارائه چارچوب LogSynergy دنبال کردند. این چارچوب برای رفع مشکلاتی مانند تفاوت‌های نحوی لاگ‌ها و کمبود دانش سیستم-خاص در روش‌های سنتی انتقال، از مدل‌های زبان بزرگ (LLM) استفاده می‌کند. LogSynergy شامل دو بخش اصلی است: (۱) یک مکانیسم استخراج الگو معنایی لاگ مبتنی بر LLM برای غلبه بر تفاوت‌های نحوی و ساختاری لاگ‌ها بین سیستم‌های مبدأ و مقصد، و (۲) یک ماژول شبکه‌های گرافی با توجه متقابل^{۲۱} برای مدل‌سازی وابستگی‌های متنی بین الگوهای استخراج‌شده و جذب دانش سیستم-خاص. این رویکرد امکان انتقال دانش از سیستم‌های بالغ با داده‌های فراوان به سیستم‌های جدید با داده‌های محدود را فراهم می‌آورد. نتایج تجربی

^{۱۸} Representation Fine-tuning

^{۱۹} Reinforcement Learning

^{۲۰} Semantic Meaning

^{۲۱} Cross-Attention Graph Networks

بر روی مجموعه‌های داده متعدد نشان داد که LogSynergy عملکرد مدل‌های تشخیص ناهنجاری لاگ را در سیستم‌های جدید به‌طور چشمگیری بهبود می‌بخشد.

در تلاشی برای توسعه منابع متن‌باز، ژو و همکاران [۱۸] در سال ۲۰۲۴ به معرفی مدل YuLan، یک سری مدل زبان بزرگ با ۱۲ میلیارد پارامتر پرداختند. هدف این مقاله، رفع کمبود جزئیات آموزش منتشر شده در مورد بسیاری از مدل‌های منبع باز و تسهیل تحقیقات بیشتر در این زمینه بود. مدل پایه YuLan بر روی تقریباً ۱.۷ تریلیون توکن از یک مجموعه داده متنوع شامل متون انگلیسی، چینی، و چندزبانه آموزش اولیه^{۲۲} داده شده است. نویسندگان یک فرآیند پیش‌آموزش سه‌مرحله‌ای طراحی کردند و جزئیات دقیق تنظیمات آموزشی، از جمله پیکربندی سخت‌افزاری و تکنیک‌های بهینه‌سازی، را به اشتراک گذاشتند. این مدل، که شامل نسخه‌های پایه و دستورالعمل محور^{۲۳} است، نتایج رقابتی را در ارزیابی‌های گسترده بر روی معیارهای مختلف، از جمله درک مطلب، دانش عمومی، و حل مسائل ریاضی (مانند MMLU، C-Eval، و GSM^K)، در مقایسه با سایر مدل‌های منبع باز هم‌اندازه، نشان داد. این پژوهش یک منبع ارزشمند برای جامعه تحقیقاتی LLM به شمار می‌رود.

جدول ۲-۱: مقایسه پژوهش‌های مرتبط با تشخیص ناهنجاری لاگ

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
مدل‌های زبانی بزرگ برای تشخیص ناهنجاری و داده‌های خارج از توزیع	بین یان، یینگلی چن، زینگوی چن، ژویانگ وو، چینگسونگ ون	۲۰۲۵	استفاده از مدل‌های زبانی بزرگ (مانند GPT و LLaMA) برای تشخیص ناهنجاری و داده‌های خارج از توزیع با استفاده از منطق استدلال زنجیره‌ای و امتیازدهی احتمالاتی	چند مجموعه داده استاندارد از حوزه‌های مختلف (متن، تصویر، و لاگ)	عملکرد بالا در تشخیص داده‌های غیرمعمول بدون نیاز به داده برچسب‌خورده، تعمیم‌پذیری بالا در حوزه‌های مختلف، تفسیرپذیری مناسب	هزینه محاسباتی بسیار زیاد، دشواری در تنظیم پارامترها، حساسیت به prompt و نوع سؤال ورودی
مدل‌های زبانی بزرگ برای تشخیص ناهنجاری و داده‌های خارج از توزیع	رویائو شو، کایزه دینگ	۲۰۲۵	مرور پژوهش‌های استفاده از مدل‌های زبانی بزرگ (مانند GPT، LLaMA، CLIP) در تشخیص ناهنجاری و داده‌های خارج از توزیع؛ دسته‌بندی روش‌ها به دو رویکرد «LLM برای	مجموعه داده‌های چندرسانه‌ای شامل تصویر (MVTEC-AD، ImageNet، UCF-) ویدیو	پوشش جامع حوزه‌ها، معرفی طبقه‌بندی جدید روش‌ها، تبیین کاربردهای چندرسانه‌ای، و بررسی چالش‌های آینده	مطالعه مروری است (فاقد روش تجربی جدید)، جزئیات ارزیابی محدود، و برخی روش‌های جدید پوشش داده نشده‌اند

^{۲۲} Pre-trained

^{۲۳} Instruction-tuned

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
			تشخیص» و «LLM برای تولید داده و توضیح»	Crime (۲۰۰), NG۲۰۰, CLINC۱۵۰, و سری زمانی Yahoo), (ODDS		
تشخیص ناهنجاری تطبیقی و بدون نظارت در لاگ‌ها با مدل زبانی ماسک‌شده مبتنی بر خودتوجهی	پرزمیک پُسیپیشنی، وویچک مورمول، کارولینا شایندلر، سانجیو کومار	۲۰۲۵	استفاده از مدل DistilBERT برای یادگیری بدون نظارت از لاگ‌های خام و تشخیص ناهنجاری با روش Masked Language Modeling و آستانه‌گذاری تطبیقی	BGL Thunderbird Spirit .	- بدون نیاز به داده برچسب‌خورده یا پارس لاگ - عملکرد بالا در مجموعه داده‌های متنوع (F۱ تا ۰.۹۵) - قابلیت تطبیق با تغییرات در ساختار لاگ	- هزینه محاسباتی بالا در آموزش و استنتاج - مناسب‌تر برای تحلیل آفلاین نسبت به تشخیص بلادرنگ - نیاز به منابع قوی برای پردازش داده‌های حجیم
بکارگیری مدل‌های زبانی بزرگ برای تشخیص ناهنجاری لاگ با تنظیم کارآمد پارامترها	ینگ فو لیم، جیاون جو، گوانسونگ پانگ	۲۰۲۵	استفاده از روش‌های تنظیم پارامتر کارآمد (PEFT) شامل LoRA و ReFT برای انطباق مدل‌های زبانی بزرگ (RoBERTa, GPT-۲, LLaMA-۳) با تشخیص ناهنجاری لاگ‌ها به صورت نظارت‌شده.	چهار دیتاست عمومی لاگ: BGL.HDFS, Spirit Thunderbird (۸۰٪ آموزش، ۲۰٪ تست).	- عملکرد بالا در دقت و F۱ نسبت به روش‌های کلاسیک (LogBERT, DeepLog, LogAnomaly) - کاهش نیاز به منابع محاسباتی با حفظ کارایی بالا - روش ReFT پایدار، کارایی نمونه‌ای و تعمیم‌پذیری بهتری دارد - قابلیت استفاده روی مدل‌های مختلف و مقیاس‌پذیری مناسب	روش ReFT زمان آموزش بالاتری نسبت به LoRA دارد حساسیت بیشتر ReFT به تغییرات واژگان (لاگ‌های ناپایدار) محدودیت تعمیم به دیتاست‌های کاملاً جدید (F۱ حدود ۰.۵ در تست بین دیتاستی)
یک مجموعه معیار جامع برای ارزیابی قابلیت مدل‌های زبان بزرگ در حوزه عملیات فناوری اطلاعات	یوخه لیو و چانگهوا پی، مینگزه سان	۲۰۲۵	طراحی معیار جامع OpsEval برای ارزیابی LLM‌ها در حوزه Ops. معرفی معیار ارزیابی جدید FAE-Score (شامل روانی، دقت، شواهد) که همبستگی بالایی با قضاوت متخصصان دارد. ارزیابی بیش از ۲۴ مدل زبان بزرگ با استفاده از تکنیک‌های CoT و ICL.	مجموعه داده دوزبانه و چندوظیفه‌ای شامل ۹۰۷۰ پرسش (۷۳۳۴) چهارگزینه‌ای و ۱۷۳۶ تشریحی؛ داده‌ها از منابع تخصصی و گواهینامه‌های IT Ops در ۹ زیردانه مختلف (مانند G۵ و پایگاه داده اوراکل) جمع‌آوری شده‌اند.	اولین مجموعه معیار جامع و دوزبانه در حوزه عملیات IT؛ FAE-Score عملکرد مدل را در کارهای تخصصی بسیار بهتر از معیارهای سنتی مانند BLEU منعکس می‌کند؛ کمک به شناسایی نقاط ضعف و قوت مدل‌ها در زمینه‌های تخصصی Ops.	اعتبار خارجی محدود به زیردانه‌های انتخابی در مجموعه داده است؛ عملکرد نهایی متأثر از پارامترهای پیاده‌سازی مدل و پرامپت‌های (Prompts) مورد استفاده است؛ ملاحظات حفظ حریم خصوصی مانع از استفاده گسترده از داده‌های واقعی شرکت‌ها می‌شود.
تشخیص ناهنجاری مبتنی بر لاگ با استفاده از مدل‌های زبانی بزرگ	وی گوان، جیان کانو، شی‌یو چیان، جیان‌چی گائو، چون اوینگ	۲۰۲۴	ترکیب BERT و LLaMA برای تشخیص ناهنجاری در لاگ‌ها با آموزش سه مرحله‌ای	BGL.HDFS, Liberty Thunderbird	دقت بالا، بدون نیاز به parser، درک معناشناسی لاگ‌ها	هزینه محاسباتی زیاد، نیاز به داده برچسب‌خورده
ارتقای کارایی در تجزیه‌ی لاگ با استفاده از مدل‌های زبانی بزرگ	اوشیانو ژونگ، دینگ‌یانو مو، گویانگ لیو، جینبو لیو، چینگ‌دا لو، چی ژو،	۲۰۲۴	ترکیب LLM با درخت پیشوندی (Prefix Tree) برای استخراج قالب لاگ به صورت خودکار و کاهش تعداد فراخوانی مدل	Loghub-۲k و LogPub	- دقت بسیار بالا در شناسایی الگوها (F۱ تا ۹۰٪) - نیاز نداشتن به داده برچسب‌خورده	- مصرف زمان و منابع زیاد در مدل‌های بزرگ مثل GPT-۴ - نیاز به تنظیم سطح گرانولاریتی با مداخله انسانی

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
	جی‌شنگ وو، کوانژنگ لی، چینگ‌سونگ ون				- کاهش چشمگیر هزینه فراخوانی LLM (تنها ۲۷۲ بار برای میلیون‌ها لاگ) - سازگار با انواع فرمت‌های لاگ و مقیاس‌پذیر	- عملکرد وابسته به کیفیت مدل زبانی مورد استفاده
چارچوب تحلیلی تطبیقی لاگ با همکاری مدل‌های زبانی بزرگ و کوچک	دینگ‌یانو مو، جیان چن، یینگالی چن، چون‌جون شیا، لیانگ چن، ژیاوجیانگ هوانگ، ژو یونگ شو	۲۰۲۴	ترکیب LLM (برای درک معنانشاسی) و مدل کوچک‌تر تطبیقی (برای تحلیل سریع) با انتخاب پویا بین مدل‌ها بر اساس پیچیدگی لاگ	LogHub BGL.HDFS	کاهش هزینه و زمان پردازش با حفظ دقت بالا، سازگاری با لاگ‌های متنوع، کاهش وابستگی به LLM پرهزینه	نیاز به تنظیم دقیق معیار تصمیم‌گیری بین مدل‌ها، پیچیدگی بیشتر در پیاده‌سازی
تشخیص ناهنجاری لاگ با استفاده از تولید تقویت‌شده بازایی	جاناتان پن، سوی لیانگ وونگ، ییدی یوان	۲۰۲۴	استفاده از معماری تولید تقویت‌شده بازایی (RAG) مبتنی بر مدل‌های زبان بزرگ ذخیره لاگ‌های «رمال» در پایگاه داده برداری و بازایی نمونه‌های مشابه برای تحلیل لاگ ورودی توسط LLM (روش Zero-shot K-means استفاده از خوشه‌بندی برای انتخاب نمونه‌های بازایی متنوع و کارآمد.	اگ‌های سیستمی واقعی مانند BGL و Thunderbird برای ارزیابی عملکرد؛ این روش به داده‌های برجسب‌گذاری شده ناهنجار نیازی ندارد و تنها با الگوهای نرمال کار می‌کند.	حل مشکل اساسی نبود یا کمبود نمونه‌های لاگ ناهنجار برای آموزش مدل‌های نظارت‌شده؛ غلبه بر چالش‌های انسانی ناشی از حجم، تنوع و سرعت بالای لاگ‌ها با استفاده از هوش مصنوعی؛ دستیابی به عملکرد بالا در تشخیص ناهنجاری در سناریوی Zero-shot	عملکرد نهایی به کیفیت پرامپت مهندسی شده و توان استدلالی مدل زبان بزرگ بستگی دارد؛ نیازمند مدیریت و به‌روزرسانی مداوم پایگاه داده برداری از لاگ‌های نرمال است.
تشخیص ناهنجاری داده‌کارا بر روی لاگ‌های ناپایدار با ترکیب مدل‌های زبانی بزرگ و یادگیری ماشین	چون‌بی ژو، چن‌بی لی، چون‌یوان وو، جی‌بی لی، چون‌فنگ یو	۲۰۲۴	ترکیب مدل زبانی بزرگ (LLM) با مدل یادگیری ماشین سبک برای تشخیص ناهنجاری در لاگ‌های ناپایدار با داده کم	BGL.HDFS Spirit	- نیاز کمتر به داده آموزشی - عملکرد پایدار در لاگ‌های ناپایدار - دقت بالا حتی در داده‌های محدود	- نیاز به تنظیم دقیق بین LLM و مدل سبک - پیچیدگی در هماهنگی مدل‌ها - هزینه زیاد در مرحله آموزش اولیه
یادگیری انتقالی مبتنی بر مدل‌های زبانی بزرگ برای تشخیص ناهنجاری در سامانه‌های نرم‌افزاری جدید	یوکینگ یانگ، دینگ‌یانو مو، چون اوایانگ، لی‌چوان گو	۲۰۲۴	استفاده از یادگیری انتقالی با LLM برای سازگاری مدل تشخیص ناهنجاری با سامانه‌های جدید بدون نیاز به بازآموزی کامل	BGL.HDFS Spirit	- کاهش هزینه و زمان آموزش داده‌ها - عملکرد قوی در دامنه‌های جدید - تعمیم‌پذیری بالا	- حساسیت به تفاوت دامنه داده‌ها - کاهش دقت در داده‌های بسیار متفاوت - نیاز به تنظیم دقیق پرامپت‌ها
تحلیل برخط و قابل تفسیر لاگ‌ها با استفاده از مدل‌های زبانی بزرگ و راهبردهای پرامپت	شی‌وو چیان، چون اوایانگ، جیان‌چی گائو، وی گوان	۲۰۲۴	استفاده از مدل‌های زبانی بزرگ (LLM) با طراحی پرامپت‌های پویا برای تحلیل بلادرنگ و تفسیرپذیر لاگ‌ها	BGL.HDFS Thunderbird	- تفسیرپذیری بالا نسبت به روش‌های مبتنی بر یادگیری عمیق - توانایی تحلیل برخط و بلادرنگ - دقت و انعطاف بالا در محیط‌های متغیر	- هزینه محاسباتی بالا برای LLM - نیاز به طراحی دقیق پرامپت‌ها - دشواری در کنترل خروجی مدل در شرایط نویزی
مدل زبانی بزرگ متن‌باز	یوتائو جو و همکاران	۲۰۲۴	طراحی و آموزش یک مدل زبانی بزرگ (LLM) متن‌باز با ۱۲ میلیارد پارامتر، شامل سه مرحله آموزشی: ۱. پیش‌آموزش (Pre-training) روی ۱.۷ تریلیون توکن از داده‌های چندزبانه ۲. تنظیم با دستور (Instruction-tuning) با ۴۲ میلیون داده مصنوعی آموزشی	ترکیبی از منابع متنوع شامل: وبسایت‌ها، کتاب‌ها، اخبار، مقالات علمی، ویکی‌پدیا، کدهای برنامه‌نویسی (GitHub)، متون حقوقی، پتنت‌ها و ارزیابی‌های	- مدل کاملاً متن‌باز با کد و وزن‌ها در GitHub - پشتیبانی از زبان انگلیسی و چینی و داده‌های چندزبانه - عملکرد قابل مقایسه با مدل‌های بزرگ معروف مثل Baichuan و LLaMA۲ - بهبود در وظایف منطقی و ریاضی با استفاده از روش یادگیری مرحله‌به‌مرحله	- مصرف بالای منابع محاسباتی (نیاز به ۹۶ عدد GPU از نوع A۸۰۰) - عملکرد نسبتاً ضعیف‌تر در وظایف مربوط به دانش واقعی (Factual Knowledge) - نسبت به مدل‌های بزرگ‌تر مثل GPT-۴ - داده‌های آموزشی محدود در برخی زبان‌های غیرچینی/انگلیسی

عنوان	نویسندگان	سال	روش	داده‌ها	مزایا	معایب
			۳. هم‌تراز سازی انسانی با (Human Alignment) ۲۰۰ هزار داده برچسب‌خورده انسانی	آموزشی. مجموعاً حدود ۱.۷ تریلیون توکن.	Curriculum (Learning) - طراحی tokenizer بهینه برای چینی و انگلیسی	- نبود fine-tuning گسترده برای کاربردهای تخصصی
تشخیص ناهنجاری در لاگ‌ها با استفاده از مدل GPT	شیائو هان، شوهان یوان، محمد ترابالسی	۲۰۲۳	استفاده از مدل GPT با یادگیری تقویتی و معیار Top-K برای تشخیص ناهنجاری در توالی لاگ‌ها	BGL.HDFS Thunderbird	- دقت بسیار بالا (F1 تا ۹۸٪) - توانایی یادگیری وابستگی بلندمدت در لاگ‌ها - بهبود نسبت به LogBERT DeepLog و	- هزینه محاسباتی زیاد به‌دلیل GPT - نیاز به تنظیم دقیق پارامتر K - زمان آموزش طولانی
تجزیه لاگ با استفاده از یادگیری کم‌نمونه مبتنی بر پرامپت	ژی‌لیانگ ژانگ، دینگ‌یانو مو، چی ژو، جیان چن، چون اویانگ، لی‌چوان گو	۲۰۲۳	استفاده از یادگیری کم‌نمونه (Few-shot) با پرامپت‌گذاری در LLM برای شناسایی و استخراج الگوهای لاگ	BGL.HDFS Spirit	- کاهش نیاز به داده آموزشی زیاد - دقت بالا در قالب‌بندی لاگ‌های جدید - سازگاری با ساختارهای متنوع لاگ	- حساسیت به طراحی پرامپت - کارایی پایین در لاگ‌های بسیار پیچیده - هزینه زمانی زیاد در تنظیم مدل
تشخیص ناهنجاری لاگ‌های سیستمی بر اساس مدل زبانی از پیش آموزش‌دیده	س۱۴ونگ چن، های لیاو	۲۰۲۲	استفاده از مدل از پیش‌آموزش‌دیده BERT با ریزتنظیم برای شناسایی ناهنجاری در توالی لاگ‌ها	BGL.HDFS	دقت بسیار بالا (F1 تا ۹۹.۴٪)، توانایی درک معنانشناسی و وابستگی توالی رویدادها، پایداری در اندازه داده‌های مختلف	نیاز به برچسب‌گذاری داده‌ها، هزینه محاسباتی بالا، وابستگی به مرحله‌ی پیش‌پردازش Drain
تشخیص ناهنجاری در لاگ‌ها با استفاده از مدل BERT	هایشوان گو، شوهان یوان، شین‌تانو وو	۲۰۲۱	استفاده از مدل BERT با دو وظیفه خودنظارتی (پیش‌بینی کلیدهای ماسک‌شده و کمینه‌سازی حجم کره) برای یادگیری الگوهای لاگ نرمال و تشخیص ناهنجاری‌ها	BGL.HDFS Thunderbird	- دقت بسیار بالا نسبت به روش‌های RNN - عدم نیاز به داده برچسب‌خورده - درک دوطرفه از متن لاگ	- هزینه محاسباتی بالا - نیاز به تنظیم دقیق هاپرپارامترها - حساس به نسبت ماسک در داده‌ها
تشخیص و عیب‌یابی ناهنجاری از لاگ‌های سیستمی با استفاده از یادگیری عمیق	مین دو، ژیهان ژو، فی‌شو، جان ژو، چنگ‌کی ژانگ، پن‌جی رن	۲۰۱۷	استفاده از مدل LSTM برای تشخیص خودکار ناهنجاری‌ها از توالی لاگ‌های سیستم بدون نیاز به ویژگی‌سازی دستی	HDFS	- حذف نیاز به مهندسی ویژگی دستی - عملکرد بهتر از روش‌های سنتی مبتنی بر قانون - توانایی یادگیری الگوهای زمانی در لاگ‌ها	- نیاز به داده برچسب‌خورده برای آموزش - کاهش دقت در داده‌های نویزی یا متنوع - عدم تفسیرپذیری کامل نتایج